

دانشگاه صنعتی خواجه نصیرالدین طوسی تهران

دانشکده مهندسی برق

پایان نامه کارشناسی

پردازش تصاویر CT Scan مغز به منظور قطعه‌بندی
خونریزی داخلی مغز با استفاده از شبکه‌های عصبی
عمیق

نگارش

سید محمد حسینی

استاد راهنما

دکتر امیرحسین نیکوفرد

شهریور ۱۴۰۳

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ

صفحه فرم ارزیابی و تصویب پایان نامه- فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تایید و تصویب پایان نامه موسوم به فرم کمیته دفاع- موجود در پرونده آموزشی- را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی خواجه نصیرالدین طوسی باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی خواجه نصیرالدین طوسی
تهران

به نام خدا

تعهدنامه اصالت اثر

تاریخ: شهریور ۱۴۰۳

اینجانب سید محمد حسینی متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی استادی دانشگاه صنعتی خواجه نصیرالدین طوسی بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مأخذ ذکر گردیده است. این پایان‌نامه قبلًا برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی خواجه نصیرالدین طوسی ممنوع است. نقل مطالب با ذکر مأخذ بلامانع است.

سید محمد حسینی

Vincent

امضا

تەقىم بە فعالىن دانشجۇرى كەھوارە دىكىنار مىن بۇندى.

پاسکزاری

با تشکر از استاد نیکوفرد و استاد علیاری که فرصت انجام این پژوهش را برای من فراهم کردند. در ادامه از خانم فاطمه پاکدامن و آقای کسری داودی تشکر می‌کنم که بدون حضور آنها امکان انجام این پژوهش میسر نبود.

سید محمد حسینی

شهریور ۱۴۰۳

چکیده

تشخیص سریع و دقیق خونریزی‌های درون‌جمجمه‌ای با استفاده از تصاویر سی‌تی اسکن، همواره به عنوان یکی از مهم‌ترین چالش‌های پزشکی در زمینه درمان افراد دارای انواع آسیب‌های مغزی، سکته‌های مغزی و خونریزی‌های درون‌جمجمه‌ای، مطرح شده است. اهمیت این موضوع زمانی آشکار می‌شود که حتی تأخیر چند دقیقه‌ای در تشخیص می‌تواند منجر به پیامدهای جبران‌ناپذیری برای بیماران شود. با توجه به پیچیدگی و حساسیت بالای تشخیص چنین آسیب‌هایی، این فرایند عموماً نیازمند تخصص و تجربه‌ی بالای پزشکان و پرتوشناسان است. اما با توجه به محدودیت منابع انسانی و احتمال خطاها ای انسانی، نیاز به توسعه سامانه‌های خودکار تشخیص مبتنی بر یادگیری عمیق بیش از پیش احساس می‌شود. در این زمینه چالش اصلی برای پزشکان خصوصاً در بخش فوریت‌های پزشکی، تشخیص دقیق و سریع نواحی خونریزی در تصاویر سه‌بعدی سی‌تی اسکن است که عملکرد متخصصین در تحلیل این تصاویر، تحت تأثیر میزان تجربه آنها و شرایط محیطی قرار دارد. توسعه یک دستیار هوشمند مبتنی بر شبکه عصبی عمیق، می‌تواند موجب بهبود فرایندهای پزشکی در این حوزه شود؛ اما توسعه این دستیار با چالش‌های متعددی روبرو است. از جمله این چالش‌ها می‌توان به عدم توازن داده‌ها، محدودیت در دسترسی به مجموعه‌داده‌های بزرگ، و تنوع کیفیت تصاویر سی‌تی اسکن در مراکز مختلف تصویربرداری اشاره کرد. این عوامل می‌توانند باعث کاهش دقت مدل‌ها در تشخیص نواحی دارای خونریزی شود. در این پایان‌نامه، با استفاده از مجموعه‌داده خونریزی درون‌جمجمه‌ای PhysioNet، یک روش دومرحله‌ای مبتنی بر طبقه‌بندی و قطعه‌بندی، به همراه یک پس‌پردازش توسعه داده شده است. در این پژوهش با استفاده از مدل ResNet 50 در مرحله اول و مدل U-Net در محله دوم، معیار IoU برابر با 0.22 و معیار ضریب Dice برابر با 0.36 کسب شده است که این نتایج نسبت به حالتی که از روش دومرحله‌ای استفاده نشده است، بهبود چشمگیری داشته است.

واژه‌های کلیدی:

شبکه عصبی عمیق، طبقه‌بندی تصاویر سی‌تی اسکن، قطعه‌بندی تصاویر سی‌تی اسکن، خونریزی درون‌جمجمه‌ای

فهرست مطالب

صفحه	عنوان
۱	۱ مقدمه
۲	۱-۱ خونریزی درون جمجمه‌ای و اهمیت آن
۲	۱-۲ انواع خونریزی درون جمجمه‌ای
۴	۳-۱ روش‌های مرسوم در تشخیص خونریزی درون جمجمه‌ای
۵	۴-۱ روش‌های رایانه‌ای در پردازش تصاویر پزشکی
۵	۵-۱ مجموعه‌داده‌ها
۶	۱-۵-۱ مجموعه‌داده‌ی انجمن پرتوشناسی آمریکای شمالی (RSNA)
۶	۲-۵-۱ MosMed
۶	۳-۵-۱ CQ500
۷	۴-۵-۱ PHE-SICH-CT-IDS
۸	۵-۵-۱ PhysioNet
۹	۶-۱ تحقیقات اخیر در زمینه یادگیری ماشین
۱۱	۱-۶-۱ نقاط ضعف موجود در پژوهش‌های گذشته
۱۱	۲-۶-۱ اهداف پژوهش
۱۳	۲ روش‌ها و مجموعه‌داده
۱۴	۱-۲ بررسی آماری مجموعه‌داده
۱۸	۲-۲ پیش‌پردازش ^۱
۲۳	۳-۲ روش پردازش تصاویر
۲۳	۱-۳-۲ یادگیری عمیق و اصول اولیه
۲۷	۴-۲ مدل‌های طبقه‌بندی در شبکه عصبی عمیق
۲۷	ResNet ۱-۴-۲
۲۸	ResNeXt ۲-۴-۲
۲۹	۳-۴-۲ شبکه (SENet) Squeeze-and-Excitation
۳۰	DenseNet ۴-۴-۲

^۱Pre-process

۳۱	EfficientNet	۵-۴-۲
۳۲	۵-۲ مدل‌های قطعه‌بندی در شبکه عصبی عمیق	
۳۲	U-Net	۱-۵-۲
۳۳	PSPNet	۶-۲
۳۴	۷-۲ پس‌پردازش	
۳۵	۸-۲ روش پیشنهادی	
۳۷	۹-۲ آموزش و تصمیم‌گیری	
۳۷	۱-۹-۲ طبقه‌بندی	
۳۹	۲-۹-۲ قطعه‌بندی	
۳۹	۳-۹-۲ سازوکار تصمیم‌گیری شورایی	
۴۱	۳ نتایج	
۴۲	۱-۳ معیارهای ارزیابی در یادگیری عمیق	
۴۲	Sensitivity	۱-۱-۳
۴۲	Specificity	۲-۱-۳
۴۲	Precision	۳-۱-۳
۴۳	F1 Score	۴-۱-۳
۴۳	Accuracy	۵-۱-۳
۴۳	Intersection over Union (IoU)	۶-۱-۳
۴۴	Dice	۷-۱-۳
۴۴	۲-۳ نتایج طبقه‌بندی	
۴۴	۱-۲-۳ نتایج برش‌محور	
۴۶	۲-۲-۳ نتایج بیمار‌محور	
۴۸	۳-۲-۳ تحلیل بیشتر نتایج	
۵۰	۳-۳ نتایج قطعه‌بندی	
۵۵	۴ کارهای پیشنهادی و نتیجه‌گیری	
۵۶	۱-۴ محدودیت‌های و پیشنهادات	
۵۷	۲-۴ نتیجه‌گیری	

۵۹	منابع و مراجع
۶۶	پیوست
۶۹	واژه‌نامه‌ی فارسی به انگلیسی
۷۲	واژه‌نامه‌ی انگلیسی به فارسی

فهرست اشکال

شکل

صفحه

۱-۱	خونریزی درون جمجمه‌ای [۱]	۳
۲-۱	چند نمونه تصویر از مجموعه‌داده PHE-SICH-CT-IDS	۸
۳-۱	چند نمونه تصویر از مجموعه داده PhysioNet	۹
۱-۲	یک نمونه کامل از تصاویر سی‌تی‌اسکن	۱۴
۲-۲	خوانش‌های متفاوت از تصاویر سی‌تی‌اسکن [۲]	۱۵
۳-۲	تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها	۱۶
۴-۲	توزیع بیماران و برش‌ها در مجموعه‌داده PhysioNet	۱۷
۵-۲	توزیع پیکسلی برش‌ها برای برش‌های دارای خونریزی در مقاله برش‌های سالم	۱۸
۶-۲	توزیع نرمال‌شده پیکسل‌های دارای خونریزی در مقابل تمام پیکسل‌های تصاویر	۱۹
۷-۲	اثر بافت‌های متفاوت در یکای Hounsfield [۲]	۱۹
۸-۲	توزیع خونریزی بر اساس برش‌ها	۲۰
۹-۲	پراکندگی مکانی خونریزی در مجموعه‌داده PhysioNet	۲۱
۱۰-۲	پراکندگی مکانی خونریزی در زیرمجموعه‌های متفاوت از مجموعه‌داده	۲۲
۱۱-۲	تأثیر پنجه‌گذاری در نمایش خونریزی در یک برش از سی‌تی‌اسکن	۲۲
۱۲-۲	مدلسازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نورون‌ها با استفاده از لایه‌های پنهان [۳]	۲۵
۱۳-۲	یک بلوک از معماری ResNet که اتصال میان برهمانی را نشان می‌دهد [۴]	۲۸
۱۴-۲	ساختارهای مختلف در معماری ResNeXt که کانولوشن‌های گروهی، مسیرهای پردازشی موازی و روش ادغام را نشان می‌دهند [۵]	۲۹
۱۵-۲	بلوک Squeeze-and-Excitation که نحوه عملکرد آن را در ارزیابی وزن‌دهی کانال‌ها نشان می‌دهد [۶]	۳۰
۱۶-۲	معماری یک بلوک DenseNet [۷]	۳۱
۱۷-۲	ساختار شبکه U-Net که شامل مسیر رمزگذار، رمزگشا و اتصالات میان بر است [۸]	۳۳
۱۸-۲	ساختار شبکه PSPNet [۹]	۳۴
۱۹-۲	نمونه لایه‌های پس‌پردازش استخراج شده از برش‌های بیمار	۳۵

۳۷	۲۰-۲ روندnamای روش پیشنهادی در این پژوهش
۴۰	۲۱-۲ سازوکار تصمیمگیری شورایی
۴۶	۱-۳ نمودار امتیاز F1 نسبت به آستانه برای Foldها و میانگین آنها
۴۷	۲-۳ نمودارهای سازوکار شورایی روی مجموعه داده ارزیابی
۴۷	۳-۳ ماتریس آشفتگی نتایج برش محور
۴۹	۴-۳ ماتریس آشفتگیب یمارمحور سازوکار شورایی
۵۰	۵-۳ چند نمونه از تصاویر تولید شده توسط Grad-CAM
۵۰	۶-۳ نمودارهای t-SNE و مقایسه آنها با یکدیگر
۵۱	۷-۳ یک نمونه از عملکرد روش پیشنهادی و پسپردازش در فرایند آموزش
۵۳	۸-۳ نتایج مدل U-Net به ازای آستانه‌های متفاوت
۵۳	۹-۳ نتایج مدل PSPNet به ازای آستانه‌های متفاوت
۵۴	۱۰-۳ نمونه عملکرد مدل در پیش‌بینی تصاویر سی‌تی‌اسکن

فهرست جداول

صفحه

جدول

۱-۱	انواع زیرگروه‌های خونریزی درون جمجمه‌ای [۱۰]	۴
۱-۲	ضرایب مورد استفاده در جستجوی شبکه‌ای	۳۸
۱-۳	نتایج برش محور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷	۴۵
۲-۳	نتیجه استفاده از فراپارامترهای بدست آمده از جستجوی شبکه‌ای روی مدل‌های دیگر	۴۸
۳-۳	نتایج بیمارمحور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷	۴۸
۴-۳	نتایج قطعه‌بندی تصاویر سی‌تی‌اسکن	۵۲

فهرست نمادها

نماد مفهوم

مقدمه

فصل اول

۱-۱ خونریزی درون جمجمه‌ای و اهمیت آن

خونریزی درون جمجمه‌ای^۱ یک وضعیت اضطراری پزشکی است که تشخیص سریع و دقیق آن به منظور درمان مؤثر بیمار و کاهش خطر ناتوانی شدید یا مرگ، حیاتی است [۱۱]. خونریزی درون جمجمه‌ای می‌تواند به دلایل مختلفی از جمله آسیب مغزی تروماتیک^۲، بیماری‌های عروقی، یا مشکلات مادرزادی ایجاد شود و بر اساس محل خونریزی در مغز طبقه‌بندی می‌شود [۱۲]. به صورت تقریبی سالانه بین ۴۰۰۰۰ تا ۶۷۰۰۰ بیمار دارای خونریزی درون جمجمه‌ای در ایالات متحده آمریکا شناسایی می‌شوند که نرخ مرگ‌ومیر آنها در ۳۰ روز اول حادثه در حدود ۴۰ درصد است که در نتیجه آن، خونریزی درون جمجمه‌ای به یکی از بیماری‌ها با بیشترین آمار مرگ‌ومیر تبدیل شده است. این در حالی است که عوارض دیگر این بیماری نیز بسیار خطناک است، به عنوان مثال بیشتر از ۴۶ درصد بیماران که دارای نوع خاصی از خونریزی درون جمجمه‌ای هستند، پس از بهبود به صورت دائمی دچار اختلالات شناختی می‌شوند [۱۳، ۱۴، ۱۵، ۱۶، ۱۷].

باتوجه به نرخ بالای مرگ‌ومیر مرتبط با خونریزی درون جمجمه‌ای، تشخیص سریع و دقیق خونریزی درون جمجمه‌ای با استفاده از روش‌های تصویربرداری ضروری است [۱۸]. سی‌تی اسکن^۳ شایع‌ترین روش برای تشخیص سریع خونریزی به‌ویژه در مراکز فوریت‌های پزشکی به حساب می‌آید که دقت مناسب را برای تشخیص این بیماری به متخصصین می‌دهد [۱۹، ۱۱، ۱۳، ۲۰].

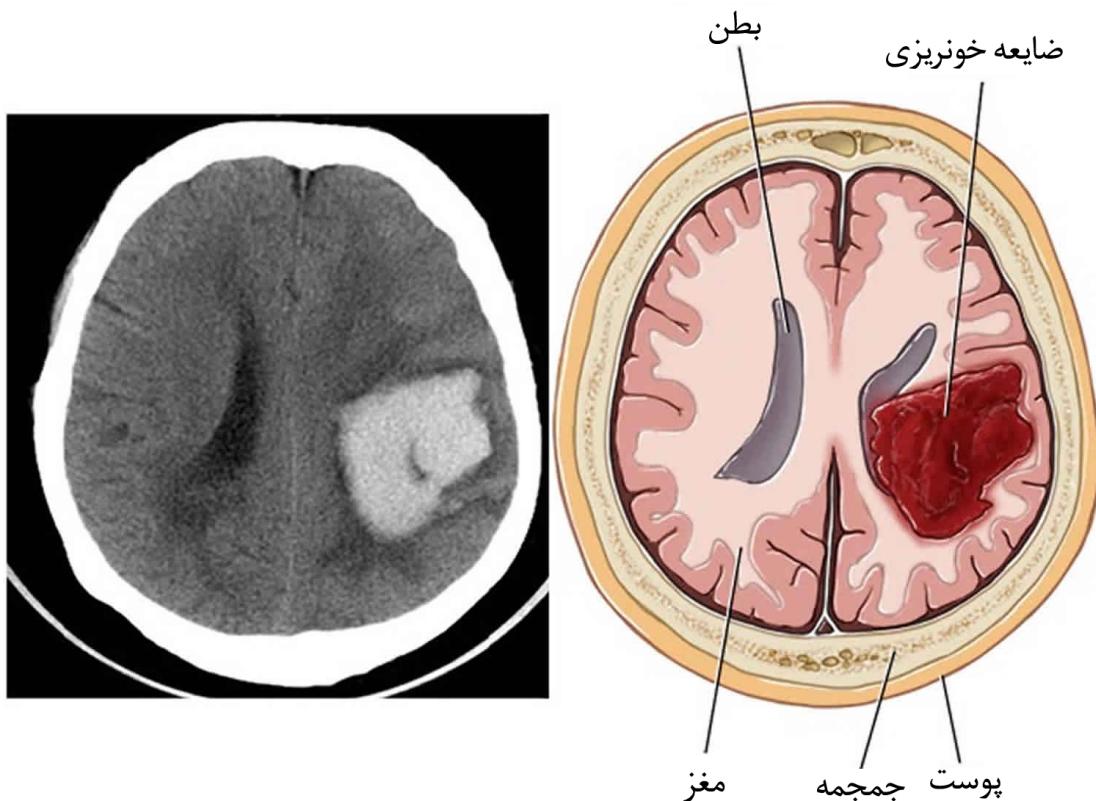
۲-۱ انواع خونریزی درون جمجمه‌ای

با پاره شدن عروق شریانی مغز، خون از درون عروق اصلی وارد بافت مغز می‌شود؛ این مسئله در حالی است که لخته شدن خون در داخل بدن سخت‌تر انجام می‌شود و به موجب آن خون وارد بافت مغز شده و با افزایش فشار داخل جمجمه، به بافت‌های حیاتی صدمات جدی وارد می‌کند. همان‌طور که در شکل ۱-۱ مشخص است، با پاره شدن شریان‌های خونی درون مغز، خونی که وارد بافت مغز شده است و یک ضایعه بزرگ خونریزی را ایجاد کرده و این ضایعه در تصویر سی‌تی اسکن به صورت یک بافت که رنگ روشن‌تری نسبت به محیط اطراف دارد قابل شناسایی است.

^۱Intracranial Hemorrhage

^۲Traumatic Brain Injury

^۳Computed Tomography Scan



[۱] شکل ۱-۱: خونریزی درون جمجمه‌ای

خونریزی درون جمجمه‌ای متناسب با محل وقوع به زیرگروه‌های مختلفی تقسیم می‌شوند؛ این طبقه‌بندی شامل خونریزی اپیدورال (EDH)^۱، خونریزی سابدوارال (SDH)^۲، خونریزی سابآرکنوئید (SAH)^۳، خونریزی پارانشیم مغزی (CPH)^۴، و خونریزی داخل بطنی (IVH)^۵ است [۲۱، ۱۴]. در جدول ۱-۱ نمونه‌هایی از زیرگروه‌های خونریزی درون جمجمه‌ای، محل خونریزی، زمینه، علت وقوع، شکل و علائم بالینی نشان داده شده است؛ همان‌طور که از تصاویر مشخص است، تشخیص بعضی از انواع خونریزی درون جمجمه‌ای به علت حضور در اطراف بقیه بافت‌های مغز، خصوصاً جمجمه که از تراکم بیشتری برخوردار است و یا شکل پیچیده‌ای که دارند، حتی برای متخصصین نیز دشوار است.

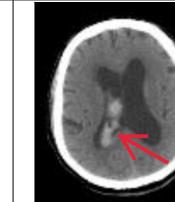
¹Epidural

²Subdural

³Subarachnoid

⁴Cerebral Parenchymal

⁵Intraventricular

EDH	SDH	SAH	IVH	CPH
محل	داخل مغز			
بین سخت شامه و جمجمه	بین سخت شامه و عنکبوتیه	بین عنکبوتیه و نرم شامه	داخل بطن	تصویر
				
ضربه یا پس از جراحی	پارگی انورسم یا ناهنجاری‌های شریانی - پارگی با خونریزی‌های درون‌مغزی و پارگی با ضربه	پارگی با خونریزی‌های شریانی - پارگی (وریدهای بلزن)	پارگی با خونریزی‌های همراه باشد - زیرعنق‌نوبه و غیره	فثار خون بالا، ضربه ناهنجاری‌های شریانی - وریدی، نوبه، و غیره
شريانی	عدم تراشی	عدم تراشی	شريانی یا پارگی	علت و قوع
هرالی	در ابتدا شریانها و شکافها	طبقان با شکل طبل	شریانی یا پارگی	علت و قوع
عديسي شكل	ممکن است تدریجی باشد (بدتر شدن سردود)	حاد (شروع ناگهانی سردود، حالت نیوچ، جاد (شروع ناگهانی سردود، حالت نیوچ، جاد (بدتر شدن سردود) (استفراغ)	معمولاً تازه	شکل
اعلام باشی	حاد (بدتر شدن سردود)	حاد (شروع ناگهانی سردود، حالت نیوچ، جاد (شروع ناگهانی سردود، حالت نیوچ، جاد (بدتر شدن سردود) (استفراغ)	اعلام باشی	اعلام باشی

جدول ۱-۱: انواع زیرگروه‌های خونریزی درون‌جمجمه‌ای [۱۰]

۱-۳ روش‌های مرسوم در تشخیص خونریزی درون‌جمجمه‌ای

در حال حاضر تصاویر سی‌تی اسکن، به عنوان استاندارد اصلی و غیرت‌های جمجمی^۱ برای تشخیص خونریزی درون‌جمجمه‌ای است. سی‌تی اسکن یک نوع تصویر پرتونگاری^۲ سه‌بعدی است که متشكل از تصاویر دو بعدی از اندام بدن است. روش عمومی پردازش تصاویر سی‌تی اسکن به صورت دستی انجام می‌پذیرد که به موجب آن متخصصین پرتونگاری^۳ و پزشکی، با بررسی برش‌های^۴ سی‌تی اسکن را به صورت مجزا بررسی می‌کنند و مناطق خونریزی را تشخیص می‌دهند. این فرایند به دلیل وابستگی به تخصص و تجربه فردی، شرایط محیطی و فشار کاری، زمان بر و مستعد خطا است.^[۱۲، ۱۱، ۱۹، ۲۰، ۱۸]. فرایند بررسی دستی تصاویر سی‌تی اسکن، زمان بر بوده و به شدت به دردسترس بودن پرتونگارهای^۵ با تجربه بستگی دارد.^[۱۴] در شرایط اضطراری، خصوصاً در مراکز فوریت‌های پزشکی، زمانی که برای پردازش برش‌های سی‌تی اسکن صرف می‌شود، می‌تواند به طور قابل توجهی در نتایج درمان بیمارها تأثیر بگذارد؛ این مسئله در مواردی از اهمیت بیشتری برخوردار می‌شود که درمان بیمار نیازمند مداخله فوری گروه پزشکی است.^[۲۰] نکته حائز اهمیت در روش معمول برای بررسی تصاویر سی‌تی اسکن در مراکز پزشکی این است که بررسی اولیه تصاویر، توسط پزشکان و پرتونگارهایی با تجربه کمتر انجام می‌شود و در مراحل بعدی این تصاویر توسط متخصصین با تجربه بیشتر بررسی می‌شود. تعدادی از مطالعات نشان داده‌اند که در روش مذکور، بین پزشکان و پرتونگارهایی که در مرحله اول تصاویر را بررسی می‌کنند و پزشکان و پرتونگارهایی که در ادامه این تصاویر را بررسی می‌کنند، اختلاف نظر وجود دارد که این مسئله می‌تواند منجر به عواقب جیران ناپذیر گردد.^[۱۹، ۲۲، ۲۳، ۲۴، ۲۵] احتمال خطای انسانی در بررسی دستی تصاویر پیچیده و

¹Non-invasive²Radiography³Radiology⁴Slice⁵Radiologist

سه بعدی سی تی اسکن، از دیگر نقاط ضعف روش معمول پردازش این تصاویر است، بهویژه در محیط‌های شلوغ و پرتنش که پرتونگارها ممکن است تحت فشار زیاد باشند [۱۹].

۴-۱ روش‌های رایانه‌ای در پردازش تصاویر پزشکی

اهمیت مسئله خونریزی درون جمجمه‌ای و چالش‌های مرتبط با آن در بخش قبل مورد بررسی قرار گرفت، روش‌های مبتنی بر پردازش رایانه‌ای^۱ تصاویر پزشکی، می‌تواند یک راه حل مناسب برای رفع نقاط ضعف روش کنونی بررسی تصاویر پزشکی باشد [۱۱، ۱۳، ۱۹، ۲۶، ۲۷، ۲۸، ۲۰، ۱۸]. ابزارهای خودکار برای تشخیص و کمیت‌سنجه خونریزی، از پیشرفت‌های روش‌های یادگیری ماشین^۲ و یادگیری عمیق^۳ و سامانه‌های^۴ تشخیص به کمک رایانه^۵ استفاده می‌کنند تا تجزیه و تحلیل سریع و دقیقی از تصاویر سی‌تی اسکن ارائه دهند. با خودکارسازی تشخیص خونریزی درون جمجمه‌ای و استفاده از آنها به صورت نظر ثانویه^۶، این سامانه‌ها می‌توانند بار کاری پرتونگارها را کاهش دهند، دقت تشخیص را افزایش دهند از اشتباهات متخصصین جلوگیری کنند، زمان تشخیص را به حداقل برسانند، بعضی از هزینه‌های فرایند درمان را به علت کاهش دخالت انسانی کاهش دهند و به صورت کلی فرایند تشخیص را بهبود ببخشند که این موارد به بهبود نتایج بیماران منجر خواهد شد. با این حال، ضمن اینکه سامانه‌های تشخیص به کمک رایانه نویدبخش هستند؛ اما امکان خطا در آنها وجود دارد که می‌تواند تصمیم‌گیری بالینی را با مشکلاتی روبرو کند؛ بنابراین، ادغام این ابزارها در عمل باید با دقت انجام شود [۲۸].

۱-۵ مجموعه‌داده‌ها

در سال‌های اخیر، مجموعه‌داده‌های متعددی برای پشتیبانی از توسعه مدل‌های^۷ یادگیری عمیق در حوزه تصویربرداری پزشکی، بهویژه برای طبقه‌بندی خونریزی درون جمجمه‌ای ایجاد شده‌اند. در ادامه به بررسی برخی از مهم‌ترین مجموعه‌داده‌هایی که در این حوزه مورد استفاده قرار گرفته‌اند، می‌پردازیم.

¹Computer

²Machine Learning

³Deep Learning

⁴System

⁵Computer-aided Diagnosis

⁶Second Opinion

⁷Model

۱-۵-۱ مجموعه‌داده‌ی انجمن پرتوشناسی آمریکای شمالی (RSNA)

مجموعه‌داده‌ی RSNA Intracranial Hemorrhage Detection [۲۹، ۱۰] که برای چالش یادگیری ماسیین سال ۲۰۱۹ انجمن پرتونگاری آمریکای شمالی جمع‌آوری شده است، یکی از منابع برجسته در زمینه طبقه‌بندی خونریزی درون‌جمجمه‌ای محسوب می‌شود. این مجموعه‌داده، از چند مرکز پرتونگاری جمع‌آوری شده است که سه مؤسسه دانشگاه استنفورد در ایالات متحده، دانشگاه فدرال سائوپائولو در برزیل و بیمارستان دانشگاه توماس جفرسون در ایالات متحده شامل آنها می‌باشد. این مجموعه شامل تصویر سی‌تی اسکن مغزی ۲۵۳۱۲ بیمار است که از این میان، ۸۸۸۹ بیمار دارای انواع مختلف خونریزی درون‌جمجمه‌ای هستند. تصاویر سی‌تی اسکن درون این مجموعه‌داده در سطح برش، حاشیه‌نویسی ^۱ شده‌اند. تصاویر سی‌تی اسکن در این مجموعه‌داده به صورت فایل‌های DICOM ^۲ ارائه شده‌اند که استانداردی برای تصویربرداری پزشکی است. این مجموعه‌داده به طور گستره‌های در طبقه‌بندی انواع خونریزی مورد استفاده قرار گرفته و به عنوان منبعی بنیادی برای آموزش و اعتبارسنجی مدل‌های یادگیری ماسیین که به طبقه‌بندی خونریزی درون‌جمجمه‌ای تبدیل شده است.

۲-۵-۱ MosMed مجموعه‌داده‌ی

مجموعه‌داده‌ی MosMed [۳۰]، یک مجموعه‌داده خونریزی درون‌جمجمه‌ای است که در روسیه جمع‌آوری شده است. این مجموعه‌داده به طور خاص برای تسهیل توسعه ابزارهای هوش مصنوعی به منظور تشخیص و طبقه‌بندی خونریزی درون‌جمجمه‌ای طراحی شده است. این مجموعه شامل سی‌تی اسکن مغزی ۸۰۰ بیمار است که ۴۰۰ بیمار دارای خونریزی درون‌جمجمه‌ای هستند. این مجموعه‌داده در سطح بیمار حاشیه‌نویسی شده است و تصاویر آن به صورت فایل‌های DICOM در دسترس قرار دارد.

۳-۵-۱ CQ500 مجموعه‌داده‌ی

مجموعه‌داده‌ی CQ500 [۳۱]، یک مجموعه‌داده مهم است که از چند مرکز متفاوت شامل پنج مرکز مختلف در هند است. این مجموعه‌داده حاوی ۴۹۱ سی‌تی اسکن سر است که برای انواع خونریزی‌های درون‌جمجمه‌ای در سطح بیمار حاشیه‌نویسی شده‌اند. تصاویر سی‌تی اسکن در این مجموعه‌داده به صورت

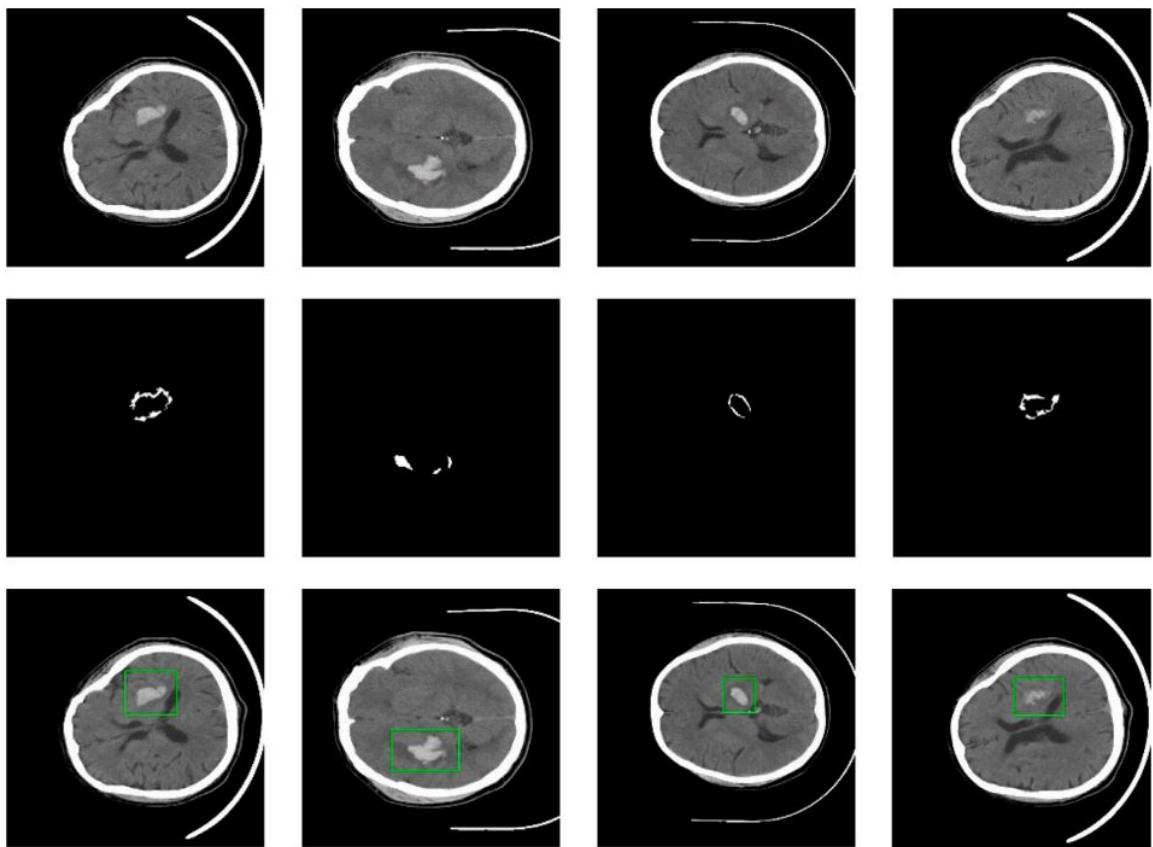
¹Annotation

²Digital Imaging and Communications in Medicine

فایل DICOM ارائه شده.

۴-۵-۱ مجموعه‌داده‌ی PHE-SICH-CT-IDS

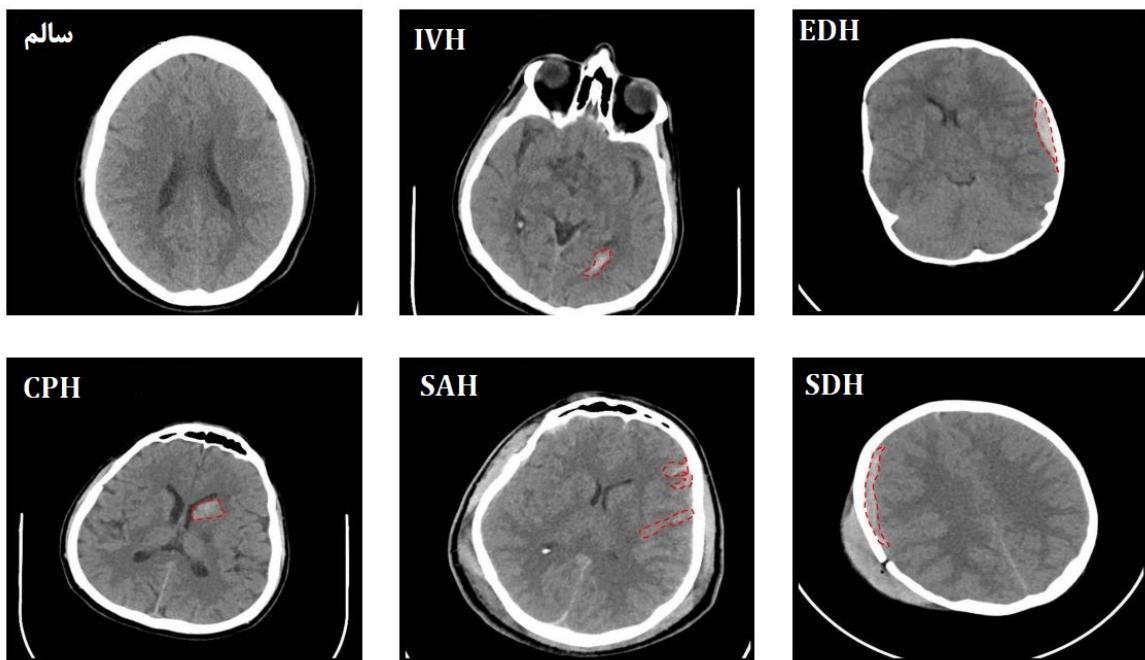
مجموعه‌داده‌ی PHE-SICH-CT-IDS [۳۲]، اگرچه به‌طور خاص برای خونریزی درون‌جمجمه‌ای جمع‌آوری نشده است، اما به دلیل تمرکز آن بر وظایف طبقه‌بندی، تشخیص و قطعه‌بندی مرتبط به در خونریزی درون‌جمجمه‌ای قابل توجه است. این مجموعه‌داده از بیمارستان Perihematomal Edema در چین جمع‌آوری شده است که شامل تصویر سی‌تی‌اسکن ۱۲۰ بیمار است که تمامی آنها خونریزی درون‌جمجمه‌ای دارند و حاشیه‌نویسی آنها در سطح برش انجام شده است. تصاویر سی‌تی‌اسکن در این مجموعه‌داده به صورت فایل‌های NIFTI، JPEG و PNG ارائه شده است. مجموعه‌داده‌ی PHE-SICH-CT-IDS منبعی ارزشمند برای توسعه مدل‌های یادگیری عمیق که هدف آن‌ها طبقه‌بندی، تشخیص یا قطعه‌بندی است. در شکل ۲-۱ چند برش از تصاویر مجموعه‌داده PHE-SICH-CT-IDS است، همان‌طور که در این تصویر مشخص است، در اطراف ضایعه خونریزی، یک حاشیه تیره‌تر وجود دارد که به آن Edema گفته می‌شود و این ضایعه قطعه‌بندی شده است؛ همچنین این مجموعه‌داده حاشیه‌نویسی مناسب برای وظیفه تشخیص را نیز دارد.



شکل ۱-۲: چند نمونه تصویر از مجموعه‌داده PHE-SICH-CT-IDS

۱-۵-۵ مجموعه‌داده‌ی PhysioNet

مجموعه‌داده‌ی خونریزی درون جمجمه‌ای [۳۳] PhysioNet، مجموعه‌داده‌ای است که در ادامه این مطالعه از آن استفاده شده است. این مجموعه‌داده از بیمارستان Al Hilla در عراق جمع‌آوری شده است و شامل ۸۲ تصویر سی‌تی اسکن از بیماران است که ۳۶ نفر از آنها دارای خونریزی درون جمجمه‌ای هستند. این مجموعه‌داده، شامل حاشیه‌نویسی‌های مناسب برای وظایف طبقه‌بندی و قطعه‌بندی است که آن را به تنها مجموعه‌داده با دسترسی عمومی تبدیل می‌کند که امکان قطعه‌بندی خونریزی درون جمجمه‌ای را فراهم می‌کند. جزئیات بیشتر در مورد این دیتابست در [فصل ۲](#) توضیح داده شده است. تصویر [شکل ۳-۱](#) چند نمونه از برش‌های خونریزی درون این مجموعه‌داده را مشخص می‌کند.



شکل ۱-۳: چند نمونه تصویر از مجموعه داده PhysioNet

۱-۶ تحقیقات اخیر در زمینه یادگیری ماشین

در سال‌های اخیر، یادگیری عمیق پیشرفتهای قابل توجهی در زمینه طبقه‌بندی و قطعه‌بندی خونریزی درون‌جمجمه‌ای داشته است و مطالعات متعددی به بررسی این موضوع پرداخته‌اند. این مدل‌ها نه تنها از نظر نوآوری فنی قابل توجه هستند، بلکه پتانسیل بالای آنها می‌تواند باعث استفاده از آنها در دستگاه‌های تشخیص و درمان بیمارستان‌ها شود که موجب بهبود عملکرد خدمه درمان، کاهش هزینه‌های درمان، کاهش زمان تشخیص و افزایش دقت در طبقه‌بندی و قطعه‌بندی خونریزی درون‌جمجمه‌ای شود. برخی از این مطالعات، از جمله تحقیقات Titano [۲۸]، Arbabshirani [۱۲] و Kuo [۱۸]، و همکارانشان مدل‌های پیشنهادی خود را در محیط‌های بیمارستانی آزمایش کرده‌اند و نتایج آن‌ها نشان داده است که ابزارهای هوش مصنوعی می‌توانند به طور مؤثری در بهبود نتایج درمان برای بیماران نقش داشته باشد. به طور خاص، Titano و همکاران یک دستگاه خودکار تشخیص خونریزی درون‌جمجمه‌ای مبتنی بر یادگیری عمیق توسعه دادند که این دستگاه توانست Accuracy ۸۷٪ و Sensitivity ۹۴٪ کسب کند که عملکرد آن با کارشناسان انسانی قابل مقایسه است، همچنین ابزار هوش مصنوعی پیشنهادی آنها در محیط‌های بالینی به کار گرفته شده است. Kuo و همکاران یک شبکه عصبی پیچشی برای طبقه‌بندی خونریزی حاد درون‌جمجمه‌ای با Accuracy ۹۹٪ و AUC برابر با ۹۹٪ توسعه داده‌اند که نشان‌دهنده قابلیت

اطمینان بالا در شرایط بالینی است. سایر مطالعات، مانند [۲۷]Chang و [۲۰]Chilamkurthy نیز نتایج قابل توجهی در زمینه طبقه‌بندی خونریزی‌ها با استفاده از مدل‌های یادگیری عمیق ارائه کرده‌اند. [۳۴]Neethi و همکاران مروری بر روش‌های مختلف یادگیری عمیق انجام داده‌اند که از مجموعه‌داده‌های مختلفی از جمله PhysioNet و مجموعه‌داده RSNA استفاده کردند. آنها از مجموعه‌داده RSN که شامل ۲۵۳۱۲ تصویر سی‌تی اسکن از بیماران است، برای آموزش مدل‌های یادگیری عمیق بهره برند و عملکرد آن را برابر روی مجموعه‌داده PhysioNet ارزیابی کردند. آن‌ها با استفاده از مدل-ResNet50- V2 بر روی مجموعه‌داده PhysioNet به F1 Score ۷۶٪ و Recall ۶۷٪ دست یافتند که این نتایج به صورت برش‌محور^۱ گزارش شده است. در میان کارهایی که روی مجموعه‌داده PhysioNet انجام شده است، [۳۵]Kyung و همکاران شبکه‌ای به نام SMART-Net را پیشنهاد کردند که به کمک روش انتقال یادگیری^۲ توانسته‌اند به F1 Score برابر با ۸۴٪ و Sensitivity برابر با ۹۷٪ و Specificity برابر با ۷۴٪ دست یابند. در ادامه Hssayeni^۳ [۳۳] و همکاران، از مدل معروف U-Net استفاده کرده‌اند تا یک مدل برای قطعه‌بندی تصاویر سی‌تی اسکن آموزش دهند. آموزش این مدل با تصاویر ورودی که از ابعاد اصلی برخوردار هستند، باعث شده است تا مدل ماسک‌هایی^۴ تماماً سیاه تولید کند که به معنی عدم تشخیص هیچ پیکسلی دارای خونریزی می‌باشد. از این نتیجه می‌توان برداشت کرد که معیار IoU در آموزش مدل با ابعاد اصلی برابر^۵ بوده است. در ادامه این تحقیق، Hssayeni و همکاران تصویر ورودی را به قسمت‌های 160×160 تقسیم کرده‌اند که به موجب آن هر تصویر سی‌تی اسکن، به تعدادی تصویر دارای همپوشانی تبدیل می‌شوند و روی هر پیکسل از تصویر سی‌تی اسکن، ۴ مرتبه پیش‌بینی انجام می‌شود. آنها با تعدیل تعداد تصاویر دارای خونریزی و تصاویری که خونریزی ندارند به روش‌های کاهش داده غالب^۶ و افزایش مصنوعی داده^۶ و توسعه یک روش سورایی برای تصمیم‌گیری، توانستند معیار شباهت IoU برابر ۲۱٪ و معیار Dice برابر ۳۱٪ دست پیدا کنند. Li [۳۶] و همکاران نیز یک مدل U-Net را روی مجموعه‌داده PhysioNet آموزش داده‌اند؛ اما از جزئیات این آموزش اطلاعات زیادی را مطرح نکرده‌اند. آنها با استفاده از مدل U-Net توانسته‌اند معیار شباهت IoU برابر ۲۱٪ و معیار Dice برابر ۳۵٪ را به دست آورده‌اند.

¹Slice-wise²Transfer Learning³Patient-wise⁴Mask⁵Undersampling⁶Augmentation

۱-۶-۱ نقاط ضعف موجود در پژوهش‌های گذشته

با وجود پیشرفت‌های قابل توجه در مدل‌های یادگیری عمیق، هنوز چالش‌هایی در تفسیرپذیری مدل‌های شبکه عصبی وجود دارد که می‌توان از آن به عنوان یکی از نقاط ضعف ادبیات موجود در این زمینه دانست؛ زیرا تفسیرپذیر بودن ابزار هوش مصنوعی، یکی از معیارهای اساسی برای متخصصین حوزه پزشکی است تا از این ابزار استفاده کنند. از دیگر نقاط ضعف در ادبیات خونریزی درون جمجمه‌ای، دردسترس نبودن مجموعه‌داده‌های بزرگ با حاشیه‌نویسی مناسب و مجموعه‌داده‌های مربوط به بیمارستان‌ها و دستگاه‌های موجود در ایران است؛ وجود یک مجموعه‌داده با ابعاد مناسب از دستگاه‌های موجود در ایران، می‌تواند مسیر توسعه یک ابزار هوش مصنوعی در زمینه خونریزی درون جمجمه‌ای را در ایران وجود هموار سازد. از دیگر نقاط ضعف موجود در ادبیات موجود در این مسئله، استفاده از شبکه‌هایی با ابعاد بسیار بزرگ توسط محققین است که نیازمند پردازشگرهایی با هزینه بیشتر هستند. از مهم‌ترین مشکلات موجود در تحقیقات گذشته، توجه نکرده به بیمارمحور بودن داده‌ها هنگام تفکیک آنها به زیرمجموعه‌های آموزش و ارزیابی اشاره کرد که درنتیجه آن برش‌هایی از یک بیمار که شباهت بسیار زیادی به یکدیگر دارند، در زیرمجموعه‌های آموزش و ارزیابی قرار گیرد که درنتیجه آن همبستگی بین این دو مجموعه‌داده زیاد خواهد شد. استفاده نکردن از روش مرسوم K-Fold-Cross-Validation، یا نداشتن روش شورا در تصمیم‌گیری در این روش، یکی دیگر از معايب موجود در تحقیقات گذشته است که بهموجب آن، تعمیم‌پذیری مدل به دست آمده از این تحقیقات محل ابهام است. به عنوان یکی از اشکالات مهم در ادبیات موجود، عدم ارائه معیارهای مناسب و کافی برای ارزیابی عملکرد مدل‌های یادگیری ماشین است که در نتیجه آن، نتایج به دست آمده از شفافیت کافی برخوردار نیست.

۱-۶-۲ اهداف پژوهش

در این پژوهش تلاش شده تا در گام نخست یک روش دومرحله‌ای شامل یک مدل طبقه‌بندی و یک مدل قطعه‌بندی که به صورت متوالی استفاده می‌شوند توسعه داده شود که این روش، موجب بهبود عملکرد مدل‌های پردازش تصویر در قطعه‌بندی شده است؛ نکته حائز اهمیت در این روش این است که با کاهش امکان ایجاد False Positive در پیش‌بینی‌های مدل قطعه‌بندی، باعث بهبود عملکرد مدل‌های قطعه‌بندی خواهد شد. در گام بعدی یک پس‌پردازش^۱ در لایه تصمیم‌گیری توسعه داده شده است که این پس‌پردازش نیز موجب بهبود عملکرد مدل طبقه‌بندی شده است. در انتهای با استفاده از انواع معیارهای

^۱Post-process

موجود، آموزش مدل با استفاده از روش 5-Fold-Cross-Validation^۱ طراحی یک ضابطه تصمیم‌گیری و استفاده از روش‌هایی برای تفسیرپذیر کردن مدل، امکان تحلیل جامع از عملکرد مدل فراهم شده است.

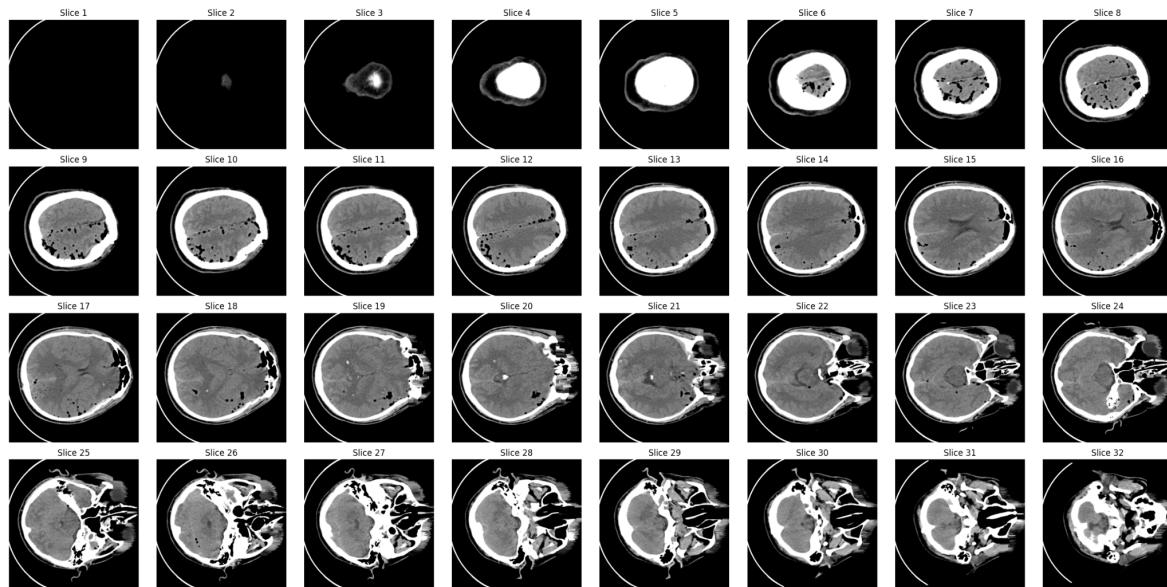
^۱Decision Policy

فصل دوم

روش‌ها و مجموعه‌داده

۱-۲ بررسی آماری مجموعه‌داده

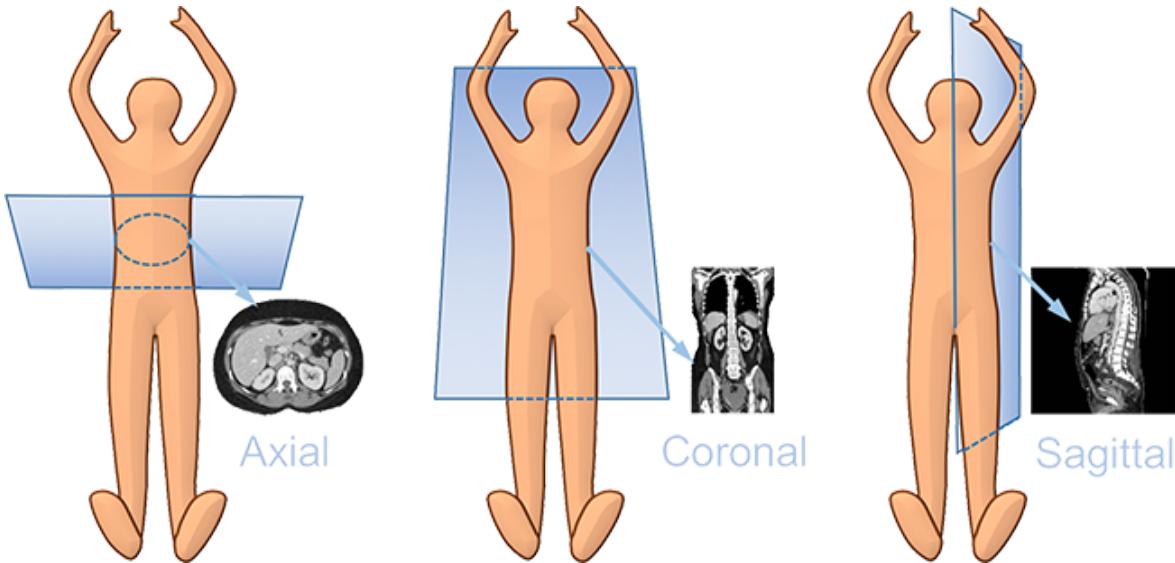
در این پژوهش از مجموعه‌داده PhysioNet [۳۷، ۳۳] استفاده شده است که شامل حاشیه‌نویسی برای وظیفه طبقه‌بندی و قطعه‌بندی است. این مجموعه‌داده شامل مجموعه‌ای از سی‌تی‌اسکن‌های مغزی است که به صورت عمومی در دسترس است.



شکل ۱-۲: یک نمونه کامل از تصاویر سی‌تی‌اسکن

همانطور که در شکل ۱-۲ نمایش داده شده است، سی‌تی‌اسکن یک نوع تصویر سه‌بعدی است که از برش‌های دوبعدی تشکیل شده است. شکل ۲-۲ نشان می‌دهد که با توجه به جهت برش‌های سی‌تی‌اسکن، این تصاویر به سه دسته Axial، Coronal و Sagittal تقسیم می‌شوند.

مجموعه‌داده PhysioNet شامل ۸۲ سی‌تی‌اسکن با برش‌های Axial است که بین فوریه و اوت ۲۰۱۸ از بیمارستان آموزشی Al Hilla در عراق جمع‌آوری شده است. این اسکن‌ها شامل طیف وسیعی از بیماران هستند که از یک روز تا ۷۲ سال سن دارند و میانگین سن آنها ۱۹.۵ ± ۲۷.۸ سال است. تنوع سنی این مجموعه‌داده بر مقیاس، شکل جمجمه و بافت مغز در سی‌تی‌اسکن تأثیر می‌گذارد، عاملی که می‌تواند عملکرد مدل‌های یادگیری عمیق برای تشخیص و قطعه‌بندی خونریزی درون جمجمه‌ای را تحت تأثیر قرار دهد. توزیع جنسیت در این مجموعه‌داده به گونه‌ای است که ۵۶٪ بیماران مرد و ۴۴٪ آنها زن هستند. ۸۲ بیماری که در این مجموعه‌داده وجود دارد که ۷ مورد از آنها طی فرایند حاشیه‌نویسی گم شده‌اند و از بین ۷۵ بیمار موجود، ۳۶ نفر دارای خونریزی درون جمجمه‌ای تشخیص داده شدند. شکل ۳-۲ نمودار تعداد برش‌های هر بیمار در این مجموعه‌داده است؛ تصاویر سی‌تی‌اسکن موجود در این مجموعه‌داده، به

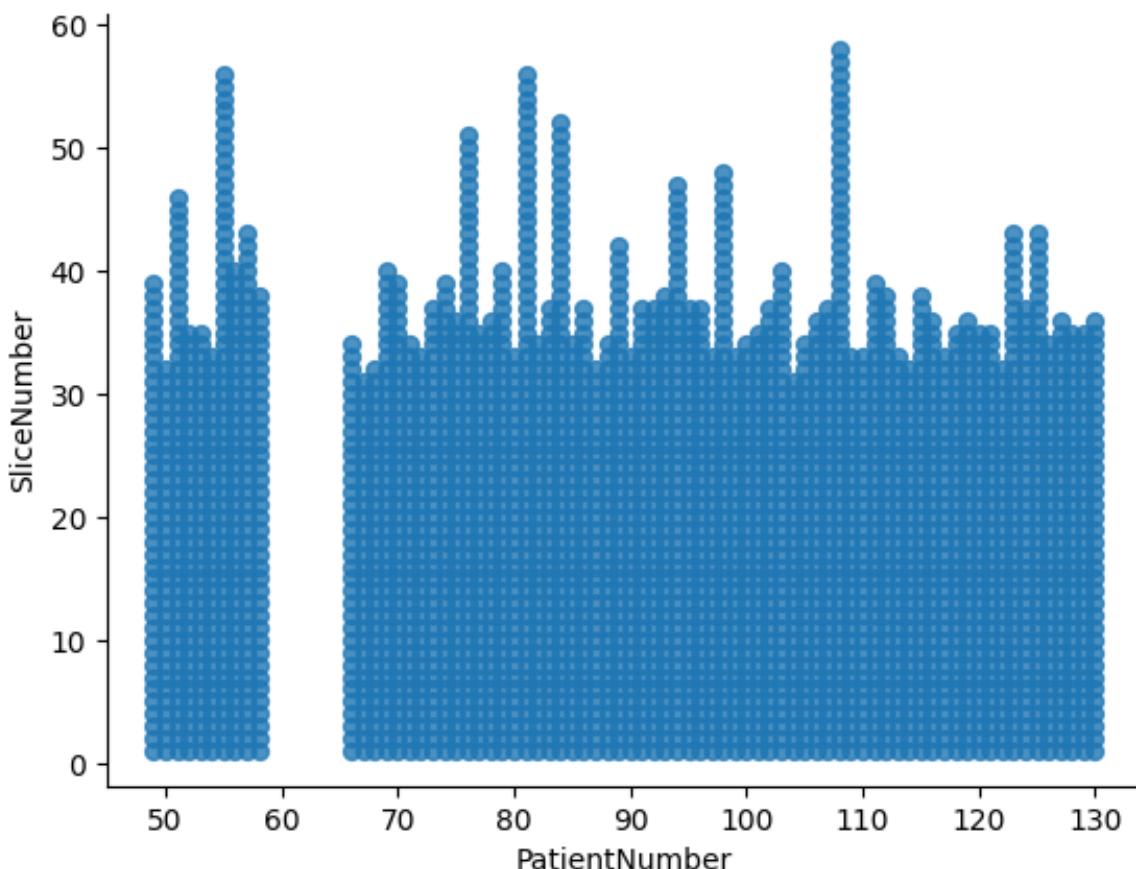


شکل ۲-۲: خواش‌های متفاوت از تصاویر سی‌تی‌اسکن [۲]

به صورت متوسط شامل ۳۴ برش با ضخامت برش ۵ میلی‌متر دارند و در مجموع ۲۸۱۴ برش در این مجموعه‌داده وجود دارد.

باین حال، این مجموعه‌داده به دلیل عدم توازن در سطح برش شناخته می‌شود، زیرا تنها ۳۱۸ برش دارای خونریزی هستند درحالی که بقیه ۲۴۹۶ برش سالم هستند. در این مجموعه‌داده، ۲۴ برش شامل زیرگروه IVH، ۷۳ برش شامل زیرگروه CPH، ۱۸ برش شامل زیرگروه SDH، ۱۷۳ برش شامل زیرگروه EDH و ۵۶ برش شامل زیرگروه SDH هستند. با توجه به تفاوت شکل انواع زیرگروه‌های خونریزی و محل وقوع آنها، این ارقام نشان‌دهنده عدم وجود تعداد برش کافی برای بعضی از انواع زیرگروه‌ها است. در این مجموعه‌داده، برش‌های سی‌تی‌اسکن توسط دو پرتوشناس بررسی شده است و هر برش سی‌تی‌اسکن از نظر وجود خونریزی یا شکستگی توسط آنها بررسی و برچسب‌گذاری شده است. در ادامه سی‌تی‌اسکن‌های دو بیمار، به علت کیفیت ضعیف تصاویر و به توصیه پرتوشناس‌ها حذف شدند [۳۵].

شکل ۴-۲ نمودارهای توزیع بیمارمحور و برش‌محور مجموعه‌داده را نمایش می‌دهد؛ همانطور که از شکل ۴-۲ آ مشخص است در بررسی بیمارمحور این مجموعه‌داده، عدم توازن دیده نمی‌شود؛ اما در بررسی برش‌محور، همانطور که در **شکل ۴-۲ ب** مشخص است، عدم توازن شدیدی در تعداد برش‌های دارای خونریزی وجود دارد که این مسئله، آموزش مدل‌های شبکه عصبی را با چالش مواجه می‌کند. علاوه بر وجود عدم توازن در حالت برش‌محور، عدم توازن شدیدی در قطعه‌بندی نواحی دارای خونریزی نسبت به نواحی سالم در برش‌های دارای خونریزی وجود دارد که بهموجب آن در یک تصویر با ابعاد



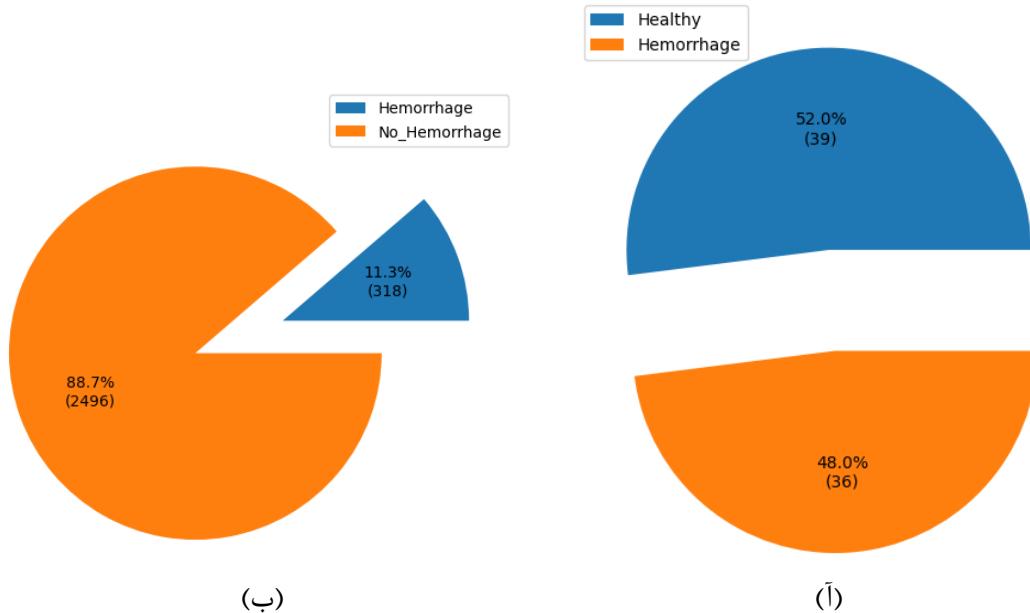
شکل ۲-۳: تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها

512×512 ، به صورت میانگین نزدیک به 2000 پیکسل^۱ دارای خونریزی درون جمجمه‌ای وجود دارد که این مسئله، آموزش مدل‌های شبکه عصبی را به منظور وظیفه قطعه‌بندی با چالش بسیار جدی مواجه می‌کند. شکل ۵-۲ نشان‌دهنده توزیع نرمال شده^۲ مقدار پیکسل‌های برش‌های سالم و برش‌های دارای خونریزی است، با توجه به شکل ۵-۲ ب، اکثر پیکسل‌های تصاویر مقداری نزدیک به 1000 – و نقطه بیشینه محلی بعدی برای این نمودار توزیع، در نزدیک مقادیر 30 است که این مقادیر به نسبت پیکسل‌ها با مقادیر نزدیک به 1000 – خیلی کمتر است.

شکل ۶-۲ نمایش‌دهنده توزیع پیکسل‌های دارای خونریزی و تمام پیکسل‌های تصاویر پرتونگاری است که در محدوده بین 100 – تا 1000 واقع شده است و نسبت به مقادیر همین بازه نرمال گشته است. همانطور که از این دو نمودار مشخص است، مقادیر مربوط به ضایعه خونریزی، به اندازه کمی از مقادیر بقیه بافت‌های مغز روشن‌تر است؛ اما همپوشانی این دو نمودار نشان می‌دهد که تشخیص خونریزی

¹Pixel

²Normalized

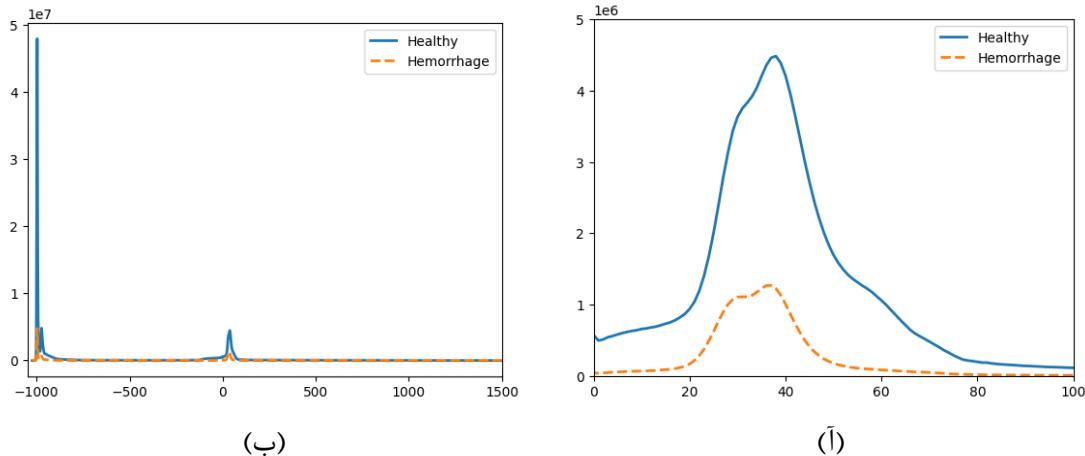


شکل ۲-۴: توزیع بیماران و برش‌ها در مجموعه‌داده PhysioNet

درون‌جمجمه‌ای تنها با استفاده از مقدار پیکسلی آن بسیار دشوار است و نیاز هست تا از شبکه‌هایی استفاده شود تا به اشکال موجود در تصویر نیز حساسیت داشته باشند.

شکل ۲-۳ توزیع خونریزی درون‌جمجمه‌ای را بر اساس شماره برش در تصویر سی‌تی‌اسکن نشان می‌دهد که بر اساس آن مشخص است به‌ازای بعضی از شماره برش‌ها، خونریزی درون‌جمجمه‌ای وجود ندارد و این برش‌ها از اهمیت کمتری برای مدل‌های یادگیری ماشین برخوردار هستند. با توجه به مطالبی که در این بخش مطرح شد، می‌توان نتیجه گرفت که مجموعه‌داده PhysioNet به عنوان تنها مجموعه‌داده عمومی قطعه‌بندی خونریزی درون‌جمجمه‌ای، می‌تواند یک مجموعه‌داده معیار برای بررسی عملکرد مدل‌های پردازش تصویر باشد.

شکل ۲-۸ نمایش پراکندگی مکانی خونریزی درون‌جمجمه‌ای را نشان می‌دهد که در مجموعه‌داده PhysioNet وجود دارد. این پراکندگی نشان می‌دهد که خونریزی درون‌جمجمه‌ای تنها در قسمت‌های خاصی از برش‌های سی‌تی‌اسکن اتفاق می‌افتد و از طرف دیگر احتمال وجود خونریزی در اطراف جمجمه و ناحیه شقیقه، بیشتر از پیشانی و پشت سر است. **شکل ۹-۲** نمایش زیرمجموعه‌های متفاوتی است که در فرایند آموزش و ارزیابی مدل دخیل بوده‌اند. باید توجه داشت که در این تصویر، نقشه پراکندگی مربوط به هر Fold نشان‌دهنده زیرمجموعه آموزش به‌ازای آن Fold است.



شکل ۲-۵: توزیع پیکسلی بر什‌ها برای برش‌های دارای خونریزی در مقال برش‌های سالم

۲-۲ پیش‌پردازش^۱

در تصاویر پرتونگاری سی‌تی اسکن، از اشعه ایکس^۲ به منظور ثبت تصویر اندام درونی بدن استفاده می‌شود. در این روش، یک کاتد^۳ را برانگیخته می‌کنند تا الکترون‌های^۴ پرانرژی را آزاد کند. با آزادشدن الکترون‌ها، انرژی به صورت اشعه ایکس آزاد می‌شود و اشعه ایکس از بافت‌ها عبور کرده و به آشکارساز در سمت دیگر برخورد می‌کند. هرچه بافت متراکم‌تر باشد، اشعه ایکس بیشتری را جذب می‌کند؛ مثلاً بافت استخوانی به علت تراکم بالا، اشعه ایکس بیشتری جذب می‌کند و در نتیجه آن اشعه کمتری به آشکارساز می‌رسد که موجب سفیدشدن آن قسمت از تصویر خواهد شد؛ اما این مسئله درمورد هوا بر عکس است [۲]. در مقایسه با تصویر اشعه ایکس ساده، سی‌تی اسکن دارای تفکیک‌پذیری بیشتر است و هیچ همپوشانی در ساختارها وجود ندارد. دستگاه‌های سی‌تی اسکن که از کالیبراسیون^۵ درستی برخوردار باشند، تصاویر خود را طبق یکای Hounsfield ثبت می‌کنند. این یکا به پرتونگارها و محققین اجازه می‌دهد تا بتوانند با آستانه‌گذاری مناسب، جزئیات بافت هدف خود را در تصویر رویت‌پذیرتر کنند. تصاویر سی‌تی اسکن به صورت معمول بر اساس یکای Hounsfield مقادیر پیکسلی بین -1024 – 3000 را دارا هستند.

شکل ۱۰-۲ نشان‌دهنده مقدار پیکسلی است که هر بافت در تصویر سی‌تی اسکن از خود نشان می‌دهد. پرتونگارها، پزشک‌ها و محققین برای اینکه بتوانند یک بیماری خاص را مورد بررسی قرار بدهند، برش‌های تصاویر را در بازه‌های خاصی از یکای Hounsfield مورد بررسی قرار می‌دهند که به این

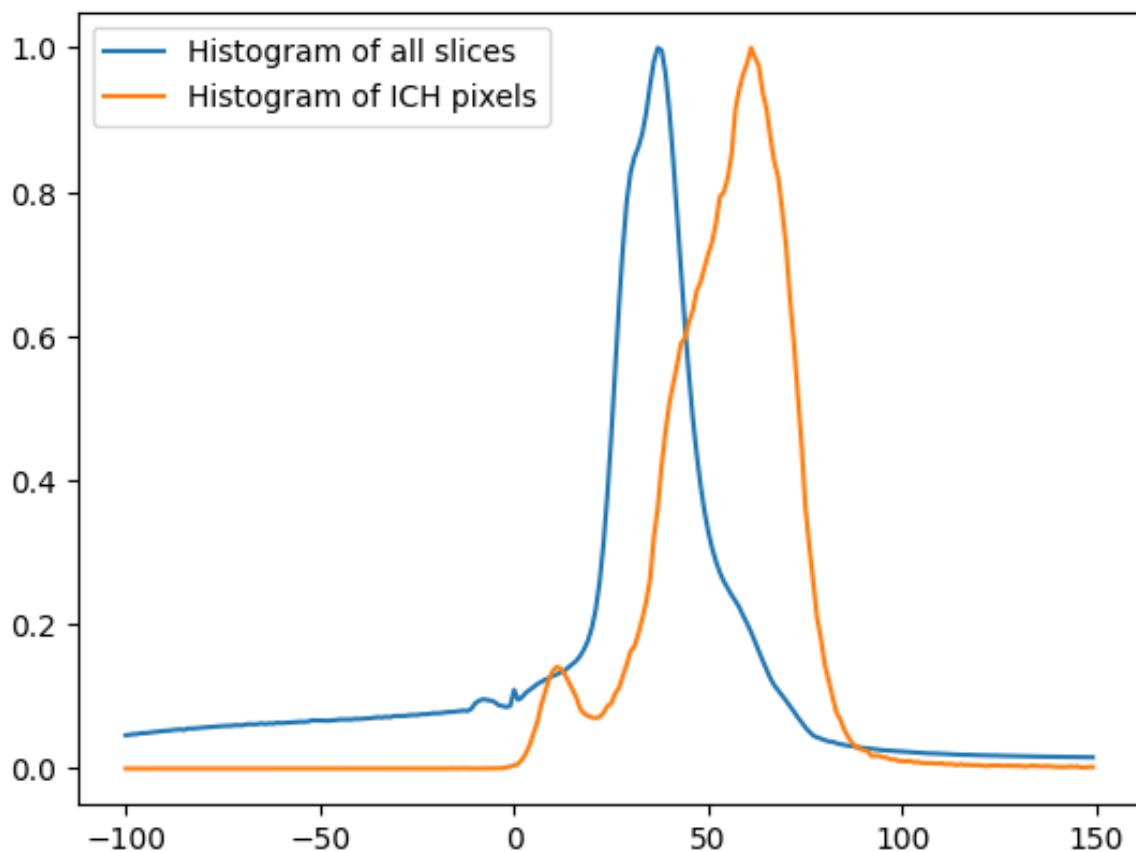
¹Pre-process

²X-Ray

³Cathode

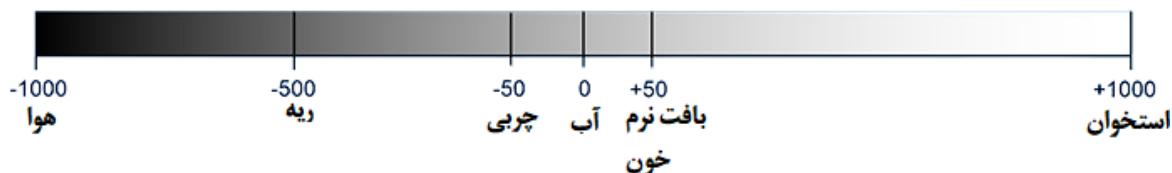
⁴Electron

⁵Calibration



شکل ۲-۶: توزیع نرمال‌شده پیکسل‌های دارای خونریزی در مقابل تمام پیکسل‌های تصاویر

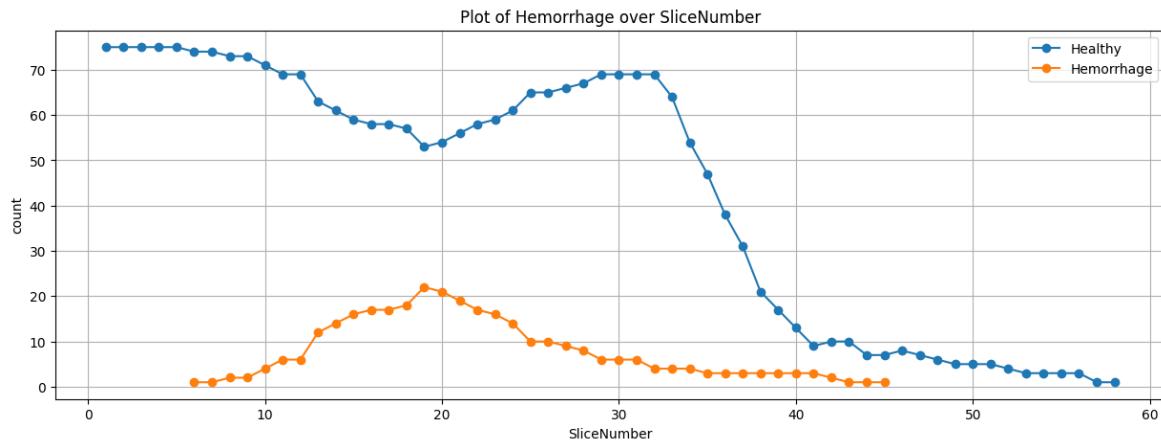
نوع از پیش‌پردازش تصاویر سی‌تی‌اسکن، پنجره‌گذاری^۱ می‌گویند.



شکل ۲-۱۰: اثر بافت‌های متفاوت در یکای Hounsfield [۲]

در روش پنجره‌گذاری، دو مقدار مرکز پنجره (WC) و پهنه‌ای پنجره (WW) بازه هدف را در تصویر مشخص می‌کند و به موجب آن هر پیکسل که مقدار آن از حداقل بازه کمتر باشد، مقدارش برابر با حداقل بازه می‌شود و هر پیکسل که مقدارش از حداکثر بازه بیشتر باشد، مقدارش برابر حداکثر بازه می‌شود. معادله ۲-۲ روش اعمال پنجره‌گذاری روی تصاویر را نمایش می‌دهد که در آن Normalize به منظور انتقال مقادیر تصویر بعد از پنجره‌گذاری بین 0° و 1° است و Threshold تابعی است که در اثر آن مقادیر

^۱Windowing

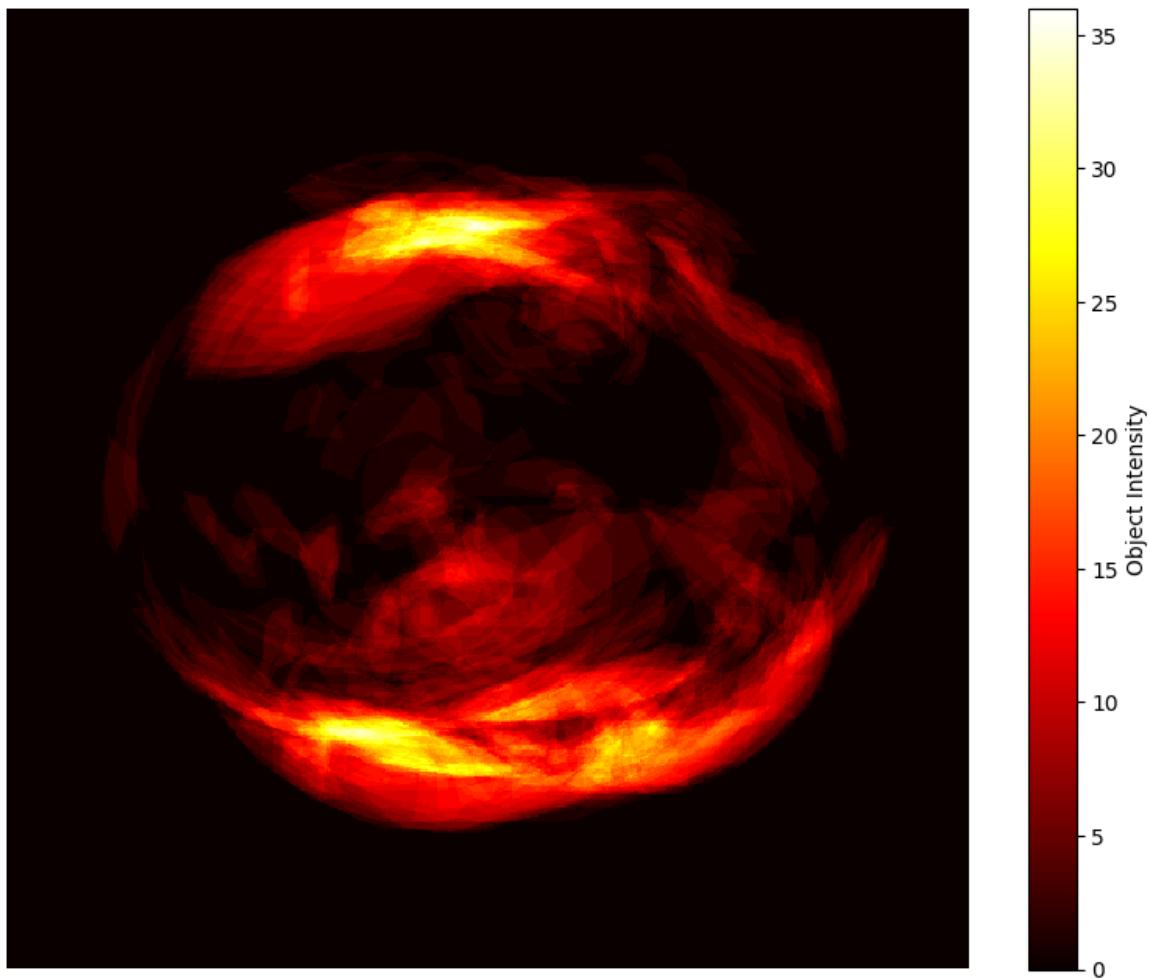


شکل ۷-۲: توزیع خونریزی بر اساس برش‌ها

کمتر از حداقل بازه هدف به مقدار حداقل تغییر پیدا می‌کنند و مقادیری بیشتر از حداقل بازه به مقدار حداقل تبدیل می‌شوند.

$$\text{Processed Image} = \text{Normalize}(\text{Threshold}(\text{Image}, WC - \frac{WW}{2}, WC + \frac{WW}{2})) \quad (2-1)$$

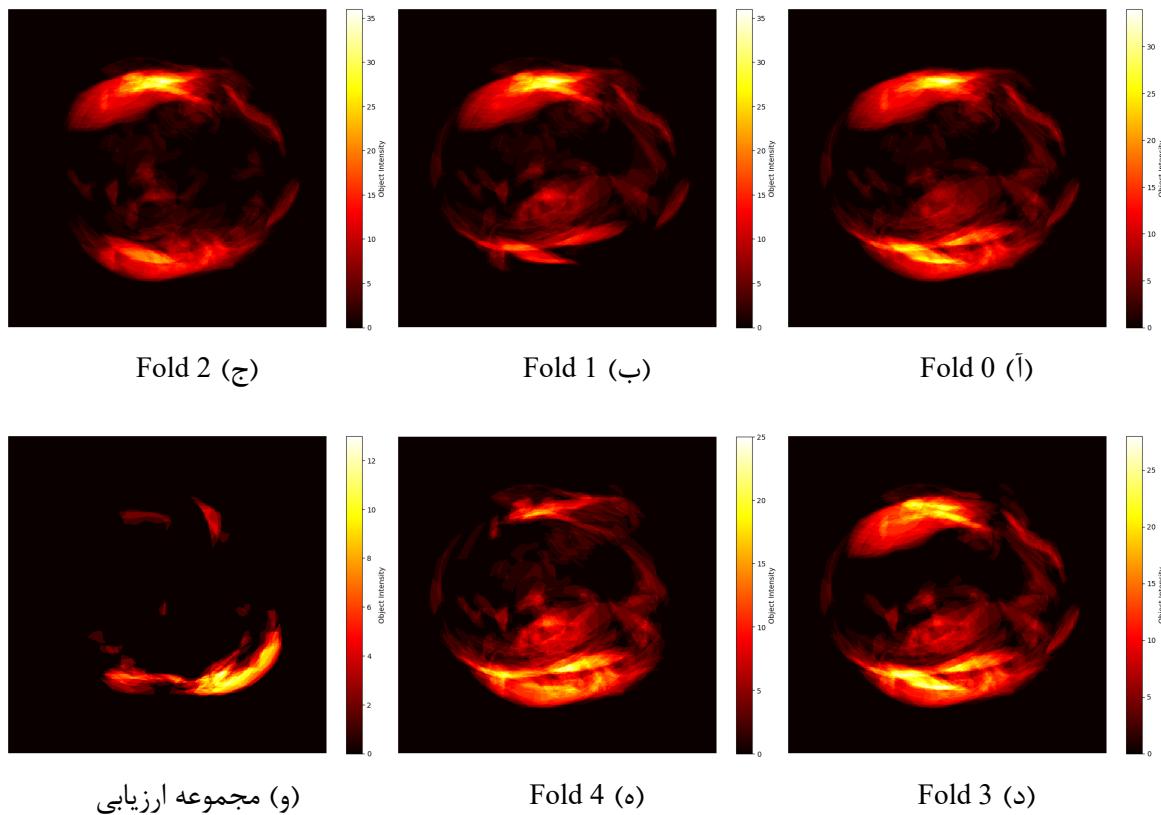
پرتونگارها مقادیر مشخصی را برای شناسایی انواع مختلف اندام در تصاویر سی‌تی اسکن تعیین کرده‌اند به عنوان مثال، در مجموعه‌داده PhysioNet، پردازش تصویر اصلی به‌ازای مرکز پنجره 40° و پهنه‌ای پنجره 120° ، پنجره مغز استخراج می‌شود و به‌ازای مرکز پنجره 70° و پهنه‌ای پنجره 320° ، پنجره استخوان استخراج می‌شود. [شکل ۱۱-۲ آ](#) اثر پنجره‌گذاری را بر یک نمونه برش سی‌تی اسکن نشان می‌دهد. همانطور که از این [شکل ۱۱-۲ آ](#) مشخص است، تصویر قبل از پیش‌پردازش جزئیات خاصی را به ما نشان نمی‌دهد و اگر این تصویر را بدون نرمال کردن برای آموزش شبکه عصبی استفاده کنیم، باعث می‌شود که لایه‌های ابتدایی شبکه مقادیر خیلی بزرگی را ایجاد کنند و در نتیجه عملکرد مدل کاهش پیدا بکند و اگر این تصویر را نرمال کنیم، به علت بازه بسیار زیاد یکای Hounsfield تفکیک‌پذیری مقادیر تصویر بهشت کاهش پیدا می‌کند. در ادامه [شکل ۱۱-۲ ب](#)، [شکل ۱۱-۲ ج](#) و [شکل ۱۱-۲ د](#) اثر سه پنجره مرسوم مغز، استخوان و سابدوارال را مشاهده می‌کنیم که هر کدام تفکیک‌پذیری بافت هدف خود را افزایش داده‌اند و در پنجره مغز و سابدوارال، محل خونریزی به‌وضوح مشخص است. [شکل ۱۱-۲ ه](#) پنجره انتخابی را نشان می‌دهد که بر اساس محدوده موجود در [شکل ۶-۲](#) انتخاب شده است و در نتیجه آن، محل خونریزی



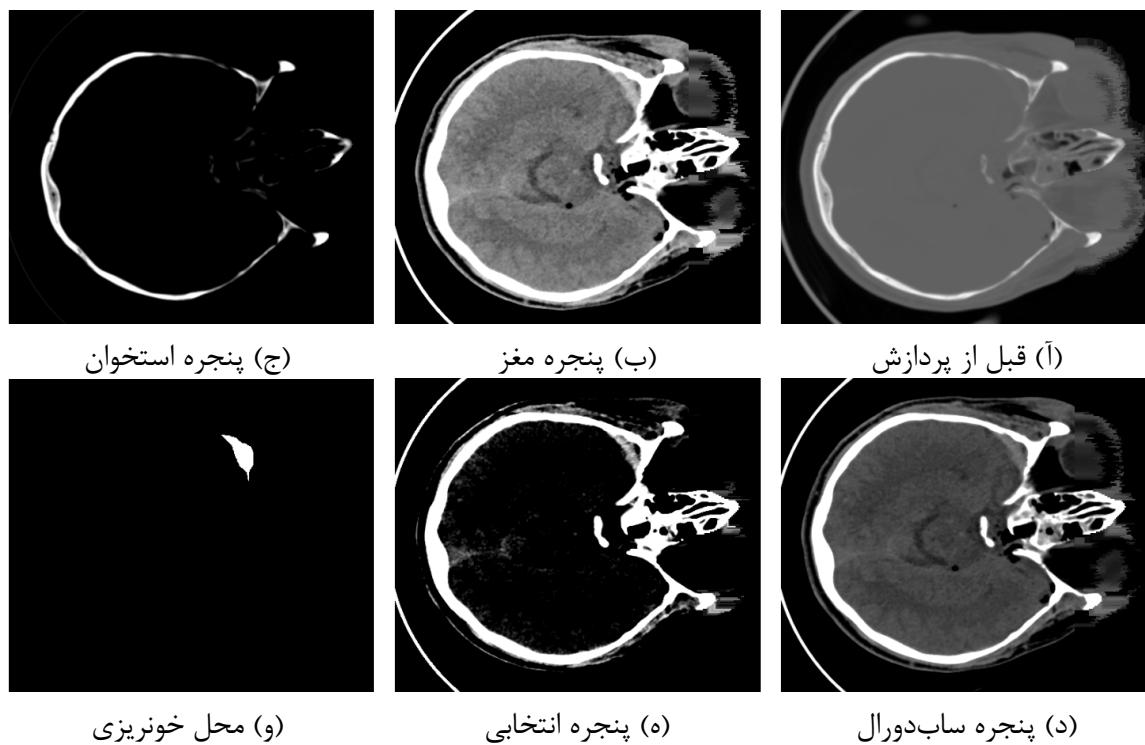
شکل ۲-۸: پراکندگی مکانی خونریزی در مجموعه‌داده PhysioNet

بروز بیشتری پیدا کرده است. در ادامه این پژوهش، پنجره مغز به عنوان پنجره اصلی آموزش و ارزیابی مدل‌ها در نظر گرفته شده است.

از دیگر روش‌های پیش‌پردازشی که در این پروژه استفاده شده است، افزایش مصنوعی داده است که به جهت بهبود عملکرد مدل در فرایند آموزش انجام شده است. تبدیل‌های افزایش مصنوعی داده‌ای که در این پژوهش استفاده شده است شامل چرخش، برش تصادفی، تبدیل آبینه حول محور افقی و بزرگنمایی تصادفی است. به علت اینکه سرتاسر تمامی بیماران در مجموعه‌داده PhysioNet جهت یکسانی دارد، استفاده از تبدیل آبینه حول محور عمودی باعث ایجاد تصاویری می‌شود که معادل آنها در مجموعه‌داده وجود ندارد [۲۱].



شکل ۲-۹: پراکندگی مکانی خونریزی در زیرمجموعه‌های مختلف از مجموعه‌داده



شکل ۱۱-۲: تأثیر پنجره‌گذاری در نمایش خونریزی در یک برش از سی‌تی‌اسکن

۳-۲ روش پردازش تصاویر

شبکه‌های عصبی عمیق به عنوان یکی از روش‌های محبوب در حوزه‌ی یادگیری ماشین شناخته می‌شوند. این شبکه‌ها از ساختارهایی شبیه به مغز انسان تشکیل شده‌اند که شامل تعدادی نورون^۱ مصنوعی هستند و قادرند با استفاده از داده‌های ورودی، الگوها و روابط پیچیده را بیاموزند. یادگیری عمیق، شاخه‌ای از شبکه‌های عصبی است که با افزایش تعداد لایه‌های مخفی در شبکه، امکان پردازش و تحلیل داده‌های بسیار پیچیده و بزرگ را فراهم می‌کند. در این پژوهش، روش اصلی مورداستفاده برای پردازش کامپیوترا تصاویر، یادگیری عمیق است.

۱-۳-۲ یادگیری عمیق و اصول اولیه

یادگیری عمیق یکی از شاخه‌های مهم یادگیری ماشین است که به دلیل توانایی‌های خود در پردازش، تحلیل و الگویابی در داده‌های پیچیده، به‌ویژه در حوزه‌ی پزشکی، به بهصورت گسترده‌ای مورداستفاده قرار گرفته است. در این بخش، به بررسی اصول پایه‌ای یادگیری عمیق در پردازش تصویر پرداخته شده است.

ساختار نورون

شبکه‌های عصبی مصنوعی از تعدادی واحد پردازشی به نام نورون تشکیل شده‌اند. هر نورون چندین ورودی x_1, x_2, \dots, x_n دریافت می‌کند که هر یک با وزن‌های w_1, w_2, \dots, w_n متناظر ضرب می‌شوند. سپس، مجموع وزن‌دار ورودی‌ها به اضافه‌ی یک بایاس b مطابق با معادله ۲-۲ محاسبه شده و از طریق یک تابع فعال‌سازی ϕ به خروجی تبدیل می‌شود که رابطه آن در معادله ۳-۲ مشخص شده است.

$$z = \sum_{i=1}^n w_i x_i + b \quad (2-2)$$

$$a = \phi(z) \quad (2-3)$$

توابع فعال‌سازی بهمنظور ایجاد خاصیت غیرخطی در نورون‌ها استفاده می‌شوند تا با استفاده از شبکه

¹Neuron

عصبی عمیق، بتوانیم توابع غیرخطی را تخمین بزنیم. دو تابع فعال‌سازی رایج عبارت‌اند از ReLU^۱ و Sigmoid^۲. رابطه تابع ReLU در معادله ۴-۲ مشخص شده است و رابطه تابع Sigmoid، در معادله ۵-۲ مشخص شده است.

$$\phi(z) = \max(0, z) \quad (2-4)$$

$$\phi(z) = \frac{1}{1 + e^{-z}} \quad (2-5)$$

لایه‌های پنهان

شبکه‌های عصبی عمیق از چندین لایه‌ی پنهان تشکیل شده‌اند که هر کدام از تعداد زیادی نورون مشابه نورون‌های توصیف شده در بخش قبلی تشکیل شده‌اند. خروجی هر نورون در یک لایه به عنوان ورودی برای نورون‌های لایه‌ی بعدی استفاده می‌شود. این ساختار چندلایه به شبکه امکان می‌دهد تا ویژگی‌های پیچیده و رفتار غیرخطی را از داده‌های ورودی استخراج کند. شکل ۱۲-۲ نمایش نحوه مدل‌سازی یک نورون را با استفاده از معادله ۲-۲ و معادله ۳-۲ نشان می‌دهد و در ادامه نحوه عملکرد لایه‌های پنهان در شبیه‌سازی ارتباط بین نورون‌ها را نشان می‌دهد.

تابع خطأ و پس‌انتشار^۳

تابع خطأ^۴ نقش کلیدی در آموزش شبکه‌های عصبی دارد. این تابع تفاوت بین خروجی پیش‌بینی شده Binary Cross و خروجی واقعی y_{true} را محاسبه می‌کند. یکی از رایج‌ترین توابع خطأ، خطای Entropy(BCE) است که طبق معادله ۶-۲ برای مسائل دسته‌بندی دوتایی استفاده می‌شود.

$$L(\mathbf{y}_{\text{true}}, \mathbf{y}_{\text{pred}}) = -\frac{1}{m} \sum_{i=1}^m \left[y_{\text{true}}^{(i)} \log(y_{\text{pred}}^{(i)}) + (1 - y_{\text{true}}^{(i)}) \log(1 - y_{\text{pred}}^{(i)}) \right] \quad (2-6)$$

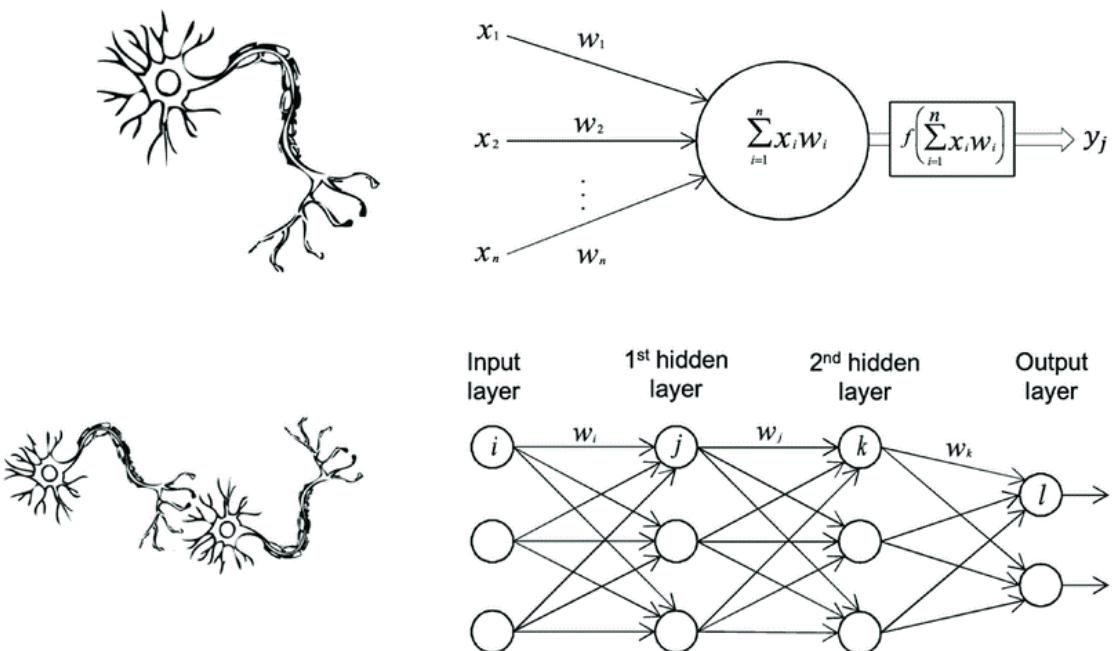
هدف از آموزش شبکه، کمینه‌سازی این تابع خطأ است که با استفاده از الگوریتم پس‌انتشار انجام

¹Rectified Linear Unit

²Sigmoid

³backpropagation

⁴Loss Function



شکل ۱۲-۲: مدل‌سازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نورون‌ها با استفاده از لایه‌های پنهان [۲]

می‌شود. در این روش، گرادیان^۱تابع خطا نسبت به هر وزن w_i طبق معادله ۷-۲ و قانون مشتقات زنجیره‌ای، محاسبه شده و سپس وزن‌ها با استفاده از روش گرادیان کاهشی مطابق معادله ۸-۲ به‌روزرسانی می‌شوند.

$$\frac{\partial L}{\partial w_i} \quad (2-7)$$

$$w_{i+1} \leftarrow w_i - \eta \frac{\partial L}{\partial w_i} \quad (2-8)$$

لایه‌های پرسپترون^۲ چندلایه

لایه‌های پرسپترون چندلایه (MLP) یکی از ساده‌ترین و پایه‌ای‌ترین ساختارها در شبکه‌های عصبی هستند. این لایه‌ها از تعدادی نورون تشکیل شده‌اند که به صورت کامل به یکدیگر متصل هستند؛ به بیان دیگر هر نورون در یک لایه به تمامی نورون‌های لایه‌ی قبلی متصل می‌شود و اطلاعات را به لایه‌ی بعدی

¹Gradient

²Perceptron

منتقل می‌کند. خروجی هر لایه $a^{[l]}$ از ترکیب خطی ورودی‌ها و اعمال تابع فعال‌سازی طبق معادله ۹-۲ به دست می‌آید:

$$a^{[l]} = \phi(W^{[l]}a^{[l-1]} + b^{[l]}) \quad (2-9)$$

شبکه عصبی پیچشی ^۱

برای بهبود عملکرد شبکه‌های عصبی در پردازش تصاویر، از لایه‌های شبکه عصبی پیچشی (CNN) استفاده می‌شود. در این لایه‌ها، عملیات کانولوشن به جای ضرب ماتریسی بین ورودی و وزن‌ها طبق معادله ۱۰-۲ انجام می‌شود. این عملیات برای هر ناحیه کوچک از تصویر با استفاده از یک فیلتر k صورت می‌گیرد.

$$z_{i,j} = (X * k)_{i,j} = \sum_m \sum_n X_{i+m,j+n} \cdot k_{m,n} \quad (2-10)$$

خروجی این عملیات، نقشه ویژگی Feature Map است که به لایه بعدی منتقل می‌شود. با عبور یک تصویر از لایه‌های یک شبکه عصبی پیچشی، بین پیکسل‌های مجاور هم در تصویر، یک رابطه برقرار می‌شود که درنتیجه آن، نقشه ویژگی استخراج شده برای هر پیکسل، به وضعت پیکسل‌های اطرافش بستگی دارد و هرچه از پیکسل مبدأ دور شویم، اثر آن در نقشه ویژگی کاهش پیدا می‌کند.

بهینه‌سازها و الگوریتم Adam

بهینه‌سازی یکی از مهم‌ترین اجزا در آموزش شبکه‌های عصبی هستند که هدف آنها به روزرسانی وزن‌ها به‌گونه‌ای است که تابع خطا به حداقل مقدار خود برسد. برای این منظور، از الگوریتم‌هایی استفاده می‌شود که بهینه‌ساز نامیده می‌شوند. یکی از رایج‌ترین بهینه‌سازها، الگوریتم گرادیان کاهشی است که در آن وزن‌ها در جهت منفی گرادیان تابع خطا به روزرسانی می‌شوند، رابطه گرادیان کاهشی در معادله ۸-۲ نشان داده شده است. یکی دیگر از بهینه‌سازهای پیشرفتی و کارآمد، بهینه‌ساز Adam است. این بهینه‌ساز از ترکیب دو روش Momentum و RMSProp بهره می‌برد [۳۸، ۳۹]. به روزرسانی وزن‌ها در Adam با استفاده از روابط در معادله ۱۱-۲ انجام می‌شود.

^۱Convolutional Neural Network

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla L(\theta_t)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L(\theta_t))^2$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$
(2-11)

در این معادلات، m_t و v_t به ترتیب تخمین میانگین حرکت‌دار گرادیان و میانگین حرکت‌دار مربعات گرادیان در زمان t هستند، و β_1 و β_2 ضرایب مربوط به این میانگین‌ها هستند. η نرخ یادگیری و ϵ یک مقدار بسیار کوچک برای جلوگیری از تقسیم بر صفر است. الگوریتم Adam به دلیل عملکرد مناسب خود در آموزش شبکه‌های عصبی عمیق، به یکی از بهینه‌سازهای پرکاربرد در این زمینه تبدیل شده است.

۴-۲ مدل‌های طبقه‌بندی در شبکه عصبی عمیق

ResNet ۱-۴-۲

شبکه‌های عصبی عمیق به یک ابزار قدرتمند در انجام وظایف مختلف یادگیری ماشین تبدیل شده‌اند. با این حال، با افزایش عمق این شبکه‌ها، مشکلاتی همچون ناپدیدشدن مشتق^۱ یا انفجار مشتق^۲ و دشوارشدن آموزش به وجود می‌آید. برای حل این مشکلات، $[He]$ ^۳ و همکارانش معماری شبکه‌های Residual را پیشنهاد کردند که امکان آموزش شبکه‌های بسیار عمیق‌تر را با معرفی اتصالات فراهم می‌کند. ایده اصلی پشت ResNet معرفی یک اتصال میان‌بر^۴ است که یک یا چند لایه از شبکه را دور می‌زند. این اتصال میان‌بر به شبکه امکان می‌دهد تا از طریق آن، مشتق خطا به لایه‌های ابتدایی برسد تا فرایند آموزش برای لایه‌هایی که از خروجی دور هستند، با مشکل موافق نشود. همانطور که در شکل ۱۳-۲ نمایش‌داده شده است، در شبکه‌های ResNet به جای یادگیری یک نگاشت مستقیم، مثلاً $H(x)$ ، شبکه نگاشت $F(x) = H(x) - x$ را می‌گیرد که بهینه‌سازی آن ساده‌تر است؛ بنابراین، خروجی نهایی بلوك^۵ $H(x) = F(x) + x$ خواهد بود که در نتیجه آن، مشتق تابع خطای L به‌ازای ورودی x در معادله ۱۲-۲ نمایش‌داده شده است.

¹Vanishing Gradient

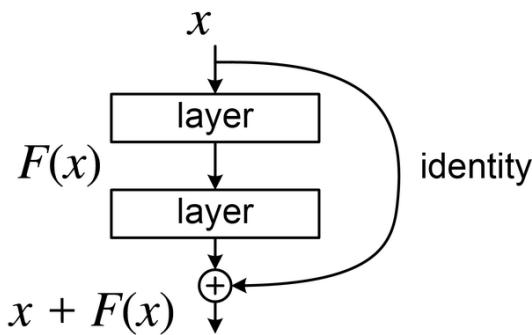
²Exploding Gradient

³Skip Connection

⁴Block

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial H(x)} \cdot \frac{\partial H(x)}{\partial x} = \frac{\partial L}{\partial H(x)} \cdot \left(1 + \frac{\partial F(x)}{\partial x}\right) \quad (2-12)$$

این فرمول نشان می‌دهد که مشتق می‌تواند به راحتی از طریق مسیر میان‌بر عبور کند که به حل مشکل ناپدیدشدن یا انفجار گرادیان کمک می‌کند.



شکل ۲-۱۳: یک بلوک از معماری ResNet که اتصال میان‌بر همانی را نشان می‌دهد [۴].

شبکه عصبی پیچشی ResNet در وظیفه طبقه‌بندی تصویر عملکرد مناسبی از خود نشان داده است. این شبکه با معرفی اتصال میان‌بر و فراهم‌کردن امکان آموزش شبکه‌های بسیار عمیق، باعث بهبود عملکرد مدل‌های شبکه عصبی عمیق شده است.

ResNeXt ۲-۴-۲

ResNeXt توسط Xie [۵] و همکاران معرفی شده است که یک معماری شبکه عصبی پیچشی عمیق است که بر اساس ساختار ResNet ساخته شده و با معرفی یک فراپارامتر ^۱ جدید به نام کاردینالیتی ^۲ سعی در بهبود مدل ResNet داشته است. این مدل بهمنظور بهبود عملکرد شبکه‌های عصبی عمیق، مسیرهای موازی متعدد را در ساختار شبکه ایجاد می‌کند که این روش مشابه مدل ساختار Inception است؛ اما با تفاوت‌های کلیدی در سادگی طراحی اجزای شبکه.

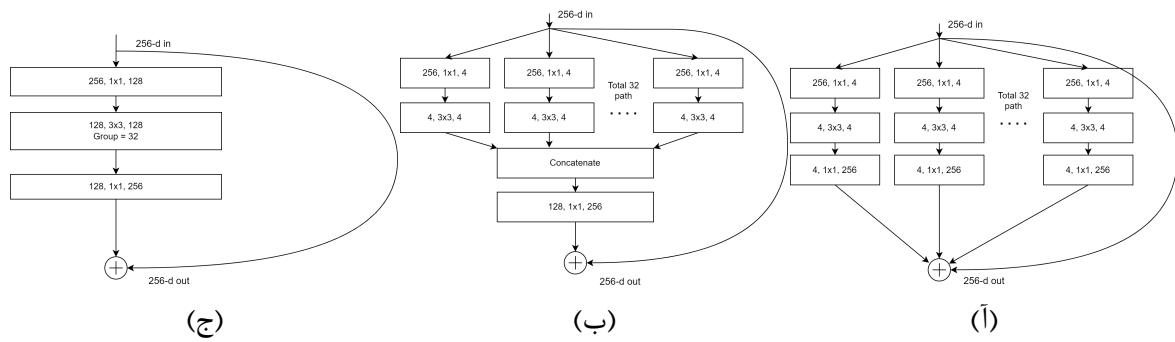
همانطور که در شکل ۱۴-۲آ، شکل ۱۴-۲ب مشخص شده است، مسیرهای موازی در ساختار شبکه ایجاد شده است که این مسیرها به مقدار کاردینالیتی بستگی دارد. کاردینالیتی به تعداد مسیرهای موازی درون هر بلوک شبکه اشاره دارد. برخلاف افزایش عمق یا عرض که به افزایش تعداد لایه‌ها یا پیچیدگی هر لایه منجر می‌شود، افزایش کاردینالیتی اجازه می‌دهد که چندین مسیر پردازشی به صورت موازی

¹Hyper-parameter

²Cardinality

عمل کنند و در نهایت خروجی‌های آن‌ها با یکدیگر ادغام شوند که از بار پردازشی شبکه کم می‌کند.

شکل ۱۴-۲ ج ساده‌سازی بلوک ResNeXt برای بهینه‌سازی و ساده‌سازی محاسبات را نشان می‌دهد که از لایه‌های پیچشی گروهی استفاده می‌کند. در این روش، کanal‌های^۱ ورودی به گروه‌های مختلف تقسیم می‌شوند و کانولوشن‌ها به صورت مستقل در هر گروه انجام می‌گیرند. افزایش کار دینالیتی در ResNeXt نه تنها باعث بهبود دقت مدل می‌شود، بلکه امکان استفاده از مسیرهای پردازشی متعدد به صورت موازی، بدون افزایش چشمگیر در پیچیدگی محاسباتی، را فراهم می‌کند. این ویژگی به ResNeXt اجازه می‌دهد که در وظایف پیچیده، مانند طبقه‌بندی تصاویر با دقت بیشتری عمل کند. علاوه بر این، استفاده از لایه‌های پیچشی گروهی به کاهش هزینه محاسباتی کمک کرده و در عین حال، قدرت الگوهای پیچیده را حفظ می‌کند.



شکل ۱۴-۲: ساختارهای مختلف در معماری ResNeXt که کانولوشن‌های گروهی، مسیرهای پردازشی موازی و روش ادغام را نشان می‌دهند [۱۵].

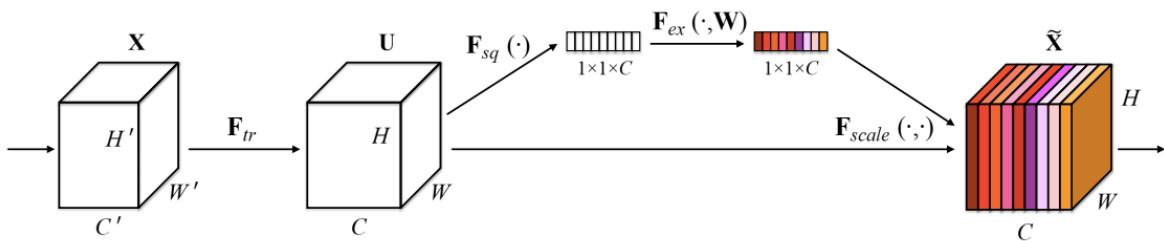
۳-۴-۲ شبکه (SENet) Squeeze-and-Excitation

Hu و همکاران، با معرفی بلوک Squeeze-and-Excitation (SE)، دقت طبقه‌بندی در ImageNet به میزان ۵۰.۲٪ نسبت به سال گذشته بهبود یافت. این بلوک با وزن‌دهی به میان کanal‌های مختلف در هر لایه از شبکه عصبی پیچشی، عملکرد شبکه‌های عصبی را با هزینه محاسباتی بسیار کمی بهبود می‌بخشد. ایده اصلی در مرور روش Squeeze-and-Excitation این است که در یک لایه معمولی در شبکه عصبی پیچشی، ارزش هر کanal در ورودی شبکه، با بقیه کanal‌ها یکسان است. بلوک SE اما، رویکردی تطبیقی را معرفی می‌کند که در آن اهمیت هر کanal به به صورت جداگانه و بر اساس زمینه ارزیابی می‌شود و به آن وزنی خاص اختصاص داده می‌شود.

شکل ۱۵-۲ نحوه عملکرد این مدل را نشان می‌دهد که در گام نخست از هر کanal نقشه ویژگی،

^۱Channel

میانگین گرفته می‌شود، سپس این میانگین از یکتابع خطی عبور داده می‌شود و در گام بعدی، تابع Sigmoid روی آن اعمال می‌شود تا وزن‌ها بین ۰ تا ۱ قرار بگیرند. در انتهای وزن‌های محاسبه شده در نقشه ویژگی ضرب می‌شود و خروجی لایه پیچشی Squeeze-and-Excitation شبکه عصبی پیچشی به دست می‌آید. ResNeXt یکی از مدل‌های پایه‌ای است که با استفاده از روش بلوک SE عملکردش ارتقا پیدا کرده است.



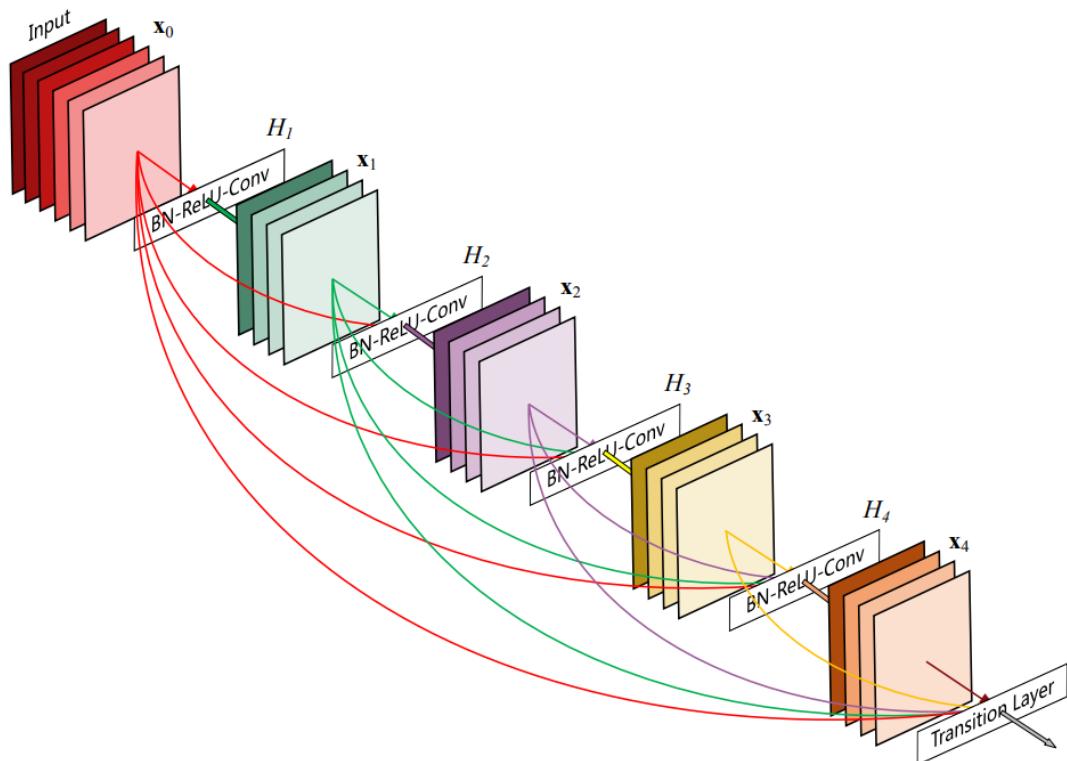
شکل ۱۵-۲: بلوک Squeeze-and-Excitation که نحوه عملکرد آن را در ارزیابی و وزن‌دهی کانال‌ها نشان می‌دهد [۶].

DenseNet ۴-۴-۲

DenseNet یک نوع شبکه عصبی پیچشی است که به منظور بهبود عملکرد شبکه‌های عصبی پیچشی سنتی معرفی شده است. یعنی این شبکه، کاهش محدودیت‌هایی است که معمولاً شبکه‌های پیچشی عمیق، با آن‌ها مواجه می‌شوند. در شبکه‌های پیچشی سنتی، یکی از مشکلات اصلی زمانی رخ می‌دهد که مشتق، نمی‌تواند در فرایند پس‌انتشار به درستی در تمامی لایه‌ها انتقال یابد که این مسئله در [زیرقسمت ۴-۲](#) بررسی شده است. مسئله ناپدیدشدن مشتق به‌ویژه در لایه‌های اولیه بسیار تأثیر می‌گذارد که این موضوع به روزرسانی وزن‌ها و بایاس‌ها را مختل کرده و بر عملکرد کلی شبکه تأثیر منفی می‌گذارد. برای کمک به کاهش مشکلاتی که قبل‌تر مطرح شد، Huang [۷] و همکاران، مدل DenseNet را معرفی کردند. در حالی که یک بلوک‌های شبکه عصبی پیچشی سنتی، تنها از نقشه ویژگی خروجی فعلی به عنوان ورودی برای لایه بعدی استفاده می‌کند، تمامی نقشه‌های ویژگی که در لایه‌های پیشین ایجاد شده را نیز در ورودی لایه فعلی استفاده می‌کند. همانطور که در [شکل ۱۶-۲](#) مشاهده می‌شود. این کار جریان اطلاعات بین لایه‌ها را به حداکثر می‌رساند، تعداد متغیرهای مدل را افزایش چشمگیری نمی‌دهد و به صورت قابل توجهی مشکل ناپدیدشدن گرادیان‌ها را بهبود می‌بخشد.

شبکه‌های DenseNet، برخلاف ResNet‌ها که از جمع برای ترکیب نقشه‌های ویژگی استفاده می‌کنند،

از الحق^۱ استفاده می‌کنند تا اطلاعات را به صورت مؤثرتری حفظ کنند. هر لایه در DenseNet نقشه‌های ویژگی تمامی لایه‌های قبلی را به عنوان ورودی دریافت کرده و آن‌ها را قبل از عبور از تبدیل غیرخطی به یکدیگر الحق می‌کند [۷].



شکل ۲: [۷] معماری یک بلوک DenseNet.

EfficientNet ۵-۴-۲

Tan [۴۱] و همکارانش یک معماری و روش مقیاس‌گذاری را در مدلی به نام EfficientNet معرفی کردند. این روش به ما امکان می‌دهد که تعداد متغیرهای مدل را به صورت بهینه افزایش دهیم. در این روش، برای افزایش تعداد متغیرهای مدل، سه ویژگی عمق، عرض و وضوح^۲ تصویر باید به صورت یکنواخت و با استفاده از سه ضریب ثابت افزایش پیدا کنند.

به به صورت مشخص، اگر بخواهیم تعداد متغیرهای مدل را به میزان 2^N برابر افزایش دهیم، می‌توانیم به سادگی عمق شبکه را به میزان α^N ، عرض شبکه را به میزان β^N و وضوح تصویر را به میزان γ^N افزایش

¹Concatenation

²Resolution

دهیم که در آن α , β و γ ضرایب ثابتی هستند که معادله ۱۳-۲ باید برای آنها برقرار باشد. این رابطه به این معناست که افزایش منابع محاسباتی به میزان 2^N برابر، به توزیع متناسبی از افزایش عمق، عرض و وضوح تصویر منجر می‌شود.

$$\alpha \times \beta^2 \times \gamma^2 \approx 2 \quad (2-13)$$

در نتیجه پژوهش Tan و همکارانش، یک خانواده از مدل‌های مبتنی بر شبکه عصبی پیچشی ایجاد شد که ضمن داشتن تعداد متغیرهای بسیار کمتر، عملکرد بهتری نسبت به مدل‌های قبلی ایفا می‌کند.

۵-۲ مدل‌های قطعه‌بندی در شبکه عصبی عمیق

۱-۵-۲ U-Net

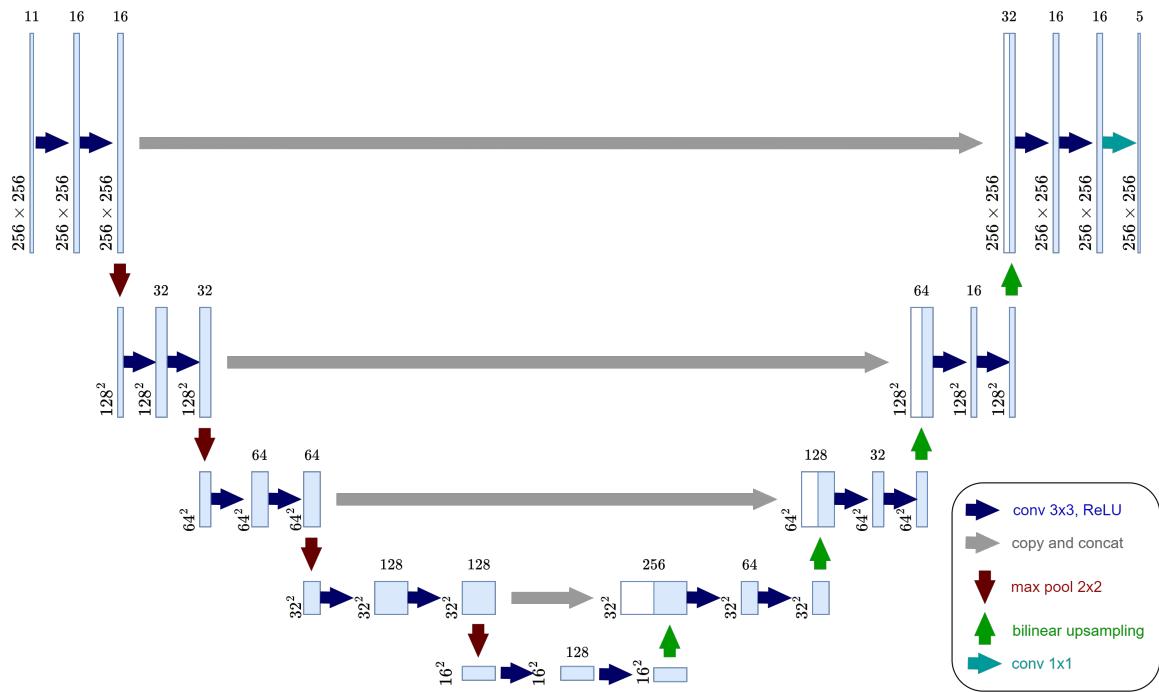
شبکه U-Net یکی از پرکاربردترین معماری‌ها در حوزه‌ی پردازش تصویر و بهویژه در بخش‌بندی تصاویر است که توسط Ronneberger [۸] و همکاران توسعه داده شده است. این مدل که در اصل به عنوان یک شبکه عصبی پیچشی خودرمزنگذار^۱ معرفی شد، به دلیل طراحی خاص خود که امکان بازیابی دقیق اطلاعات مکانی را به کمک مسیرهای میان‌بر فراهم می‌آورد، به صورت گسترده‌ای مورد استفاده قرار می‌گیرد.

ساختار U-Net شامل دو مسیر اصلی است؛ مسیر اول، رمزگذار نام دارد که مسئول استخراج ویژگی‌ها و کاهش ابعاد و افزایش تعداد کanal‌ها است. مسیر بعدی، رمزگشا نام دارد که وظیفه بازسازی تصویر به اندازه اصلی و مشخص کردن محل جسم را بر عهده دارد که این کار را با استفاده از اطلاعات استخراج شده از مسیر رمزگذار انجام می‌دهد.

ساختار شبکه U-Net در شکل ۱۷-۲ مشاهده می‌شود که مسیر رمزگذار شامل چندین مرحله از شبکه عصبی پیچشی و لایه ادغام^۲ است. از سوی دیگر، مسیر رمزگشا شامل افزایش ابعاد و ترکیب ویژگی‌های استخراج شده در مسیر رمزگذار است تا تصویر نهایی با دقت بالایی بازسازی شود. یکی از ویژگی‌های کلیدی U-Net مسیرهای میان‌بر بین لایه‌های رمزگذار و رمزگشا متناظر است که اطلاعات مکانی دقیق را از رمزگذار به رمزگشا منتقل می‌کند.

¹Autoencoder

²Pooling



شکل ۱۷-۲: ساختار شبکه U-Net که شامل مسیر رمزگذار، رمزگشا و اتصالات میانبر است [۹].

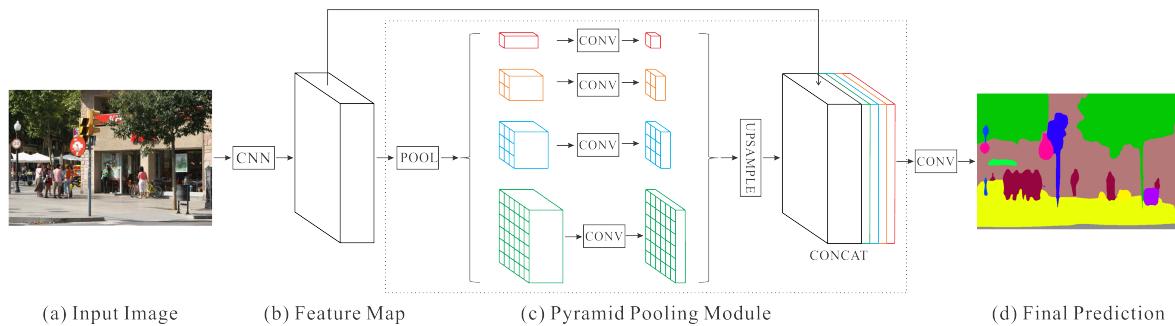
در حالی که ساختار اصلی U-Net به خوبی قادر به انجام وظایف مختلف است، امکان بهبود عملکرد آن با استفاده از مدل‌های پیشرفته‌تر در بخش رمزگذار وجود دارد. به عنوان مثال، می‌توان از مدل‌هایی که در بخش‌های قبل مطرح شد، مانند EfficientNet، SENet، ResNeXt، ResNet و U-Net استفاده کرد. این مدل‌ها به دلیل قابلیت‌های قدرتمند خود در استخراج ویژگی‌ها و مدیریت اطلاعات پیچیده، می‌توانند عملکرد U-Net را در وظایف پیچیده‌تر به بهصورت قابل توجهی بهبود بخشدند. این قابلیت بهویژه در موقعی که تصاویر ورودی دارای جزئیات بسیار بالایی هستند یا نیاز به دقت بالایی در خروجی است، اهمیت بیشتری پیدا می‌کند. به همین دلیل، U-Net با ساختار خود، یکی از انعطاف‌پذیرترین مدل‌ها برای ترکیب با معماری‌های دیگر به شمار می‌رود و به بهصورت گسترده در زمینه‌های مختلف از جمله پزشکی و بینایی ماشین مورد استفاده قرار می‌گیرد.

PSPNet ۶-۲

شبکه Pyramid Scene Parsing Network (PSPNet) [۹]، که توسط Zhao، یک مدل مبتنی بر شبکه عصبی پیچشی برای وظیفه طبقه‌بندی است. یکی از نقاط قوت اصلی PSPNet توانایی آن برای استخراج ویژگی‌ها با مقایسه‌های متفاوت از طریق لایه ادغام است. این ویژگی به مدل

اجازه می‌دهد که با در نظر گرفتن اطلاعات از نواحی مختلف تصویر در مقیاس‌های متفاوت، پیش‌بینی‌های پیکسلی دقیق‌تری ارائه دهد.

PSPNet با استفاده از انواع رمزگذار که در بخش قبل مطرح شد به عنوان بلوک استخراج ویژگی، ساختار خود را ایجاد می‌کند. این معماری برای رفع چالش‌های رایج در طبقه‌بندی تصاویر، مانند دسته‌بندی‌های گیج‌کننده و اشیاء کوچک که به سختی دیده می‌شوند، طراحی شده است و مشکلاتی که در ساختارهای قبلی منجر به طبقه‌بندی نادرست می‌شوند را بهبود می‌بخشد. [شکل ۱۸-۲](#) ساختار این شبکه را نشان می‌دهد که در گام نخست با استفاده از رمزگذار، نقشه ویژگی‌ها استخراج شده است و در ادامه با استفاده از بلوک ادغام هرمی، ویژگی‌ها با ابعاد متفاوت استخراج می‌شوند، سپس ویژگی‌ها به یکدیگر الحاق شده و در انتها ابعاد ویژگی‌ها به ابعاد اصلی تصویر تبدیل می‌شوند تا پیش‌بینی نهایی بدست آید.

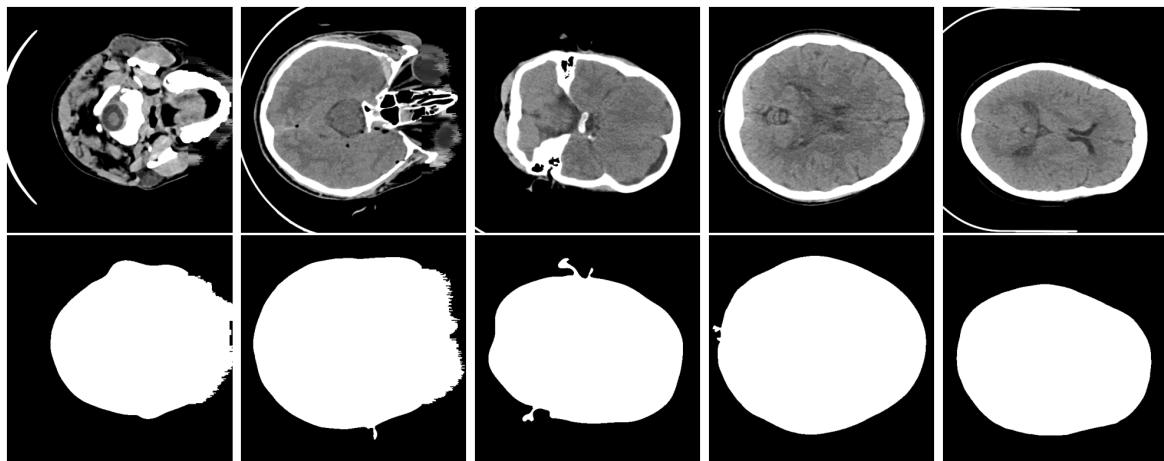


[شکل ۱۸-۲](#): ساختار شبکه **PSPNet**

۷-۲ پس‌پردازش

پس‌پردازش پیشنهادی در این پژوهش، به منظور بهبود عملکرد مدل قطعه‌بندی، توسعه داده شده است. [شکل ۱-۲](#) یک نمونه تصویر سی‌تی‌اسکن را نشان می‌دهد. به همان صورت که در این تصویر مشخص است، حاشیه سیاه برش‌ها، شامل هیچ اندامی نیست و بدینهی است که هیچ ضایعه خونریزی در این نواحی یافت نخواهد شد، بنابراین، با توجه به اینکه یکای Hounsfield این نواحی بسیار از مقدار آن در بافت مغز متفاوت است، بنابراین روش آستانه‌گذاری روی برش‌ها اعمال شد که آستانه مربوطه از روی [شکل ۱۹-۲](#)، به گونه‌ای انتخاب شد که نواحی شامل بافت مغز از نواحی فاقد اندام جدا شوند. روش انتخاب آستانه‌گذاری را برای برش‌های متفاوت نشان می‌دهد. این لایه‌های پس‌پردازش استخراج شده با روش آستانه‌گذاری را برای برش‌های متفاوت نشان می‌دهد. این لایه‌ها پس از استخراج، در مرحله تصمیم‌گیری مدل قطعه‌بندی استفاده می‌شوند. روش استفاده از این

لایه‌ها به‌گونه‌ای است که احتمال هرگونه پیش‌بینی موجود در نواحی سیاه از تصویر را برابر ۰ قرار می‌دهد و باعث می‌شود تا نیاز به آموزش لایه‌های مدل قطعه‌بندی در این نواحی لازم نباشد.



شکل ۲-۱۹: نمونه لایه‌های پس‌پردازش استخراج شده از برش‌های بیمار

۸-۲ روش پیشنهادی

هدف اصلی در این پژوهش، بهبود عملکرد مدل‌های قطعه‌بندی در تصاویر سی‌تی‌اسکن بوده به‌گونه‌ای که این روش به صورت عام، امکان پیاده‌سازی روی مدل‌های قطعه‌بندی را داشته باشد. به‌منظور توسعه این روش، ناترازی داده‌ها، به عنوان یکی از اصلی‌ترین مشکلات در پردازش تصاویر سه‌بعدی پزشکی و سی‌تی‌اسکن مورد مطالعه قرار گرفت.

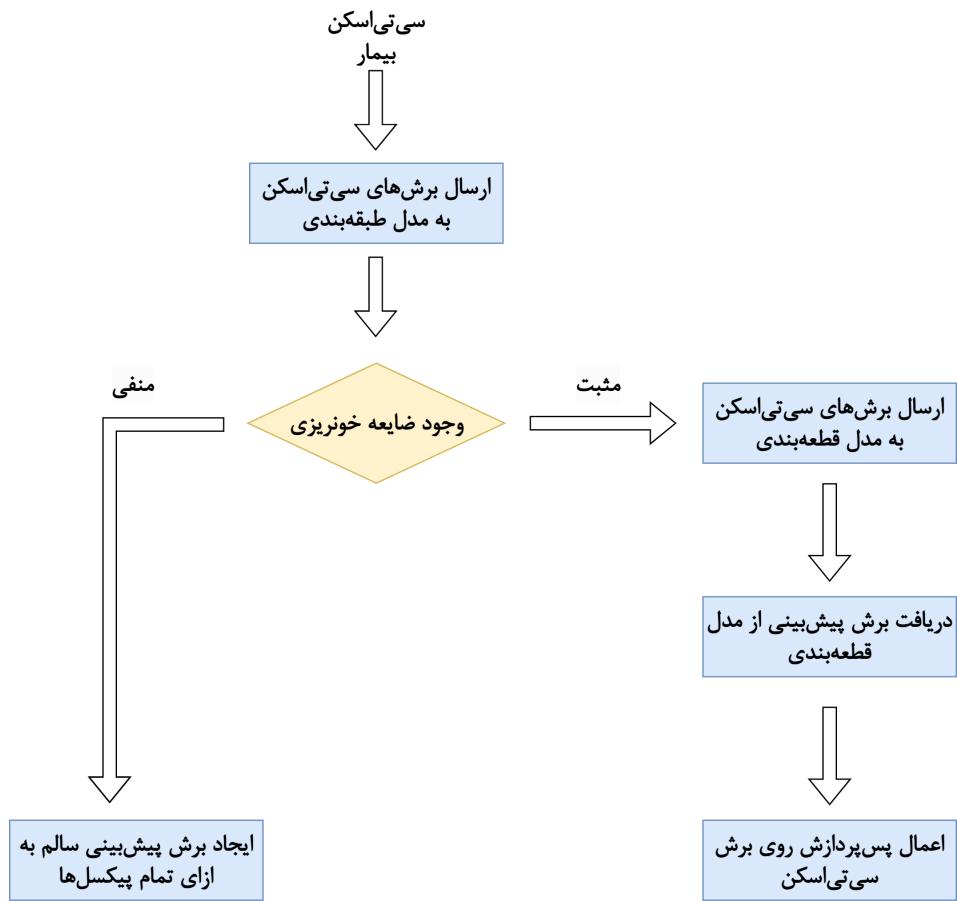
натرازی در داده‌های سی‌تی‌اسکن، خصوصاً برای پردازش خونریزی درون‌جمجمه‌ای، می‌تواند در سه سطح بیمارمحور، برش‌محور و پیکسل‌محور رخ دهد که در مجموعه‌داده موجود، این ناترازی تنها در دو سطح برش‌محور و پیکسل‌محور رخداده است. [شکل ۴-۲](#) پراکندگی داده را به صورت بیمارمحور و [شکل ۴-۲](#) پراکندگی داده را به صورت برش‌محور نشان می‌دهد که ناترازی در سطح برش، بسیار شدید است. پراکندگی پیکسل‌های دارای خونریزی نیز در این مجموعه‌داده، به‌گونه‌ای است که در برش‌هایی که ضایعه خونریزی وجود دارد، تعداد پیکسل‌های دارای خونریزی، در حدود ۲۰۰۰ پیکسل است که این مقدار در برابر تعداد پیکسل‌های کل برش که برابر ۲۱۸ پیکسل است، نشان‌دهنده شدت بیشتر ناترازی در سطح پیکسل است.

برای کاهش مشکل ناترازی در سطح برش، یک روش دومرحله‌ای، توسعه داده شد که به موجب آن، در گام نخست برش‌های سی‌تی‌اسکن طبقه‌بندی خواهند شد تا وجود ضایعه تشخیص داده شود و در

گام بعدی، برش‌هایی که دارای بیماری پیش‌بینی شده‌اند، به یک شبکه قطعه‌بندی ارسال می‌شوند تا مراحل قطعه‌بندی در این برش‌ها طی شود. استفاده از این روش برای پردازش تصاویر سی‌تی اسکن، این مزیت را دارد که با حذف برش‌های سالم از فرایند تصمیم‌گیری، باعث کاهش تعداد پیکسل‌هایی می‌شود که به صورت اشتباه، به عنوان پیکسل‌های دارای ضایعه خونریزی در نظر گرفته شده‌اند. نکته حائز اهمیت در مورد این روش این است که تمام خطاهایی که در مدل طبقه‌بندی رخ بدنه‌ند، مستقیماً در عملکرد مدل قطعه‌بندی تأثیر می‌گذارند خصوصاً اگر برشی که دارای خونریزی بوده، به عنوان برش سالم در نظر گرفته شود؛ بنابراین باید توجه داشت تا آستانه تصمیم‌گیری در این روش به گونه‌ای انتخاب شود تا تعداد برش‌هایی که واقعاً سالم نیستند، اما سالم تشخیص داده می‌شوند به حداقل مقدار خود برسد. حد بالای پیشنهادی برای این آستانه به گونه‌ای است که به موجب آن، تمام سی‌تی اسکن‌های دارای خونریزی موجود در مجموعه‌داده به درستی تشخیص داده شوند (تشخیص بیمار محور).

استفاده از روش پس‌پردازش مذکور در [قسمت ۷-۲](#)، باعث می‌شود تا ناترازی در سطح پیکسل تا حد خوبی کاهش پیدا کند و به موجب آن فرایند آموزش مدل، بیشتر معطوف به شناسایی نواحی دارای خونریزی شود تا اینکه یک قسمت از فرایند آموزش مدل صرف این شود تا نواحی خارج از جمجمه شناسایی شود. این پس‌پردازش به ما این امکان را می‌دهد تا با کاهش میزان آستانه تصمیم، تعداد پیکسل‌هایی که به درستی درون جمجمه شناسایی می‌شوند را افزایش دهیم. پس‌پردازش مذکور در پژوهش، به صورت مجتمع در فرایند آموزش استفاده شده است.

شکل ۲۰-۲ روندnamای روش پیشنهادی و پس‌پردازش را به منظور بررسی برش‌های خونریزی نشان می‌دهد که در این پردازش استفاده شده است. همانطور که از این روندnam مشخص است، این روند بستگی به مدل طبقه‌بندی و قطعه‌بندی مورد استفاده ندارد و می‌توان از هر مدلی در این روند استفاده کرد که این مسئله باعث افزایش قابلیت توسعه و نگهداری نرم‌افزارهایی می‌شود که بر پایه این روند توسعه داده شده‌اند.



شکل ۲-۲۰: روند نمای روش پیشنهادی در این پژوهش

۹-۲ آموزش و تصمیم‌گیری

۱-۹-۲ طبقه‌بندی

گام نخست در این پژوهش، آموزش یک مدل طبقه‌بندی مناسب به منظور استفاده در روش دوم رحله‌ای است که به موجب آن یک جستجوی شبکه‌ای^۱ با استفاده از مدل ResNet 50 انجام شد که وزن اولیه این مدل با استفاده از روش انتقال یادگیری به روی مجموعه‌داده ImageNet [۴۲] انتخاب شده است. در این جستجوی شبکه‌ای، با توجه به چالش ناترازی مجموعه‌داده، ازتابع هزینه Cross Entropy وزن‌دار استفاده شد و همچنین با استفاده از روش افزایش مصنوعی داده، جاگذاری داده^۲ و کاهش داده غالب در ضرایب متفاوت استفاده شد تا بهترین نتیجه ممکن برای مدل طبقه‌بندی یافته شود. [جدول ۱-۲](#) نمایش دهنده مقادیر مورداستفاده در جستجوی شبکه‌ای است. در این جستجوی شبکه‌ای، کاهش داده غالب با توجه به

¹Grid Search

²Bootstrap

توزیع برش‌های دارای خونریزی که در شکل ۷-۲ نمایش داده شده است انجام شده تا داده‌هایی که کمترین تأثیر را در آموزش دارند، با احتمال بیشتری کنار گذاشته شوند و ضریبی که در جدول جدول ۱-۲ برای این روش اعلام شده، به این معنی است که نسبت برش‌های بیمار به برش‌های سالم پس از اعمال این روش، برابر ضریب اعلامی خواهد شد. در ادامه افزایش مصنوعی داده و جاگذاری داده نیز تنها به روی برش‌هایی با تشخیص خونریزی درون‌جمجمه‌ای صورت پذیرفته و تا متناسب با پراکندگی برش‌های دارای خونریزی، افزایش این داده‌ها صورت پذیرد که در شکل ۷-۲ توزیع این داده‌ها نمایش داده شده است و پس از اعمال این روش‌ها، تعداد برش‌های بیمار در ضریب اعلام شده ضرب شده است. باید توجه داشت که در جستجوی شبکه‌ای ابتدا افزایش مصنوعی داده و جاگذاری داده اعمال شده و پس از آن کاهش داده غالب روی مجموعه‌داده اعمال شده است. در آموزش مدل طبقه‌بندی، به علت وجود تعداد کم داده‌های دارای خونریزی و احتمال بیش‌برازش^۱، از روش 5-fold-cross-validation استفاده شد. در گام نخست از استفاده از این روش، یک زیرمجموعه ارزیابی^۲ که ۲۰ درصد از کل مجموعه‌داده می‌باشد، انتخاب شده است و پس از آن روی باقی مجموعه‌داده عملیات 5-fold-cross-validation را برای آموزش مدل انجام شده است؛ در انتهای پس از فرایند آموزش، تنظیم متغیرهای تصمیم‌گیری مدل‌های به‌دست‌آمده روی مجموعه‌داده ارزیابی انجام شده و سازوکار تصمیم‌گیری شورایی^۳ نهایی شده است که این سازوکار در زیر قسمت ۳-۹-۲ توضیح داده شده است. در انتهای مدل پیشنهادی روی مجموعه‌داده ارزیابی آزمایش شده است. استفاده از این روش باعث می‌شود تا از عملکرد مدل و مقاوم‌بودن آن اطمینان حاصل شود. به‌منظور اطمینان از اینکه متغیرهای به‌دست‌آمده در عملیات جستجوی شبکه‌ای، در بهبود عملکرد مدل‌های شبکه عصبی تأثیرگذار است، مدل‌های Inception-V3 و MobileNet-V2، VGG16 و ResNet50 آموزش داده شد.

جدول ۱-۲: ضرایب مورد استفاده در جستجوی شبکه‌ای

روش	ضریب اول	ضریب دوم	ضریب سوم
افزایش مصنوعی داده	۲/۵	۲	۳/۳
جاگذاری داده	۲/۵	۲	۳/۳
کاهش داده غالب	۱	۱	۳
افزایش وزن داده مثبت در تابع هزینه	۲	۴	۶
کاهش وزن داده منفی در تابع هزینه	۰/۵	۰/۲۵	-

¹Overfit

²Test

³Voting

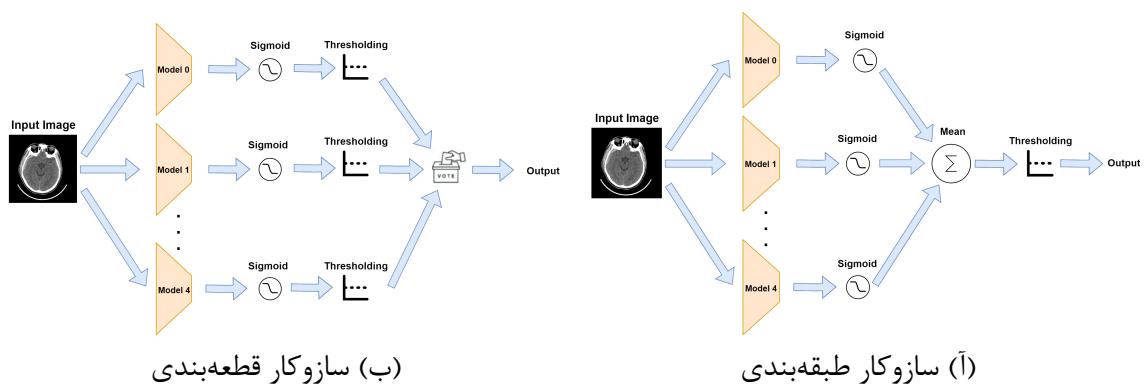
۲-۹-۲ قطعه‌بندی

در این پژوهش، مدل شبکه عصبی عمیق U-Net به عنوان ساختار اصلی برای آموزش وظیفه قطعه‌بندی در نظر گرفته شده است که وزن اولیه این مدل با استفاده از روش انتقال یادگیری به روی مجموعه‌داده [۴۲] ImageNet انتخاب شده است. به منظور آموزش این مدل یک جستجوی شبکه‌ای جامع روی مجموعه‌داده انجام شد. متناسب با نتایجی که به روی وظیفه طبقه‌بندی به دست آمد، استفاده از روش‌هایی مثل کاهش داده غالب و جاگذاری داده تأثیر مناسبی روی نتایج نداشته است؛ بنابراین این دو روش در جستجوی شبکه‌ای مدل قطعه‌بندی استفاده نشده است. در آموزش مدل قطعه‌بندی به روش جستجوی شبکه‌ای، از روش افزایش مصنوعی داده با ضرایب ۳، ۴، ۵ و ۶ به همراه انواع مختلف توابع هزینه شامل Cross-entropy، Focal Tversky، Dice و Tversky با وزن‌های ۱۰، ۱۰۰، ۲۰۰، ۵۰۰ و ۱۰۰۰ برای پیکسل‌های مثبت و انواع مختلف رمزگذار در ساختار DenseNet و EfficientNet، SE-ResNeXt، ResNeXt، ResNet شبکه U-Net با ابعاد متفاوت شامل U-Net با استفاده شده است.

در مراحل آموزش مدل قطعه‌بندی، داده ارزیابی ابتدا از مدل شورایی طبقه‌بندی عبور داده شد و تمام برش‌هایی که در این مدل دارای خونریزی درون جمجمه‌ای تشخیص داده شده‌اند، طبق روند نمای شکل ۲۰-۲ به مدل قطعه‌بندی ارسال شدند تا برش‌ها قطعه‌بندی شوند. در گام آخر، یک سازوکار تصمیم‌گیری شورایی که در [زیرقسمت ۳-۹-۲](#) توضیح داده شده است، برای قطعه‌بندی برش‌ها استفاده شد تا پیش‌بینی مدل‌های متفاوت مورد استفاده قرار گیرد.

۳-۹-۲ سازوکار تصمیم‌گیری شورایی

استفاده از روش 5-fold-cross-validation برای ارزیابی مدل‌های شبکه عصبی، می‌تواند با یک سازوکار شورایی در لایه تصمیم‌گیری همراه شود که به موجب آن اثر بیش‌برازش روی مجموعه‌داده کاهش پیدا می‌کند. در این پژوهش، یک روش شورایی ساده برای وظیفه طبقه‌بندی پیشنهاد شده است که به موجب آن، از پیش‌بینی احتمالاتی تمام مدل‌ها میانگین گرفته می‌شود و در انتهای آستانه‌گذاری روی این میانگین اعمال می‌شود. در ادامه برای وظیفه قطعه‌بندی، مراحل به گونه‌ای است که ابتدا برای هر مدل آستانه‌گذاری انجام شده و سپس بین آرای هر مدل رأی گرفته می‌شود [شکل ۲۱-۲](#)، عملکرد این روش را به صورت روند نمای مشخص می‌کند.



شکل ۲۱-۲: سازوکار تصمیم‌گیری شورایی

فصل سوم

نتائج

۱-۳ معیارهای ارزیابی در یادگیری عمیق

در این بخش، به بررسی معیارهای مختلفی که برای ارزیابی مدل‌های یادگیری عمیق استفاده می‌شوند، Intersec-، Accuracy، F1 Score، Precision، Specificity، Sensitivity می‌پردازیم. این معیارها شامل Dice و ضریب tion over Union (IoU) است.

قبل از پرداختن به تعریف این معیارها، ابتدا به تعریف چهار مفهوم اساسی می‌پردازیم که در فرمول‌های ارزیابی به کار می‌روند:

• (True Positives): تعداد نمونه‌های مثبت که به درستی به عنوان مثبت دسته‌بندی شده‌اند.

• (False Positives): تعداد نمونه‌های منفی که به اشتباه به عنوان مثبت دسته‌بندی شده‌اند.

• (True Negatives): تعداد نمونه‌های منفی که به درستی به عنوان منفی دسته‌بندی شده‌اند.

• (False Negatives): تعداد نمونه‌های مثبت که به اشتباه به عنوان منفی دسته‌بندی شده‌اند.

۱-۱-۳ Sensitivity

Sensitivity که با نام نرخ تشخیص صحیح نیز شناخته می‌شود، معیاری برای ارزیابی توانایی مدل در تشخیص صحیح نمونه‌های مثبت است. فرمول این معیار در [معادله ۱-۳](#) مشخص شده است.

$$\text{Sensitivity} = \frac{TP}{TP + FN} \quad (3-1)$$

۲-۱-۳ Specificity

Specificity، معیاری است که نشان‌دهنده توانایی مدل در شناسایی صحیح نمونه‌های منفی است. فرمول این معیار در [معادله ۲-۳](#) مشخص شده است.

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (3-2)$$

۳-۱-۳ Precision

Precision، معیاری برای ارزیابی میزان درستی دسته‌بندی نمونه‌های مثبت است. به عبارت دیگر،

Precision نسبت نمونه‌های مثبت درست دسته‌بندی شده به تمام نمونه‌های پیش‌بینی شده به عنوان مثبت است. فرمول آن در معادله ۳-۳ مشخص شده است.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3-3)$$

F1 Score ۴-۱-۳

F1 Score، میانگین موزون Sensitivity و Precision است که تعادلی بین این دو معیار ایجاد می‌کند. این امتیاز به‌ویژه در مواردی که تعادل بین Sensitivity و Precision اهمیت دارد، مورد استفاده قرار می‌گیرد. فرمول F1 Score در معادله ۴-۳ مشخص شده است.

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}} \quad (3-4)$$

Accuracy ۵-۱-۳

Accuracy، نسبت نمونه‌هایی است که به درستی دسته‌بندی شده‌اند به تمام نمونه‌ها. این معیار نشان‌دهنده عملکرد کلی مدل است و فرمول آن در معادله ۵-۳ مشخص شده است.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-5)$$

Intersection over Union (IoU) ۶-۱-۳

ارزیابی همپوشانی بین دو مجموعه، به‌ویژه در مسائل بخش‌بندی تصویر، استفاده می‌شود. فرمول IoU در معادله ۶-۳ مشخص شده است.

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{TP}{TP + FP + FN} \quad (3-6)$$

٧-١-٣ ضریب Dice

ضریب Dice، مشابه IoU است؛ اما وزن بیشتری به ناحیه اشتراک می‌دهد و در مسائل بخش‌بندی تصویر بسیار مورداستفاده قرار می‌گیرد. فرمول ضریب Dice در [معادله ٧-٣](#) مشخص شده است.

$$\text{Dice Coefficient} = \frac{2 \times |A \cap B|}{|A| + |B|} = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (3-7)$$

٢-٣ نتایج طبقه‌بندی

در این بخش، نتایج حاصل از مدل‌های طبقه‌بندی خونریزی درون‌جمجمه‌ای در تصاویر سی‌تی‌اسکن، بررسی و تحلیل شده‌اند. مرکز اصلی آموزش مدر طبقه‌بندی بر روی بهینه‌سازی فرآپارامترها برای مدل ResNet50 بوده است که بهبود قابل توجهی در عملکرد مدل بهویژه در معیار Sensitivity به همراه داشته است. بهترین نتایج به‌دست‌آمده در جستجوی شبکه‌ای زمانی حاصل می‌شود که ضریب افزایش مصنوعی داده برابر $\frac{3}{3}$ و وزن تابع خطا Cross-entropy برای برش‌های مثبت برابر $\frac{4}{4}$ و برای برش‌های منفی برابر $\frac{1}{1}$ است.

١-٢-٣ نتایج برش محور

پس از آموزش مدل طبقه‌بندی برای تمام Fold‌ها، نمودار امتیاز F1 نسبت به آستانه‌های متفاوت رسم شد و در گام بعدی میانگین این نمودارها محاسبه شد. در انتهای بهترین آستانه روی میانگین این نمودارها محاسبه شده و در محاسبه معیارهای مربوط به زیرمجموعه ارزیابی استفاده شده است. [جدول ١-٣](#) نتایج به‌دست‌آمده از آموزش مدل‌های ResNet50 و سازوکار شورا برای طبقه‌بندی برش محور نشان می‌دهد. همان‌طور که در جدول مشاهده می‌شود، بهترین نتایج در Fold 0 به‌دست‌آمده است که امتیاز F1 برابر با $\frac{62}{62}$ را نشان می‌دهد. این نشان‌دهنده این است که توزیع داده‌ها در مجموعه‌های آموزشی و اعتبارسنجی این Fold بیشتر شبیه به مجموعه آزمون است. در مقابل، Fold 4 کمترین نتایج را به‌دست‌آورده، در حالی که نتایج مراحل دیگر با هم بیشتر هم‌خوانی دارند. نتایج به‌دست‌آمده از روش شورایی، در مقایسه با نتایج گزارش شده توسط Hssayeni [٢١] و همکاران، در معیار Sensitivity $\frac{3}{3}$ درصد ضعیفتر عمل کرده است اما در معیار Specificity $\frac{41}{41}$ درصد بهتر عمل کرده است. مقایسه این نتایج نشان می‌دهد که مدل پیشنهادی در این پژوهش، به صورت نسبی همان قدر که در تشخیص برش‌هایی که

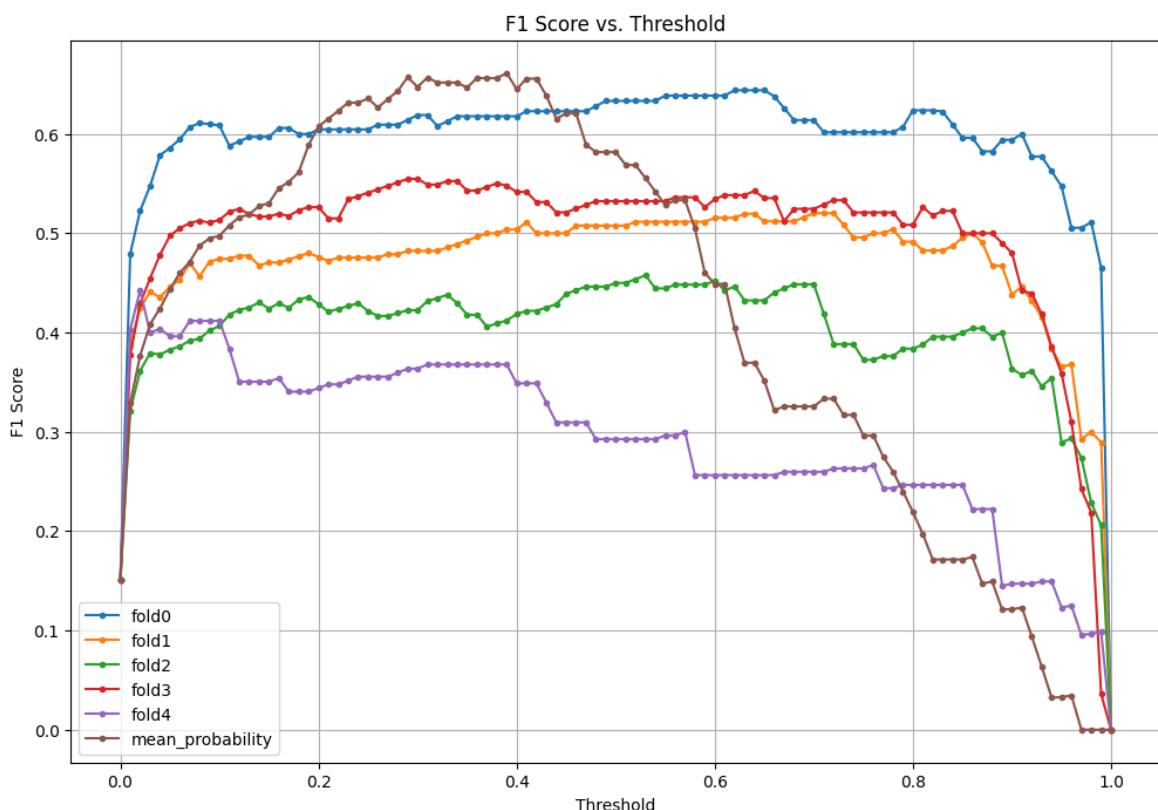
خونریزی درون جمجمه‌ای دارند درست عمل می‌کند، در تشخیص برش‌هایی که سالم هستند نیز درست عمل می‌کند اما Hssayeni و همکاران در تشخیص برش‌های سالم که تعداد آنها نیز بسیار زیاد هست، ضعیف عمل کرده‌اند و ۵۰ درصد از این برش‌ها را دارای خونریزی درون جمجمه‌ای تشخیص داده‌اند. نکته‌ای که در مورد پژوهش آنها وجود دارد، عدم ارائه بقیه معیارهای ارزیابی مدل است که تحلیل و مقایسه بیشتر این پژوهش را دشوار می‌سازد. پژوهش بعدی که در زمینه طبقه‌بندی برش‌های خونریزی درون جمجمه‌ای با استفاده از انتقال یادگیری عمل کرده است، مربوط به [۳۴] Neethi است که از مدل ResNet 50 استفاده کرده‌اند. این پژوهش در معیار Precision ۲۰ درصد و در معیار امتیاز F1 ۳ درصد بهتر عمل کرده است اما در معیار Sensitivity مدل آنها ۱۸ درصد ضعیفتر و در معیار Accuracy مدل آنها ۳۷ درصد ضعیفتر عمل کرده است. در تحلیل نتایج به دست آمده، از آنجایی که در زمینه پزشکی، تشخیص اشتباه یک نمونه دارای بیماری، می‌تواند منجر به حوادث جبران‌ناپذیر شود، معیار Sensitivity مهم‌تر از معیار Precision است؛ با توجه به این نکته، مدل پیشنهادی ما توانسته اختلاف بسیار زیادی در این معیار ایجاد کند. از طرف دیگر با توجه به عدد Accuracy گزارش شده، مشخص است که مدل پیشنهادی Neethi تنها نیمی از برش‌های تمام مجموعه‌داده را درست تشخیص داده که نشان‌دهنده تعداد خیلی کم TN و مقدار کم Specificity است که در پژوهش آنها گزارش نشده است. نکته‌ای که باید توجه داشت این است که مدل‌های استفاده شده در هر دو پژوهش بکسان است و تنها فرآپارامترهای پیشنهادی ما باعث بهبود عملکرد مدل شده است.

جدول ۱-۳: نتایج برش محور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷

Accuracy	F1	Precision	Specificity	Sensitivity	مدل
۰/۹۱	۰/۶۲	۰/۵۱	۰/۹۳	۰/۷۸	ResNet50 Fold 0
۰/۸۸	۰/۴۹	۰/۳۸	۰/۹۰	۰/۶۸	ResNet50 Fold 1
۰/۸۶	۰/۴۲	۰/۳۳	۰/۸۹	۰/۶۰	ResNet50 Fold 2
۰/۸۹	۰/۵۵	۰/۴۱	۰/۸۹	۰/۸۶	ResNet50 Fold 3
۰/۹۰	۰/۳۶	۰/۴۲	۰/۹۶	۰/۳۲	ResNet50 Fold 4
۰/۵۴	۰/۶۷	۰/۶۹	—	۰/۷۶	[۳۴] Neethi et al.
—	—	—	۰/۵۰	۰/۹۷	[۲۱] Hssayeni et al.
۰/۹۱	۰/۶۴	۰/۴۹	۰/۹۱	۰/۹۴	شورایی ResNet50

همان‌طور که در شکل ۱-۳ مشاهده می‌شود، با استفاده از سازوکار شورایی، امتیاز F1 بهبود قابل توجهی پیدا کرده است که نشان‌دهنده بهبود عملکرد مدل طبقه‌بندی با استفاده از سازوکار شورایی است. مدل به صورت برش محور ۰/۹۴ بود که یک دستاورد قابل توجه در مقایسه با سایر مطالعات است خصوصاً در زمینه استفاده‌های پزشکی. نکته‌ای که باید به آن توجه کرد این است که

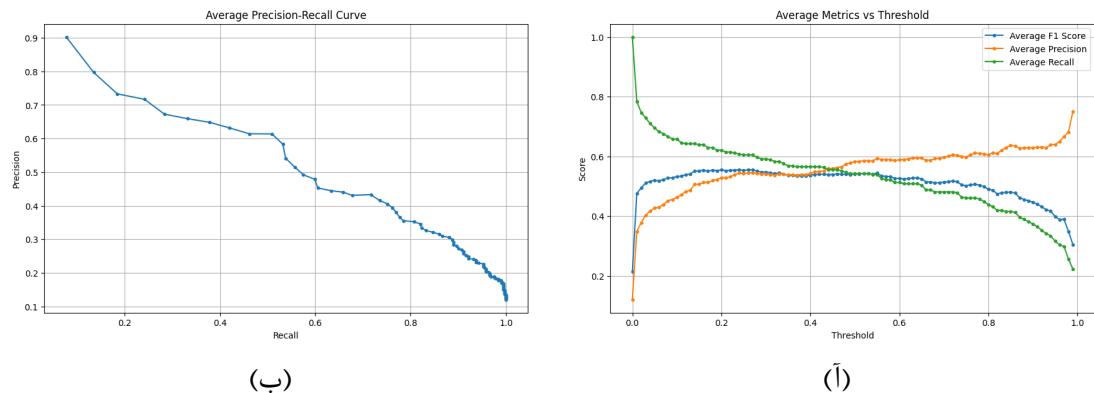
مقادیر گزارش شده برای Fold های متفاوت، بهازی آستانه های متفاوت می توانند مقادیر بهتری داشته باشند، اما اعداد گزارش شده در بهترین آستانه برای میانگین نمودارها است. [شکل ۲-۳](#) نمودارهای Sen-[F1](#) و امتیاز [Precision](#) و [Sensitivity](#) بهازی آستانه های متفاوت را نشان می دهد و [شکل ۲-۳](#) نمودار منحنی Precision-Sensitivity را نشان می دهد. [شکل ۳-۳](#) ماتریس آشفتگی مدل ها را نشان می دهد، همان طور که مشخص است مدلی که از سازوکار شورایی استفاده می کند به صورت قابل توجهی عملکرد بهتری پیدا می کند. در انتها [جدول ۲-۳](#) عملکرد دیگر ساختارهای شبکه عصبی عمیق با استفاده از فرآپارامترهای به دست آمده در این قسمت از پژوهش است. همان طور که مشخص است این فرآپارامترها باعث بهبود عملکرد تمامی مدل ها شده است.



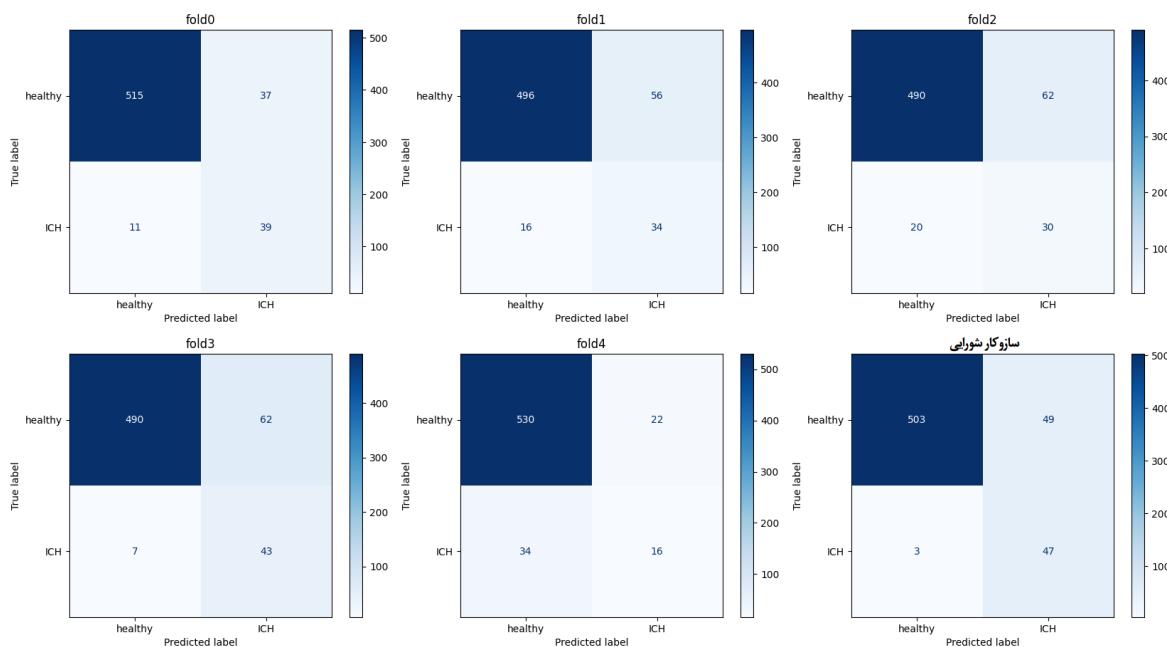
شکل ۳-۱: نمودار امتیاز F1 نسبت به آستانه برای Fold ها و میانگین آنها

۲-۲-۳ نتایج بیمارمحور

طبقه بندی بیمارمحور خونریزی درون جمجمه ای بر اساس پیش بینی های برش محور انجام شده است. یک بیمار در صورتی دارای خونریزی درون جمجمه ای در نظر گرفته می شود اگر حداقل یک برش از سی تی اسکن او دارای علائم خونریزی شناسایی شود. نتایج به دست آمده نشان می دهند که مدل



شکل ۲-۳: نمودارهای سازوکار شورایی روی مجموعه داده ارزیابی



شکل ۳: ماتریس آشفتگی نتایج برش محور

در بررسی بیمارمحور سی تی اسکن‌ها، با استفاده از روش شورایی، به Sensitivity برابر با ResNet50 ۸۸٪ دست یافته است که از تمامی معیارهای گزارش شده در سایر مطالعات، نتیجه بهتری کسب کرده است. جدول ۳-۳ نتایج بیمارمحور مدل ResNet50 را برای هر مرحله آموزشی نشان می‌دهد. شکل ۴-۳ ماتریس آشفتگی بیمارمحور را نشان می‌دهد که از ۱۶ بیمار در مجموعه ارزیابی قرار داشته‌اند که همه ۶ بیمار دارای خونریزی درست تشخیص داده شده‌اند.

جدول ۲-۳: نتیجه استفاده از فراپارامترهای بدست آمده از جستجوی شبکه‌ای روی مدل‌های دیگر

مدل	فراپارامتر پیشنهادی	Sensitivity	Specificity	Precision	F1	Accuracy
ResNet 50	✓	۰.۹۴	۰.۹۱	۰.۶۴	۰.۶۹	۰.۹۱
ResNet 50	✗	۰.۷۶	۰.۷۸	۰.۲۳	۰.۳۶	۰.۷۷
VGG-16	✓	۰.۹۲	۰.۸۸	۰.۴۱	۰.۵۶	۰.۸۸
VGG-16	✗	۰.۸۸	۰.۷۶	۰.۲۵	۰.۳۹	۰.۷۷
MobileNet-V2	✓	۰.۹۸	۰.۸۲	۰.۳۳	۰.۵۰	۰.۸۴
MobileNet-V2	✗	۱.۰۰	۰.۶۸	۰.۲۲	۰.۳۶	۰.۷۱
Inception-V3	✓	۰.۶۴	۰.۹۰	۰.۳۶	۰.۴۶	۰.۸۸
Inception-V3	✗	۰.۸۸	۰.۷۸	۰.۲۷	۰.۴۱	۰.۷۹

جدول ۳-۳: نتایج بیمارمحور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷

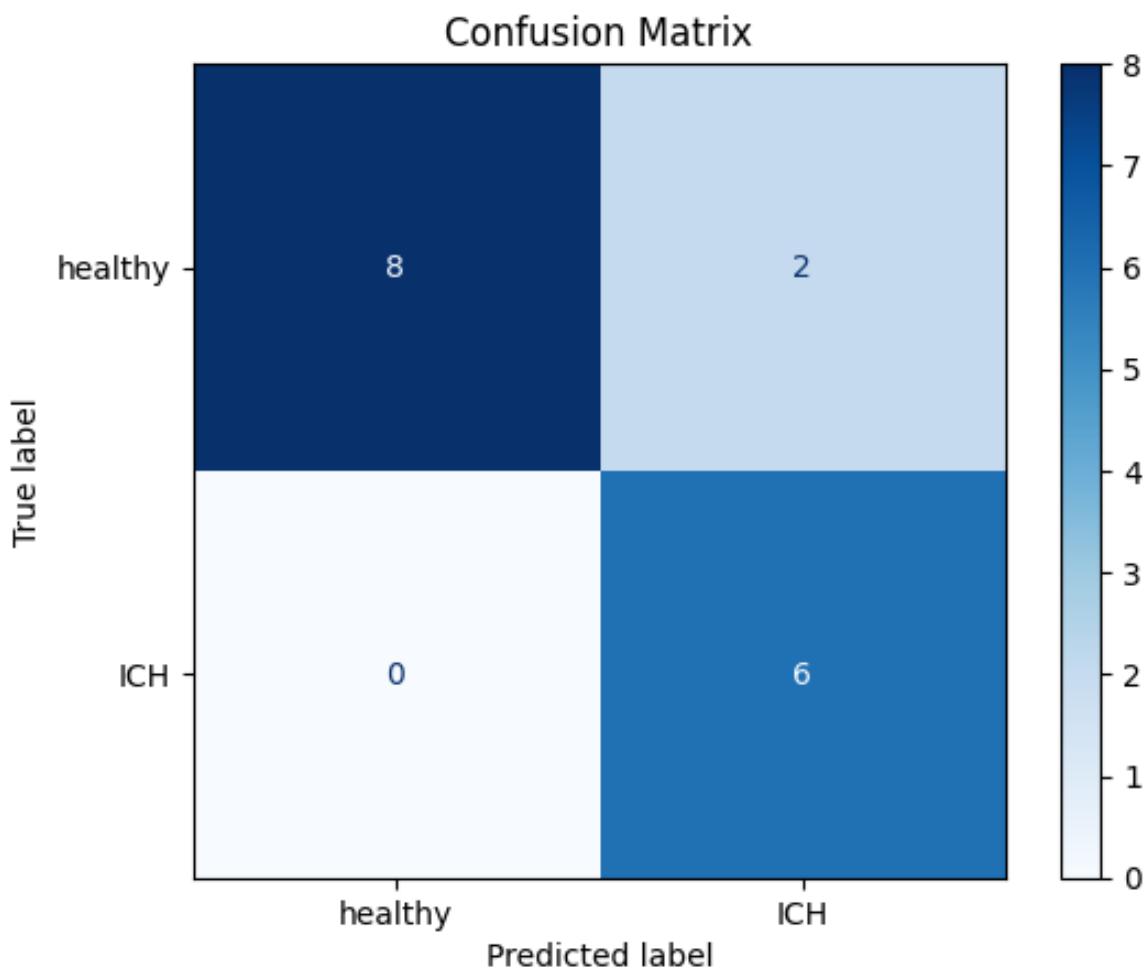
مدل	Sensitivity	Specificity	Precision	F1	Accuracy
ResNet50 Fold 1	۱.۰۰	۰.۶۰	۰.۶۰	۰.۷۵	۰.۷۵
ResNet50 Fold 2	۱.۰۰	۰.۶۰	۰.۶۰	۰.۷۵	۰.۷۵
ResNet50 Fold 3	۱.۰۰	۰.۶۰	۰.۶۰	۰.۷۵	۰.۷۵
ResNet50 Fold 4	۰.۸۳	۰.۸۰	۰.۷۱	۰.۷۷	۰.۸۱
[۳۵] Kyung et al.	۰.۹۷	۰.۷۴	—	۰.۸۴	—
ResNet50 Voting	۱.۰۰	۰.۸۰	۰.۷۵	۰.۸۶	۰.۸۸

۳-۲-۳ تحلیل بیشتر نتایج

در این بخش، نتایج مرتبط با تفسیرپذیری مدل ResNet50 از طریق روش‌های t-SNE و Grad-CAM تحلیل و بررسی می‌شوند.

تحلیل Grad-CAM

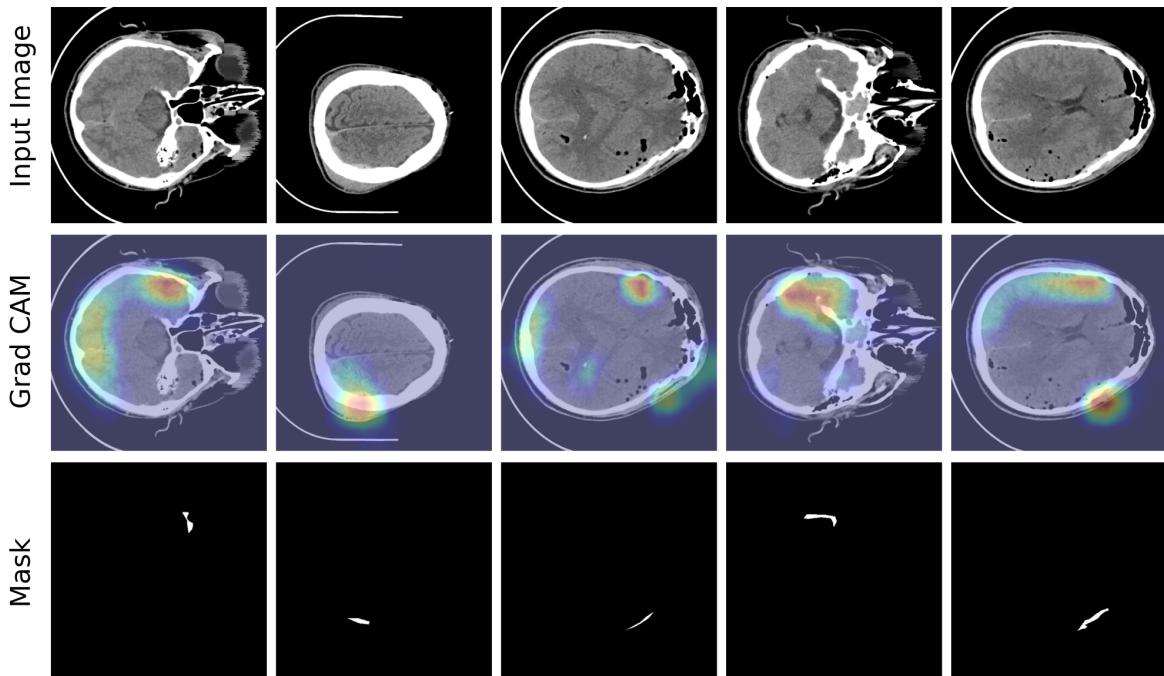
روش Grad-CAM (Gradient-weighted Class Activation Mapping) یک ابزار قدرتمند برای تفسیر مدل‌های شبکه عصبی عمیق استفاده می‌شود. این روش به ما اجازه می‌دهد تا ببینیم کدام بخش‌های تصویر ورودی، بیشتر در تصمیم‌گیری مدل تأثیر داشته‌اند. در این پژوهه، از روش Grad-CAM برای افزایش تفسیرپذیری مدل‌های طبقه‌بندی به کمک ایجاد تصویر استفاده شده است که نواحی مهم برش‌های سی‌تی‌اسکن که منجر به تشخیص خونریزی توسط مدل شده‌اند را مشخص می‌کند. [شکل ۵-۳](#) نمونه‌ای از این نقشه‌های حرارتی را نشان می‌دهد که به‌وضوح مشخص می‌کند که مدل چگونه نواحی مختلف تصویر را برای تشخیص ICH مورد ارزیابی قرار داده است.



شکل ۳-۴: ماتریس آشفتگیب یمارمحور سازوکار شورایی

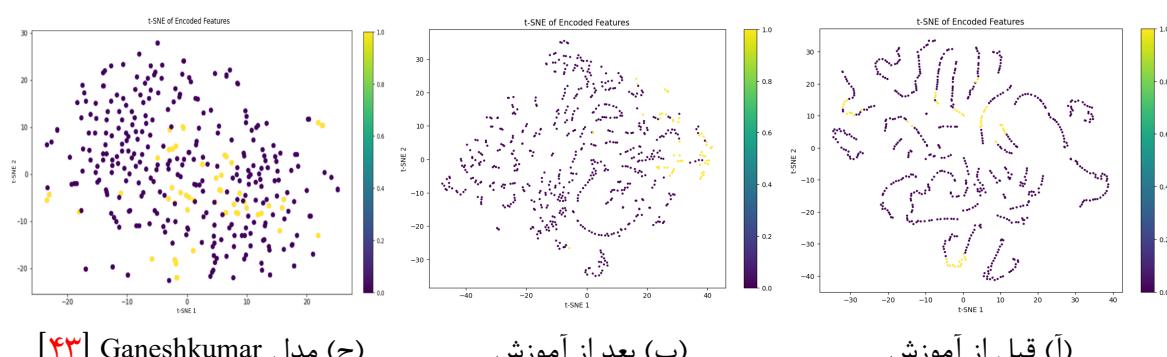
t-SNE تحلیل

روش t-SNE (t-Distributed Stochastic Neighbor Embedding) یک روش برای کاهش ابعاد و تجسم داده‌های با ابعاد بالا است. در این پژوهش، از t-SNE برای تجسم توزیع ویژگی‌های استخراج شده از مدل ResNet50 استفاده شده است تا نشان داده شود که آموزش مدل، باعث تولید ویژگی‌هایی شده است که تفکیک‌پذیری برش‌های سالم را از ناسالم زیاد کرده است. [شکل ۳-۶](#) نشان‌دهنده توزیع ویژگی‌های استخراجی با روش t-SNE از تصاویر سی‌تی‌اسکن در فضای دوبعدی است که [شکل ۳-۶](#) پراکندگی ویژگی‌ها از مدل طبقه‌بندی قبل از آموزش آن است و [شکل ۳-۶](#) بعد از آموزش مدل طبقه‌بندی است. [شکل ۳-۶](#) به‌وضوح نشان می‌دهد چگونه مدل قادر است تفکیک‌پذیری خطی را برای برش‌های حاوی خونریزی درون جمجمه‌ای ایجاد کند. این استخراج ویژگی کمک می‌کند تا دیدگاه بهتری نسبت به نحوه عملکرد مدل در سطح ویژگی‌ها داشته باشیم و نقاط ضعف و قوت آن را بهتر درک کنیم. [شکل ۳-۶](#)



شکل ۳-۵: چند نمونه از تصاویر تولید شده توسط Grad-CAM

نمودار t-SNE حاصل از مدل طبقه‌بندی Ganeshkumar [۴۳] و همکاران است که نشان می‌دهد مدل به دست آمده در پژوهش آنها، امکان تفکیک‌پذیری خطی را برای برش‌ها ایجاد نکرده است.

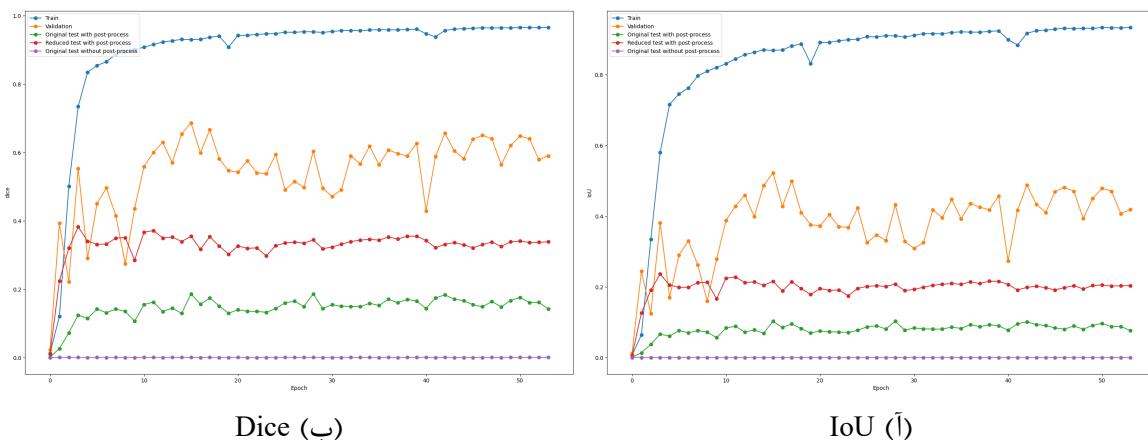


شکل ۳-۶: نمودارهای t-SNE و مقایسه آنها با یکدیگر

۳-۳ نتایج قطعه‌بندی

در این قسمت به بررسی نتایج حاصل شده از آموزش مدل قطعه‌بندی PSPNet و U-Net می‌پردازیم. نتیجه استفاده از جستجوی شبکه‌ای به روی مدل U-Net نشان می‌دهد که مدل با رمزگذار SE-ResNeXt-101 که با استفاده از تابع خطا Dice آموزش دیده و میزان برش‌های دارای خونریزی آن، ۵ برابر شده

است، بهترین نتیجه را به دست آورده. با توجه به فرآپارامترهایی که در جستجوی شبکه‌ای مدل U-Net به دست آمد، مدل PSPNet آموزش داده شد تا نشان دهیم این فرآپارامترها می‌توانند عملکرد مدل‌های قطعه‌بندی را بهبود بخشند. **شکل ۷-۳** منحنی‌های مربوط به آموزش مدل روی Fold 1 را نشان می‌دهد که در آن Original test without post-process، مربوط به مجموعه‌داده ارزیابی است که از مدل طبقه‌بندی عبور نشده است و عملیات پس‌پردازش به روی آن انجام نشده است. منحنی Original test with post-process مربوط به مجموعه‌داده ارزیابی است که از مدل طبقه‌بندی عبور نشده است؛ اما عملیات پس‌پردازش به روی آن انجام شده است. منحنی Reduced test with post-process مربوط به مجموعه‌داده ارزیابی است که از مدل طبقه‌بندی عبور نشده و عملیات پس‌پردازش به روی آن انجام شده است. همان‌طور که از نمودارهای مربوط به معیار IoU در **شکل ۷-۳آ** و معیار Dice در **شکل ۷-۳ب** مشخص است، پس‌پردازش پیشنهادی و روش دومرحله‌ای هر کدام باعث بهبود چشمگیر نتایج مدل شبکه عصبی شده‌اند.



شکل ۷-۳: یک نمونه از عملکرد روش پیشنهادی و پس‌پردازش در فرایند آموزش

با درنظر گرفتن کمترین مقدار تابع خطا، بهترین Epoch هر Fold انتخاب می‌شود و پس از آن برای تنظیم متغیرهای مربوط به سازوکار شورا، نمودارهای IoU و Dice نسبت به آستانه‌های متفاوت رسم می‌شود و بهترین آستانه به دست می‌آید.

جدول ۴-۳ نتایج Fold‌ها، روش شورایی و تحقیقات گذشته را نشان می‌دهد. همان‌طور که مشخص است روش مذکور توانسته معیار Dice را نسبت به مطالعات پیشین بهبود ببخشد در حالی که مقدار IoU آن نیز به صورت کلی از آنها بهتر است.

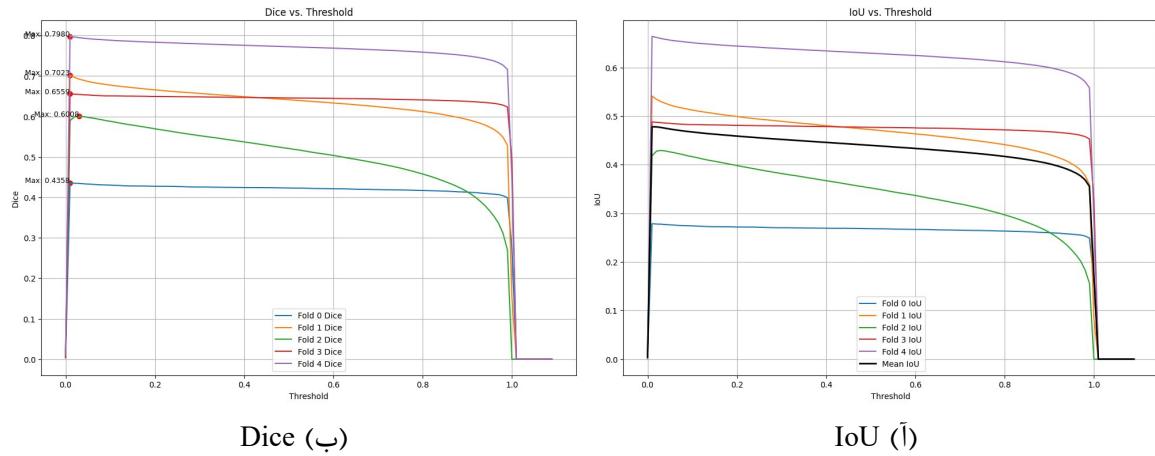
شکل ۸-۳ و **شکل ۹-۳** نتایج IoU و Dice را به ازای آستانه‌های متفاوت برای دو مدل U-Net و PSPNet نشان می‌دهند. همان‌طور که مشخص است، میانگین عملکرد مدل‌ها به روی زیرمجموعه

جدول ۴-۳: نتایج قطعه‌بندی تصاویر سی‌تی‌اسکن

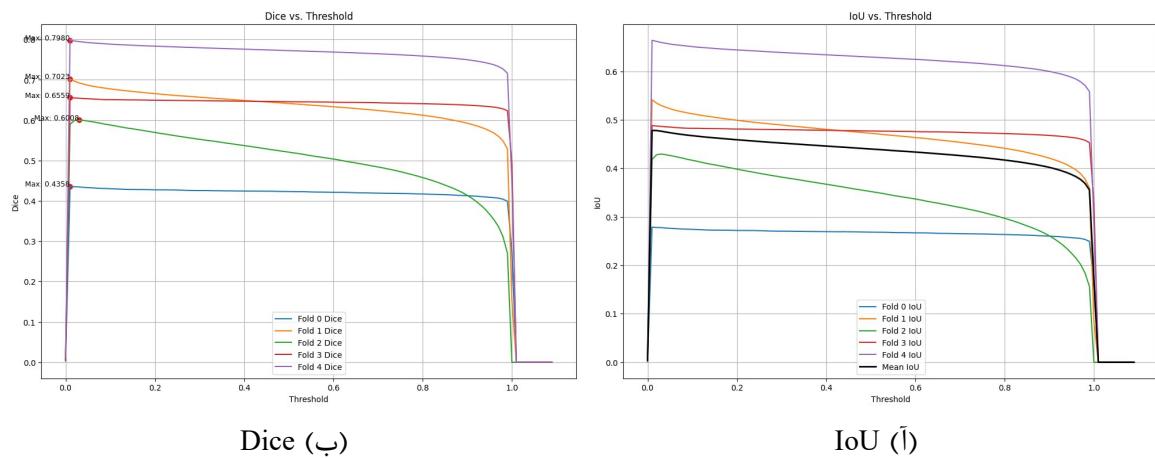
Dice	IoU		Mdl
	عادی	دو مرحله‌ای	
۰/۳۵	۰/۲۱	۰/۲۱	U-Net Fold 0
۰/۳۶	۰/۳۱	۰/۲۲	PSPNet Fold 0
۰/۳۴	۰/۲۹	۰/۲۰	U-Net Fold 1
۰/۳۵	۰/۲۹	۰/۲۱	PSPNet Fold 1
۰/۳۳	۰/۱۲	۰/۲۰	U-Net Fold 2
۰/۲۸	۰/۲۰	۰/۱۶	PSPNet Fold 2
۰/۳۲	۰/۱۶	۰/۱۹	U-Net Fold 3
۰/۳۷	۰/۳۴	۰/۲۳	PSPNet Fold 3
۰/۳۳	۰/۱۶	۰/۱۹	U-Net Fold 4
۰/۳۵	۰/۲۷	۰/۲۱	PSPNet Fold 4
-	۰/۳۲	-	[۲۱]U-Net Hssayeni
-	۰/۳۵	-	[۳۴]U-Net Neethi
۰/۳۶	۰/۲۹	۰/۲۲	U-Net شورایی
۰/۳۸	۰/۳۴	۰/۲۳	PSPNet شورایی

اعتبارسنجی که توزیع برش‌های آن، مشابه با توزیع برش‌ها در زیرمجموعه ارزیابی است، بسیار بیشتر از نتایج بهدست‌آمده به روی زیرمجموعه ارزیابی است. علت اصلی این تفاوت، در توزیع مکانی خونریزی درون‌جمجمه‌ای موجود در زیرمجموعه ارزیابی نسبت به بقیه زیرمجموعه‌ها است که در [شکل ۹-۲](#) این تفاوت توزیع مشخص است. [۲۱]Hssayeni و همکاران، در پژوهشی که نتایج آن در [جدول ۴-۳](#) آورده شده است، نتایج خود را از میانگین گرفتن از نتایج بهدست‌آمده از هر Fold گزارش کرده‌اند؛ بنابراین اگر این معیار را برای ارزیابی نتایج روش دو مرحله‌ای در نظر بگیریم، این روش بهبود قابل توجهی در معیارهای قطعه‌بندی ایجاد کرده است.

[شکل ۱۰-۳](#) چند عملکرد مدل را در پیش‌بینی خونریزی در چند نمونه برش نشان می‌دهد. از بررسی این تصاویر مشخص است که مدل شبکه عصبی در پیش‌بینی خونریزی در برش‌ها دچار زیرقطعه‌بندی Under Segmentation و لازم است تا با اضافه کردن یکتابع هزینه مناسب یا یک پس‌پردازش این مسئله رفع شود، از طرف دیگر با بررسی ستون‌های موجود در [شکل ۱۰-۳](#)، مشخص است که در ستون آخر با وجود اینکه مساحت خونریزی زیاد بوده، اما قطعه‌بندی به صورت درستی انجام نشده است. علت به وجود آمدن این مشکل این است که خونریزی درون‌جمجمه‌ای، در زمان ابتدایی وقوع حادثه بافت تیره‌تری نسبت به بقیه قسمت‌های مغز دارد و با گذر زمان رنگ این ضایعه نسبت به بقیه اجزای مغز روشن‌تر می‌شود؛ بنابراین با توجه به اینکه تصویر سی‌تی‌اسکن در چه زمانی گرفته شود رنگ این ضایعه

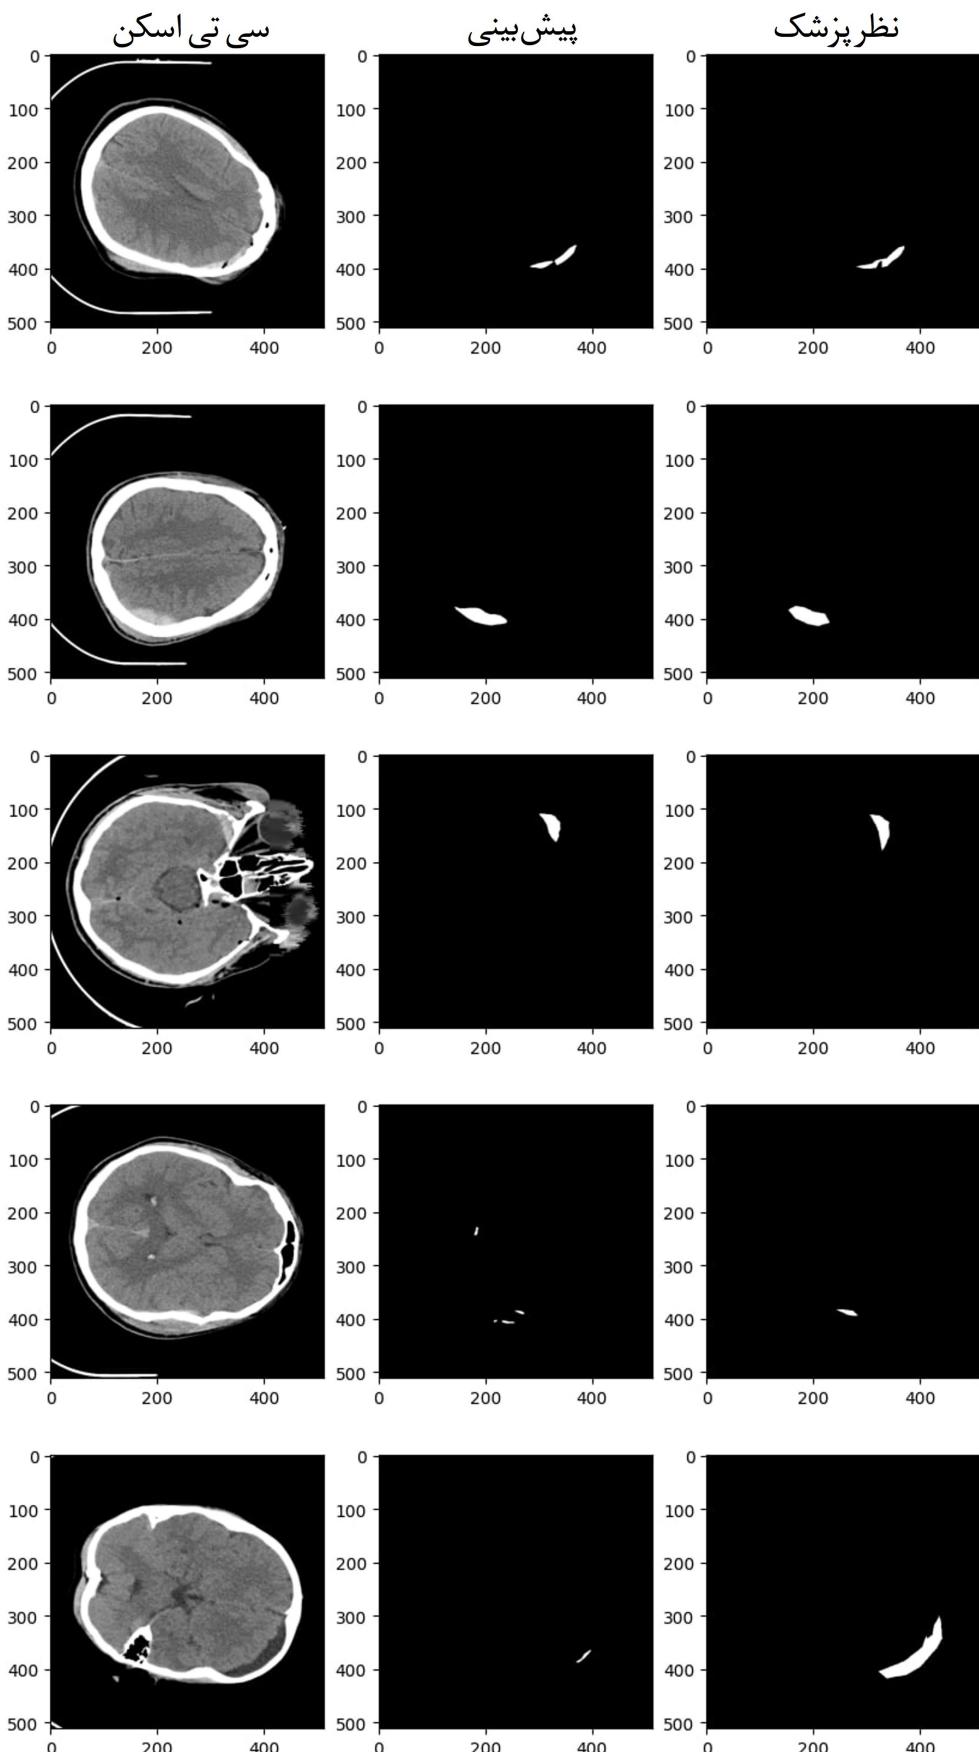


شکل ۸-۳: نتایج مدل U-Net به ازای آستانه‌های متفاوت



شکل ۹-۳: نتایج مدل PSPNet به ازای آستانه‌های متفاوت

متفاوت است. مشکل موجود در مجموعه‌داده PhysioNet نبود تعداد کافی برش دارای خونریزی به رنگ تیره می‌باشد و در ادامه آن مدل‌های مبتنی بر شبکه عصبی پیچشی حساسیت بیشتری به بافت تصویر دارند تا شکل ضایعه موجود در تصویر بنابراین مدل پیشنهادی Bias بیشتری دارد تا خونریزی‌هایی با رنگ روشن را بهتر تشخیص دهد.



شکل ۳-۱۰: نمونه عملکرد مدل در پیش‌بینی تصاویر سی‌تی‌اسکن

فصل چهارم

کارهای پیشنهادی و نتیجه‌گیری

۱-۴ محدودیت‌های و پیشنهادات

خونریزی درون جمجمه‌ای یک وضعیت اضطراری پزشکی است که به دلایل متفاوت مثل آسیب‌های مغزی تروماتیک، بیماری‌های عروقی یا مشکلات مادرزادی ایجاد شود [۱۲]. جلوگیری از مرگ و کاهش عوارض ایجاد شده در خونریزی درون جمجمه‌ای نیازمند مداخله سریع است؛ اما به علت وجود عوامل محیطی مانند شلوغی مراکز درمان یا نبود متخصص مربوطه، تشخیص و درمان بیمار دارای خونریزی درون جمجمه‌ای می‌تواند با تأخیر انجام شود. علاوه‌بر این بررسی تصاویر پیچیده و سه‌بعدی سی‌تی اسکن نیز یکی دیگر از چالش‌ها در تشخیص دستی خونریزی درون جمجمه‌ای است.

این پژوهش در گام نخست با استفاده یک روش پردازش تصاویر سی‌تی اسکن مبتنی بر شبکه‌های عصبی عمیق، یک دستیار هوشمند را برای استفاده در مراکز پزشکی توسعه داده و در گام بعدی با توسعه روش‌های موجود در پردازش تصاویر سی‌تی اسکن، دقت این دستیار را در زمینه طبقه‌بندی و قطعه‌بندی افزایش داده است. استفاده از روش دومرحله‌ای موجب کاهش Field-of-View در مدل قطعه‌بندی به Region-of-Interest می‌شود که در نتیجه آن، امکان ایجاد خطأ در برش‌های سالم کاهش پیدا می‌کند. از دیگر روش‌های دومرحله‌ای به Cascaded U-Net و روش Fine to coarse می‌توان اشاره کرد. نتایج به دست آمده از روش دومرحله‌ای پیشنهاد شده در این پژوهش به همراه پس‌پردازش استفاده شده، نشان داد که عملکرد مدل می‌تواند بهبود قابل توجهی پیدا بکند که نشان‌دهنده این است که این روش می‌تواند در مراکز پزشکی استفاده شود.

با این حال، چالش‌ها و محدودیت‌هایی در این تحقیق وجود دارد. یکی از مهم‌ترین چالش‌ها، دسترسی محدود به مجموعه‌داده‌های متنوع و بزرگ در حوزه طبقه‌بندی و قطعه‌بندی خونریزی درون جمجمه‌ای است. تنوع ناکافی در کیفیت تصاویر سی‌تی اسکن نیز ممکن است بر قابلیت تعمیم‌پذیری مدل‌های ما تأثیر بگذارد. همچنین، توان محاسباتی موردنیاز برای آموزش مدل‌ها و اجرای پس‌پردازش ممکن است باعث افزایش زمان پردازش شود که باید در آینده با استفاده از روش‌های بهینه‌سازی بهبود یابد. یکی از محدودیت‌های اساسی در این پژوهش این است که برای پردازش یک تصویر سی‌تی اسکن، لازم است تا این تصویر از ۱۰ مدل شبکه عصبی عبور داده شود و سازوکار شورایی روی آنها اعمال شود که این مسئله توان محاسباتی موردنیاز را افزایش می‌دهد.

یکی از مهم‌ترین زمینه‌های موجود برای پژوهش‌های آینده، جمع‌آوری یکم مجموعه‌داده با کیفیت و حجم مناسب از مراکز موجود در ایران است که با استفاده از این مجموعه‌داده امکان ارزیابی عملکرد مدل در مراکز بهداشتی ایران فراهم شود. در ادامه استفاده از مجموعه‌داده‌های موجود مثل RSNA [۱۰] که

تعداد بسیار زیادی تصویر مناسب برای طبقه‌بندی دارد و استفاده از روش‌های یادگیری انتقالی، می‌تواند یکی از راه‌های بهبود عملکرد مدل‌های پردازش تصویر باشد. از آنجایی که تصاویر سی‌تی‌اسکن یک توالی از برش‌ها است، اضافه کردن لایه‌های زمانی در مراحل تصمیم‌گیری می‌تواند در عملکرد مدل تأثیرگذار باشد. تصاویر سی‌تی‌اسکن ماهیت سه‌بعدی دارند؛ بنابراین توسعه مدل‌هایی که از لایه‌های پیچشی سه‌بعدی استفاده کنند یا روش‌های $1D + 2D$ ^۱ به منظور افزایش مشارکت برش‌ها در تصمیم‌گیری مدل یک زمینه تحقیقاتی است. استفاده از مدل‌های جدید در زمینه پردازش تصاویر خصوصاً مدل‌های مبتنی بر مکانیزم توجه و مدل‌هایی که حساسیت آنها به شکل ضایعه بیشتر از بافت ضایعه باشد یکی از زمینه‌های موجود برای پژوهش‌های آینده است. روش Model soups نیز می‌تواند یک زمینه جذاب برای توسعه عملکرد مدل‌ها برای استفاده در زمینه پزشکی باشد. توسعه سازوکار شورایی، یک زمینه مناسب برای توسعه عملکرد مدل‌ها است، با توجه به اینکه آستانه بهینه برای هر مدل می‌تواند با مدل دیگر متفاوت باشد و فاصله پیشビینی مدل از آستانه بهینه می‌تواند اطمینان پیشビینی را بالا ببرد، استفاده از روش‌هایی مبتنی بر ریاضیات فازی^۲ یک پیشنهاد مناسب برای مواجهه با این چالش است. زمینه پیشنهادی دیگر برای پردازش تصاویر سی‌تی‌اسکن، تغییر ساختار روش دومرحله‌ای از یک مدل طبقه‌بندی به همراه یک مدل قطعه‌بندی، به یک مدل بخش‌بندی به همراه یک مدل قطعه‌بندی است. این روش با شناسایی محدوده خونریزی، ناترازی پیکسلی را به منظور آموزش مدل قطعه‌بندی کاهش می‌دهد.

۲-۴ نتیجه‌گیری

در این پایان‌نامه، یک روش دومرحله‌ای برای شناسایی و قطعه‌بندی خودکار خونریزی‌های درون‌جمجمه‌ای با استفاده از تصاویر سی‌تی‌اسکن ارائه شده است. استفاده از روش پس‌پردازش و تصمیم‌گیری پس از قطعه‌بندی، بهبود قابل توجهی در دقت و صحت نتایج داشته است. نتایج به دست‌آمده نشان می‌دهد که این روش می‌تواند به عنوان یک ابزار کارآمد در تشخیص‌های پزشکی به کار رود. با توجه به نتایج حاصل از این پژوهش، ابزارهای هوش مصنوعی و یادگیری عمیق می‌توانند نقشی اساسی در بهبود کیفیت تشخیص‌های پزشکی داشته باشند. در آینده، می‌توان این مدل را با استفاده از مجموعه‌داده‌های متنوع‌تر و روش‌های پیچیده‌تر مانند استفاده از مکانیسم‌های توجه گسترش داد. همچنین، امکان ادغام این مدل با فرایندهای بیمارستانی برای تشخیص زمان‌واقعی و کمک به تصمیم‌گیری پزشکان وجود دارد.

^۱Mechanism

^۲Fuzzy

این پژوهش نشان می‌دهد که ادغام مدل‌های هوش مصنوعی با فرایندهای پزشکی می‌تواند به بهبود کارایی و کاهش زمان و هزینه‌های تشخیص و درمان کمک کند. با توسعه بیشتر این مدل‌ها، استفاده گسترده‌تر از آن‌ها در بیمارستان‌ها و مراکز درمانی ممکن است منجر به بهبود نتایج بیماران و کاهش خطاهای پزشکی شود.

مراجع و مراجع

- [1] Team, Health Jade. Intracerebral hemorrhage causes, symptoms, diagnosis, treatment & recovery, October 18 2019. Accessed: 2024-08-26.
- [2] CT-Scans, DICOM files, Windowing Explained — kaggle.com. <https://www.kaggle.com/code/redwankarimsony/ct-scans-dicom-files-windowing-explained/notebook>. [Accessed 29-08-2024].
- [3] at 3rd Wave Media, Xiaoying Riley. Introduction to Deep Learning — blogs.brain-mentors.com. <https://blogs.brain-mentors.com/introduction-to-deep-learning/>. [Accessed 30-08-2024].
- [4] Residual neural network - Wikipedia — en.wikipedia.org. https://en.wikipedia.org/wiki/Residual_neural_network. [Accessed 31-08-2024].
- [5] Xie, Saining, Girshick, Ross, Dollár, Piotr, Tu, Zhuowen, and He, Kaiming. Aggregated residual transformations for deep neural networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1492–1500, 2017.
- [6] Hu, Jie, Shen, Li, and Sun, Gang. Squeeze-and-excitation networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 7132–7141, 2018.

- [7] Huang, Gao, Liu, Zhuang, Van Der Maaten, Laurens, and Weinberger, Kilian Q. Densely connected convolutional networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4700–4708, 2017.
- [8] Ronneberger, Olaf, Fischer, Philipp, and Brox, Thomas. U-net: Convolutional networks for biomedical image segmentation. in Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18, pp. 234–241. Springer, 2015.
- [9] Zhao, Hengshuang, Shi, Jianping, Qi, Xiaojuan, Wang, Xiaogang, and Jia, Jiaya. Pyramid scene parsing network. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 2881–2890, 2017.
- [10] Rsna intracranial hemorrhage detection. <https://www.kaggle.com/competitions/rsna-intracranial-hemorrhage-detection/overview>, 2019. Accessed: 2024-08-26.
- [11] Grewal, Monika, Srivastava, Muktabh Mayank, Kumar, Pulkit, and Varadarajan, Srikrishna. Radnet: Radiologist level accuracy using deep learning for hemorrhage detection in ct scans. in 2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018), pp. 281–284. IEEE, 2018.
- [12] Monica Jenefer, Balraj M, Senathipathi, K, Aarthi, and Annapandi. Detection and categorization of acute intracranial hemorrhage subtypes using a multilayer densenet-resnet architecture with improved random forest classifier. Concurrency and Computation: Practice and Experience, 34(22):e7167, 2022.
- [13] Arbabshirani, Mohammad R, Fornwalt, Brandon K, Mongelluzzo, Gino J, Suever, Jonathan D, Geise, Brandon D, Patel, Aalpen A, and Moore, Gregory J. Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration. NPJ digital medicine, 1(1):9, 2018.

- [14] Burduja, Mihail, Ionescu, Radu Tudor, and Verga, Nicolae. Accurate and efficient intracranial hemorrhage detection and subtype classification in 3d ct scans with convolutional and long short-term memory neural networks. *Sensors*, 20(19):5611, 2020.
- [15] Morgenstern, Lewis B, Hemphill III, J Claude, Anderson, Craig, Becker, Kyra, Broderick, Joseph P, Connolly Jr, E Sander, Greenberg, Steven M, Huang, James N, Macdonald, R Loch, Messé, Steven R, et al. Guidelines for the management of spontaneous intracerebral hemorrhage: a guideline for healthcare professionals from the american heart association/american stroke association. *Stroke*, 41(9):2108–2129, 2010.
- [16] Van Asch, Charlotte JJ, Luitse, Merel JA, Rinkel, Gabriël JE, van der Tweel, Ingeborg, Algra, Ale, and Klijn, Catharina JM. Incidence, case fatality, and functional outcome of intracerebral haemorrhage over time, according to age, sex, and ethnic origin: a systematic review and meta-analysis. *The Lancet Neurology*, 9(2):167–176, 2010.
- [17] Hackett, Maree L and Anderson, Craig S. Health outcomes 1 year after subarachnoid hemorrhage: an international population-based study. *Neurology*, 55(5):658–662, 2000.
- [18] Kuo, Weicheng, Häne, Christian, Mukherjee, Pratik, Malik, Jitendra, and Yuh, Esther L. Expert-level detection of acute intracranial hemorrhage on head computed tomography using deep learning. *Proceedings of the National Academy of Sciences*, 116(45):22737–22745, 2019.
- [19] Ye, Hai, Gao, Feng, Yin, Youbing, Guo, Danfeng, Zhao, Pengfei, Lu, Yi, Wang, Xin, Bai, Junjie, Cao, Kunlin, Song, Qi, et al. Precise diagnosis of intracranial hemorrhage and subtypes using a three-dimensional joint convolutional and recurrent neural network. *European radiology*, 29:6191–6201, 2019.
- [20] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier,

- Prashant. Deep learning algorithms for detection of critical findings in head ct scans: a retrospective study. *The Lancet*, 392(10162):2388–2396, 2018.
- [21] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [22] Alfaro, Dennis, Levitt, M Andrew, English, David K, Williams, Virgil, and Eisenberg, Ronald. Accuracy of interpretation of cranial computed tomography scans in an emergency medicine residency program. *Annals of emergency medicine*, 25(2):169–174, 1995.
- [23] Lal, Nirish R, Murray, Uwada M, Eldevik, O Petter, and Desmond, Jeffrey S. Clinical consequences of misinterpretations of neuroradiologic ct scans by on-callradiology residents. *American journal of neuroradiology*, 21(1):124–129, 2000.
- [24] Erly, William K, Berger, William G, Krupinski, Elizabeth, Seeger, Joachim F, and Guisto, John A. Radiology resident evaluation of head ct scan orders in the emergency department. *American journal of neuroradiology*, 23(1):103–107, 2002.
- [25] Strub, WM, Leach, JL, Tomsick, T, and Vagal, A. Overnight preliminary head ct interpretations provided by residents: locations of misidentified intracranial hemorrhage. *American journal of neuroradiology*, 28(9):1679–1682, 2007.
- [26] Lee, Hyunkwang, Yune, Sehyo, Mansouri, Mohammad, Kim, Myeongchan, Tajmir, Shahein H, Guerrier, Claude E, Ebert, Sarah A, Pomerantz, Stuart R, Romero, Javier M, Kamalian, Shahmir, et al. An explainable deep-learning algorithm for the detection of acute intracranial haemorrhage from small datasets. *Nature biomedical engineering*, 3(3):173–182, 2019.
- [27] Chang, Peter D, Kuoy, Edward, Grinband, Jack, Weinberg, Brent D, Thompson, Matthew, Homo, Richelle, Chen, Jefferson, Abcede, Hermelinda, Shafie, Mohammad,

- Sugrue, Leo, et al. Hybrid 3d/2d convolutional neural network for hemorrhage evaluation on head ct. *American Journal of Neuroradiology*, 39(9):1609–1616, 2018.
- [28] Titano, Joseph J, Badgeley, Marcus, Schefflein, Javin, Pain, Margaret, Su, Andres, Cai, Michael, Swinburne, Nathaniel, Zech, John, Kim, Jun, Bederson, Joshua, et al. Automated deep-neural-network surveillance of cranial images for acute neurologic events. *Nature medicine*, 24(9):1337–1341, 2018.
- [29] Rsna intracranial hemorrhage detection, 2024. Accessed: 2024-08-27.
- [30] Khoruzhaya, Anna N, Bobrovskaya, Tatiana M, Kozlov, Dmitriy V, Kuligovskiy, Dmitriy, Novik, Vladimir P, Arzamasov, Kirill M, and Kremneva, Elena I. Expanded brain ct dataset for the development of ai systems for intracranial hemorrhage detection and classification. *Data*, 9(2):30, 2024.
- [31] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier, Prashant. Development and validation of deep learning algorithms for detection of critical findings in head ct scans. *arXiv preprint arXiv:1803.05854*, 2018.
- [32] Ma, Deguo, Li, Chen, Du, Tianming, Qiao, Lin, Tang, Dechao, Ma, Zhiyu, Shi, Liyu, Lu, Guotao, Meng, Qingtao, Chen, Zhihao, et al. Phe-sich-ct-ids: A benchmark ct image dataset for evaluation semantic segmentation, object detection and radiomic feature extraction of perihematomal edema in spontaneous intracerebral hemorrhage. *Computers in Biology and Medicine*, 173:108342, 2024.
- [33] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [34] Neethi, AS, Niyas, S, Kannath, Santhosh Kumar, Mathew, Jimson, Anzar, Ajimi Mol, and Rajan, Jeny. Stroke classification from computed tomography scans using 3d

- convolutional neural network. *Biomedical Signal Processing and Control*, 76:103720, 2022.
- [35] Kyung, Sunggu, Shin, Keewon, Jeong, Hyunsu, Kim, Ki Duk, Park, Jooyoung, Cho, Kyungjin, Lee, Jeong Hyun, Hong, GilSun, and Kim, Namkug. Improved performance and robustness of multi-task representation learning with consistency loss between pre-texts for intracranial hemorrhage identification in head ct. *Medical Image Analysis*, 81:102489, 2022.
- [36] Li, Lu, Wei, Meng, Liu, BO, Atchaneyasakul, Kunakorn, Zhou, Fugen, Pan, Zehao, Kumar, Shimran A, Zhang, Jason Y, Pu, Yuehua, Liebeskind, David S, et al. Deep learning for hemorrhagic lesion detection and segmentation on brain ct images. *IEEE journal of biomedical and health informatics*, 25(5):1646–1659, 2020.
- [37] Hssayeni, Murtadha, Croock, M, Salman, A, Al-khafaji, H, Yahya, Z, and Ghoraani, B. Computed tomography images for intracranial hemorrhage detection and segmentation. *Intracranial hemorrhage segmentation using a deep convolutional model*. *Data*, 5(1):14, 2020.
- [38] Efimov, Vyacheslav. Understanding deep learning optimizers: Momentum, adagrad, rmsprop, adam. *Towards Data Science*, 2018. Accessed: 2024-09-09.
- [39] Khandewal, Harsh. Momentum ,RMSprop And Adam Optimizer — medium.com. <https://medium.com/analytics-vidhya/momentum-rmsprop-and-adam-optimizer-5769721b4b19>. [Accessed 30-08-2024].
- [40] He, Kaiming, Zhang, Xiangyu, Ren, Shaoqing, and Sun, Jian. Deep residual learning for image recognition. in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.

- [41] Tan, Mingxing. Efficientnet: Rethinking model scaling for convolutional neural networks. arXiv preprint arXiv:1905.11946, 2019.
- [42] Deng, Jia, Dong, Wei, Socher, Richard, Li, Li-Jia, Li, Kai, and Fei-Fei, Li. Imagenet: A large-scale hierarchical image database. in 2009 IEEE conference on computer vision and pattern recognition, pp. 248–255. Ieee, 2009.
- [43] Ganeshkumar, M, Ravi, Vinayakumar, Sowmya, V, Gopalakrishnan, EA, Soman, KP, and Chakraborty, Chinmay. Identification of intracranial haemorrhage (ich) using resnet with data augmentation using cyclegan and ich segmentation using segan. Multimedia Tools and Applications, 81(25):36257–36273, 2022.

پیوست

موضوعات مرتبط با متن گزارش پایان نامه که در یکی از گروههای زیر قرار می‌گیرد، در بخش پیوستها آورده شوند:

۱. اثبات‌های ریاضی یا عملیات ریاضی طولانی.
۲. داده و اطلاعات نمونه (های) مورد مطالعه (Case Study) چنانچه طولانی باشد.
۳. نتایج کارهای دیگران چنانچه نیاز به تفصیل باشد.
۴. مجموعه تعاریف متغیرها و پارامترها، چنانچه طولانی بوده و در متن به انجام نرسیده باشد.

کد میپل

```
with(DifferentialGeometry):  
with(Tensor):  
DGsetup([x, y, z], M)  
frame name: M  
a := evalDG(D_x)  
D_x  
b := evalDG(-2 y z D_x+2 x D_y/z^3-D_z/z^2)
```

در این قسمت با نحوه‌ای دیگر از درج انواع کدها و برنامه‌ها آشنا می‌شوید:

```

1 # This program prints Hello, world!
2
3 print('Hello, world!')

```

Code 1: My Caption (Python)

```

1 clc; clear all; close all;
2 disp('Hello world!')

```

Code 2: My Caption (MATLAB)

```

1 // Your First C++ Program
2
3 #include <iostream>
4
5 int main() {
6     std::cout << "Hello World!";
7     return 0;
8 }

```

Code 3: My Caption (C++)

```

1 #include <stdio.h>
2
3 int main()
4 {
5     printf("Hello world!\n");
6     return 0;
7 }

```

6 }

Code 4: My Caption (C)

واژه‌نامه‌ی فارسی به انگلیسی

Slice	برش	الف
Slice-wise	برش محور	آسیب مغزی تروماتیک ...
Block	بلوک	injury
Overfit	بیش برآذش	اتصال میانبر
Patient-wise	بیمار محور	ادغام
پ		
Radiography	پرتونگاری	ارزیابی
Radiologist	پرتونگار	اعتبار سنجی
Perceptron	پرسپترون	افزایش مصنوعی داده
Backpropagation	پس انتشار	الحاق
Post-process	پس پردازش	الکترون
Pixel	پیکسل	انتقال یادگیری
Windowing	پنجره‌گذاری	انفجار مشتق
Pre-process	پیش پردازش	X-Ray
ت		
Loss Function	تابع خطا	بایاس
Bias		

System	سامانه	ج
Computed Tomography Scan	سی تی اسکن	
	ش	
Convolutional Neural Network	شبکه عصبی پیچشی	ح
	Network	
Deep Neural Network	شبکه عصبی عمیق	خ
Voting	شورا	
	ط	
Classification	طبقه‌بندی	
	غ	
Non-invasive	غیر تهاجمی	
	ف	
Fuzzy	فازی	
Hyper-parameter	فرآپارامتر	
	ق	
Segmentation	قطعه‌بندی	
	ک	
Cathode	کاتد	
Channel	کanal	د
Cardinality	کاردینالیتی	
Calibration	کالیبراسیون	ز
Undersampling	کاهش داده غالب	س
	گ	
Bootstrap	جاگذاری داده	
Grid Search	جستجوی شبکه‌ای	
	ح	
Annotation	حاشیه‌نویسی	
	خ	
Autoencoder	خودرمزنگذار	
Hemorrhage	خونریزی	
Epidural Hemorrhage	خونریزی اپیدورال	
Intracerebral Hemorrhage (ICH)	خونریزی درون جمجمه‌ای	
Intraventricular Hemorrhage	خونریزی داخل بطنی	
Subdural Hemorrhage	خونریزی سابد دورال	
Cerebral Hemorrhage	خونریزی پارانشیم مغزی	
	Parenchymal Hemorrhage	
Subarachnoid Hemorrhage	ساب آرکنوئید	
Computer	رایانه	
Real Time	زمان واقعی	

Gradient گرادیان

۵

Mask ماسک

Model مدل

Mechanism مکانیزم

ن

ناپدیدشدن مشتق . . . Vanishing Gradient

Neuron نرون

نظر ثانویه . . . Second Opinion

نقشه ویژگی . . . Feature Map

۶

وضوح Resolution

ی

یادگیری عمیق . . . Deep Learning

یادگیری ماشین . . . Machine Learning

واژه‌نامه‌ی انگلیسی به فارسی

	A	کanal
Annotation		طبقه‌بندی
افزایش مصنوعی داده		سی‌تی‌اسکن Computed Tomography Scan
Autoencoder		الحاق Concatenation
	B	رایانه Computer
Backpropagation		شبکه عصبی پیچشی Convolutional Neural Network
Bias		
Block		یادگیری عمیق Deep Learning
Bootstrap		شبکه عصبی عمیق Deep Neural Network
	C	
Calibration		الکترون Electron
Cardinality		خونریزی اپیدورال Epidural Hemorrhage
Cathode		انفجار مشتق Exploding Gradient
Cerebral		
Parenchymal Hemorrhage		فازی Fuzzy

Feature Map	نقشه ویژگی	O
	G	
Gradient	گرادیان	P
Grid Search	جستجوی شبکه‌ای	H
Hemorrhage	خونریزی	
Hyper-parameter	فرآپارامتر	I
Intraventricular Hemorrhage	خونریزی داخل بطنی	
Intracerebral Hemorrhage (ICH)	خونریزی درون جمجمه‌ای	L
Loss Function	تابع خطا	M
Machine Learning	یادگیری ماشین	
Mask	ماسک	
Mechanism	mekanizm	
Model	مدل	N
Neuron	نرون	
Non-invasive	غیر تهاجمی	
Overfit	بیش‌برازش	
Patient-wise	بیمار محور	
Perceptron	پرسپیترون	
Pixel	پیکسل	
Pooling	ادغام	
Post-process	پس‌پردازش	R
Pre-process	پیش‌پردازش	
Radiography	پرتونگاری	
Radiologist	پرتونگار	
Real Time	زمان واقعی	
Resolution	وضوح	S
Segmentation	قطعه‌بندی	
Second Opinion	نظر ثانویه	
Skip Connection	اتصال میانبر	
Slice	برش	
Slice-wise	برش محور	
Subarachnoid Hemorrhage	ساب آر اکنوئید	

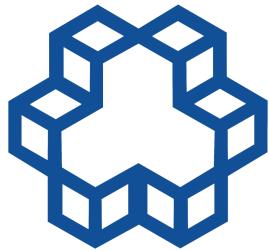
Subdural Hemorrhage	خونریزی ساب دورال	V
System	سامانه	اعتبار سنجی
	T	
Test	ارزیابی	ناپدیدشدن مشتق
Traumatic brain . . .	آسیب مغزی تروماتیک . . .	Voting
	injury	شورا
Transfer Learning	انتقال یادگیری	Windowing
	U	X
Undersampling	کاهش داده غالب	اشعه ایکس
	X-Ray	

Abstract

The rapid and accurate detection of intracranial hemorrhages using CT scan images has consistently been recognized as one of the most significant medical challenges in treating individuals with various brain injuries, strokes, and intracranial hemorrhages. The importance of this issue becomes apparent when even a few minutes of delay in diagnosis can lead to irreversible consequences for patients. Given the complexity and high sensitivity of diagnosing such injuries, this process typically requires a high level of expertise and experience from physicians and radiologists. However, due to the limitations of human resources and the potential for human error, the need for the development of automated diagnostic systems based on deep learning has become increasingly evident. In this context, the primary challenge for physicians, especially in emergency departments, is the accurate and rapid detection of hemorrhage regions in three-dimensional CT scan images. The performance of specialists in analyzing these images is influenced by their level of experience and environmental conditions. The development of an intelligent assistant based on deep neural networks can improve medical processes in this area; however, developing such an assistant faces several challenges. Among these challenges are data imbalance, limited access to large datasets, and the variation in CT scan image quality across different imaging centers. These factors can reduce the accuracy of models in detecting hemorrhagic regions. In this research, a two-stage method based on classification and segmentation, along with a post-processing step, has been developed using the PhysioNet intracranial hemorrhage dataset. In this research, the ResNet-50 model was used in the first stage and the U-Net model in the second stage, resulting in an IoU score of 0.22 and a Dice coefficient of 0.36. These results represent a significant improvement compared to the case where the two-stage method was not utilized.

Key Words:

Deep Neural Network, CT Scan Image Classification, CT Scan Image Segmentation, Intracranial Hemorrhage



**K. N. Toosi University of Technology
Department of Electrical Engineering**

B. Sc. Thesis

Processing Brain CT Scan Images for Interacerbral Brain Hemorrhage with Deep Neural Network

By

Seyed Mohammad Hoseyni

Supervisor

Dr. Amirhossein Nikoofard

September & 2024