

دانشگاه صنعتی خواجه نصیرالدین طوسی تهران
دانشکده مهندسی برق و کامپیوتر

پایان نامه کارشناسی ارشد
گرایش کنترل

پردازش تصاویر CT Scan مغز به منظور قطعه‌بندی
خونریزی داخلی مغز با استفاده از شبکه‌های عصبی
عمیق

پایان نامه

نگارش

سید محمد حسینی

استاد راهنما

دکتر امیرحسین نیکوفرد

شهریور ۱۴۰۳

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته

دفاع

در این صفحه فرم دفاع یا تأیید و تصویب پایان نامه موسوم به فرم کمیته دفاع - موجود در پرونده آموزشی - را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی خواجه نصیرالدین طوسی باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی خواجه نصیرالدین طوسی
تهران

به نام خدا

تعهدنامه اصالت اثر

تاریخ: شهریور ۱۴۰۳

اینجانب سید محمد حسینی متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی خواجه نصیرالدین طوسی بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی خواجه نصیرالدین طوسی ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

سید محمد حسینی

Vincent

امضا

نویسنده پایان نامه، در صورت تمایل میتواند برای پاسخگویی پایان نامه خود را به شخص یا اشخاص و یا ارگان خاصی تقدیم نماید.

پاس کزاری

نویسنده پایان نامه می تواند مراتب امتنان خود را نسبت به استاد راهنما و استاد مشاور و یا دیگر افرادی که طی انجام پایان نامه به نحوی او را یاری و یا با او همکاری نموده اند ابراز دارد.

سید محمد حسینی

شهریور ۱۴۰۳

چکیده

تشخیص سریع و دقیق خونریزی‌های درون جمجمه‌ای با استفاده از تصاویر سی‌تی‌اسکن، همواره به‌عنوان یکی از مهم‌ترین چالش‌های پزشکی در زمینه درمان افراد دارای انواع آسیب‌های مغزی، سکته‌های مغزی و خونریزی‌های درون جمجمه‌ای، مطرح شده است. اهمیت این موضوع زمانی آشکار می‌شود که حتی تأخیر چنددقیقه‌ای در تشخیص می‌تواند منجر به پیامدهای جبران‌ناپذیری برای بیماران شود. باتوجه‌به پیچیدگی و حساسیت بالای تشخیص چنین آسیب‌هایی، این فرایند معمولاً نیازمند تخصص و تجربه‌ی بالای پزشکان و پرتوشناسان است. اما باتوجه‌به محدودیت منابع انسانی و احتمال خطاهای انسانی، نیاز به توسعه سامانه‌های خودکار تشخیص مبتنی بر یادگیری عمیق بیش‌ازپیش احساس می‌شود. در این زمینه چالش اصلی برای پزشکان خصوصاً در بخش فوریت‌های پزشکی، تشخیص دقیق و سریع نواحی خونریزی در تصاویر سه‌بعدی سی‌تی‌اسکن است که عملکرد متخصصین در تحلیل این تصاویر، تحت‌تأثیر میزان تجربه آنها و شرایط محیطی قرار دارد. توسعه یک دستیار هوشمند مبتنی بر شبکه عصبی عمیق، می‌تواند موجب بهبود فرایندهای پزشکی در این حوزه شود؛ اما توسعه این دستیار با چالش‌های متعددی روبرو است. از جمله این چالش‌ها می‌توان به عدم توازن داده‌ها، محدودیت در دسترسی به مجموعه داده‌های بزرگ، و تنوع کیفیت تصاویر سی‌تی‌اسکن در مراکز مختلف تصویربرداری اشاره کرد. این عوامل می‌توانند باعث کاهش دقت مدل‌ها در تشخیص نواحی دارای خونریزی شود. در این پایان‌نامه، یک روش دومرحله‌ای مبتنی بر طبقه‌بندی و قطعه‌بندی، به همراه یک پس‌پردازش توسعه داده شده است.

واژه‌های کلیدی:

شبکه عصبی عمیق، طبقه‌بندی تصاویر سی‌تی‌اسکن، قطعه‌بندی تصاویر سی‌تی‌اسکن، خونریزی درون جمجمه‌ای

فهرست مطالب

صفحه

عنوان

۱	۱ مقدمه
۲	۱-۱ خونریزی درون جمجمه‌ای و اهمیت آن
۲	۲-۱ انواع خونریزی درون جمجمه‌ای
۴	۳-۱ روش‌های مرسوم در تشخیص خونریزی درون جمجمه‌ای
۵	۴-۱ روش‌های رایانه‌ای در پردازش تصاویر پزشکی
۵	۵-۱ مجموعه داده‌ها
۶	۱-۵-۱ مجموعه داده‌ی انجمن پرتوشناسی آمریکای شمالی (RSNA)
۶	۲-۵-۱ مجموعه داده‌ی MosMed
۶	۳-۵-۱ مجموعه داده‌ی CQ500
۷	۴-۵-۱ مجموعه داده‌ی PHE-SICH-CT-IDS
۸	۵-۵-۱ مجموعه داده‌ی PhysioNet
۹	۶-۱ تحقیقات اخیر در زمینه یادگیری ماشین
۱۱	۱-۶-۱ نقاط ضعف موجود در پژوهش‌های گذشته
۱۱	۲-۶-۱ اهداف پژوهش
۱۳	۲ روش‌ها و مجموعه داده
۱۴	۱-۲ بررسی آماری مجموعه داده
۱۸	۲-۲ پیش‌پردازش ^۱
۲۱	۳-۲ روش پردازش تصاویر
۲۱	۱-۳-۲ یادگیری عمیق و اصول اولیه
۲۶	منابع و مراجع
۳۲	واژه‌نامه‌ی فارسی به انگلیسی
۳۴	واژه‌نامه‌ی انگلیسی به فارسی

^۱Pre-process

فهرست اشکال

شکل	صفحه
۱-۱	خونریزی درون جمجمه‌ای [۱] ۳
۲-۱	چند نمونه تصویر از مجموعه داده PHE-SICH-CT-IDS ۸
۳-۱	چند نمونه تصویر از مجموعه داده PhysioNet ۹
۱-۲	یک نمونه کامل از تصاویر سی‌تی‌اسکن ۱۴
۲-۲	خوانش‌های متفاوت از تصاویر سی‌تی‌اسکن [۲] ۱۵
۳-۲	تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها ۱۶
۴-۲	توزیع بیماران و برش‌ها در مجموعه داده PhysioNet ۱۷
۵-۲	توزیع پیکسلی برش‌ها برای برش‌های داداری خونریزی در مقال برش‌های سالم ۱۷
۶-۲	توزیع نرمال شده پیکسل‌های دارای خونریزی درمقابل تمام پیکسل‌های تصاویر ۱۸
۷-۲	توزیع خونریزی بر اساس برش‌ها ۱۹
۸-۲	اثر بافت‌های متفاوت در یکای Hounsfield [۲] ۱۹
۹-۲	تاثیر اثر پنجره‌گذاری در نمایش خونریزی در یک برش از سی‌تی‌اسکن ۲۱
۱۰-۲	مدلسازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نرون‌ها با استفاده از
۲۳	لایه‌های پنهان [۳] ۲۳

فهرست جداول

صفحه

جدول

۱-۱ انواع زیرگروه‌های خونریزی درون جمجمه‌ای [۴] ۴

فهرست نمادها

نماد	مفهوم
\mathbb{R}^n	فضای اقلیدسی با بعد n
\mathbb{S}^n	کره n یکه بعدی
M^m	خمینه m -بعدی M
$\mathfrak{X}(M)$	جبر میدان‌های برداری هموار روی M
$\mathfrak{X}^1(M)$	مجموعه میدان‌های برداری هموار 1 یکه روی (M, g)
$\Omega^p(M)$	مجموعه p -فرمی‌های روی خمینه M
Q	اپراتور ریچی
\mathcal{R}	تانسور انحنای ریمان
ric	تانسور ریچی
L	مشتق لی
Φ	2 -فرم اساسی خمینه تماسی
∇	التصاق لوی-چویتای
Δ	لاپلاسین ناهموار
∇^*	عملگر خودالحاق صوری القا شده از التصاق لوی-چویتای
g_s	متر ساساکی
∇	التصاق لوی-چویتای وابسته به متر ساساکی
Δ	عملگر لاپلاس-بلترامی روی p -فرم‌ها

فصل اول

مقدمه

۱-۱ خونریزی درون جمجمه‌ای و اهمیت آن

خونریزی درون جمجمه‌ای^۱ یک وضعیت اضطراری پزشکی است که تشخیص سریع و دقیق آن به‌منظور درمان مؤثر بیمار و کاهش خطر ناتوانی شدید یا مرگ، حیاتی است [۵]. خونریزی درون جمجمه‌ای می‌تواند به دلایل مختلفی از جمله آسیب مغزی تروماتیک^۲، بیماری‌های عروقی، یا مشکلات مادرزادی ایجاد شود و بر اساس محل خونریزی در مغز طبقه‌بندی می‌شود [۶]. به‌صورت تقریبی سالانه بین ۴۰۰۰۰ تا ۶۷۰۰۰ بیمار دارای خونریزی درون جمجمه‌ای در ایالات متحده آمریکا شناسایی می‌شوند که نرخ مرگ‌ومیر آنها در ۳۰ روز اول حادثه در حدود ۴۰ درصد است که در نتیجه آن، خونریزی درون جمجمه‌ای به یکی از بیماری‌ها با بیشترین آمار مرگ و میر تبدیل شده است. این در حالی است که عوارض دیگر این بیماری نیز بسیار خطرناک است، به‌عنوان مثال بیشتر از ۴۶ درصد بیماران که دارای نوع خاصی از خونریزی درون جمجمه‌ای هستند، پس از بهبود به‌صورت دائمی دچار اختلالات شناختی می‌شوند [۷، ۸، ۹، ۱۰، ۱۱].

باتوجه به نرخ بالای مرگ‌ومیر مرتبط با خونریزی درون جمجمه‌ای، تشخیص سریع و دقیق خونریزی درون جمجمه‌ای با استفاده از روش‌های تصویربرداری ضروری است [۱۲]. سی‌تی‌اسکن^۳ شایع‌ترین روش برای تشخیص سریع خونریزی خصوصاً در مراکز فوریت‌های پزشکی به‌حساب می‌آید که دقت مناسب را برای تشخیص این بیماری به متخصصین می‌دهد [۱۳، ۵، ۷، ۱۴].


۲-۱ انواع خونریزی درون جمجمه‌ای

با پاره شدن عروق شریانی مغز، خون از درون عروق اصلی وارد بافت مغز می‌شود؛ این مسئله در حالی است که لخته‌شدن خون در داخل بدن سخت‌تر انجام می‌شود و به‌موجب آن خون وارد بافت مغز شده و با افزایش فشار داخل جمجمه، به بافت‌های حیاتی صدمات جدی وارد می‌کند. همان‌طور که در شکل ۱-۱ مشخص است، با پاره شدن شریان‌های خونی درون مغز، خونی که وارد بافت مغز شده است و یک ضایعه بزرگ خونریزی را ایجاد کرده و این ضایعه در تصویر سی‌تی‌اسکن به‌صورت یک بافت که رنگ روشن‌تری نسبت به محیط اطراف دارد قابل‌شناسایی است.

¹Intracranial Hemorrhage

²Traumatic Brain Injury

³Computed Tomography Scan



شکل ۱-۱: خونریزی درون جمجمه‌ای [۱]

خونریزی درون جمجمه‌ای متناسب با محل وقوع به زیرگروه‌های مختلفی تقسیم می‌شوند؛ این طبقه‌بندی شامل خونریزی اپیدورال (EDH)^۱، خونریزی ساب‌دورال (SDH)^۲، خونریزی ساب‌آراکنوئید (SAH)^۳، خونریزی پارانشیم مغزی (CPH)^۴، و خونریزی داخل بطنی (IVH)^۵ است [۸، ۱۵]. در جدول ۱-۱ نمونه‌هایی از زیرگروه‌های خونریزی درون جمجمه‌ای، محل خونریزی، زمینه، علت وقوع، شکل و علائم بالینی نشان داده شده است؛ همانطور که از تصاویر مشخص است، تشخیص بعضی از انواع خونریزی درون جمجمه‌ای به علت حضور در اطراف بقیه بافت‌های مغز، خصوصاً جمجمه که از تراکم بیشتری برخوردار است و یا شکل پیچیده‌ای که دارند، حتی برای متخصصین نیز دشوار است.


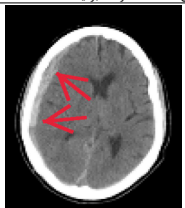



¹Epidural

²Subdural

³Subarachnoid

⁴Cerebral Parenchymal

⁵Intraventricular

EDH	SDH	SAH	IVH	CPH	محل
بین سخت‌شامه و جمجمه	بین سخت‌شامه و عنکبوتیه	بین عنکبوتیه و نرم‌شامه	داخل بطن	داخل مغز	تصویر
					
ضربه یا پس از جراحی	ضربه	پارگی آنوریسم یا ناهنجاری‌های شریانی-وریدی یا ضربه عمدتاً شریانی	می‌تواند با خونریزی‌های درون‌مغزی و زیرعنکبوتیه همراه باشد	قشار خون بالا، ضربه، ناهنجاری‌های شریانی-وریدی، تومور، و غیره	زمینه‌ها
شریانی	وریدی (وریدهای یل‌زن)	عمدتاً شریانی	شریانی یا وریدی	شریانی یا وریدی	علت وقوع
عدسی شکل	هلالی	در امتداد شیارها و شکاف‌ها	مطابق با شکل بطن	معمولاً گرد	شکل
حاد (شکستگی جمجمه و تغییر وضعیت دهنی)	ممکن است تدریجی باشد (بدتر شدن سردرد)	حاد (بدترین سردرد زندگی)	حاد (شروع ناگهانی سردرد، حالت تهوع، استفراغ)	حاد (شروع ناگهانی سردرد، حالت تهوع، استفراغ)	علامت بالینی

جدول ۱-۱: انواع زیرگروه‌های خونریزی درون جمجمه‌ای [۴]

۳-۱ روش‌های مرسوم در تشخیص خونریزی درون جمجمه‌ای

در حال حاضر تصاویر سی‌تی‌اسکن، به‌عنوان استاندارد اصلی و غیرتهاجمی^۱ برای تشخیص خونریزی درون جمجمه‌ای است. سی‌تی‌اسکن یک نوع تصویر پرتونگاری^۲ سه‌بعدی است که متشکل از تصاویر دوبعدی از اندام بدن است. روش عمومی پردازش تصاویر سی‌تی‌اسکن به‌صورت دستی انجام می‌پذیرد که به‌موجب آن متخصصین پرتونگاری^۳ و پزشکی، با بررسی برش‌های^۴ سی‌تی‌اسکن را به‌صورت مجزا بررسی می‌کنند و مناطق خونریزی را تشخیص می‌دهند. این فرایند به دلیل وابستگی به تخصص و تجربه فردی، شرایط محیطی و فشار کاری، زمان‌بر و مستعد خطا است. [۷، ۵، ۱۳، ۱۴، ۱۲]. فرایند بررسی دستی تصاویر سی‌تی‌اسکن، زمان‌بر بوده و به‌شدت به دردسترس بودن پرتونگارهای^۵ باتجربه بستگی دارد [۸]. در شرایط اضطراری، خصوصاً در مراکز فوریت‌های پزشکی، زمانی که برای پردازش برش‌های سی‌تی‌اسکن صرف می‌شود، می‌تواند به طور قابل توجهی در نتایج درمان بیمارها تأثیر بگذارد؛ این مسئله در مواردی از اهمیت بیشتری برخوردار می‌شود که درمان بیمار نیازمند مداخله فوری گروه پزشکی است [۱۴]. نکته حائز اهمیت در روش معمول برای بررسی تصاویر سی‌تی‌اسکن در مراکز پزشکی این است که بررسی اولیه تصاویر، توسط پزشکان و پرتونگارهایی با تجربه کمتر انجام می‌شود و در مراحل بعدی این تصاویر توسط متخصصینی با تجربه بیشتر بررسی می‌شود. تعدادی از مطالعات نشان داده‌اند که در روش مذکور، بین پزشکان و پرتونگارهایی که در مرحله اول تصاویر را بررسی می‌کنند و پزشکان و پرتونگارهایی که در ادامه این تصاویر را بررسی می‌کنند، اختلاف نظر وجود دارد که این مسئله می‌تواند منجر به عواقب جبران‌ناپذیر گردد [۱۳، ۱۶، ۱۷، ۱۸، ۱۹]. احتمال خطای انسانی در بررسی دستی تصاویر پیچیده و

¹Non-invasive²Radiography³Radiology⁴Slice⁵Radiologist

سه بعدی سی تی اسکن، از دیگر نقاط ضعف روش معمول پردازش این تصاویر است، به ویژه در محیط های شلوغ و پرتنش که پرتونگاریها ممکن است تحت فشار زیاد باشند [۱۳].

۴-۱ روش های رایانه ای در پردازش تصاویر پزشکی

اهمیت مسئله خونریزی درون جمجمه ای و چالش های مرتبط با آن در بخش قبل مورد بررسی قرار گرفت، روش های مبتنی بر پردازش رایانه ای^۱ تصاویر پزشکی، می تواند یک راه حل مناسب برای رفع نقاط ضعف روش کنونی بررسی تصاویر پزشکی باشد [۵، ۷، ۱۳، ۲۰، ۲۱، ۱۴، ۲۲، ۱۲]. ابزارهای خودکار برای تشخیص و کمیت سنجی خونریزی، از پیشرفت های روش های یادگیری ماشین^۲ و یادگیری عمیق^۳ و سامانه های^۴ تشخیص به کمک رایانه^۵ استفاده می کنند تا تجزیه و تحلیل سریع و دقیقی از تصاویر سی تی اسکن ارائه دهند. با خودکارسازی تشخیص خونریزی درون جمجمه ای و استفاده از آنها به صورت نظر ثانویه^۶، این سامانه ها می توانند بار کاری پرتونگاریها را کاهش دهند، دقت تشخیص را افزایش دهند از اشتباهات متخصصین جلوگیری کنند، زمان تشخیص را به حداقل برسانند، بعضی از هزینه های فرایند درمان را به علت کاهش دخالت انسانی کاهش دهند و به صورت کلی فرایند تشخیص را بهبود ببخشند که این موارد به بهبود نتایج بیماران منجر خواهد شد. با این حال، ضمن اینکه سامانه های تشخیص به کمک رایانه نویدبخش هستند؛ اما امکان خطا در آنها وجود دارد که می تواند تصمیم گیری بالینی را با مشکلاتی روبرو کند؛ بنابراین، ادغام این ابزارها در عمل باید با دقت انجام شود [۲۲].

۵-۱ مجموعه داده ها

در سال های اخیر، مجموعه داده های متعددی برای پشتیبانی از توسعه مدل های^۷ یادگیری عمیق در حوزه تصویربرداری پزشکی، به ویژه برای طبقه بندی خونریزی درون جمجمه ای ایجاد شده اند. در ادامه به بررسی برخی از مهم ترین مجموعه داده هایی که در این حوزه مورد استفاده قرار گرفته اند، می پردازیم.

¹Computer

²Machine Learning

³Deep Learning

⁴System

⁵Computer-aided Diagnosis

⁶Second Opinion

⁷Model

۱-۵-۱ مجموعه داده‌ی انجمن پرتوشناسی آمریکای شمالی (RSNA)

مجموعه داده‌ی RSNA Intracranial Hemorrhage Detection [۲۳، ۴] که برای چالش یادگیری ماشین سال ۲۰۱۹ انجمن پرتونگاری آمریکای شمالی جمع‌آوری شده است، یکی از منابع برجسته در زمینه طبقه‌بندی خونریزی درون جمجمه‌ای محسوب می‌شود. این مجموعه داده، از چند مرکز پرتونگاری جمع‌آوری شده است که سه مؤسسه دانشگاه استنفورد در ایالات متحده، دانشگاه فدرال سائو پائولو در برزیل و بیمارستان دانشگاه توماس جفرسون در ایالات متحده شامل آنها می‌باشد. این مجموعه شامل تصویر سی‌تی‌اسکن مغزی ۲۵۳۱۲ بیمار است که از این میان، ۸۸۸۹ بیمار دارای انواع مختلف خونریزی درون جمجمه‌ای هستند. تصاویر سی‌تی‌اسکن درون این مجموعه داده در سطح برش، حاشیه‌نویسی^۱ شده‌اند. تصاویر سی‌تی‌اسکن در این مجموعه داده به فرمت DICOM^۲ ارائه شده‌اند که استاندارد برای تصویربرداری پزشکی است. این مجموعه داده به‌طور گسترده‌ای در طبقه‌بندی انواع خونریزی مورد استفاده قرار گرفته و به‌عنوان منبعی بنیادی برای آموزش و اعتبارسنجی مدل‌های یادگیری ماشین که به طبقه‌بندی خونریزی درون جمجمه‌ای تبدیل شده است.

۲-۵-۱ مجموعه داده‌ی MosMed

مجموعه داده‌ی MosMed [۲۴]، یک مجموعه داده خونریزی درون جمجمه‌ای می‌باشد که در روسیه جمع‌آوری شده است. این مجموعه داده به‌طور خاص برای تسهیل توسعه سیستم‌های هوش مصنوعی به‌منظور تشخیص و طبقه‌بندی خونریزی درون جمجمه‌ای طراحی شده است. این مجموعه شامل سی‌تی‌اسکن مغزی ۸۰۰ بیمار است که ۴۰۰ بیمار دارای خونریزی درون جمجمه‌ای هستند. این مجموعه داده در سطح بیمار حاشیه‌نویسی شده است و تصاویر آن به صورت فایل‌های DICOM در دسترس قرار دارد.

۳-۵-۱ مجموعه داده‌ی CQ500

مجموعه داده‌ی CQ500 [۲۵]، یک مجموعه داده مهم است که از چند مرکز متفاوت شامل پنج مرکز مختلف در هند می‌باشد. این مجموعه داده حاوی ۴۹۱ سی‌تی‌اسکن سر است که برای انواع خونریزی‌های درون جمجمه‌ای در سطح بیمار حاشیه‌گذاری شده‌اند. تصاویر سی‌تی‌اسکن در این مجموعه داده به صورت


¹ Annotation

² Digital Imaging and Communications in Medicine

فایل DICOM ارائه شده.

۴-۵-۱ مجموعه داده‌ی PHE-SICH-CT-IDS


مجموعه داده‌ی PHE-SICH-CT-IDS [۲۶]، اگرچه به‌طور خاص برای خونریزی درون‌جمجمه‌ای جمع‌آوری نشده است، اما به دلیل تمرکز آن بر وظایف طبقه‌بندی، تشخیص و قطعه‌بندی مرتبط به Perihematomal Edema در خونریزی درون‌جمجمه‌ای قابل توجه است. این مجموعه داده از بیمارستان Shengjing در چین جمع‌آوری شده است که شامل تصویر سی‌تی‌اسکن ۱۲۰ بیمار است که تمامی آنها خونریزی درون‌جمجمه‌ای دارند و حاشیه‌نویسی آنها در سطح برش انجام شده است. تصاویر سی‌تی‌اسکن در این مجموعه داده به صورت فایل‌های NIFTI، JPG و PNG ارائه شده است. مجموعه داده‌ی PHE-SICH-CT-IDS منبعی ارزشمند برای توسعه مدل‌های یادگیری عمیق که هدف آنها طبقه‌بندی، تشخیص یا قطعه‌بندی می‌باشد، است. در شکل ۱-۲ چند برش از تصاویر مجموعه داده PHE-SICH-CT-IDS است، همانطور که در این تصویر مشخص است، در اطراف ضایعه خونریزی، یک حاشیه تیره‌تر وجود دارد که به آن Edma گفته می‌شود و این ضایعه قطعه‌بندی شده است؛ همچنین این مجموعه داده حاشیه‌نویسی مناسب برای وظیفه تشخیص را نیز دارد.



شکل ۱-۲: چند نمونه تصویر از مجموعه داده PHE-SICH-CT-IDS

۵-۵-۱ مجموعه داده‌ی PhysioNet

مجموعه داده‌ی خونریزی درون جمجمه‌ای PhysioNet [۲۷]، مجموعه داده‌ای می‌باشد که در ادامه این مطالعه از آن استفاده شده است. این مجموعه داده از بیمارستان Al Hilla در عراق جمع‌آوری شده است و شامل ۸۲ تصویر سی‌تی‌اسکن از بیماران است که ۳۶ نفر از آنها دارای خونریزی درون جمجمه‌ای می‌باشند. این مجموعه داده، شامل حاشیه‌نویسی‌های مناسب برای وظایف طبقه‌بندی و قطعه‌بندی است که آن را به تنها مجموعه داده با دسترسی عمومی تبدیل می‌کند که امکان قطعه‌بندی خونریزی درون جمجمه‌ای را فراهم می‌کند. جزییات بیشتر در مورد این دیتاست در؟؟ توضیح داده شده است. تصویر شکل ۱-۳ چند نمونه از برش‌های خونریزی درون این مجموعه داده را مشخص می‌کند.



شکل ۱-۳: چند نمونه تصویر از مجموعه داده PhysioNet

۶-۱ تحقیقات اخیر در زمینه یادگیری ماشین

در سال‌های اخیر، یادگیری عمیق پیشرفت‌های قابل توجهی در زمینه طبقه‌بندی و قطعه‌بندی خونریزی درون‌جمجمه‌ای داشته است و مطالعات متعددی به بررسی این موضوع پرداخته‌اند. این مدل‌ها نه تنها از نظر نوآوری فنی قابل توجه هستند، بلکه پتانسیل بالای آنها می‌تواند باعث استفاده از آنها در سیستم‌های تشخیص و درمان بیمارستان‌ها بشود که می‌تواند بهبود عملکرد کادر درمان، کاهش هزینه‌ها و زمان تشخیص و افزایش دقت در طبقه‌بندی خونریزی درون‌جمجمه‌ای را به همراه داشته باشد. برخی از این مطالعات، از جمله تحقیقات Titano [۲۲]، Arbabshirani [۷] و Kuo [۱۲]، و همکارانشان مدل‌های پیشنهادی خود را در محیط‌های بیمارستانی آزمایش کرده‌اند و نتایج آن‌ها نشان داده است که این سیستم‌ها می‌توانند به طور مؤثری در بهبود نتایج درمان برای بیماران نقش داشته باشند. به طور خاص، Titano و همکاران یک سیستم یادگیری عمیق خودکار با دقت ۸۷٪ و حساسیت ۹۴٪ معرفی کرده‌اند که عملکرد آن با کارشناسان انسانی مقایسه شده و در محیط‌های بالینی به کار گرفته شده است. همچنین، Kuo و همکاران یک شبکه عصبی پیچشی برای طبقه‌بندی خونریزی حاد درون‌جمجمه‌ای با دقت ۹۹٪ و AUC برابر با ۹۹٪ توسعه داده‌اند که نشان‌دهنده قابلیت اطمینان بالا در شرایط بالینی است. سایر مطالعات، مانند Chang [۲۱] و Chilamkurthy [۱۴] نیز نتایج قابل توجهی در زمینه طبقه‌بندی

خونریزی‌ها با استفاده از مدل‌های یادگیری عمیق ارائه کرده‌اند.

Neethi [۲۸] و همکاران مروری بر روش‌های مختلف یادگیری عمیق انجام داده‌اند که از مجموعه داده‌های مختلفی از جمله PhysioNet و مجموعه داده RSNA استفاده کردند. آنها از مجموعه داده RSN که شامل ۲۵۳۱۲ تصویر سی تی اسکن از بیماران است، برای آموزش مدل‌های یادگیری عمیق بهره بردند و عملکرد آن را بر روی مجموعه داده PhysioNet ارزیابی کردند. آنها با استفاده از مدل ResNet50-V2 بر روی مجموعه داده PhysioNet به ۷۶٪ Recall و F1 Score برابر با ۶۷٪ دست یافتند که این نتایج به صورت برش محور^۱ گزارش شده است. در میان کارهایی که روی مجموعه داده PhysioNet انجام شده است، Kyung [۲۹] و همکاران شبکه‌ای به نام SMART-Net را پیشنهاد کردند که به کمک روش انتقال یادگیری^۲ توانسته‌اند به F1 Score برابر با ۸۴٪، Sensitivity برابر با ۹۷٪ و Specificity برابر با ۷۴٪ بیمار محور^۳ دست یابند. در ادامه Hssayeni [۲۷] و همکاران، از مدل معروف U-Net استفاده کرده‌اند تا یک مدل برای قطعه‌بندی تصاویر سی تی اسکن آموزش دهند. آموزش این مدل با تصاویر ورودی که از ابعاد اصلی برخوردار هستند، باعث شده‌است تا مدل ماسک‌هایی^۴ تماماً سیاه تولید کند که به معنی عدم تشخیص هیچ پیکسلی دارای خونریزی می‌باشد. از این نتیجه می‌توان برداشت کرد که معیار IoU و Dice در آموزش مدل با ابعاد اصلی برابر^۵ بوده است. در ادامه این تحقیق، Hssayeni و همکاران تصاویر ورودی را به قسمت‌های 160×160 تقسیم کرده‌اند که به موجب آن هر تصویر سی تی اسکن، به تعدادی تصویر دارای همپوشانی تبدیل می‌شوند و روی هر پیکسل از تصویر سی تی اسکن، ۴ مرتبه پیش‌بینی انجام می‌شود. آنها با تعدیل تعداد تصاویر دارای خونریزی و تصاویری که خونریزی ندارند به روش‌های کاهش داده غالب^۵ و افزایش مصنوعی داده^۶ و توسعه یک روش شورایی برای تصمیم‌گیری، توانستند معیار شباهت IoU برابر ۲۱/۸٪ و معیار Dice برابر ۳۱/۵٪ دست پیدا کنند. Li [۳۰] و همکاران نیز یک مدل U-Net را روی مجموعه داده PhysioNet آموزش داده‌اند اما از جزئیات این آموزش اطلاعات زیادی را مطرح نکرده‌اند. آنها با استفاده از مدل U-Net توانسته‌اند معیار شباهت IoU برابر ۲۱٪ و معیار Dice برابر ۳۵٪ را بدست آورده‌اند.

¹ Slice-wise

² Transfer Learning

³ Patient-wise

⁴ Mask

⁵ Undersampling

⁶ Augmentation

۱-۶-۱ نقاط ضعف موجود در پژوهش‌های گذشته

با وجود پیشرفت‌های قابل توجه در مدل‌های یادگیری عمیق، هنوز چالش‌هایی در تفسیرپذیری مدل‌های شبکه عصبی وجود دارد که می‌توان از آن به عنوان یکی از نقاط ضعف ادبیات موجود در این زمینه دانست زیرا تفسیرپذیر بودن یک سیستم هوش مصنوعی، یکی از معیارهای اساسی برای متخصصین حوزه پزشکی است تا از این ابزار استفاده کنند. از دیگر نقاط ضعف در ادبیات خونریزی درون‌جمجمه‌ای، دردسترس نبودن مجموعه داده‌های بزرگ با حاشیه‌نویسی مناسب و مجموعه داده‌های مربوط به بیمارستان‌ها و دستگاه‌های موجود در ایران است؛ وجود یک مجموعه داده با ابعاد مناسب از دستگاه‌های موجود در ایران، می‌تواند مسیر توسعه یک سیستم هوش مصنوعی در زمینه خونریزی درون‌جمجمه‌ای را در ایران وجود هموار سازد. از دیگر نقاط ضعف موجود در ادبیات موجود در این مسئله، استفاده از شبکه‌هایی با ابعاد بسیار بزرگ توسط محققین می‌باشد که نیازمند پردازشگرهایی با هزینه بیشتر هستند. از مهم‌ترین مشکلات موجود در تحقیقات گذشته، توجه نکرده به بیمارمحور بودن داده‌ها هنگام تفکیک آنها به زیرمجموعه‌های آموزش و ارزیابی اشاره کرد که در نتیجه آن برش‌هایی از یک بیمار که شباهت بسیار زیادی به یکدیگر دارند، در زیرمجموعه‌های آموزش و ارزیابی قرار گیرد که در نتیجه آن همبستگی بین این دو مجموعه داده زیاد خواهد شد. استفاده نکردن از روش مرسوم K-Fold-Cross-Validation، یا نداشتن روش شورا در تصمیم‌گیری در این روش، یکی دیگر از معایب موجود در تحقیقات گذشته است که به موجب آن، تعمیم‌پذیری مدل بدست آمده از این تحقیقات محل ابهام می‌باشد. به عنوان یکی از اشکالات مهم در ادبیات موجود، عدم ارائه معیارهای مناسب و کافی برای ارزیابی عملکرد مدل‌های یادگیری ماشین است که در نتیجه آن، نتایج بدست آمده از شفافیت کافی برخوردار نیست.

۱-۶-۲ اهداف پژوهش

در این پژوهش تلاش شده تا در گام نخست یک روش دو مرحله‌ای شامل یک مدل طبقه‌بندی و یک مدل قطعه‌بندی که به صورت متوالی استفاده می‌شوند توسعه داده شود که این روش، موجب بهبود عملکرد مدل‌های پردازش تصویر در قطعه‌بندی شده است؛ نکته حائز اهمیت در این روش این است که با کاهش امکان ایجاد False Positive در پیش‌بینی‌های مدل قطعه‌بندی، باعث بهبود عملکرد مدل‌های قطعه‌بندی خواهد شد. در گام بعدی یک پس‌پردازش^۱ در لایه تصمیم‌گیری توسعه داده شده است که این پس‌پردازش نیز موجب بهبود عملکرد مدل طبقه‌بندی شده است. در انتها با استفاده از انواع معیارهای

¹Post-process

موجود، آموزش مدل با استفاده از روش 5-Fold-Cross-Validation، طراحی یک ضابطه تصمیم‌گیری^۱ و استفاده از روش‌هایی برای تفسیرپذیر کردن مدل، امکان تحلیل جامع از عملکرد مدل فراهم شده است.


^۱Decision Policy

فصل دوم

روش‌ها و مجموعه داده

۱-۲ بررسی آماری مجموعه داده


در این پژوهش از مجموعه داده PhysioNet [۲۷، ۳۱] استفاده شده است که شامل حاشیه‌نویسی برای وظیفه طبقه‌بندی و قطعه‌بندی است. این مجموعه داده شامل مجموعه‌ای از سی‌تی‌اسکن‌های مغزی است که به صورت عمومی در دسترس است.



شکل ۱-۲: یک نمونه کامل از تصاویر سی‌تی‌اسکن

همانطور که در **شکل ۱-۲** نمایش داده شده است، سی‌تی‌اسکن یک نوع تصویر سه‌بعدی است که از برش‌های دو بعدی تشکیل شده است. **شکل ۲-۲** نشان می‌دهد که با توجه به جهت بررسی برش‌های سی‌تی‌اسکن، این تصاویر به سه دسته Axial، Sagittal و Coronal تقسیم می‌شوند.

مجموعه داده PhysioNet شامل ۸۲ سی‌تی‌اسکن با برش‌های Axial است که بین فوریه و آگوست ۲۰۱۸ از بیمارستان آموزشی Al Hilla در عراق جمع‌آوری شده است. این اسکن‌ها شامل طیف وسیعی از بیماران هستند که از یک روز تا ۷۲ سال سن دارند و میانگین سن آنها $۱۹/۵ \pm ۲۷/۸$ سال است. تنوع سنی این مجموعه داده بر مقیاس، شکل جمجمه و بافت مغز در سی‌تی‌اسکن تأثیر می‌گذارد، عاملی که می‌تواند عملکرد مدل‌های یادگیری عمیق برای تشخیص و قطعه‌بندی خونریزی درون جمجمه‌ای را تحت تأثیر قرار دهد. توزیع جنسیت در این مجموعه داده به گونه‌ای است که ۵۶٪ بیماران مرد و ۴۴٪ آنها زن هستند. ۸۲ بیماری که در این مجموعه داده وجود دارد که ۷ مورد از آنها طی قرائند حاشیه‌نویسی گم شده‌اند و از بین ۷۵ بیمار موجود، ۳۶ نفر دارای خونریزی درون جمجمه‌ای تشخیص داده شدند. **شکل ۲-۳** نمودار مربوط به تعداد برش‌های هر بیمار در این مجموعه داده است؛ تصاویر



شکل ۲-۲: خوانش‌های متفاوت از تصاویر سی‌تی‌اسکن [۲]


سی‌تی‌اسکن موجود در این مجموعه داده، به طور متوسط شامل ۳۴ برش با ضخامت برش ۵ میلی‌متر دارند و در مجموع ۲۸۱۴ برش در این مجموعه داده وجود دارد.

با این حال، این مجموعه داده به دلیل عدم توازن در سطح برش شناخته می‌شود، زیرا تنها ۳۱۸ برش دارای خونریزی هستند در حالی که بقیه ۲۴۹۶ برش سالم هستند. در این مجموعه داده، ۲۴ برش شامل زیرگروه IVH، ۷۳ برش شامل زیرگروه CPH، ۱۸ برش شامل زیرگروه SDH، ۱۷۳ برش شامل زیرگروه EDH و ۵۶ برش شامل زیرگروه SDH هستند. با توجه به تفاوت شکل انواع زیرگروه‌های خونریزی و محل وقوع آنها، این ارقام نشان دهنده عدم وجود تعداد برش کافی برای بعضی از انواع زیرگروه‌های است. در این مجموعه داده، برش‌های سی‌تی‌اسکن توسط دو پرتوشناس بررسی شده‌است و هر برش سی‌تی‌اسکن از نظر وجود خونریزی یا شکستگی توسط آنها بررسی و برچسب‌گذاری شده‌است. در ادامه سی‌تی‌اسکن‌های دو بیمار، به علت کیفیت ضعیف تصاویر و به توصیه پرتوشناس‌ها حذف شدند [۲۹].

شکل ۲-۴ نمودارهای توزیع بیمار محور و برش محور مجموعه داده را نمایش می‌دهد؛ همانطور که از

شکل ۲-۴ مشخص است در بررسی بیمار محور این مجموعه داده، عدم توازن دیده نمی‌شود اما در بررسی برش محور، همانطور که در **شکل ۲-۴ ب** مشخص است، عدم توازن شدیدی در تعداد برش‌های دارای خونریزی وجود دارد که این مسئله آموزش مدل‌های شبکه عصبی را با چالش مواجه می‌کند.

علاوه بر وجود عدم توازن در حالت برش محور، عدم توازن شدیدی در قطعه‌بندی نواحی دارای خونریزی نسبت به نواحی سالم در برش‌های دارای خونریزی وجود دارد که به موجب آن در یک تصویر با




شکل ۲-۳: تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها

ابعاد 512×512 ، به صورت میانگین نزدیک به ۲۰۰۰ پیکسل^۱ دارای خونریزی درون مجموعه‌ای وجود دارد که این مسئله آموزش مدل‌های شبکه عصبی را به منظور وظیفه قطعه‌بندی با چالش بسیار جدی مواجه می‌کند. شکل ۲-۵ نشان‌دهنده توزیع نرمال شده^۲ مقدار پیکسل‌های برش‌های سالم و برش‌های دارای خونریزی می‌باشد، با توجه به شکل ۲-۵، اکثر پیکسل‌های تصاویر مقداری نزدیک به ۱۰۰۰- و نقطه بیشینه محلی بعدی برای این نمودار توزیع، در نزدیک مقادیر ۳۰ می‌باشد که این مقادیر به نسبت پیکسل‌ها با مقادیر نزدیک به ۱۰۰۰- خیلی کمتر می‌باشد.


شکل ۲-۶ نمایش‌دهنده توزیع پیکسل‌های دارای خونریزی و تمام پیکسل‌های تصاویر رادیوگرافی می‌باشد که در محدوده بین ۱۰۰- تا ۱۰۰ واقع شده است و نسبت به مقادیر همین بازه نرمال گشته است. همانطور که از این دو نمودار مشخص است، مقادیر مربوط به ضایعه خونریزی، مقدار کمی از مقادیر بقیه بافت‌های مغز روشن‌تر است اما همپوشانی این دو نمودار نشان می‌دهد که تشخیص خونریزی

¹Pixel

²Normalized




شکل ۲-۴: توزیع بیماران و برش‌ها در مجموعه داده PhysioNet



شکل ۲-۵: توزیع پیکسلی برش‌ها برای برش‌های دادرسی خونریزی در مقال برش‌های سالم

درون مجموعه‌ای تنها با استفاده از مقدار پیکسلی آن بسیار دشوار می‌باشد و نیاز هست تا از شبکه‌هایی استفاده شود تا به اشکال موجود در تصویر نیز حساسیت داشته باشند.

شکل ۲-۳ توزیع خونریزی درون مجموعه‌ای را بر اساس شماره برش در تصویر سی‌تی‌اسکن نشان می‌دهد که بر اساس آن مشخص است به ازای بعضی از شماره برش‌ها، خونریزی درون مجموعه‌ای وجود ندارد و این برش‌ها از اهمیت کمتری برای مدل‌های یادگیری ماشین برخوردار هستند. باتوجه به مطالبی که دی این بخش مطرح شد، می‌توان نتیجه گرفت که مجموعه داده PhysioNet، به عنوان تنها مجموعه داده عمومی قطعه‌بندی خونریزی درون مجموعه‌ای، می‌تواند یک مجموعه داده معیار برای بررسی عملکرد مدل‌های پردازش تصویر باشد.



شکل ۲-۶: توزیع نرمال شده پیکسل‌های دارای خونریزی در مقابل تمام پیکسل‌های تصاویر

۲-۲ پیش‌پردازش^۱


در تصاویر پرتونگاری سی‌تی‌اسکن، از اشعه ایکس^۲ به منظور ثبت تصویر اندام درونی بدن استفاده می‌شود. در این روش، یک کاتد^۳ را برانگیخته می‌کنند تا الکترون‌های^۴ پراثری را آزاد کند. با آزاد شدن الکترون‌ها، انرژی به صورت اشعه ایکس آزاد می‌شود و اشعه ایکس از بافت‌ها عبور کرده و به آشکارساز در سمت دیگر برخورد می‌کند. هرچه بافت متراکم‌تر باشد، اشعه ایکس بیشتری را جذب می‌کند؛ مثلاً بافت استخوانی به علت تراکم بالا، اشعه ایکس بیشتری جذب می‌کند و در نتیجه آن اشعه کمتری به آشکارساز می‌رسد که موجب سفید شدن آن قسمت از تصویر خواهد شد اما این مسئله در مورد هوا برعکس است [۲]. در مقایسه با تصویر اشعه ایکس ساده، سی‌تی‌اسکن دارای تفکیک‌پذیری بیشتر

^۱Pre-process

^۲X-Ray

^۳Cathode


^۴Electron



شکل ۲-۷: توزیع خونریزی بر اساس برش‌ها

است و هیچ هم‌پوشانی در ساختارها وجود ندارد. دستگاه‌های سی‌تی‌اسکن که از کالیبراسیون^۱ درستی برخوردار باشند، تصاویر خود را طبق یکای Hounsfield ثبت می‌کنند. این یکا به پروتون‌گاراها و محققین اجازه می‌دهد تا بتوانند با آستانه گذاری مناسب، جزییات بافت هدف خود را در تصویر رویت پذیرتر کنند. تصاویر سی‌تی‌اسکن به صورت معمول بر اساس یکای Hounsfield مقادیر پیکسلی بین ۱۰۲۴- تا ۳۰۰۰ را دارا می‌باشند.

شکل ۲-۸ نشان‌دهنده مقدار پیکسلی است که هر بافت در تصویر سی‌تی‌اسکن از خود نشان می‌دهد. پروتون‌گاراها، پزشک‌ها و محققین برای اینکه بتوانند یک بیماری خاص را مورد بررسی قرار بدهند، برش‌های تصاویر را در بازه‌های خاصی از یکای Hounsfield مورد بررسی قرار می‌دهند که به این نوع از پیش‌پردازش تصاویر سی‌تی‌اسکن، پنجره گذاری^۲ می‌گویند.



شکل ۲-۸: اثر بافت‌های متفاوت در یکای Hounsfield [۲]

در روش پنجره‌گذاری، دو مقدار مرکز پنجره (WC) و پهنای پنجره (WW) بازه هدف را در تصویر مشخص می‌کند و به موجب آن هر پیکسل که مقدار آن از حداقل بازه کمتر باشد، مقدارش برابر با حداقل بازه می‌شود و هر پیکسل که مقدارش از حداکثر بازه بیشتر باشد، مقدارش برابر حداکثر بازه می‌شود.


¹Calibration

²Windowing

معادله ۲-۲ روش اعمال پنجره‌گذاری روی تصاویر را نمایش می‌دهد که در آن Normalize به منظور انتقال مقادیر تصویر بعد از پنجره‌گذاری بین 0 و 1 است و Threshold تابعی است که در اثر آن مقادیر کمتر از حداقل بازه هدف به مقدار حداقل تغییر پیدا می‌کنند و مقادیری بیشتر از حداکثر بازه به مقدار حداکثر تبدیل می‌شوند.

$$\text{Processed Image} = \text{Normalize}(\text{Threshold}(\text{Image}, WC - \frac{WW}{2}, WC + \frac{WW}{2})) \quad (2-1)$$

پرتونگاریها مقادیر مشخصی را برای شناسایی انواع مختلف اندام در تصاویر سی‌تی‌اسکن تعیین کرده‌اند به عنوان مثال، در مجموعه داده PhysioNet، پردازش تصویر اصلی به‌ازای مرکز پنجره 40 و پهنا 120 ، پنجره مغز استخراج می‌شود و به‌ازای مرکز پنجره 700 و پهنا 3200 ، پنجره استخوان استخراج می‌شود. **شکل ۲-۹** اثر پنجره‌گذاری را بر یک نمونه برش سی‌تی‌اسکن نشان می‌دهد. همانطور که از این **شکل ۲-۹** مشخص است، تصویر قبل از پیش‌پردازش جزئیات خاصی را به ما نشان نمی‌دهد و اگر این تصویر را بدون نرمال کردن برای آموزش شبکه عصبی استفاده کنیم، باعث می‌شود که لایه‌های ابتدایی شبکه مقادیر خیلی بزرگی را ایجاد کنند و در نتیجه عملکرد مدل کاهش پیدا کند و اگر این تصویر را نرمال کنیم، به علت بازه بسیار زیاد یکای Hounsfield تفکیک‌پذیری مقادیر تصویر به شدت کاهش پیدا می‌کند. در ادامه **شکل ۲-۹**، **شکل ۲-۹** ج و **شکل ۲-۹** د اثر سه پنجره مرسوم مغز، استخوان و سابدورال را مشاهده می‌کنیم که هر کدام تفکیک‌پذیری بافت هدف خود را افزایش داده‌اند و در پنجره مغز و سابدورال، محل خونریزی به وضوح مشخص است. **شکل ۲-۹** پنجره انتخابی را نشان می‌دهد که براساس محدوده موجود در **شکل ۲-۶** انتخاب شده‌است و در نتیجه آن، محل خونریزی بروز بیشتری پیدا کرده است. در ادامه این پژوهش، پنجره مغز به عنوان پنجره اصلی آموزش و ارزیابی مدل‌ها در نظر گرفته شده است.



شکل ۲-۹: تاثیر اثر پنجره‌گذاری در نمایش خونریزی در یک برش از سی‌تی‌اسکن

۳-۲ روش پردازش تصاویر

شبکه‌های عصبی عمیق به عنوان یکی از روش‌های محبوب در حوزه‌ی یادگیری ماشین شناخته می‌شوند. این شبکه‌ها از ساختارهایی شبیه به مغز انسان تشکیل شده‌اند که شامل تعدادی نورون^۱ مصنوعی هستند و قادرند با استفاده از داده‌های ورودی، الگوها و روابط پیچیده را بیاموزند. یادگیری عمیق، شاخه‌ای از شبکه‌های عصبی است که با افزایش تعداد لایه‌های مخفی در شبکه، امکان پردازش و تحلیل داده‌های بسیار پیچیده و بزرگ را فراهم می‌کند. در این پژوهش، روش اصلی مورد استفاده برای پردازش کامپیوتری تصاویر، یادگیری عمیق است.

۱-۳-۲ یادگیری عمیق و اصول اولیه

یادگیری عمیق یکی از شاخه‌های مهم یادگیری ماشین است که به دلیل توانایی‌های خود در پردازش، تحلیل و الگویابی در داده‌های پیچیده، به‌ویژه در حوزه‌ی پزشکی، به طور گسترده‌ای مورد استفاده قرار گرفته است. در این بخش، به بررسی اصول پایه‌ای یادگیری عمیق در پردازش تصویر پرداخته شده است.

^۱Neuron

ساختار نورون

شبکه‌های عصبی مصنوعی از تعدادی واحد پردازشی به نام نورون تشکیل شده‌اند. هر نورون چندین ورودی x_1, x_2, \dots, x_n دریافت می‌کند که هر یک با وزن‌های w_1, w_2, \dots, w_n متناظر ضرب می‌شوند. سپس، مجموع وزن‌دار ورودی‌ها به اضافه‌ی یک بایاس b مطابق با معادله ۲-۲ محاسبه شده و از طریق یک تابع فعال‌سازی ϕ به خروجی تبدیل می‌شود، که رابطه آن در معادله ۳-۲ مشخص شده است.

$$z = \sum_{i=1}^n w_i x_i + b \quad (2-2)$$

$$a = \phi(z) \quad (2-3)$$

توابع فعال‌سازی به منظور ایجاد خاصیت غیرخطی در نورون‌ها استفاده می‌شوند تا با استفاده از شبکه عصبی عمیق، بتوانیم توابع غیرخطی را تخمین بزنیم. دو تابع فعال‌سازی رایج عبارتند از ReLU^۱ و Sigmoid^۲. رابطه تابع ReLU در معادله ۴-۲ مشخص شده است و رابطه تابع Sigmoid، در معادله ۵-۲ مشخص شده است.

$$\phi(z) = \max(0, z) \quad (2-4)$$

و تابع سیگموید نیز به صورت زیر تعریف می‌شود:

$$\phi(z) = \frac{1}{1 + e^{-z}} \quad (2-5)$$


لایه‌های پنهان

شبکه‌های عصبی عمیق از چندین لایه‌ی پنهان تشکیل شده‌اند که هر کدام از تعداد زیادی نورون مشابه نورون‌های توصیف‌شده در بخش قبلی تشکیل شده‌اند. خروجی هر نورون در یک لایه به عنوان ورودی برای نورون‌های لایه‌ی بعدی استفاده می‌شود. این ساختار چندلایه به شبکه امکان می‌دهد تا ویژگی‌های پیچیده و رفتار غیرخطی را از داده‌های ورودی استخراج کند. شکل ۱۰-۲ نمایش نحوه مدل‌سازی یک

^۱Rectified Linear Unit

^۲Sigmoid

نورون را با استفاده از معادله ۲-۲ و معادله ۳-۲ نشان می‌دهد و در ادامه نحوه عملکرد لایه‌های پنهان در شبیه‌سازی ارتباط بین نرون‌ها را نشان می‌دهد.



شکل ۲-۱۰: مدل‌سازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نرون‌ها با استفاده از لایه‌های پنهان [۳]

تابع خطا و پس‌انتشار^۱

تابع خطا^۲ نقش کلیدی در آموزش شبکه‌های عصبی دارد. این تابع تفاوت بین خروجی پیش‌بینی شده y_{pred} و خروجی واقعی y_{true} را محاسبه می‌کند. یکی از رایج‌ترین توابع خطا، خطای Binary Cross Entropy (BCE) است که طبق معادله ۶-۲ برای مسائل دسته‌بندی دوتایی استفاده می‌شود.

$$L(\mathbf{y}_{true}, \mathbf{y}_{pred}) = -\frac{1}{m} \sum_{i=1}^m \left[y_{true}^{(i)} \log(y_{pred}^{(i)}) + (1 - y_{true}^{(i)}) \log(1 - y_{pred}^{(i)}) \right] \quad (2-6)$$

هدف از آموزش شبکه، کمینه‌سازی این تابع خطا است که با استفاده از الگوریتم پس‌انتشار انجام می‌شود. در این روش، گرادیان^۳ تابع خطا نسبت به هر وزن w_i طبق معادله ۷-۲ و قانون مشتقات

^۱backpropagation

^۲Loss Function

^۳Gradient

زنجیره‌ای، محاسبه شده و سپس وزن‌ها با استفاده از قانون گرادیان کاهشی مطابق معادله ۸-۲ به روزرسانی می‌شوند:

$$\frac{\partial L}{\partial w_i} \quad (2-7)$$

$$w_{i+1} \leftarrow w_i - \eta \frac{\partial L}{\partial w_i} \quad (2-8)$$

لایه‌های پرسپترون^۱ چندلایه

لایه‌های پرسپترون چندلایه (MLP) یکی از ساده‌ترین و پایه‌ای‌ترین ساختارها در شبکه‌های عصبی هستند. این لایه‌ها از تعدادی نورون تشکیل شده‌اند که به صورت کامل به یکدیگر متصل هستند؛ به بیان دیگر هر نورون در یک لایه به تمامی نورون‌های لایه‌ی قبلی متصل می‌شود و اطلاعات را به لایه‌ی بعدی منتقل می‌کند. خروجی هر لایه $a^{[l]}$ از ترکیب خطی ورودی‌ها و اعمال تابع فعال‌سازی طبق معادله ۹-۲ به دست می‌آید:

$$a^{[l]} = \phi(W^{[l]}a^{[l-1]} + b^{[l]}) \quad (2-9)$$

شبکه عصبی پیچشی^۲

برای بهبود عملکرد شبکه‌های عصبی در پردازش تصاویر، از لایه‌های شبکه عصبی پیچشی (CNN) استفاده می‌شود. در این لایه‌ها، عملیات کانولوشن به جای ضرب ماتریسی بین ورودی و وزن‌ها طبق معادله ۱۰-۲ انجام می‌شود. این عملیات برای هر ناحیه کوچک از تصویر با استفاده از یک فیلتر k صورت می‌گیرد.

$$z_{i,j} = (X * k)_{i,j} = \sum_m \sum_n X_{i+m,j+n} \cdot k_{m,n} \quad (2-10)$$

خروجی این عملیات، نقشه ویژگی Feature Map است که به لایه بعدی منتقل می‌شود. با عبور یک تصویر از لایه‌های یک شبکه عصبی پیچشی، بین پیکسل‌های کناره‌هم در تصویر، یک رابطه برقرار

^۱Perceptron

^۲Convolutional Neural Network

می‌شود که در نتیجه آن، نقشه ویژگی استخراج شده برای هر پیکسل، به وضعت پیکسل‌های اطرافش بستگی دارد و هرچه از پیکسل مبدا دور شویم، اثر آن در نقشه ویژگی کاهش پیدا می‌کند.

بهینه‌سازها و الگوریتم Adam

بهینه‌سازی یکی از مهم‌ترین اجزا در آموزش شبکه‌های عصبی هستند که هدف آنها به‌روزرسانی وزن‌ها به گونه‌ای است که تابع خطا به حداقل مقدار خود برسد. برای این منظور، از الگوریتم‌هایی استفاده می‌شود که بهینه‌ساز نامیده می‌شوند. یکی از رایج‌ترین بهینه‌سازها، الگوریتم گرادینت کاهشی است که در آن وزن‌ها در جهت منفی گرادینت تابع خطا به‌روزرسانی می‌شوند، هرابطه گرادینت کاهشی در [معادله ۲-۸](#) نشان داده شده است. یکی دیگر از بهینه‌سازهای پیشرفته و کارآمد، بهینه‌ساز Adam است. این بهینه‌ساز از ترکیب دو روش Momentum و RMSProp بهره می‌برد [\[۳۲، ۳۳\]](#). به‌روزرسانی وزن‌ها در Adam با استفاده از روابط در [معادله ۲-۱۱](#) انجام می‌شود.

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla L(\theta_t) \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L(\theta_t))^2 \\ \theta_{t+1} &= \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned} \quad (2-11)$$

در این معادلات، m_t و v_t به ترتیب تخمین میانگین حرکت‌دار گرادینت و میانگین حرکت‌دار مربعات گرادینت در زمان t هستند، و β_1 و β_2 ضرایب مربوط به این میانگین‌ها هستند. η نرخ یادگیری و ϵ یک مقدار بسیار کوچک برای جلوگیری از تقسیم بر صفر است. Adam به دلیل توانایی خود در تنظیم نرخ یادگیری برای هر پارامتر به‌طور خودکار، به یکی از پرکاربردترین بهینه‌سازها در آموزش شبکه‌های عصبی عمیق تبدیل شده است.

منابع و مراجع

- [1] Team, Health Jade. Intracerebral hemorrhage causes, symptoms, diagnosis, treatment & recovery, October 18 2019. Accessed: 2024-08-26.
- [2] CT-Scans, DICOM files, Windowing Explained — kaggle.com. <https://www.kaggle.com/code/redwankarimsony/ct-scans-dicom-files-windowing-explained/notebook>. [Accessed 29-08-2024].
- [3] at 3rd Wave Media, Xiaoying Riley. Introduction to Deep Learning — blogs.brain-mentors.com. <https://blogs.brain-mentors.com/introduction-to-deep-learning/>. [Accessed 30-08-2024].
- [4] Rsna intracranial hemorrhage detection. <https://www.kaggle.com/competitions/rsna-intracranial-hemorrhage-detection/overview>, 2019. Accessed: 2024-08-26.
- [5] Grewal, Monika, Srivastava, Muktabh Mayank, Kumar, Pulkit, and Varadarajan, Srikrishna. Radnet: Radiologist level accuracy using deep learning for hemorrhage detection in ct scans. in 2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018), pp. 281–284. IEEE, 2018.
- [6] Monica Jenefer, Balraj M, Senathipathi, K, Aarthi, and Annapandi. Detection and categorization of acute intracranial hemorrhage subtypes using a multilayer densenet-resnet

- architecture with improved random forest classifier. *Concurrency and Computation: Practice and Experience*, 34(22):e7167, 2022.
- [7] Arbabshirani, Mohammad R, Fornwalt, Brandon K, Mongelluzzo, Gino J, Suever, Jonathan D, Geise, Brandon D, Patel, Aalpen A, and Moore, Gregory J. Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration. *NPJ digital medicine*, 1(1):9, 2018.
- [8] Burduja, Mihail, Ionescu, Radu Tudor, and Verga, Nicolae. Accurate and efficient intracranial hemorrhage detection and subtype classification in 3d ct scans with convolutional and long short-term memory neural networks. *Sensors*, 20(19):5611, 2020.
- [9] Morgenstern, Lewis B, Hemphill III, J Claude, Anderson, Craig, Becker, Kyra, Broderick, Joseph P, Connolly Jr, E Sander, Greenberg, Steven M, Huang, James N, Macdonald, R Loch, Messé, Steven R, et al. Guidelines for the management of spontaneous intracerebral hemorrhage: a guideline for healthcare professionals from the american heart association/american stroke association. *Stroke*, 41(9):2108–2129, 2010.
- [10] Van Asch, Charlotte JJ, Luitse, Merel JA, Rinkel, Gabriël JE, van der Tweel, Ingeborg, Algra, Ale, and Klijn, Catharina JM. Incidence, case fatality, and functional outcome of intracerebral haemorrhage over time, according to age, sex, and ethnic origin: a systematic review and meta-analysis. *The Lancet Neurology*, 9(2):167–176, 2010.
- [11] Hackett, Maree L and Anderson, Craig S. Health outcomes 1 year after subarachnoid hemorrhage: an international population-based study. *Neurology*, 55(5):658–662, 2000.
- [12] Kuo, Weicheng, Häne, Christian, Mukherjee, Pratik, Malik, Jitendra, and Yuh, Esther L. Expert-level detection of acute intracranial hemorrhage on head computed tomography using deep learning. *Proceedings of the National Academy of Sciences*, 116(45):22737–22745, 2019.

- [13] Ye, Hai, Gao, Feng, Yin, Youbing, Guo, Danfeng, Zhao, Pengfei, Lu, Yi, Wang, Xin, Bai, Junjie, Cao, Kunlin, Song, Qi, et al. Precise diagnosis of intracranial hemorrhage and subtypes using a three-dimensional joint convolutional and recurrent neural network. *European radiology*, 29:6191–6201, 2019.
- [14] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier, Prashant. Deep learning algorithms for detection of critical findings in head ct scans: a retrospective study. *The Lancet*, 392(10162):2388–2396, 2018.
- [15] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [16] Alfaro, Dennis, Levitt, M Andrew, English, David K, Williams, Virgil, and Eisenberg, Ronald. Accuracy of interpretation of cranial computed tomography scans in an emergency medicine residency program. *Annals of emergency medicine*, 25(2):169–174, 1995.
- [17] Lal, Nirish R, Murray, Uwada M, Eldevik, O Petter, and Desmond, Jeffrey S. Clinical consequences of misinterpretations of neuroradiologic ct scans by on-call radiology residents. *American journal of neuroradiology*, 21(1):124–129, 2000.
- [18] Erly, William K, Berger, William G, Krupinski, Elizabeth, Seeger, Joachim F, and Guisto, John A. Radiology resident evaluation of head ct scan orders in the emergency department. *American journal of neuroradiology*, 23(1):103–107, 2002.
- [19] Strub, WM, Leach, JL, Tomsick, T, and Vagal, A. Overnight preliminary head ct interpretations provided by residents: locations of misidentified intracranial hemorrhage. *American journal of neuroradiology*, 28(9):1679–1682, 2007.

- [20] Lee, Hyunkwang, Yune, Sehyo, Mansouri, Mohammad, Kim, Myeongchan, Tajmir, Shahein H, Guerrier, Claude E, Ebert, Sarah A, Pomerantz, Stuart R, Romero, Javier M, Kamalian, Shahmir, et al. An explainable deep-learning algorithm for the detection of acute intracranial haemorrhage from small datasets. *Nature biomedical engineering*, 3(3):173–182, 2019.
- [21] Chang, Peter D, Kuoy, Edward, Grinband, Jack, Weinberg, Brent D, Thompson, Matthew, Homo, Richelle, Chen, Jefferson, Abcede, Hermelinda, Shafie, Mohammad, Sugrue, Leo, et al. Hybrid 3d/2d convolutional neural network for hemorrhage evaluation on head ct. *American Journal of Neuroradiology*, 39(9):1609–1616, 2018.
- [22] Titano, Joseph J, Badgeley, Marcus, Schefflein, Javin, Pain, Margaret, Su, Andres, Cai, Michael, Swinburne, Nathaniel, Zech, John, Kim, Jun, Bederson, Joshua, et al. Automated deep-neural-network surveillance of cranial images for acute neurologic events. *Nature medicine*, 24(9):1337–1341, 2018.
- [23] Rsna intracranial hemorrhage detection, 2024. Accessed: 2024-08-27.
- [24] Khoruzhaya, Anna N, Bobrovskaya, Tatiana M, Kozlov, Dmitriy V, Kuligovskiy, Dmitriy, Novik, Vladimir P, Arzamasov, Kirill M, and Kremneva, Elena I. Expanded brain ct dataset for the development of ai systems for intracranial hemorrhage detection and classification. *Data*, 9(2):30, 2024.
- [25] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier, Prashant. Development and validation of deep learning algorithms for detection of critical findings in head ct scans. *arXiv preprint arXiv:1803.05854*, 2018.
- [26] Ma, Deguo, Li, Chen, Du, Tianming, Qiao, Lin, Tang, Dechao, Ma, Zhiyu, Shi, Liyu, Lu, Guotao, Meng, Qingtao, Chen, Zhihao, et al. Phe-sich-ct-ids: A benchmark ct image dataset for evaluation semantic segmentation, object detection and radiomic feature

- extraction of perihematoma edema in spontaneous intracerebral hemorrhage. *Computers in Biology and Medicine*, 173:108342, 2024.
- [27] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [28] Neethi, AS, Niyas, S, Kannath, Santhosh Kumar, Mathew, Jimson, Anzar, Ajimi Mol, and Rajan, Jeny. Stroke classification from computed tomography scans using 3d convolutional neural network. *Biomedical Signal Processing and Control*, 76:103720, 2022.
- [29] Kyung, Sunggu, Shin, Keewon, Jeong, Hyunsu, Kim, Ki Duk, Park, Jooyoung, Cho, Kyungjin, Lee, Jeong Hyun, Hong, GilSun, and Kim, Namkug. Improved performance and robustness of multi-task representation learning with consistency loss between pre-texts for intracranial hemorrhage identification in head ct. *Medical Image Analysis*, 81:102489, 2022.
- [30] Li, Lu, Wei, Meng, Liu, BO, Atchaneeyasakul, Kunakorn, Zhou, Fugen, Pan, Zehao, Kumar, Shimran A, Zhang, Jason Y, Pu, Yuehua, Liebeskind, David S, et al. Deep learning for hemorrhagic lesion detection and segmentation on brain ct images. *IEEE journal of biomedical and health informatics*, 25(5):1646–1659, 2020.
- [31] Hssayeni, Murtadha, Croock, M, Salman, A, Al-khafaji, H, Yahya, Z, and Ghoraani, B. Computed tomography images for intracranial hemorrhage detection and segmentation. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [32] Efimov, Vyacheslav. Understanding Deep Learning Optimizers: Momentum, AdaGrad, RMSProp & Adam — towardsdatascience.com. <https://towardsdatascience.com/>

[understanding-deep-learning-optimizers-momentum-adagrad-rmsprop-adam-e311e377e9c](#)
[Accessed 30-08-2024].

- [33] Khandewal, Harsh. Momentum ,RMSprop And Adam Optimizer
— medium.com. [https://medium.com/analytics-vidhya/
momentum-rmsprop-and-adam-optimizer-5769721b4b19](https://medium.com/analytics-vidhya/momentum-rmsprop-and-adam-optimizer-5769721b4b19). [Accessed 30-
08-2024].

واژه‌نامه‌ی فارسی به انگلیسی

Perceptron پرسپترون	الف
backpropagation پس‌انتشار	آسیب مغزی تروماتیک . . . injury
Post-process پس‌پردازش	
Windowing پنجره‌گذاری	Electron الکترون
Pre-process پیش‌پردازش	انتقال یادگیری Transfer Learning
pixel پیکسل	X-Ray اشعه ایکس
ت	Augmentation افزایش مصنوعی داده
Loss Function تابع خطا	ب
ح	Bias بایاس
Annotation حاشیه‌نویسی	Slice برش
خ	Slice-wise برش‌محور
Hemorrhage خونریزی	Patient-wise بیمار‌محور
Intracerebral خونریزی درون‌جمجمه‌ای	پ
Hemorrhage (ICH)	
Epidural Hemorrhage خونریزی اپیدورال	Radiography پرتونگاری
Subdural Hemorrhage خونریزی ساب‌دورال	Radiologist پرتونگار

Cathode کاتد	ساب‌آراکتوئید . Subarachnoid Hemorrhage
Calibration کالیبراسیون	Cerebral خونریزی پارانشیم مغزی
Undersampling کاهش داده غالب	Parenchymal Hemorrhage
گی	Intraventricular خونریزی داخل بطنی
Gradient گرادیان	Hemorrhage
م	ر
Mask ماسک	Computer رایانه
Model مدل	ز
ن	Real Time زمان واقعی
Neuron نرون	س
Second Opinion نظر ثانویه	سی‌تی‌اسکن Computed Tomography Scan
Feature Map نقشه ویژگی	سامانه System
ی	ش
Deep Learning یادگیری عمیق	شبکه عصبی عمیق . Deep Neural Network
Machine Learning یادگیری ماشین	شبکه عصبی پیچشی Convolutional Neural Network
	ط
	طبقه‌بندی Classification
	غ
	غیر تهاجمی Non-invasive
	ق
	قطعه‌بندی Segmentation
	ک

واژه‌نامه‌ی انگلیسی به فارسی

A	Homomorphism همریختی
KNTUomorphism خودریختی	I
B	Invariant پایا
Bijection دوسویی	L
C	Lift بالابر
Cycle group گروه دوری	M
D	Module مدول
Degree درجه	N
E	Natural map نگاشت طبیعی
Edge یال	O
F	One to One یک به یک
Function تابع	P
G	Permutation group گروه جایگشتی
Group گروه	Q
H	


Quotient graph	گراف خارج‌قسمتی	Trivial character	سرشت بدیهی
R		U	
Reducible	تحویل پذیر	Unique	منحصربفرد
S		V	
Sequence	دنباله	Vector space	فضای برداری
T			

Abstract

This page is accurate translation from Persian abstract into English.

Key Words:

Write a 3 to 5 KeyWords is essential. Example: KNTU, M.Sc., Ph. D, ..



K. N. Toosi University of Technology
Department of ...

M. Sc. Thesis

Title of Thesis

By

Name Surname

Supervisor

Dr.

Advisor

Dr.

Month & Year