

دانشگاه صنعتی خواجه نصیرالدین طوسی تهران
دانشکده مهندسی برق و کامپیوتر

پایان نامه کارشناسی ارشد
گرایش کنترل

پردازش تصاویر CT Scan مغز به منظور قطعه‌بندی
خونریزی داخلی مغز با استفاده از شبکه‌های عصبی
عمیق

پایان نامه

نگارش
سید محمد حسینی

استاد راهنما
دکتر امیرحسین نیکوفرد

شهریور ۱۴۰۳

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ

صفحه فرم ارزیابی و تصویب پایان نامه- فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تایید و تصویب پایان نامه موسوم به فرم کمیته دفاع- موجود در پرونده آموزشی- را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی خواجه نصیرالدین طوسی باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی خواجه نصیرالدین طوسی
تهران

به نام خدا

تعهدنامه اصالت اثر

تاریخ: شهریور ۱۴۰۳

اینجانب سید محمد حسینی متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی استادی دانشگاه صنعتی خواجه نصیرالدین طوسی بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مأخذ ذکر گردیده است. این پایان‌نامه قبلًا برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی خواجه نصیرالدین طوسی ممنوع است. نقل مطالب با ذکر مأخذ بلامانع است.

سید محمد حسینی

Vincent

امضا

نویسنده مایان نامه، در صورت تایل میتواند برای پیمان نامه خود را به شخص یا اشخاص و یا ارگان خاصی تقدیم نماید.

پاسکزاری

نویسنده پایان نامه می تواند مراتب امتحان خود را نسبت به استاد راهنمای و استاد مشاور و یا دیگر افرادی که طی انجام پایان نامه به نحوی او را یاری و یا با او همکاری نموده اند ابراز دارد.

سید محمد حسینی

شهریور ۱۴۰۳

چکیده

تشخیص سریع و دقیق خونریزی‌های درون‌جمجمه‌ای با استفاده از تصاویر سی‌تی اسکن، همواره به عنوان یکی از مهم‌ترین چالش‌های پزشکی در زمینه درمان افراد دارای انواع آسیب‌های مغزی، سکته‌های مغزی و خونریزی‌های درون‌جمجمه‌ای، مطرح شده است. اهمیت این موضوع زمانی آشکار می‌شود که حتی تأخیر چند دقیقه‌ای در تشخیص می‌تواند منجر به پیامدهای جبران‌ناپذیری برای بیماران شود. با توجه به پیچیدگی و حساسیت بالای تشخیص چنین آسیب‌هایی، این فرایند عموماً نیازمند تخصص و تجربه‌ی بالای پزشکان و پرتوشناسان است. اما با توجه به محدودیت منابع انسانی و احتمال خطاها ای انسانی، نیاز به توسعه سامانه‌های خودکار تشخیص مبتنی بر یادگیری عمیق بیش از پیش احساس می‌شود. در این زمینه چالش اصلی برای پزشکان خصوصاً در بخش فوریت‌های پزشکی، تشخیص دقیق و سریع نواحی خونریزی در تصاویر سه‌بعدی سی‌تی اسکن است که عملکرد متخصصین در تحلیل این تصاویر، تحت تأثیر میزان تجربه آنها و شرایط محیطی قرار دارد. توسعه یک دستیار هوشمند مبتنی بر شبکه عصبی عمیق، می‌تواند موجب بهبود فرایندهای پزشکی در این حوزه شود؛ اما توسعه این دستیار با چالش‌های متعددی روبرو است. از جمله این چالش‌ها می‌توان به عدم توازن داده‌ها، محدودیت در دسترسی به مجموعه داده‌های بزرگ، و تنوع کیفیت تصاویر سی‌تی اسکن در مراکز مختلف تصویربرداری اشاره کرد. این عوامل می‌توانند باعث کاهش دقت مدل‌ها در تشخیص نواحی دارای خونریزی شود. در این پایان‌نامه، یک روش دومرحله‌ای مبتنی بر طبقه‌بندی و قطعه‌بندی، به همراه یک پس‌پردازش توسعه داده شده است.

واژه‌های کلیدی:

شبکه عصبی عمیق، طبقه‌بندی تصاویر سی‌تی اسکن، قطعه‌بندی تصاویر سی‌تی اسکن، خونریزی درون‌جمجمه‌ای

فهرست مطالب

صفحه	عنوان
۱۳	۲ روش‌ها و مجموعه‌داده
۱۴	۱-۲ بررسی آماری مجموعه داده
۱۸	۲-۲ پیش‌پردازش ^۱
۲۱	۳-۲ روش پردازش تصاویر
۲۱	۱-۳-۲ یادگیری عمیق و اصول اولیه
۲۵	۴-۲ مدل‌های طبقه‌بندی در شبکه عصبی عمیق
۲۵	ResNet ۱-۴-۲
۲۷	ResNeXt ۲-۴-۲
۲۷	۳-۴-۲ شبکه (SENet) Squeeze-and-Excitation
۲۹	DenseNet ۴-۴-۲
۲۹	EfficientNet ۵-۴-۲
۳۱	۵-۲ مدل‌های قطعه‌بندی در شبکه عصبی عمیق
۳۱	U-Net ۱-۵-۲
۳۲	۶-۲ پس‌پردازش
۳۳	۷-۲ روش پیشنهادی
۳۴	۸-۲ آموزش و تصمیم‌گیری
۳۴	۱-۸-۲ طبقه‌بندی
۳۶	۲-۸-۲ قطعه‌بندی
۳۷	۳-۸-۲ سازوکار تصمیم‌گیری شورایی
۳۹	۳ نتایج
۴۰	۱-۳ معیارهای ارزیابی در یادگیری عمیق
۴۰	Sensitivity ۱-۱-۳
۴۰	Specificity ۲-۱-۳
۴۰	Precision ۳-۱-۳

¹Pre-process

۴۱	F1 Score ۴-۱-۳
۴۱	Accuracy ۵-۱-۳
۴۱	Intersection over Union (IoU) ۶-۱-۳
۴۲	Dice Coefficient ۷-۱-۳
۴۲	۲-۳ نتایج طبقه‌بندی
۴۲	۱-۲-۳ نتایج برش‌محور
۴۳	۲-۲-۳ نتایج بیمار‌محور
۴۳	۳-۲-۳ تحلیل بیشتر نتایج
۴۸	منابع و مراجع
۵۵	واژه‌نامه‌ی فارسی به انگلیسی
۵۸	واژه‌نامه‌ی انگلیسی به فارسی

فهرست اشکال

شکل

صفحه

۱-۱	خونریزی درون جمجمه‌ای [۱]	۳
۲-۱	چند نمونه تصویر از مجموعه داده PHE-SICH-CT-IDS	۸
۳-۱	چند نمونه تصویر از مجموعه داده PhysioNet	۹
۱-۲	یک نمونه کامل از تصاویر سی‌تی اسکن	۱۴
۲-۲	خواش‌های متفاوت از تصاویر سی‌تی اسکن [۲]	۱۵
۳-۲	تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها	۱۶
۴-۲	توزیع بیماران و برش‌ها در مجموعه داده PhysioNet	۱۷
۵-۲	توزیع پیکسلی برش‌ها برای برش‌های دارای خونریزی در مقاله برش‌های سالم	۱۷
۶-۲	توزیع نرمال شده پیکسل‌های دارای خونریزی در مقابل تمام پیکسل‌های تصویر	۱۸
۷-۲	توزیع خونریزی بر اساس برش‌ها	۱۹
۸-۲	اثر بافت‌های متفاوت در یکای Hounsfield [۲]	۱۹
۹-۲	تأثیر اثر پنجره‌گذاری در نمایش خونریزی در یک برش از سی‌تی اسکن	۲۱
۱۰-۲	مدلسازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نرون‌ها با استفاده از لایه‌های پنهان [۳]	۲۳
۱۱-۲	یک بلوک از معماری ResNet که اتصال میانبر همانی را نشان می‌دهد [۴]	۲۶
۱۲-۲	ساختارهای مختلف در معماری ResNeXt که کانولوشن‌های گروهی، مسیرهای پردازشی موازی و روش ادغام را نشان می‌دهند [۵]	۲۸
۱۳-۲	بلوک Squeeze-and-Excitation که نحوه عملکرد آن را در ارزیابی و وزن‌دهی کانال‌ها نشان می‌دهد [۶]	۲۸
۱۴-۲	معماری یک بلوک DenseNet [۷]	۳۰
۱۵-۲	ساختار شبکه U-Net که شامل مسیر رمزگذار و رمزگشا، همراه با اتصالات کپی و الحاق است [۸]	۳۲
۱۶-۲	نمونه لایه‌های پس‌پردازش استخراج شده از برش‌های بیمار	۳۳
۱۷-۲	روندنمای روش پیشنهادی در این پژوهش	۳۵
۱۸-۲	سازوکار تصمیم‌گیری شورایی	۳۷

۱-۳	نمودار امتیاز F1 نسبت به آستانه برای Fold‌ها و میانگین آنها	۴۴
۲-۳	نمودارهای سازوکار شورایی روی مجموعه داده ارزیابی	۴۴
۳-۳	ماتریس آشفتگی نتایج برش محور	۴۵
۴-۳	ماتریس آشفتگیب یمارمحور سازوکار شورایی	۴۶
۵-۳	چند نمونه از تصاویر تولید شده توسط Grad-CAM	۴۷
۶-۳	نمودارهای t-SNE و مقایسه آنها با یکدیگر	۴۷

فهرست جداول

صفحه

جدول

۱-۱	انواع زیرگروه‌های خونریزی درون جمجمه‌ای [۹]	۴
۱-۲	ضرایب مورد استفاده در جستجوی شبکه‌ای	۳۶
۱-۳	نتایج برش محور مدل ResNet50 برای آستانه تصمیم‌گیری $0/27$	۴۳
۲-۳	نتایج بیمارمحور مدل ResNet50 برای آستانه تصمیم‌گیری $0/27$	۴۵

مقدمه

فصل اول

۱-۱ خونریزی درون جمجمه‌ای و اهمیت آن

خونریزی درون جمجمه‌ای^۱ یک وضعیت اضطراری پزشکی است که تشخیص سریع و دقیق آن به منظور درمان مؤثر بیمار و کاهش خطر ناتوانی شدید یا مرگ، حیاتی است [۱۰]. خونریزی درون جمجمه‌ای می‌تواند به دلایل مختلفی از جمله آسیب مغزی تروماتیک^۲، بیماری‌های عروقی، یا مشکلات مادرزادی ایجاد شود و بر اساس محل خونریزی در مغز طبقه‌بندی می‌شود [۱۱]. به صورت تقریبی سالانه بین ۴۰۰۰۰ تا ۶۷۰۰۰ بیمار دارای خونریزی درون جمجمه‌ای در ایالات متحده آمریکا شناسایی می‌شوند که نرخ مرگ‌ومیر آنها در ۳۰ روز اول حادثه در حدود ۴۰ درصد است که در نتیجه آن، خونریزی درون جمجمه‌ای به یکی از بیماری‌ها با بیشترین آمار مرگ و میر تبدیل شده است. این در حالی است که عوارض دیگر این بیماری نیز بسیار خطناک است، به عنوان مثال بیشتر از ۴۶ درصد بیماران که دارای نوع خاصی از خونریزی درون جمجمه‌ای هستند، پس از بهبود به صورت دائمی دچار اختلالات شناختی می‌شوند [۱۲، ۱۳، ۱۴، ۱۵].

باتوجه به نرخ بالای مرگ‌ومیر مرتبط با خونریزی درون جمجمه‌ای، تشخیص سریع و دقیق خونریزی درون جمجمه‌ای با استفاده از روش‌های تصویربرداری ضروری است [۱۷]. سی‌تی اسکن^۳ شایع‌ترین روش برای تشخیص سریع خونریزی خصوصاً در مراکز فوریت‌های پزشکی به حساب می‌آید که دقت مناسب را برای تشخیص این بیماری به متخصصین می‌دهد [۱۸، ۱۹، ۱۰].

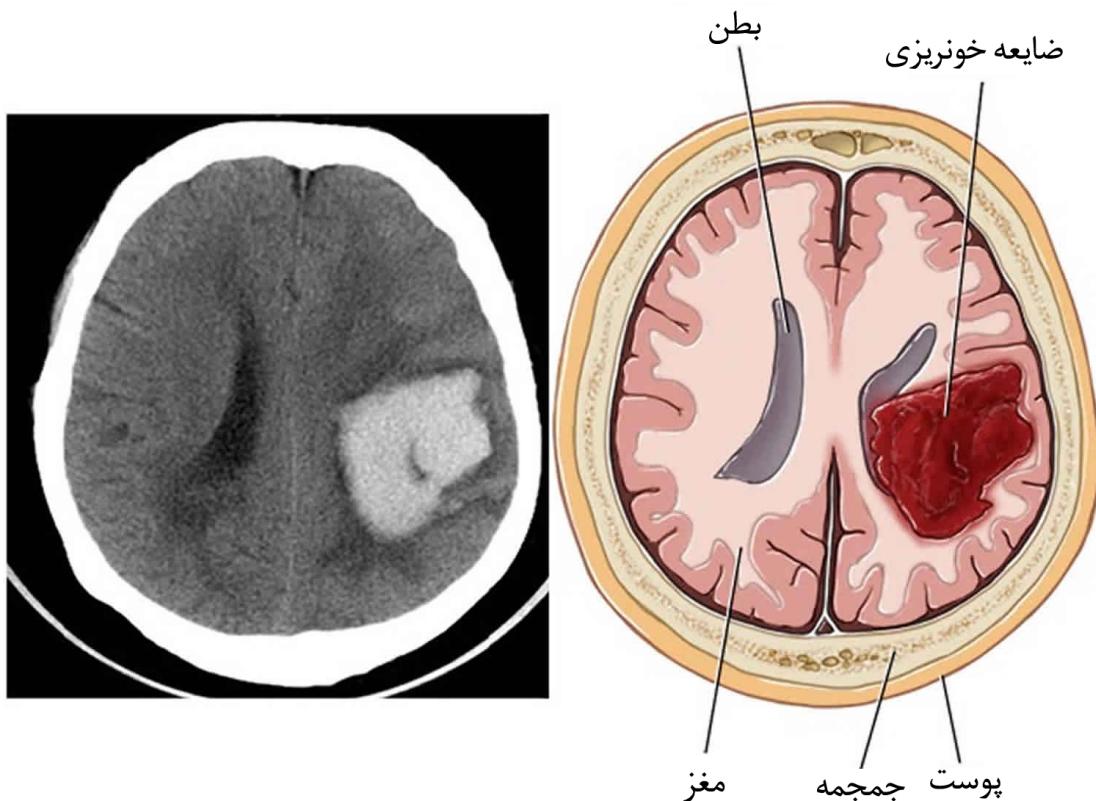
۲-۱ انواع خونریزی درون جمجمه‌ای

با پاره شدن عروق شریانی مغز، خون از درون عروق اصلی وارد بافت مغز می‌شود؛ این مسئله در حالی است که لخته شدن خون در داخل بدن سخت‌تر انجام می‌شود و به موجب آن خون وارد بافت مغز شده و با افزایش فشار داخل جمجمه، به بافت‌های حیاتی صدمات جدی وارد می‌کند. همان‌طور که در شکل ۱-۱ مشخص است، با پاره شدن شریان‌های خونی درون مغز، خونی که وارد بافت مغز شده است و یک ضایعه بزرگ خونریزی را ایجاد کرده و این ضایعه در تصویر سی‌تی اسکن به صورت یک بافت که رنگ روشن‌تری نسبت به محیط اطراف دارد قابل شناسایی است.

¹Intracranial Hemorrhage

²Traumatic Brain Injury

³Computed Tomography Scan



شکل ۱-۱: خونریزی درون جمجمه‌ای [۱]

خونریزی درون جمجمه‌ای متناسب با محل وقوع به زیرگروه‌های مختلفی تقسیم می‌شوند؛ این طبقه‌بندی شامل خونریزی اپیدورال (EDH)^۱، خونریزی سابدوارال (SDH)^۲، خونریزی سابآرکنوئید (SAH)^۳، خونریزی پارانشیم مغزی (CPH)^۴، و خونریزی داخل بطنی (IVH)^۵ است [۲۰، ۱۲]. در **جدول ۱-۱** نمونه‌هایی از زیرگروه‌های خونریزی درون جمجمه‌ای، محل خونریزی، زمینه، علت وقوع، شکل و علائم بالینی نشان داده شده است؛ همانطور که از تصاویر مشخص است، تشخیص بعضی از انواع خونریزی درون جمجمه‌ای به علت حضور در اطراف بقیه بافت‌های مغز، خصوصاً جمجمه که از تراکم بیشتری برخوردار است و یا شکل پیچیده‌ای که دارند، حتی برای متخصصین نیز دشوار است.

¹Epidural

²Subdural

³Subarachnoid

⁴Cerebral Parenchymal

⁵Intraventricular

EDH	SDH	SAH	IVH	CPH
محل	داخل مغز			
بین سخت شامه و جمجمه	بین سخت شامه و عنکبوتیه	بین عنکبوتیه و نرم شامه	داخل بطن	تصویر
ضربه یا پس از جراحی	پارگی انورسم یا ناهنجاری های شریانی - وریدی یا خونریزی های درون مغزی و وریدی با ضربه	پارگی انورسم یا ناهنجاری های شریانی - وریدی (وریدهای بلزن)	می تواند با خونریزی های شریانی - زیرعنق بوئی همراه باشد	فثار خون بالا، ضربه ناهنجاری های شریانی - وریدی، نعموده و غیره
	شریانی	هدالی	عدم تراشی	علت و قوع
	عده سی شکل	در استناد شریانها و شکافها	طبقانی یا وردی	شریانی یا وردی
	ممکن است تدریجی باشد (بدتر شدن سردرد)	حداد (شروع ناگهانی سردرد، حالت نهوع، حداد (بدترین سردرد زندگی)	عده سی شکل	عده سی شکل
		(استفراغ)	اعلام باشی	اعلام باشی
			استفراغ	

جدول ۱-۱: انواع زیرگروههای خونریزی درون جمجمه‌ای [۹]

۱-۳ روش‌های مرسوم در تشخیص خونریزی درون جمجمه‌ای

در حال حاضر تصاویر سی‌تی اسکن، به عنوان استاندارد اصلی و غیر تهاجمی^۱ برای تشخیص خونریزی درون جمجمه‌ای است. سی‌تی اسکن یک نوع تصویر پرتونگاری^۲ سه بعدی است که متشكل از تصاویر دو بعدی از اندام بدن است. روش عمومی پردازش تصاویر سی‌تی اسکن به صورت دستی انجام می‌پذیرد که به موجب آن متخصصین پرتونگاری^۳ و پزشکی، با بررسی برش‌های^۴ سی‌تی اسکن را به صورت مجزا بررسی می‌کنند و مناطق خونریزی را تشخیص می‌دهند. این فرایند به دلیل وابستگی به تخصص و تجربه فردی، شرایط محیطی و فشار کاری، زمان بر و مستعد خطا است. [۱۲، ۱۰، ۱۸، ۱۹، ۱۷]. فرایند بررسی دستی تصاویر سی‌تی اسکن، زمان بر بوده و به شدت به دردسترس بودن پرتونگارهای^۵ با تجربه بستگی دارد [۱۳]. در شرایط اضطراری، خصوصاً در مراکز فوریت‌های پزشکی، زمانی که برای پردازش برش‌های سی‌تی اسکن صرف می‌شود، می‌تواند به طور قابل توجهی در نتایج درمان بیمارها تأثیر بگذارد؛ این مسئله در مواردی از اهمیت بیشتری برخوردار می‌شود که درمان بیمار نیازمند مداخله فوری گروه پزشکی است [۱۹]. نکته حائز اهمیت در روش معمول برای بررسی تصاویر سی‌تی اسکن در مراکز پزشکی این است که بررسی اولیه تصاویر، توسط پزشکان و پرتونگارهایی با تجربه کمتر انجام می‌شود و در مراحل بعدی این تصاویر توسط متخصصینی با تجربه بیشتر بررسی می‌شود. تعدادی از مطالعات نشان داده‌اند که در روش مذکور، بین پزشکان و پرتونگارهایی که در مرحله اول تصاویر را بررسی می‌کنند و پزشکان و پرتونگارهایی که در ادامه این تصاویر را بررسی می‌کنند، اختلاف نظر وجود دارد که این مسئله می‌تواند منجر به عواقب جیران ناپذیر گردد [۱۸، ۲۱، ۲۲، ۲۳، ۲۴]. احتمال خطای انسانی در بررسی دستی تصاویر پیچیده و

¹Non-invasive²Radiography³Radiology⁴Slice⁵Radiologist

سه بعدی سی تی اسکن، از دیگر نقاط ضعف روش معمول پردازش این تصاویر است، بهویژه در محیط‌های شلوغ و پرتنش که پرتونگارها ممکن است تحت فشار زیاد باشند [۱۸].

۴-۱ روش‌های رایانه‌ای در پردازش تصاویر پزشکی

اهمیت مسئله خونریزی درون جمجمه‌ای و چالش‌های مرتبط با آن در بخش قبل مورد بررسی قرار گرفت، روش‌های مبتنی بر پردازش رایانه‌ای^۱ تصاویر پزشکی، می‌تواند یک راه حل مناسب برای رفع نقاط ضعف روش کنونی بررسی تصاویر پزشکی باشد [۱۰، ۱۲، ۱۸، ۲۵، ۲۶، ۲۷، ۱۹، ۲۲]. ابزارهای خودکار برای تشخیص و کمیت‌سنجدی خونریزی، از پیشرفتهای روش‌های یادگیری ماشین^۲ و یادگیری عمیق^۳ و سامانه‌های^۴ تشخیص به کمک رایانه^۵ استفاده می‌کنند تا تجزیه و تحلیل سریع و دقیقی از تصاویر سی‌تی اسکن ارائه دهند. با خودکارسازی تشخیص خونریزی درون جمجمه‌ای و استفاده از آنها به صورت نظر ثانویه^۶، این سامانه‌ها می‌توانند بار کاری پرتونگارها را کاهش دهند، دقت تشخیص را افزایش دهند از اشتباهات متخصصین جلوگیری کنند، زمان تشخیص را به حداقل برسانند، بعضی از هزینه‌های فرایند درمان را به علت کاهش دخالت انسانی کاهش دهند و به صورت کلی فرایند تشخیص را بهبود ببخشند که این موارد به بهبود نتایج بیماران منجر خواهد شد. با این حال، ضمن اینکه سامانه‌های تشخیص به کمک رایانه نویدبخش هستند؛ اما امکان خطا در آنها وجود دارد که می‌تواند تصمیم‌گیری بالینی را با مشکلاتی روبرو کند؛ بنابراین، ادغام این ابزارها در عمل باید با دقت انجام شود [۲۷].

۱-۵ مجموعه‌داده‌ها

در سال‌های اخیر، مجموعه‌داده‌های متعددی برای پشتیبانی از توسعه مدل‌های^۷ یادگیری عمیق در حوزه تصویربرداری پزشکی، بهویژه برای طبقه‌بندی خونریزی درون جمجمه‌ای ایجاد شده‌اند. در ادامه به بررسی برخی از مهم‌ترین مجموعه‌داده‌هایی که در این حوزه مورد استفاده قرار گرفته‌اند، می‌پردازیم.

¹Computer

²Machine Learning

³Deep Learning

⁴System

⁵Computer-aided Diagnosis

⁶Second Opinion

⁷Model

۱-۵-۱ مجموعه‌داده‌ی انجمن پرتوشناسی آمریکای شمالی (RSNA)

مجموعه‌داده‌ی [۲۸، ۹] RSNA Intracranial Hemorrhage Detection که برای چالش یادگیری ماشین سال ۲۰۱۹ انجمن پرتونگاری آمریکای شمالی جمع‌آوری شده است، یکی از منابع برجسته در زمینه طبقه‌بندی خونریزی درون‌جمجمه‌ای محسوب می‌شود. این مجموعه‌داده، از چند مرکز پرتونگاری جمع آوری شده است که سه مؤسسه دانشگاه استنفورد در ایالات متحده، دانشگاه فدرال سائو پائولو در برزیل و بیمارستان دانشگاه توماس جفرسون در ایالات متحده شامل آنها می‌باشد. این مجموعه شامل تصویر سی‌تی‌اسکن مغزی ۲۵۳۱۲ بیمار است که از این میان، ۸۸۸۹ بیمار دارای انواع مختلف خونریزی درون‌جمجمه‌ای هستند. تصاویر سی‌تی‌اسکن درون این مجموعه‌داده در سطح برش، حاشیه‌نویسی^۱ شده‌اند. تصاویر سی‌تی‌اسکن در این مجموعه‌داده به فرمت DICOM^۲ ارائه شده‌اند که استانداردی برای تصویربرداری پزشکی است. این مجموعه‌داده به‌طور گستردگی در طبقه‌بندی انواع خونریزی مورد استفاده قرار گرفته و به عنوان منبعی بنیادی برای آموزش و اعتبارسنجی مدل‌های یادگیری ماشین که به طبقه‌بندی خونریزی درون‌جمجمه‌ای تبدیل شده است.

۲-۵-۱ MosMed مجموعه‌داده‌ی

مجموعه‌داده‌ی [۲۹] MosMed، یک مجموعه‌داده خونریزی درون‌جمجمه‌ای می‌باشد که در روسیه جمع‌آوری شده است. این مجموعه‌داده به‌طور خاص برای تسهیل توسعه سیستم‌های هوش مصنوعی به‌منظور تشخیصی و طبقه‌بندی خونریزی درون‌جمجمه‌ای طراحی شده است. این مجموعه شامل سی‌تی‌اسکن مغزی ۸۰۰ بیمار است که ۴۰۰ بیمار دارای خونریزی درون‌جمجمه‌ای هستند. این مجموعه داده در سطح بیمار حاشیه‌نویسی شده است و تصاویر آن به صورت فایل‌های DICOM در دسترس قرار دارد.

۳-۵-۱ CQ500 مجموعه‌داده‌ی

مجموعه‌داده‌ی [۳۰] CQ500، یک مجموعه‌داده مهم است که از چند مرکز متفاوت شامل پنج مرکز مختلف در هند می‌باشد. این مجموعه‌داده خاوی ۴۹۱ سی‌تی‌اسکن سر است که برای انواع خونریزی‌های درون‌جمجمه‌ای در سطح بیمار حاشیه‌گذاری شده‌اند. تصاویر سی‌تی‌اسکن در این مجموعه‌داده به صورت

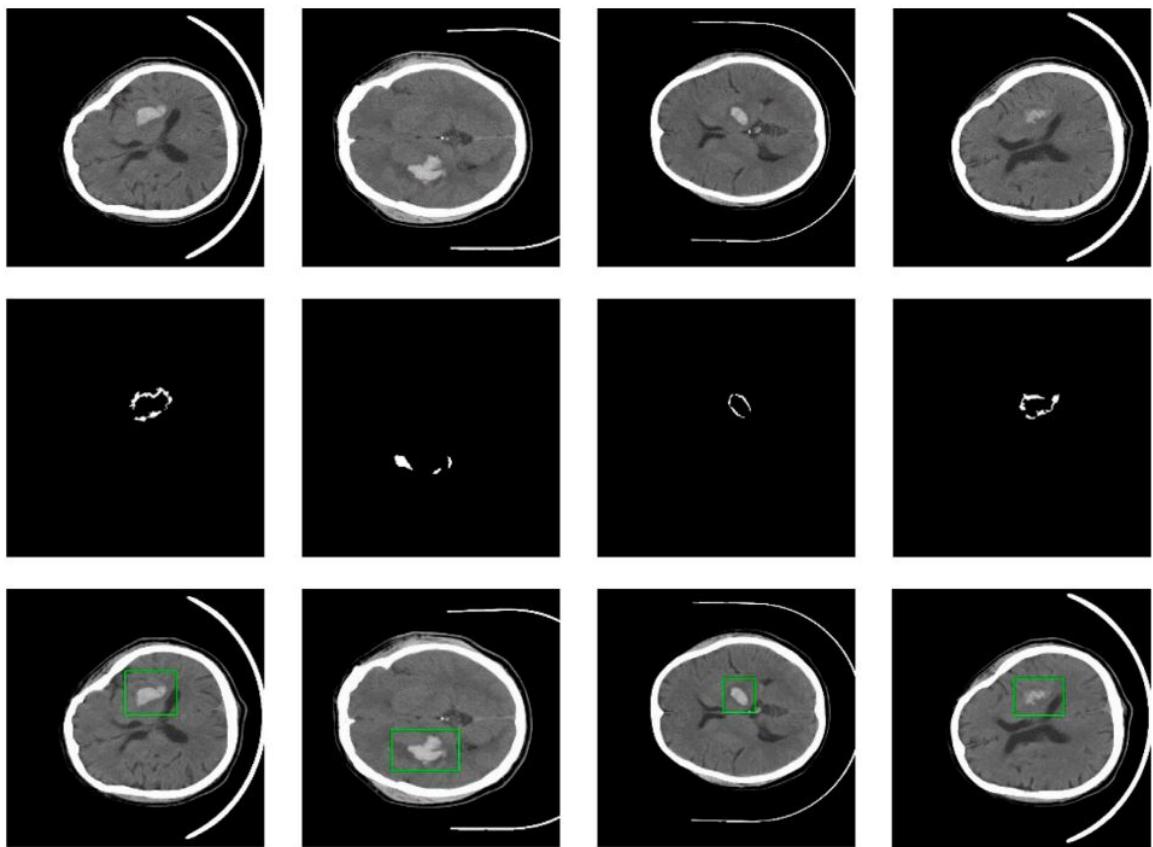
¹Annotation

²Digital Imaging and Communications in Medicine

فایل DICOM ارائه شده.

۴-۵-۱ مجموعه‌داده‌ی PHE-SICH-CT-IDS

مجموعه‌داده‌ی PHE-SICH-CT-IDS [۳۱]، اگرچه به‌طور خاص برای خونریزی درون‌جمجمه‌ای جمع‌آوری نشده است، اما به دلیل تمرکز آن بر وظایف طبقه‌بندی، تشخیص و قطعه‌بندی مرتبط به Perihematomal Edema در خونریزی درون‌جمجمه‌ای قابل توجه است. این مجموعه‌داده از بیمارستان Shengjing در چین جمع‌آوری شده است که شامل تصویر سی‌تی‌اسکن ۱۲۰ بیمار است که تمامی آنها خونریزی درون‌جمجمه‌ای دارند و حاشیه‌نویسی آنها در سطح برش انجام شده است. تصاویر سی‌تی‌اسکن در این مجموعه داده به صورت فایل‌های NIFTI، JPG و PNG ارائه شده است. مجموعه‌داده‌ی PHE-SICH-CT-IDS منبعی ارزشمند برای توسعه مدل‌های یادگیری عمیق که هدف آن‌ها طبقه‌بندی، تشخیص یا قطعه‌بندی می‌باشد، است. در شکل ۲-۱ چند برش از تصاویر مجموعه داده PHE-SICH-CT-IDS است، همانطور که در این تصویر مشخص است، در اطراف ضایعه خونریزی، یک حاشیه تیره‌تر وجود دارد که به آن Edema گفته می‌شود و این ضایعه قطعه‌بندی شده است؛ همچنین این مجموعه داده حاشیه‌نویسی مناسب برای وظیفه تشخیص را نیز دارد.

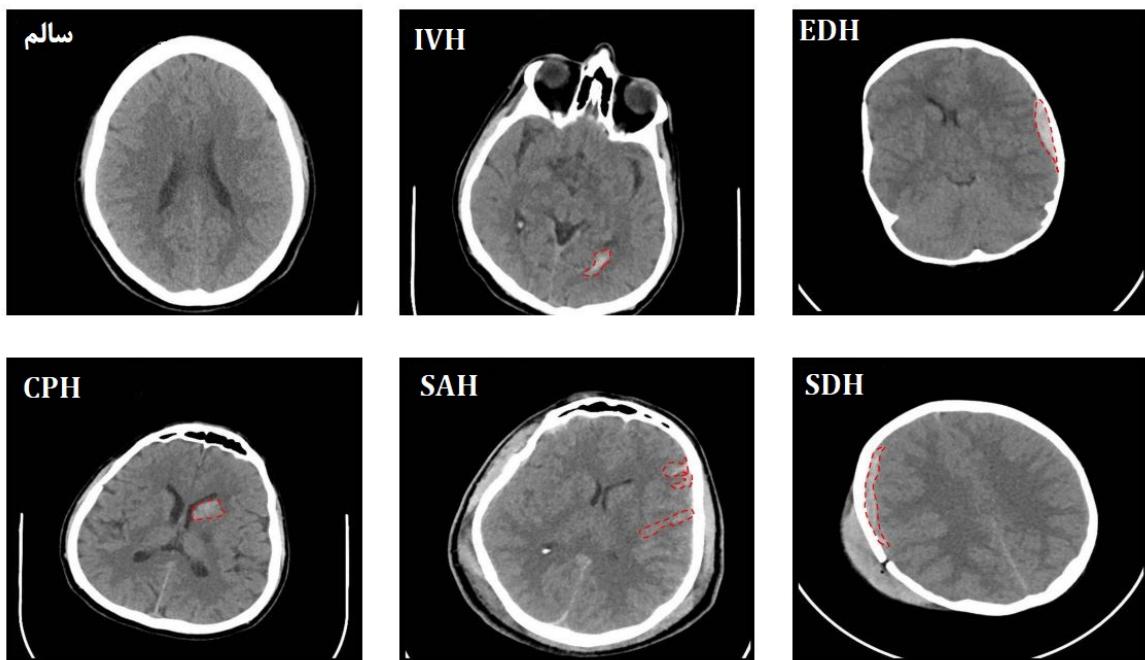


شکل ۱-۲: چند نمونه تصویر از مجموعه‌داده PHE-SICH-CT-IDS

۱-۵-۵ مجموعه‌داده‌ی PhysioNet

مجموعه‌داده‌ی خونریزی درون‌جمجمه‌ای [۳۲] PhysioNet، مجموعه‌داده‌ای می‌باشد که در ادامه این مطالعه از آن استفاده شده است. این مجموعه داده از بیمارستان Al Hilla در عراق جمع‌آوری شده است و شامل ۸۲ تصویر سی‌تی‌اسکن از بیماران است که ۳۶ نفر از آنها دارای خونریزی درون‌جمجمه‌ای می‌باشند. این مجموعه داده، شامل حاشیه‌نویسی‌های مناسب برای وظایف طبقه‌بندی و قطعه‌بندی است که آن را به تنها مجموعه‌داده با دسترسی عمومی تبدیل می‌کند که امکان قطعه‌بندی خونریزی درون‌جمجمه‌ای را فراهم می‌کند. جزئیات بیشتر درمورد این دیتابست در [۴] توضیح داده شده است.

تصویر شکل ۱-۳ چند نمونه از برش‌های خونریزی درون این مجموعه‌داده را مشخص می‌کند.



شکل ۱-۳: چند نمونه تصویر از مجموعه داده PhysioNet

۱-۶ تحقیقات اخیر در زمینه یادگیری ماشین

در سال‌های اخیر، یادگیری عمیق پیشرفتهای قابل توجهی در زمینه طبقه‌بندی و قطعه‌بندی خونریزی درون‌جمجمه‌ای داشته است و مطالعات متعددی به بررسی این موضوع پرداخته‌اند. این مدل‌ها نه تنها از نظر نوآوری فنی قابل توجه هستند، بلکه پتانسیل بالای آنها می‌تواند باعث استفاده از آنها در سیستم‌های تشخیص و درمان بیمارستان‌ها بشود که می‌تواند بهبود عملکرد کادر درمان، کاهش هزینه‌ها و زمان تشخیص و افزایش دقت در طبقه‌بندی خونریزی درون‌جمجمه‌ای را به همراه داشته باشد. برخی از این مطالعات، از جمله تحقیقات Titano [۲۷] و Arbabshirani [۱۲] و Kuo [۱۷]، و همکارانشان مدل‌های پیشنهادی خود را در محیط‌های بیمارستانی آزمایش کرده‌اند و نتایج آن‌ها نشان داده است که این سیستم‌ها می‌توانند به‌طور مؤثری در بهبود نتایج درمان برای بیماران نقش داشته باشند. به‌طور خاص، Titano و همکاران یک سیستم یادگیری عمیق خودکار با دقت ۸۷٪ و حساسیت ۹۴٪ معرفی کرده‌اند که عملکرد آن با کارشناسان انسانی مقایسه شده و در محیط‌های بالینی به کار گرفته شده است. همچنین، Kuo و همکاران یک شبکه عصبی پیچشی برای طبقه‌بندی خونریزی حاد درون‌جمجمه‌ای با دقت ۹۹٪ و AUC برابر با ۹۹٪ توسعه داده‌اند که نشان‌دهنده قابلیت اطمینان بالا در شرایط بالینی است. سایر مطالعات، مانند Chang [۲۶] و Chilamkurthy [۱۹] نیز نتایج قابل توجهی در زمینه طبقه‌بندی

خونریزی‌ها با استفاده از مدل‌های یادگیری عمیق ارائه کردند.

[۳۳]Neethi و همکاران مروری بر روش‌های مختلف یادگیری عمیق انجام داده‌اند که از مجموعه‌داده‌های مختلفی از جمله PhysioNet و مجموعه‌داده RSNA استفاده کردند. آنها از مجموعه‌داده RSN که شامل ۲۵۳۱۲ تصویر سی‌تی اسکن از بیماران است، برای آموزش مدل‌های یادگیری عمیق بهره برند و عملکرد آن را بروی مجموعه‌داده PhysioNet ارزیابی کردند. آن‌ها با استفاده از مدل ResNet50- V2 بر روی مجموعه‌داده PhysioNet به F1 Score ۷۶٪ Recall با ۶۷٪ دست یافتند که این نتایج به صورت برش‌محور^۱ گزارش شده است. در میان کارهایی که روی مجموعه‌داده PhysioNet انجام شده است، Kyung [۳۴] و همکاران شبکه‌ای به نام SMART-Net را پیشنهاد کردند که به کمک روش انتقال یادگیری^۲ توانسته‌اند به F1 Score برابر با ۸۴٪ و Sensitivity برابر با ۹۷٪ و Specificity برابر با ۷۴٪ دست یابند. در ادامه Hssayeni [۳۲] و همکاران، از مدل معروف U-Net استفاده کردند که تا یک مدل برای قطعه‌بندی تصاویر سی‌تی اسکن آموزش دهنده. آموزش این مدل با تصاویر ورودی که از ابعاد اصلی برخوردار هستند، باعث شده‌است تا مدل ماسک‌هایی^۴ تماماً سیاه تولید کند که به معنی عدم تشخیص هیچ پیکسلی دارای خونریزی می‌باشد. از این نتیجه می‌توان برداشت کرد که معیار IoU و Dice در آموزش مدل با ابعاد اصلی برابر^۰ بوده است. در ادامه این تحقیق، Hssayeni و همکاران تصویر ورودی را به قسمت‌های 160×160 تقسیم کردند که به موجب آن هر تصویر سی‌تی اسکن، به تعدادی تصویر دارای همپوشانی تبدیل می‌شوند و روی هر پیکسل از تصویر سی‌تی اسکن، ۴ مرتبه پیش‌بینی انجام می‌شود. آنها با تعدیل تعداد تصاویر دارای خونریزی و تصاویری که خونریزی ندارند به روش‌های کاهش داده غالب^۵ و افزایش مصنوعی داده^۶ و توسعه یک روش سورایی برای تصمیم گیری، توانستند معیار شباهت IoU برابر ۲۱٪ و معیار Dice برابر ۳۱٪ دست پیدا کنند. Li [۳۵] و همکاران نیز یک مدل U-Net را روی مجموعه‌داده PhysioNet آموزش داده‌اند اما از جزئیات این آموزش اطلاعات زیادی را مطرح نکرده‌اند. آنها با استفاده از مدل U-Net توانسته‌اند معیار شباهت IoU برابر ۲۱٪ و معیار Dice برابر ۳۵٪ را بدست آورده‌اند.

¹Slice-wise

²Transfer Learning

³Patient-wise

⁴Mask

⁵Undersampling

⁶Augmentation

۱-۶ نقاط ضعف موجود در پژوهش‌های گذشته

با وجود پیشرفت‌های قابل توجه در مدل‌های یادگیری عمیق، هنوز چالش‌هایی در تفسیرپذیری مدل‌های شبکه عصبی وجود دارد که می‌توان از آن به عنوان یکی از نقاط ضعف ادبیات موجود در این زمینه دانست زیرا تفسیرپذیر بودن یک سیستم هوش مصنوعی، یکی از معیارهای اساسی برای متخصصین حوزه پزشکی است تا از این ابزار استفاده کنند. از دیگر نقاط ضعف در ادبیات خونریزی درون جمجمه‌ای، دردسترس نبودن مجموعه‌داده‌های بزرگ با حاشیه‌نویسی مناسب و مجموعه‌داده‌های مربوط به بیمارستان‌ها و دستگاه‌های موجود در ایران است؛ وجود یک مجموعه‌داده با ابعاد مناسب از دستگاه‌های موجود در ایران، می‌تواند مسیر توسعه یک سیستم هوش مصنوعی در زمینه خونریزی درون جمجمه‌ای را در ایران وجود هموار سازد. از دیگر نقاط ضعف موجود در ادبیات موجود در این مسئله، استفاده از شبکه‌هایی با ابعاد بسیار بزرگ توسط محققین می‌باشد که نیازمند پردازشگرهایی با هزینه بیشتر هستند. از مهم‌ترین مشکلات موجود در تحقیقات گذشته، توجه نکرده به بیمارمحور بودن داده‌ها هنگام تفکیک آنها به زیرمجموعه‌های آموزش و ارزیابی اشاره کرد که درنتیجه آن برش‌هایی از یک بیمار که شباهت بسیار زیادی به یکدیگر دارند، در زیرمجموعه‌های آموزش و ارزیابی قرار گیرد که درنتیجه آن همبستگی بین این دو مجموعه داده زیاد خواهد شد. استفاده نکردن از روش مرسوم K-Fold-Cross-Validation، یا نداشتن روش شورا در تصمیم‌گیری در این روش، یکی دیگر از معایب موجود در تحقیقات گذشته است که به موجب آن، تعمیم‌پذیری مدل بدست آمده از این تحقیقات محل ابهام می‌باشد. به عنوان یکی از اشکالات مهم در ادبیات موجود، عدم ارائه معیارهای مناسب و کافی برای ارزیابی عملکرد مدل‌های یادگیری ماشین است که در نتیجه آن، نتایج بدست آمده از شفافیت کافی برخوردار نیست.

۲-۶ اهداف پژوهش

در این پژوهش تلاش شده تا در گام نخست یک روش دو مرحله‌ای شامل یک مدل طبقه‌بندی و یک مدل قطعه‌بندی که به صورت متوالی استفاده می‌شوند توسعه داده شود که این روش، موجب بهبود عملکرد مدل‌های پردازش تصویر در قطعه‌بندی شده است؛ نکته حائز اهمیت در این روش این است که با کاهش امکان ایجاد False Positive در پیش‌بینی‌های مدل قطعه‌بندی، باعث بهبود عملکرد مدل‌های قطعه‌بندی خواهد شد. در گام بعدی یک پس‌پردازش^۱ در لایه تصمیم‌گیری توسعه داده شده است که این پس‌پردازش نیز موجب بهبود عملکرد مدل طبقه‌بندی شده است. در انتهای با استفاده از انواع معیارهای

^۱Post-process

موجود، آموزش مدل با استفاده از روش 5-Fold-Cross-Validation^۱ طراحی یک ضابطه تصمیم‌گیری و استفاده از روش‌هایی برای تفسیرپذیر کردن مدل، امکان تحلیل جامع از عملکرد مدل فراهم شده است.

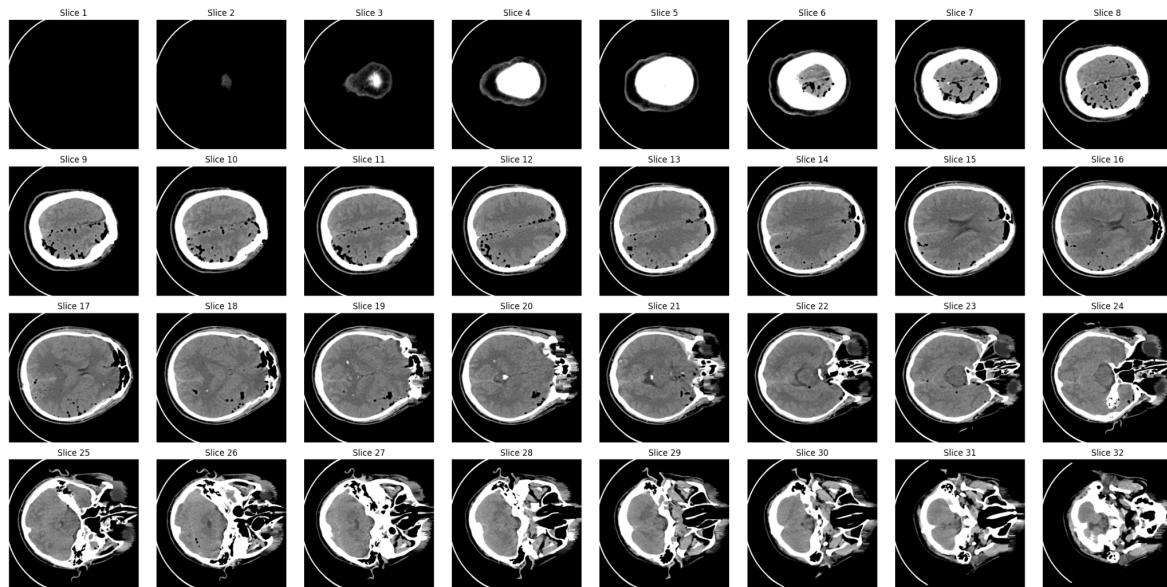
^۱Decision Policy

فصل دوم

روش‌ها و مجموعه‌داده

۱-۲ بررسی آماری مجموعه داده

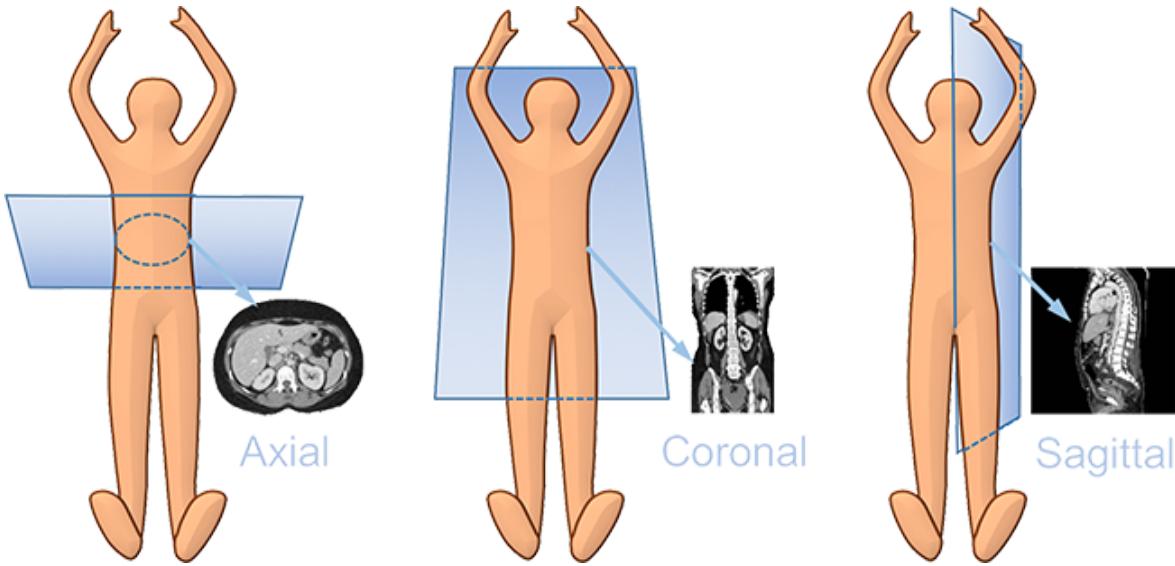
در این پژوهش از مجموعه داده است که شامل حاشیه‌نویسی برای وظیفه طبقه‌بندی و قطعه‌بندی است. این مجموعه داده شامل مجموعه‌ای از سی‌تی‌اسکن‌های مغزی است که به صورت عمومی در دسترس است.



شکل ۱-۲: یک نمونه کامل از تصاویر سی‌تی‌اسکن

همانطور که در شکل ۱-۲ نمایش داده شده است، سی‌تی‌اسکن یک نوع تصویر سه‌بعدی است که از برش‌های دو بعدی تشکیل شده است. شکل ۲-۲ نشان می‌دهد که با توجه به جهت بررسی برش‌های سی‌تی‌اسکن، این تصاویر به سه دسته Axial، Coronal و Sagittal تقسیم می‌شوند.

مجموعه‌داده PhysioNet شامل ۸۲ سی‌تی‌اسکن با برش‌های Axial است که بین فوریه و آگوست ۲۰۲۰ از بیمارستان آموزشی Al Hilla در عراق جمع‌آوری شده است. این اسکن‌ها شامل طیف وسیعی از بیماران هستند که از یک روز تا ۷۲ سال سن دارند و میانگین سن آنها 19.5 ± 27.8 سال است. تنوع سنی این مجموعه داده بر مقیاس، شکل جمجمه و بافت مغز در سی‌تی‌اسکن تأثیر می‌گذارد، عاملی که می‌تواند عملکرد مدل‌های یادگیری عمیق برای تشخیص و قطعه‌بندی خونریزی درون جمجمه‌ای را تحت تأثیر قرار دهد. توزیع جنسیت در ای نمجومه‌داده به گونه‌ای است که ۵۶٪ بیماران مرد و ۴۴٪ آنها زن هستند. ۸۲ بیماری که در این مجموعه داده وجود دارد که ۷ مورد از آنها طی قرابند حاشیه‌نویسی گم شده‌اند و از بین ۷۵ بیمار موجود، ۳۶ نفر دارای خونریزی درون‌جمجمه‌ای تشخیص داده شدند. شکل ۳-۲ نمودار مربوط به تعداد برش‌های هر بیمار در این مجموعه‌داده است؛ تصاویر



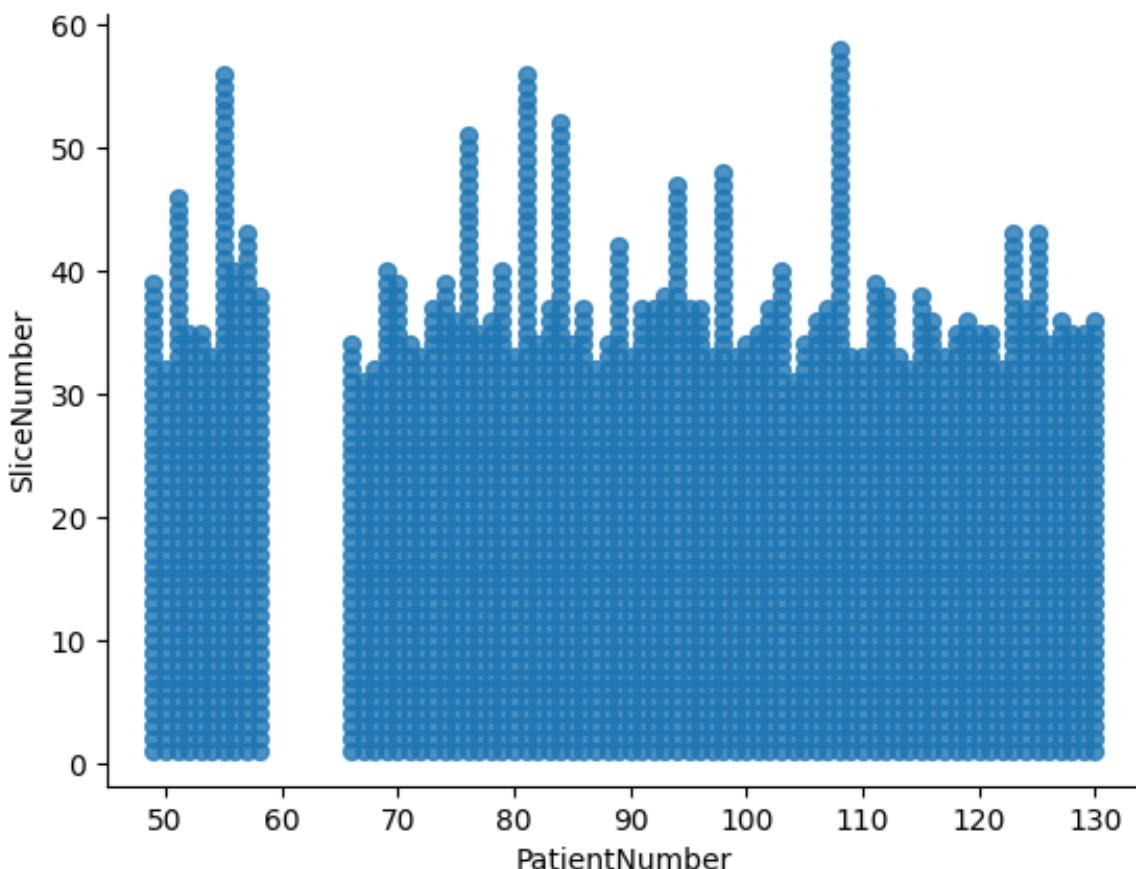
شکل ۲-۲: خواش‌های متفاوت از تصاویر سی‌تی‌اسکن [۲]

سی‌تی‌اسکن موجود در این مجموعه داده، به طور متوسط شامل ۳۴ برش با ضخامت برش ۵ میلی‌متر دارند و در مجموع ۲۸۱۴ برش در این مجموعه داده وجود دارد.

با این حال، این مجموعه داده به دلیل عدم توازن در سطح برش شناخته می‌شود، زیرا تنها ۳۱۸ برش دارای خونریزی هستند در حالی که بقیه ۲۴۹۶ برش سالم هستند. در این مجموعه داده، ۲۴ برش شامل زیرگروه IVH، ۷۳ برش شامل زیرگروه CPH، ۱۸ برش شامل زیرگروه SDH، ۱۷۳ برش شامل زیرگروه EDH و ۵۶ برش شامل زیرگروه SDH هستند. با توجه به تفاوت شکل انواع زیرگروه‌های خونریزی و محل وقوع آنها، این ارقام نشان دهنده عدم وجود تعداد برش کافی برای بعضی از انواع زیرگروه‌های است. در این مجموعه داده، برش‌های سی‌تی‌اسکن توسط دو پرتوشناس بررسی شده‌است و هر برش سی‌تی‌اسکن از نظر وجود خونریزی یا شکستگی توسط آنها بررسی و برچسب‌گذاری شده است. در ادامه سی‌تی‌اسکن‌های دو بیمار، به علت کیفیت ضعیف تصاویر و به توصیه پرتوشناس‌ها حذف شدند [۳۴].

شکل ۲-۴ نمودارهای توزیع بیمارمحور و برش‌محور مجموعه‌داده را نمایش می‌دهد؛ همانطور که از شکل ۲-۴آ مشخص است در بررسی بیمارمحور این مجموعه‌داده، عدم توازن دیده نمی‌شود اما در بررسی برش‌محور، همانطور که در **شکل ۲-۴ب** مشخص است، عدم توازن شدیدی در تعداد برش‌های دارای خونریزی وجود دارد که این مسئله آموزش مدل‌های شبکه عصبی را با چالش مواجه می‌کند.

علاوه بر وجود عدم توازن در حالت برش‌محور، عدم توازن شدیدی در قطعه‌بندی نواحی دارای خونریزی نسبت به نواحی سالم در برش‌های دارای خونریزی وجود دارد که به موجب آن در یک تصویر با



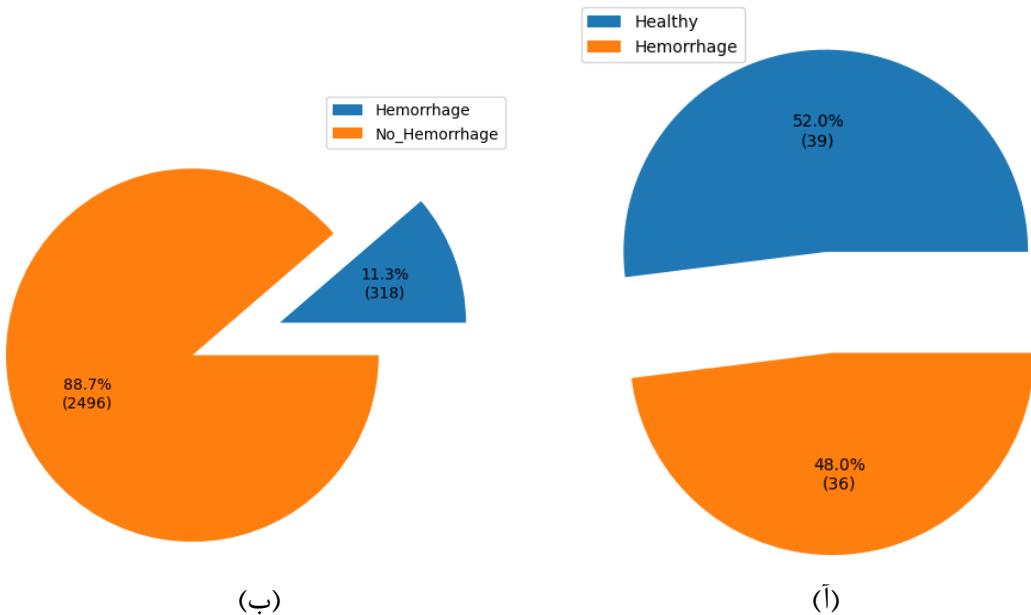
شکل ۲-۳: تعداد برش‌های بیماران بر اساس شناسه اختصاصی آنها

ابعاد 512×512 ، به صورت میانگین نزدیک به 2000 پیکسل^۱ دارای خونریزی درون جمجمه‌ای وجود دارد که این مسئله آموزش مدل‌های شبکه عصبی را به منظور وظیفه قطعه‌بندی با چالش بسیار جدی مواجه می‌کند. شکل ۲-۵ نشان‌دهنده توزیع نرمال شده^۲ مقدار پیکسل‌های برش‌های سالم و برش‌های دارای خونریزی می‌باشد، با توجه به شکل ۲-۱۵آ، اکثر پیکسل‌های تصاویر مقداری نزدیک به 1000 و نقطه بیشینه محلی بعدی برای این نمودار توزیع، در نزدیک مقادیر 30 می‌باشد که این مقادیر به نسبت پیکسل‌ها با مقادیر نزدیک به 1000 – خیلی کمتر می‌باشد.

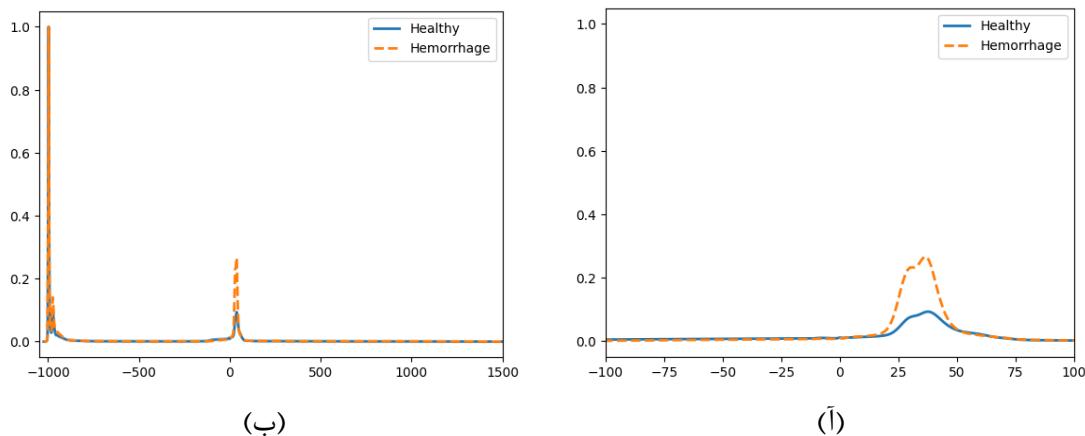
شکل ۶-۲ نمایش‌دهنده توزیع پیکسل‌های دارای خونریزی و تمام پیکسل‌های تصاویر رادیوگرافی می‌باشد که در محدوده بین 100 – 1000 واقع شده است و نسبت به مقادیر همین بازه نرمال گشته است. همانطور که از این دو نمودار مشخص است، مقادیر مربوط به ضایعه خونریزی، مقدار کمی از مقادیر بقیه بافت‌های مغز روشن‌تر است اما همپوشانی این دو نمودار نشان می‌دهد که تشخیص خونریزی

¹Pixel

²Normalized



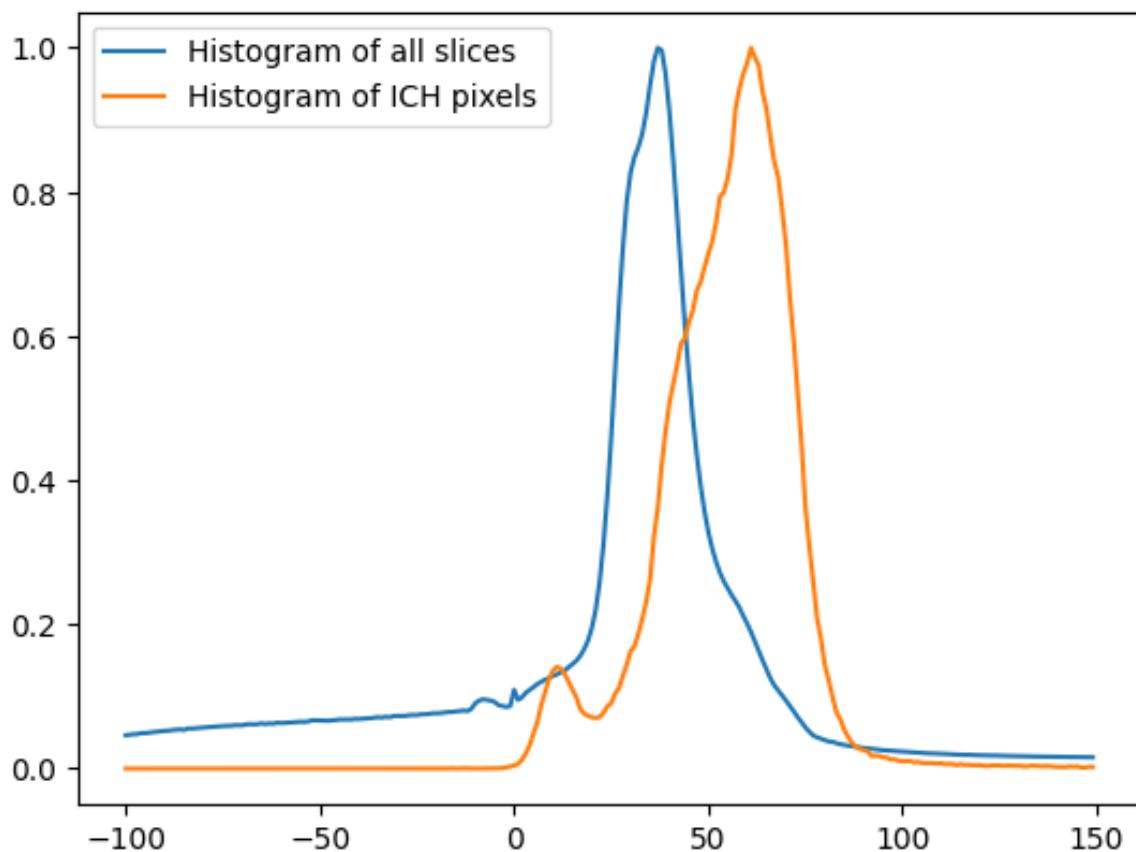
شکل ۲-۴: توزیع بیماران و برش‌ها در مجموعه داده PhysioNet



شکل ۲-۵: توزیع پیکسلی برش‌ها برای برش‌های دارای خونریزی در مقال برش‌های سالم

درون‌جمجمه‌ای تنها با استفاده از مقدار پیکسلی آن بسیار دشوار می‌باشد و نیاز هست تا از شبکه‌هایی استفاده شود تا به اشکال موجود در تصویر نیز حساسیت داشته باشند.

شکل ۲-۳ توزیع خونریزی درون‌جمجمه‌ای را بر اساس شماره برش در تصویر سی‌تی‌اسکن نشان می‌دهد که بر اساس آن مشخص است به ازای بعضی از شماره برش‌ها، خونریزی درون‌جمجمه‌ای وجود ندارد و این برش‌ها از اهمیت کمتری برای مدل‌های یادگیری ماشین برخوردار هستند. با توجه به مطالبی که دی‌این بخش مطرح شد، می‌توان نتیجه گرفت که مجموعه داده PhysioNet، به عنوان تنها مجموعه داده عمومی قطعه‌بندی خونریزی درون‌جمجمه‌ای، می‌تواند یک مجموعه داده معیار برای بررسی عملکرد مدل‌های پردازش تصویر باشد.



شکل ۲-۶: توزیع نرمال‌شده پیکسل‌های دارای خونریزی در مقابل تمام پیکسل‌های تصاویر

۲-۲ پیش‌پردازش^۱

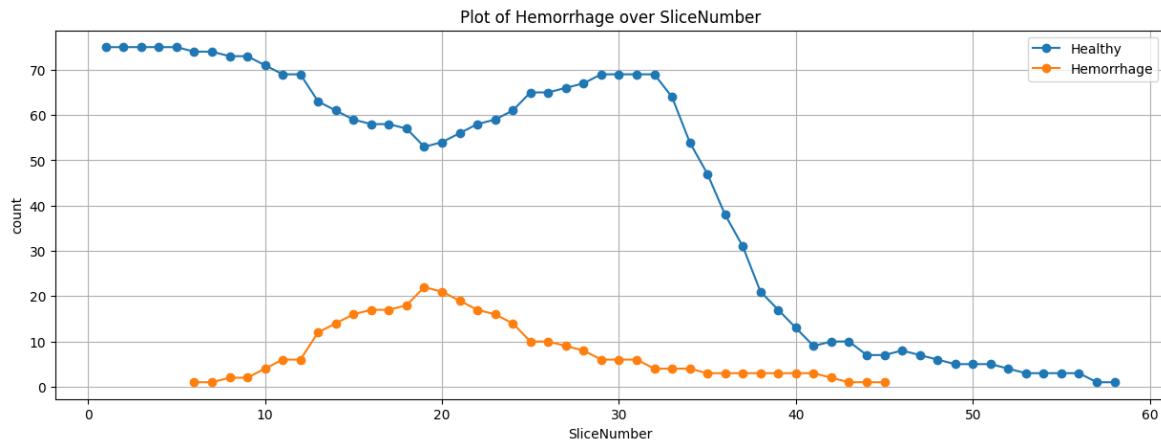
در تصاویر پرتونگاری سی‌تی‌اسکن، از اشعه ایکس^۲ به منظور ثبت تصویر اندام درونی بدن استفاده می‌شود. در این روش، یک کاتد^۳ را برانگیخته می‌کنند تا الکترون‌های^۴ پرانرژی را آزاد کند. با آزاد شدن الکترون‌ها، انرژی به صورت اشعه ایکس آزاد می‌شود و اشعه ایکس از بافت‌ها عبور کرده و به آشکارساز در سمت دیگر برخورد می‌کند. هرچه بافت متراکم‌تر باشد، اشعه ایکس بیشتری را جذب می‌کند؛ مثلاً باقت استخوانی به علت تراکم بالا، اشعه ایکس بیشتری جذب می‌کند و در نتیجه آن اشعه کمتری به آشکارساز می‌رسد که موجب سفید شدن آن قسمت از تصویر خواهد شد اما این مسئله درمورد هوا بر عکس است [۲]. در مقایسه با تصویر اشعه ایکس ساده، سی‌تی‌اسکن دارای تفکیک‌پذیری بیشتر

¹Pre-process

²X-Ray

³Cathode

⁴Electron



شکل ۲-۷: توزیع خونریزی بر اساس برش‌ها

است و هیچ همپوشانی در ساختارها وجود ندارد. دستگاه‌های سی‌تی‌اسکن که از کالیبراسیون^۱ درستی برخوردار باشند، تصاویر خود را طبق یکای Hounsfield ثبت می‌کنند. این یکا به پرتونگارها و محققین اجازه می‌دهد تا بتوانند با آستانه گذاری مناسب، جزئیات بافت هدف خود را در تصویر رویت‌پذیرتر کنند. تصاویر سی‌تی‌اسکن به صورت معمول بر اساس یکای Hounsfield مقادیر پیکسلی بین ۱۰۲۴ – تا ۳۰۰۰ را دارا می‌باشند.

شکل ۲-۸^۲ نشان‌دهنده مقدار پیکسلی است که هر بافت در تصویر سی‌تی‌اسکن از خود نشان می‌دهد. پرتونگارها، پزشک‌ها و محققین برای اینکه بتوانند یک بیماری خاص را مورد بررسی قرار بدهند، برش‌های تصاویر را در بازه‌های خاصی از یکای Hounsfield مورد بررسی قرار می‌دهند که به این نوع از پیش‌پردازش تصاویر سی‌تی‌اسکن، پنجره‌گذاری^۲ می‌گویند.



شکل ۲-۸: اثر بافت‌های متفاوت در یکای Hounsfield [۲]

در روش پنجره‌گذاری، دو مقدار مرکز پنجره (WW) و پهنانی پنجره (WC) بازه هدف را در تصویر مشخص می‌کند و به موجب آن هر پیکسل که مقدار آن از حداقل بازه کمتر باشد، مقدارش برابر با حداقل بازه می‌شود و هر پیکسل که مقدارش از حداقل بازه بیشتر باشد، مقدارش برابر حداقل بازه می‌شود.

¹Calibration

²Windowing

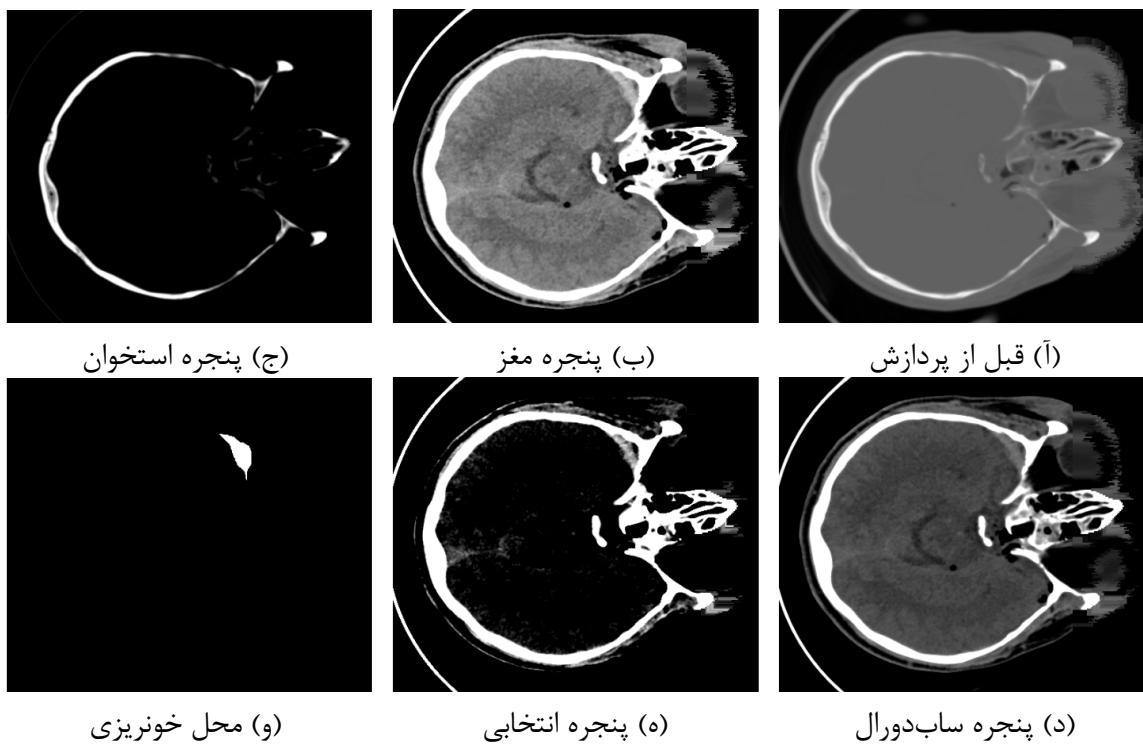
معادله ۲-۲ روش اعمال پنجره‌گذاری روی تصاویر را نمایش می‌دهد که در آن Normalize به منظور انتقال مقادیر تصویر بعد از پنجره‌گذاری بین 0° و 1° است و Threshold تابعی است که در اثر آن مقادیر کمتر از حداقل بازه هدف به مقدار حداقل تغییر پیدا می‌کنند و مقادیری بیشتر از حداقل بازه به مقدار حداقل تبدیل می‌شوند.

$$\text{Processed Image} = \text{Normalize}(\text{Threshold}(\text{Image}, WC - \frac{WW}{2}, WC + \frac{WW}{2})) \quad (2-1)$$

پرتونگارها مقادیر مشخصی را برای شناسایی انواع مختلف اندام در تصاویر سی‌تی اسکن تعیین کردند. به عنوان مثال، در مجموعه‌داده PhysioNet، پردازش تصویر اصلی بهازای مرکز پنجره 40° و پهناهی پنجره 120° ، پنجره مغز استخراج می‌شود و بهازای مرکز پنجره 70° و پهناهی پنجره 320° ، پنجره استخوان استخراج می‌شود. **شکل ۹-۲** اثر پنجره‌گذاری را بر یک نمونه برش سی‌تی اسکن نشان می‌دهد. همانطور که از این **شکل ۹-۲** مشخص است، تصویر قبل از پیش‌پردازش جزئیات خاصی را به ما نشان نمی‌دهد و اگر این تصویر را بدون نرمال کردن برای آموزش شبکه عصبی استفاده کنیم، باعث می‌شود که لایه‌های ابتدایی شبکه مقادیر خیلی بزرگی را ایجاد کنند و در نتیجه عملکرد مدل کاهش پیدا بکند و اگر این تصویر را نرمال کنیم، به علت بازه بسیار زیاد یکای Hounsfield تفکیک‌پذیری مقادیر تصویر به شدت کاهش پیدا می‌کند. در ادامه **شکل ۹-۲ ب**، **شکل ۹-۲ ج** و **شکل ۹-۲ د** اثر سه پنجره مرسوم مغز، استخوان و سابدوارال را مشاهده می‌کنیم که هر کدام تفکیک‌پذیری بافت هدف خود را افزایش داده‌اند و در پنجره مغز و سابدوارال، محل خونریزی به وضوح مشخص است. **شکل ۹-۲ ه** پنجره انتخابی را نشان می‌دهد که براساس محدوده موجود در **شکل ۶-۲** انتخاب شده‌است و در نتیجه آن، محل خونریزی بروز بیشتری پیدا کرده است. در ادامه این پژوهش، پنجره مغز به عنوان پنجره اصلی آموزش و ارزیابی مدل‌ها در نظر گرفته شده است.

از دیگر روش‌های پیش‌پردازشی که در این پژوهش استفاده شده است، افزایش مصنوعی داده می‌باشد که به جهت بهبود عملکرد مدل در فرایند آموزش انجام شده است. تبدیل‌های افزایش مصنوعی داده‌ای که در این پژوهش استفاده شده است شامل چرخش، برش تصادفی، تبدیل آیینه حول محور افقی و بزرگنمایی تصادفی است. به علت اینکه سر تمامی بیماران در مجموعه‌داده PhysioNet جهت یکسانی دارد، استفاده از تبدیل آیینه حول محور عمودی باعث ایجاد تصاویری می‌شود که معادل آنها در مجموعه‌داده وجود

ندارد [۲۰].



شکل ۲-۹: تاثیر اثر پنجره‌گذاری در نمایش خونریزی در یک برش از سی‌تی‌اسکن

۳-۲ روش پردازش تصاویر

شبکه‌های عصبی عمیق به عنوان یکی از روش‌های محبوب در حوزه‌ی یادگیری ماشین شناخته می‌شوند. این شبکه‌ها از ساختارهایی شبیه به مغز انسان تشکیل شده‌اند که شامل تعدادی نورون^۱ مصنوعی هستند و قادرند با استفاده از داده‌های ورودی، الگوها و روابط پیچیده را بیاموزند. یادگیری عمیق، شاخه‌ای از شبکه‌های عصبی است که با افزایش تعداد لایه‌های مخفی در شبکه، امکان پردازش و تحلیل داده‌های بسیار پیچیده و بزرگ را فراهم می‌کند. در این پژوهش، روش اصلی مورد استفاده برای پردازش کامپیوترا تصاویر، یادگیری عمیق است.

۱-۳-۲ یادگیری عمیق و اصول اولیه

یادگیری عمیق یکی از شاخه‌های مهم یادگیری ماشین است که به دلیل توانایی‌های خود در پردازش، تحلیل و الگویابی در داده‌های پیچیده، به ویژه در حوزه‌ی پزشکی، به طور گسترده‌ای مورد استفاده قرار

^۱Neuron

گرفته است. در این بخش، به بررسی اصول پایه‌ای یادگیری عمیق در پردازش تصویر پرداخته شده است.

ساختار نورون

شبکه‌های عصبی مصنوعی از تعدادی واحد پردازشی به نام نورون تشکیل شده‌اند. هر نورون چندین ورودی x_1, x_2, \dots, x_n دریافت می‌کند که هر یک با وزن‌های w_1, w_2, \dots, w_n متناظر ضرب می‌شوند. سپس، مجموع وزن‌دار ورودی‌ها به اضافه‌ی یک بایاس b مطابق با معادله ۲-۲ محاسبه شده و از طریق یک تابع فعال‌سازی ϕ به خروجی تبدیل می‌شود، که رابطه آن در معادله ۳-۲ مشخص شده است.

$$z = \sum_{i=1}^n w_i x_i + b \quad (2-2)$$

$$a = \phi(z) \quad (2-3)$$

توابع فعال‌سازی به منظور ایجاد خاصیت غیرخطی در نورون‌ها استفاده می‌شوند تا با استفاده از شبکه عصبی عمیق، بتوانیم تابع غیرخطی را تخمین بزنیم. دو تابع فعال‌سازی رایج عبارتند از ReLU^۱ و Sigmoid^۲. رابطه تابع ReLU در معادله ۴-۲ مشخص شده است و رابطه تابع Sigmoid، در معادله ۵-۲ مشخص شده است.

$$\phi(z) = \max(0, z) \quad (2-4)$$

و تابع سیگموید نیز به صورت زیر تعریف می‌شود:

$$\phi(z) = \frac{1}{1 + e^{-z}} \quad (2-5)$$

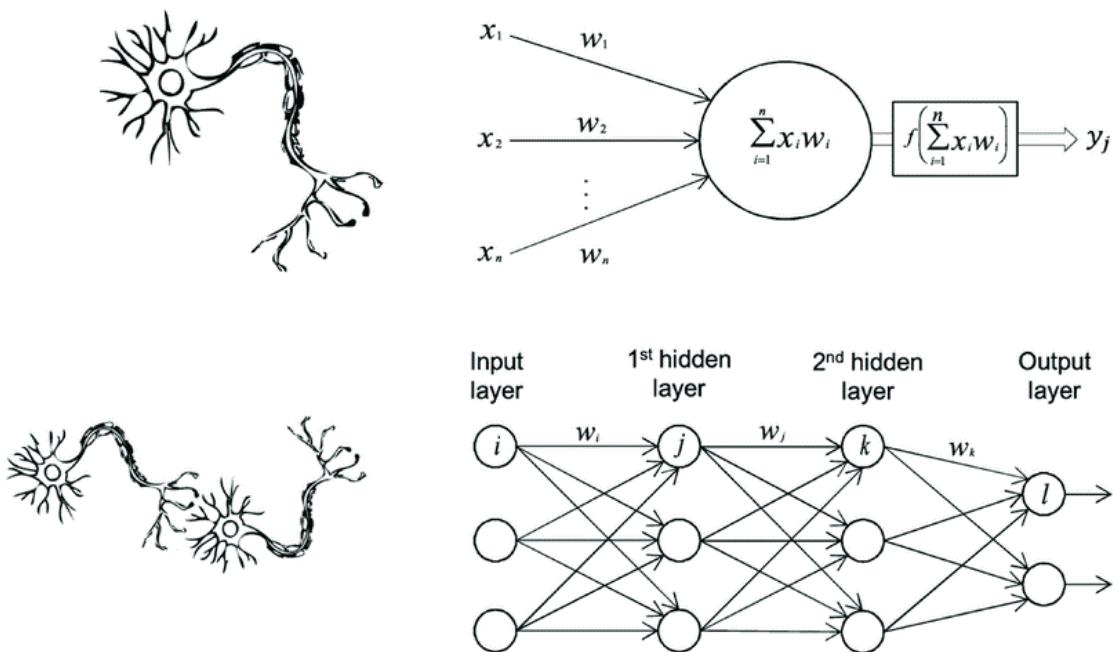
لایه‌های پنهان

شبکه‌های عصبی عمیق از چندین لایه‌ی پنهان تشکیل شده‌اند که هر کدام از تعداد زیادی نورون مشابه نورون‌های توصیف شده در بخش قبلی تشکیل شده‌اند. خروجی هر نورون در یک لایه به عنوان ورودی برای نورون‌های لایه‌ی بعدی استفاده می‌شود. این ساختار چندلایه به شبکه امکان می‌دهد تا ویژگی‌های

¹Rectified Linear Unit

²Sigmoid

پیچیده و رفتار غیرخطی را از داده‌های ورودی استخراج کند. شکل ۱۰-۲ نمایش نحوه مدلسازی یک نورون را با استفاده از معادله ۲-۲ و معادله ۳-۲ نشان می‌دهد و در ادامه نحوه عملکرد لایه‌های پنهان در شبیه‌سازی ارتباط بین نرون‌ها را نشان می‌دهد.



شکل ۱۰-۲: مدلسازی یک نورون عصبی توسط رابطه ریاضی و ارتباط بین نرون‌ها با استفاده از لایه‌های پنهان [۳]

تابع خطا و پس‌انتشار^۱

تابع خطا^۲ نقش کلیدی در آموزش شبکه‌های عصبی دارد. این تابع تفاوت بین خروجی پیش‌بینی شده y_{true} و خروجی واقعی y_{pred} را محاسبه می‌کند. یکی از رایج‌ترین توابع خطا، خطای Entropy(BCE) است که طبق معادله ۲-۶ برای مسائل دسته‌بندی دوستایی استفاده می‌شود.

$$L(y_{\text{true}}, y_{\text{pred}}) = -\frac{1}{m} \sum_{i=1}^m \left[y_{\text{true}}^{(i)} \log(y_{\text{pred}}^{(i)}) + (1 - y_{\text{true}}^{(i)}) \log(1 - y_{\text{pred}}^{(i)}) \right] \quad (2-6)$$

هدف از آموزش شبکه، کمینه‌سازی این تابع خطا است که با استفاده از الگوریتم پس‌انتشار انجام می‌شود. در این روش، گرادیان^۳ تابع خطا نسبت به هر وزن w_i طبق معادله ۷-۲ و قانون مشتقات

¹backpropagation

²Loss Function

³Gradient

زنگیرهای، محاسبه شده و سپس وزن‌ها با استفاده از قانون گرادیان کاهشی مطابق معادله ۲-۸ به روزرسانی می‌شوند:

$$\frac{\partial L}{\partial w_i} \quad (2-7)$$

$$w_{i+1} \leftarrow w_i - \eta \frac{\partial L}{\partial w_i} \quad (2-8)$$

لایه‌های پرسپترون^۱ چندلایه

لایه‌های پرسپترون چندلایه (MLP) یکی از ساده‌ترین و پایه‌ای‌ترین ساختارها در شبکه‌های عصبی هستند. این لایه‌ها از تعدادی نورون تشکیل شده‌اند که به صورت کامل به یکدیگر متصل هستند؛ به بیان دیگر هر نورون در یک لایه به تمامی نورون‌های لایه‌ی قبلی متصل می‌شود و اطلاعات را به لایه‌ی بعدی منتقل می‌کند. خروجی هر لایه $a^{[l]}$ از ترکیب خطی ورودی‌ها و اعمال تابع فعال‌سازی طبق معادله ۹-۲ به دست می‌آید:

$$a^{[l]} = \phi(W^{[l]}a^{[l-1]} + b^{[l]}) \quad (2-9)$$

شبکه عصبی پیچشی^۲

برای بهبود عملکرد شبکه‌های عصبی در پردازش تصاویر، از لایه‌های شبکه عصبی پیچشی (CNN) استفاده می‌شود. در این لایه‌ها، عملیات کانولوشن به جای ضرب ماتریسی بین ورودی و وزن‌ها طبق معادله ۱۰-۲ انجام می‌شود. این عملیات برای هر ناحیه کوچک از تصویر با استفاده از یک فیلتر k صورت می‌گیرد.

$$z_{i,j} = (X * k)_{i,j} = \sum_m \sum_n X_{i+m,j+n} \cdot k_{m,n} \quad (2-10)$$

خروجی این عملیات، نقشه ویژگی Feature Map است که به لایه بعدی منتقل می‌شود. با عبور یک تصویر از لایه‌های یک شبکه عصبی پیچشی، بین پیکسل‌های کنارهم در تصویر، یک رابطه برقرار

¹Perceptron

²Convolutional Neural Network

می‌شود که درنتیجه آن، نقشه ویژگی استخراج شده برای هر پیکسل، به وضعت پیکسل‌های اطرافش بستگی دارد و هرچه از پیکسل مبدا دور شویم، اثر آن در نقشه ویژگی کاهش پیدا می‌کند.

بهینه‌سازها و الگوریتم Adam

بهینه‌سازی یکی از مهم‌ترین اجزا در آموزش شبکه‌های عصبی هستند که هدف آنها به روزرسانی وزن‌ها به گونه‌ای است که تابع خطا به حداقل مقدار خود برسد. برای این منظور، از الگوریتم‌هایی استفاده می‌شود که بهینه‌ساز نامیده می‌شوند. یکی از رایج‌ترین بهینه‌سازها، الگوریتم گرادیان کاهشی است که در آن وزن‌ها در جهت منفی گرادیان تابع خطا به روزرسانی می‌شوند، هرابطه گرادیات کاهشی در معادله ۸-۲ نشان داده شده است. یکی دیگر از بهینه‌سازهای پیشرفته و کارآمد، بهینه‌ساز Adam است. این بهینه‌ساز از ترکیب دو روش RMSProp و Momentum بهره می‌برد [۳۷، ۳۸]. به روزرسانی وزن‌ها در Adam با استفاده از روابط در معادله ۱۱-۲ انجام می‌شود.

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla L(\theta_t) \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L(\theta_t))^2 \\ \theta_{t+1} &= \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \end{aligned} \quad (2-11)$$

در این معادلات، m_t و v_t به ترتیب تخمین میانگین حرکت‌دار گرادیان و میانگین حرکت‌دار مربعات گرادیان در زمان t هستند، و β_1 و β_2 ضرایب مربوط به این میانگین‌ها هستند. η نرخ یادگیری و ϵ یک مقدار بسیار کوچک برای جلوگیری از تقسیم بر صفر است. Adam به دلیل توانایی خود در تنظیم نرخ یادگیری برای هر پارامتر به طور خودکار، به یکی از پرکاربردترین بهینه‌سازها در آموزش شبکه‌های عصبی عمیق تبدیل شده است.

۴-۲ مدل‌های طبقه‌بندی در شبکه عصبی عمیق

ResNet ۱-۴-۲

شبکه‌های عصبی عمیق به یک ابزار قدرتمند در انجام وظایف مختلف یادگیری ماشین تبدیل شده‌اند. با این حال، با افزایش عمق این شبکه‌ها، مشکلاتی همچون ناپدیدشدن مشتق^۱ یا انچجار مشتق^۲ و

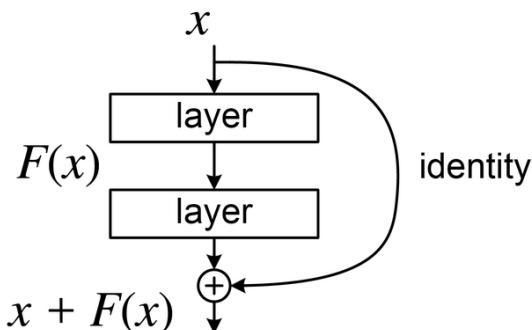
¹Vanishing Gradient

²Exploding Gradient

دشوار شدن آموزش به وجود می‌آید. برای حل این مشکلات، [۳۹] He و همکارانش معماری شبکه‌های ResNet را پیشنهاد کردند که امکان آموزش شبکه‌های بسیار عمیق‌تر را با معرفی اتصالات Residual فراهم می‌کند. ایده اصلی پشت ResNet معرفی یک اتصال میانبر^۱ است که یک یا چند لایه از شبکه را دور می‌زند. این اتصال میانبر به شبکه امکان می‌دهد تا از طریق آن، مشتق خطابه لایه‌های ابتدایی برسد تا فرایند آموزش برای لایه‌هایی که از خروجی دور هستند، با مشکل موواجه نشود. همانطور که در شکل ۱۱-۲ نمایش داده شده است، در شبکه‌های ResNet به جای یادگیری یک نگاشت مستقیم، مثلاً $H(x)$ ، شبکه نگاشت x را یاد می‌گیرد که بهینه‌سازی آن ساده‌تر است. بنابراین، خروجی نهایی بلوک^۲ $H(x) = F(x) + x$ خواهد بود که در نتیجه آن، مشتق تابع خطابی L به‌ازای ورودی x در معادله ۱۲-۲ نمایش داده شده است.

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial H(x)} \cdot \frac{\partial H(x)}{\partial x} = \frac{\partial L}{\partial H(x)} \cdot \left(1 + \frac{\partial F(x)}{\partial x}\right) \quad (2-12)$$

این فرمول نشان می‌دهد که مشتق می‌تواند به راحتی از طریق مسیر میانبر عبور کند، که به حل مشکل ناپدید شدن یا انفجار گرادیان کمک می‌کند.



شکل ۱۱-۲: یک بلوک از معماری ResNet که اتصال میانبر همانی را نشان می‌دهد [۴۰].

در انجام وظیفه طبقه‌بندی تصویر، عملکرد مناسبی از خود نشان داده است. این شبکه با معرفی اتصال میانبر و فراهم کردن امکان آموزش شبکه‌های بسیار عمیق، باعث بهبود عملکرد مدل‌های شبکه عصبی عمیق شده است.

¹Skip Connection

²Block

ResNeXt ۲-۴-۲

ResNeXt [۵] و همکاران معرفی شده است که یک معماری شبکه عصبی پیچشی عمیق است که براساس ساختار ResNet ساخته شده و با معرفی یک فراپارامتر^۱ جدید به نام کاردینالیتی^۲ سعی در بهبود مدل ResNet داشته است. این مدل به منظور بهبود عملکرد شبکه‌های عصبی عمیق، مسیرهای موازی متعدد را در ساختار شبکه ایجاد می‌کند که این روش مشابه مدل ساختار Inception می‌باشد اما با تفاوت‌های کلیدی در سادگی طراحی اجزای شبکه.

همانطور که در شکل ۱۲-۲آ، شکل ۱۲-۲ب مشخص شده است، مسیرهای موازی در ساختار شبکه ایجاد شده است که این مسیرها به مقدار کاردینالیتی بستگی دارد. کاردینالیتی به تعداد مسیرهای موازی درون هر بلوک شبکه اشاره دارد. برخلاف افزایش عمق یا عرض که به افزایش تعداد لایه‌ها یا پیچیدگی هر لایه منجر می‌شود، افزایش کاردینالیتی اجازه می‌دهد که چندین مسیر پردازشی به صورت موازی عمل کنند و در نهایت خروجی‌های آن‌ها با یکدیگر ادغام شوند که از بار پردازشی شبکه کم می‌کند. شکل ۱۲-۲ج ساده‌سازی بلوک ResNeXt برای بهینه‌سازی و ساده‌سازی محاسبات را نشان می‌دهد که از لایه‌های پیچشی گروهی استفاده می‌کند. در این روش، کanal‌های^۳ ورودی به گروه‌های مختلف تقسیم می‌شوند و کانولوشن‌ها به صورت مستقل در هر گروه انجام می‌گیرند. افزایش کاردینالیتی در ResNeXt نه تنها باعث بهبود دقت مدل می‌شود، بلکه امکان استفاده از مسیرهای پردازشی متعدد به صورت موازی، بدون افزایش چشمگیر در پیچیدگی محاسباتی، را فراهم می‌کند. این ویژگی به ResNeXt اجازه می‌دهد که در وظایف پیچیده مانند طبقه‌بندی تصاویر با دقت بیشتری عمل کند. علاوه بر این، استفاده از لایه‌های پیچشی گروهی به کاهش هزینه محاسباتی کمک کرده و در عین حال، قدرت الگوهای پیچیده را حفظ می‌کند.

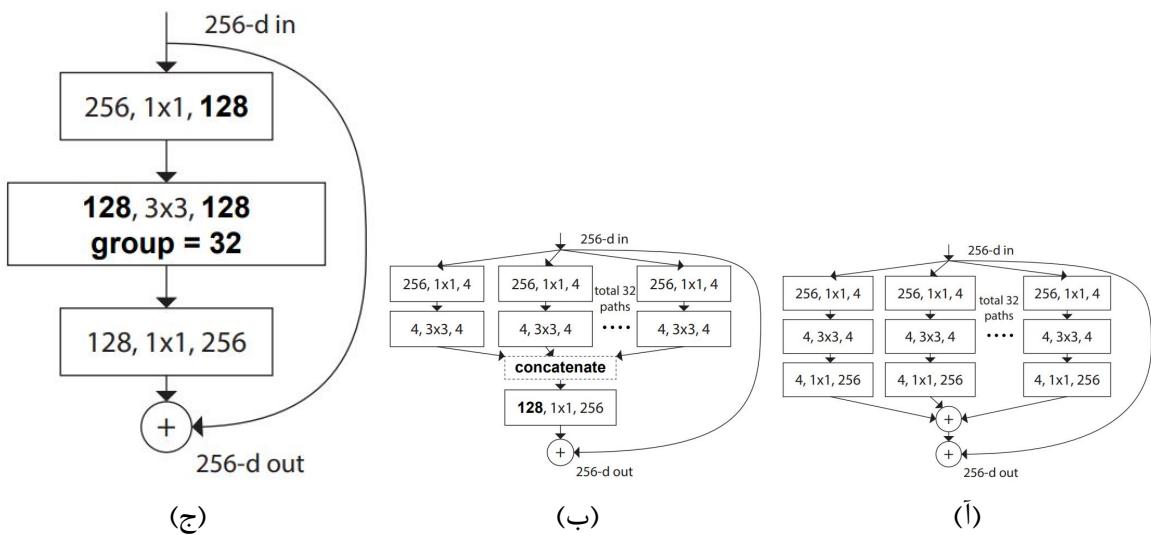
شبکه ۳-۴-۲ (SENet) Squeeze-and-Excitation

Hu [۶] و همکاران، با معرفی بلوک (SE) Squeeze-and-Excitation در ImageNet به میزان ۵۰.۲٪ نسبت به سال گذشته بهبود یافت. این بلوک با وزن‌دهی به میان کanal‌های مختلف در هر لایه از شبکه عصبی پیچشی، عملکرد شبکه‌های عصبی را با هزینه محاسباتی بسیار کمی بهبود می‌بخشد. ایده اصلی درمورد روش Squeeze-and-Excitation این است که در یک لایه معمولی در شبکه عصبی

¹Hyper-parameter

²Cardinality

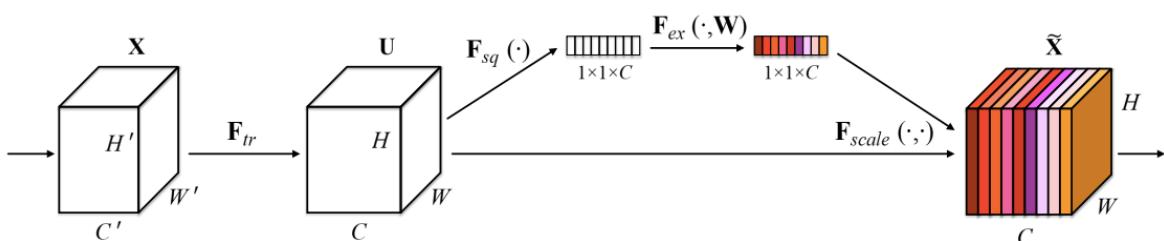
³Channel



شکل ۱۲-۲: ساختارهای مختلف در معماری ResNeXt که کانولوشن‌های گروهی، مسیرهای پردازشی موازی و روش ادغام را نشان می‌دهند [۵].

پیچشی، ارزش هر کanal در ورودی شبکه، با بقیه کanal‌ها یکسان است. بلوک SE اما، رویکردی تطبیقی را معرفی می‌کند که در آن اهمیت هر کanal به طور جداگانه و بر اساس زمینه ارزیابی می‌شود و به آن وزنی خاص اختصاص‌داده می‌شود.

شکل ۱۳-۲ نحوه عملکرد این مدل را نشان می‌دهد که در گام نخست از هر کanal نقضه ویژگی میانگین گرفته می‌شود، سپس این میانگین از یک تابع خطی عبور داده می‌شود و در گام بعدی، تابع Sigmoid روی آن اعمال می‌شود تا وزن‌ها بین ۰ تا ۱ قرار بگیرند. در انتها وزن‌های محاسبه شده در نقشه ویژگی ضرب می‌شود و خروجی لایه پیچشی Squeeze-and-Excitation شبکه عصبی پیچشی به‌دست می‌آید. ResNeXt یکی از مدل‌های پایه‌ای است که با استفاده از روش بلوک SE عملکردش ارتقا پیدا کرده است.



شکل ۱۳-۲: بلوک Squeeze-and-Excitation که نحوه عملکرد آن را در ارزیابی و وزن‌دهی کanal‌ها نشان می‌دهد [۶].

DenseNet ۴-۴-۲

DenseNet یک نوع شبکه عصبی پیچشی است که به منظور بهبود عملکرد شبکه‌های عصبی پیچشی سنتی معرفی شده است. هدف اصلی این شبکه، کاهش محدودیت‌هایی است که معمولاً شبکه‌های پیچشی عمیق، با آن‌ها مواجه می‌شوند. در شبکه‌های پیچشی سنتی، یکی از مشکلات اصلی زمانی رخ می‌دهد که مشتق، نمی‌تواند در فرایند پس‌انتشار به درستی در تمامی لایه‌ها انتقال یابد که این مسئله در [زیرقسمت ۱-۴-۲](#) بررسی شده است. مسئله ناپدید شدن مشتق به ویژه در لایه‌های اولیه بسیار تاثیر می‌گذارد که این موضوع به روزرسانی وزن‌ها و بایاس‌ها را مختل کرده و بر عملکرد کلی شبکه تأثیر منفی می‌گذارد. برای کمک به کاهش مشکلاتی که پیشتر مطرح شد [\[۷\]](#). Huang [\[۷\]](#) و همکاران، مدل DenseNet را معرفی کردند. در حالی که یک بلوک‌های شبکه عصبی پیچشی سنتی، تنها از نقشه ویژگی خروجی فعلی به عنوان ورودی برای لایه بعدی استفاده می‌کند، همانطور نقشه‌های ویژگی که در لایه‌های پیشین ایجاد شده را نیز در ورودی لایه فعلی استفاده می‌کند. همانطور که در [شکل ۱۴-۲](#) مشاهده می‌شود. این کار جریان اطلاعات بین لایه‌ها را به حداقل می‌رساند، تعداد متغیرهای مدل را افزایش چشمگیری نمی‌دهد و به طور قابل توجهی مشکل ناپدید شدن گرادیان‌ها را بهبود می‌بخشد.

شبکه‌های DenseNet، برخلاف ResNet ها که از جمع برای ترکیب نقشه‌های ویژگی استفاده می‌کنند، از [الحق](#)^۱ استفاده می‌کنند تا اطلاعات را به صورت موثرتری حفظ کنند. هر لایه در DenseNet نقشه‌های ویژگی تمامی لایه‌های قبلی را به عنوان ورودی دریافت کرده و آن‌ها را قبل از عبور از تبدیل غیرخطی به یکدیگر [الحق](#) می‌کند [\[۷\]](#).

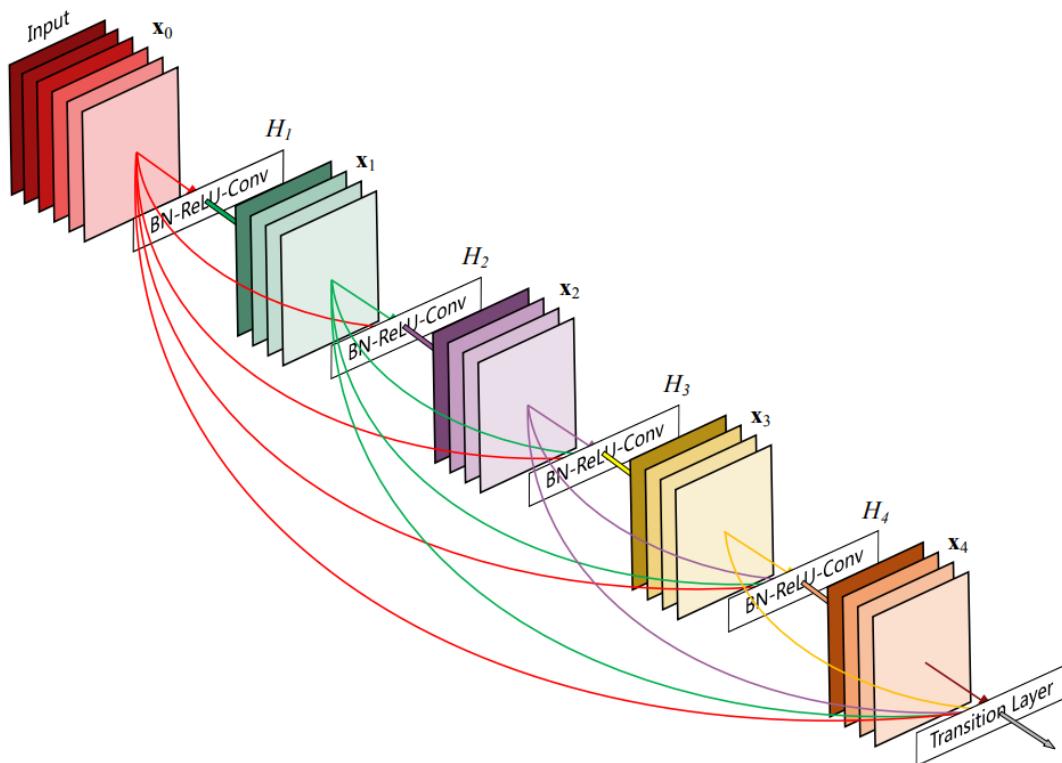
EfficientNet ۵-۴-۲

Tan [\[۴۰\]](#) و همکارانش یک معماری و روش مقیاس‌گذاری را در مدلی به نام EfficientNet معرفی کردند. این روش به ما امکان می‌دهد که تعداد متغیرهای مدل را به صورت بهینه افزایش دهیم. در این روش، برای افزایش تعداد متغیرهای مدل، سه ویژگی عمق، عرض و وضوح [۲](#) تصویر باید به صورت یکنواخت و با استفاده از سه ضربی ثابت افزایش پیدا کنند.

به طور مشخص، اگر بخواهیم تعداد متغیرهای مدل را به میزان 2^N برابر افزایش دهیم، می‌توانیم به سادگی عمق شبکه را به میزان α^N ، عرض شبکه را به میزان β^N و وضوح تصویر را به میزان γ^N افزایش

¹Concatenation

²Resolution



شکل ۱۴-۲: [۱۷]DenseNet یک بلوک معماری.

دهیم، که در آن α ، β و γ ضرایب ثابتی هستند که معادله ۱۳-۲ باید برای آنها برقرار باشد. این رابطه به این معناست که افزایش منابع محاسباتی به میزان 2^N برابر، به توزیع متناسبی از افزایش عمق، عرض و وضوح تصویر منجر می‌شود.

$$\alpha \times \beta^2 \times \gamma^2 \approx 2 \quad (2-13)$$

در نتیجه پژوهش Tan و همکارانش، یک خانواده از مدل‌های مبتنی بر شبکه عصبی پیچشی ایجاد شد که ضمن داشتن تعداد متغیرهای بسیار کمتر، عملکرد بهتری نسبت به مدل‌های قبلی ایفا می‌کند.

۵-۲ مدل‌های قطعه‌بندی در شبکه عصبی عمیق

۱-۵-۲ U-Net

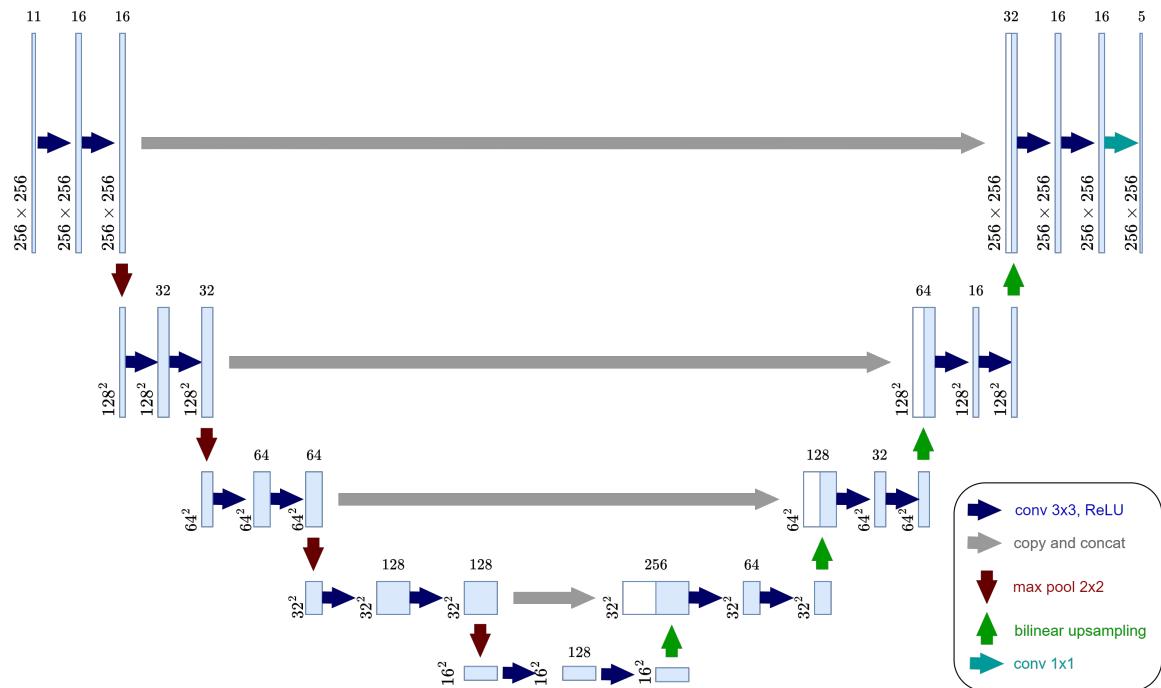
شبکه U-Net یکی از پرکاربردترین معماری‌ها در حوزه‌ی پردازش تصویر و به‌ویژه در بخش‌بندی تصاویر است که توسط Ronneberger [۸] و همکاران توسعه داده شده است. این مدل، که در اصل به عنوان یک شبکه عصبی پیچشی خودرمزنگذار^۱ معرفی شد، به دلیل طراحی خاص خود که امکان بازیابی دقیق اطلاعات مکانی را به کمک مسیرهای میانبر فراهم می‌آورد، به‌طور گستردگی مورد استفاده قرار می‌گیرد. ساختار U-Net شامل دو مسیر اصلی است؛ مسیر اول، رمزگذار نام دارد که مسئول استخراج ویژگی‌ها و کاهش ابعاد و افزایش تعداد کانال‌ها است. مسیر بعدی، رمزگشا نام دارد که وظیفه بازسازی تصویر به اندازه اصلی و مشخص کردن محل جسم را بر عهده دارد که این کار را با استفاده از اطلاعات استخراج شده از مسیر رمزگذار انجام می‌دهد.

ساختار شبکه U-Net در شکل ۱۵-۲ مشاهده می‌شود که مسیر رمزگذار شامل چندین مرحله از شبکه عصبی پیچشی و لایه ادغام^۲ است. از سوی دیگر، مسیر رمزگشا شامل افزایش ابعاد و ترکیب ویژگی‌های استخراج شده در مسیر رمزگذار است تا تصویر نهایی با دقت بالایی بازسازی شود. یکی از ویژگی‌های کلیدی U-Net مسیرهای میانبر بین لایه‌های رمزگذار و رمزگشا متناظر است که اطلاعات مکانی دقیق را از رمزگذار به رمزگشا منتقل می‌کند.

در حالی که ساختار اصلی U-Net به‌خوبی قادر به انجام وظایف مختلف است، امکان بهبود عملکرد آن با استفاده از مدل‌های پیشرفته‌تر در بخش رمزگذار وجود دارد. به عنوان مثال، می‌توان از مدل‌هایی که در بخش‌های قلی مطرح شد، مانند EfficientNet، SENet، ResNeXt، ResNet و U-Net در مسیر رمزگذار استفاده کرد. این مدل‌ها به دلیل قابلیت‌های قدرتمند خود در استخراج ویژگی‌ها و مدیریت اطلاعات پیچیده، می‌توانند عملکرد U-Net را در وظایف پیچیده‌تر به‌طور قابل توجهی بهبود بخشدند. این قابلیت به‌ویژه در مواقعي که تصاویر ورودی دارای جزئیات بسیار بالایی هستند یا نیاز به دقت بالایی در خروجی است، اهمیت بیشتری پیدا می‌کند. به همین دلیل، U-Net با ساختار خود، یکی از انعطاف‌پذیرترین مدل‌ها برای ترکیب با معماری‌های دیگر به‌شمار می‌رود و به‌طور گستردگی در زمینه‌های مختلف از جمله پزشکی و بینایی ماشین مورد استفاده قرار می‌گیرد.

¹Autoencoder

²Pooling



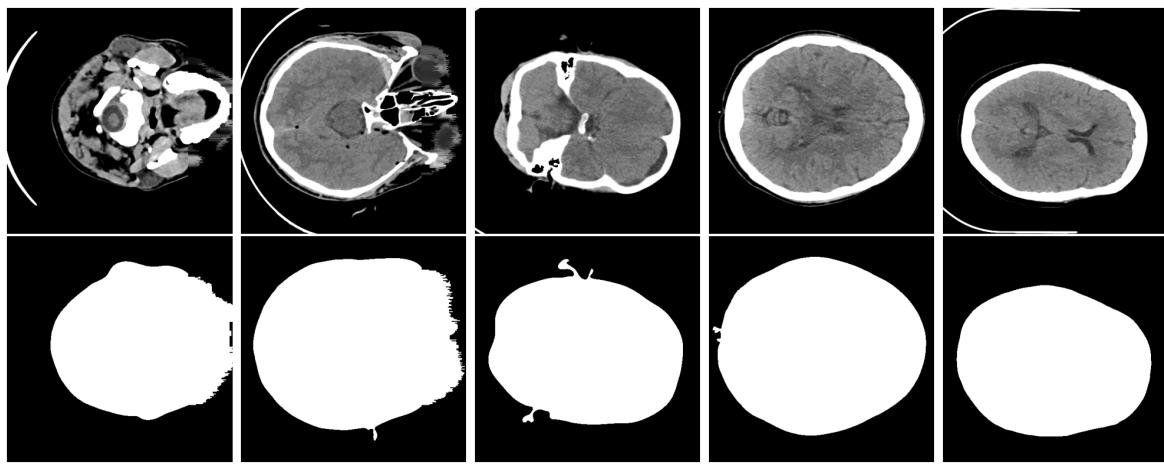
شکل ۱۵-۲: ساختار شبکه U-Net که شامل مسیر رمزگذار و رمزگشا، همراه با اتصالات کپی و الحاق است [۸].

۶-۲ پسپردازش

پسپردازش پیشنهادی در این پژوهش، به منظور بهبود عملکرد مدل قطعه‌بندی، توسعه داده شده است.

شکل ۱-۲ یک نمونه تصویر سی‌تی‌اسکن را نشان می‌دهد؛ همانطور که در این تصویر مشخص است، حاشیه‌سیاه برش‌ها شامل هیچ اندامی نمی‌باشد و بدیهی است که هیچ ضایعه خونریزی در این نواحی یافت نخواهد شد، بنابراین با توجه به اینکه یکای Hounsfield این نواحی بسیار از مقدار آن در بافت مغز متفاوت است، روش آستانه‌گذاری روی برش‌ها اعمال شد که آستانه مربوطه از روی **شکل ۲-۵ب**، به گونه‌ای انتخاب شد که نواحی شامل بافت مغز، از نواحی که هیچ اندامی در آنها وجود ندارد جدا شود.

شکل ۱۶-۲ لایه‌های پسپرداز استخراج شده با روش آستانه‌گذاری را برای برش‌های متفاوت نشان می‌دهد. این لایه‌ها پس از آنکه استخراج شدند، در مرحله تصمیم‌گیری مدل قطعه‌بندی مورد استفاده قرار گرفته می‌شوند. روش استفاده از این لایه‌ها به گونه‌ای است که احتماً هر گونه پیش‌بینی موجود در نواحی سیاه از تصویر را برابر ° قرار می‌دهد و باعث می‌شود تا نیاز به آموزش لایه‌های مدل قطعه‌بندی در این نواحی لازم نباشد.



شکل ۲-۱۶: نمونه لایه‌های پس‌پردازش استخراج شده از برش‌های بیمار

۷-۲ روش پیشنهادی

هدف اصلی در این پژوهش، بهبود عملکرد مدل‌های قطعه‌بندی در تصاویر سی‌تی‌اسکن بوده به گونه‌ای که این روش به صورت عام، امکان پیاده‌سازی روی مدل‌های قطعه‌بندی را داشته باشد. به منظور توسعه این روش، ناترازی داده‌ها، به عنوان یکی از اصلی‌ترین مشکلات در پردازش تصاویر سه‌بعدی پزشکی و سی‌تی‌اسکن مورد مطالعه قرار گرفت.

натرازی در داده‌های سی‌تی‌اسکن، خصوصاً برای پردازش خونریزی درون‌جمجمه‌ای، می‌تواند در سه سطح بیمارمحور، برش‌محور و پیکسل‌محور رخ دهد که در مجموعه‌داده موجود، این ناترازی تنها در دو سطح برش‌محور و پیکسل‌محور رخ داده است. [شکل ۲-۱۴آ](#) پراکندگی داده را به صورت بیمارمحور و [شکل ۲-۱۴ب](#) پراکندگی داده را به صورت برش‌محور نشان می‌دهد که ناترازی در سطح برش، بسیار شدید می‌باشد. پراکندگی پیکسل‌های دارای خونریزی نیز در این مجموعه‌داده، به گونه‌ای است که در برش‌هایی که ضایعه خونریزی وجود دارد، تعداد پیکسل‌های دارای خونریزی، در حدود 2000 پیکسل می‌باشد که این مقدار در برابر تعداد پیکسل‌های کل برش که برابر 2^{18} پیکسل می‌باشد، نشان‌دهنده شدت بیشتر ناترازی در سطح پیکسل می‌باشد.

برای کاهش مشکل ناترازی در سطح برش، یک روش دو مرحله‌ای، توسعه داده شد که به موجب آن، در گام نخست برش‌های سی‌تی‌اسکن طبقه‌بندی خواهند شد تا وجود ضایعه تشخیص داده شود و در گام بعدی، برش‌هایی که دارای بیماری پیش‌بینی شده‌اند، به یک شبکه قطعه‌بندی ارسال می‌شوند تا مراحل قطعه‌بندی در این برش‌ها طی شود. استفاده از این روش برای پردازش تصاویر سی‌تی‌اسکن، این مزیت را دارد که با حذف برش‌های سالم از فرایند تصمیم‌گیری، باعث کاهش تعداد پیکسل‌هایی می‌شود که

به صورت اشتباه، به عنوان پیشکسل‌های دارای ضایعه خونریزی درنظر گرفته شده‌اند. نکته حائز اهمیت درمورد این روش این است که تمام خطاهایی که در مدل طبقه‌بندی رخ بدهند، مستقیماً در عملکرد مدل قطعه‌بندی تاثیر می‌گذارند خصوصاً اگر برشی که دارای خونریزی بوده، به عنوان برش سالم درنظر گرفته شود بنابراین باید توجه داشت تا آستانه تصمیم‌گیری در این روش به گونه‌ای انتخاب شود تا تعداد برش‌هایی که واقعاً سالم نیستند اما سالم تشخیص‌داده می‌شوند به حداقل مقدار خود برسد. حد بالای پیشنهادی برای این آستانه به گونه‌ای است که به موجب آن، تمام سی‌تی‌اسکن‌های دارای خونریزی موجود در مجموعه‌داده به درستی تشخیص داده شوند (تشخیص بیمارمحور).

استفاده از روش پس‌پردازش مذکور در [قسمت ۶-۲](#)، باعث می‌شود تا ناترازی در سطح پیکسل تا حد خوبی کاهش پیدا کند و ب موجب آن فرایند آموزش مدل، بیشتر معطوف به شناسایی نواحی دارای خونریزی شود تا اینکه یک قسمت از فرایند آموزش مدل صرف این شود تا نواحی خارج از جمجمه شناسایی شود. این پس‌پردازش به ما این امکان را می‌دهد تا با کاهش میزان آستانه تصمیم، تعداد پیکسل‌هایی که به درستی درون جمجمه شناسایی می‌شوند را افزایش دهیم. پس‌پردازش مذکور در پژوهش، به صورت مجتمع در فرایند آموزش استفاده شده است.

شکل ۱۷-۲ روندnamای روش پیشنهادی و پس‌پردازش را به منظور بررسی برش‌های خونریزی نشان می‌دهد که در این پردازش استفاده شده است. همانطور که از این روندnam مشخص است، این روند بستگی به مدل طبقه‌بندی و قطعه‌بندی مورد استفاده ندارد و می‌توان از هر مدلی در این روند استفاده کرد که این مسئله باعث افزایش قابلیت توسعه و نگهداری نرم‌افزارهایی می‌شود که بر پایه این روند توسعه داده شده‌اند.

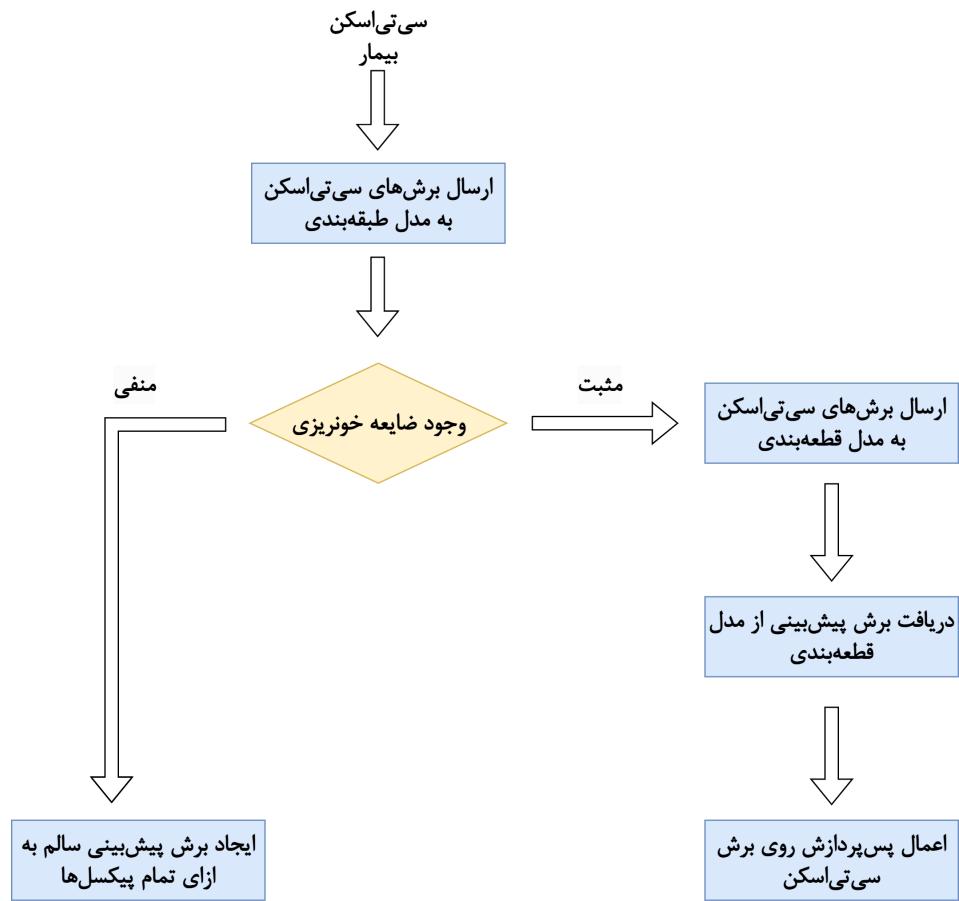
۸-۲ آموزش و تصمیم‌گیری

۱-۸-۲ طبقه‌بندی

گام نخست در این پژوهش، آموزش یک مدل طبقه‌بندی مناسب به منظور استفاده در روش دو مرحله‌ای است که به موجب آن یک جستجوی شبکه‌ای^۱ با استفاده از مدل ResNet 50 انجام شد. در این جستجوی شبکه‌ای، با توجه به چالش ناترازی مجموعه‌داده، ازتابع هزینه Cross Entropy وزن‌دار استفاده شد و همچنین با استفاده از روش افزایش مصنوعی داده، جاگذاری داده^۲ و کاهش داده غالب در ضرایب

¹Grid Search

²Bootstrap



شکل ۱۷-۲: روند نمای روش پیشنهادی در این پژوهش

متفاوت استفاده شد تا بهترین نتیجه ممکن برای مدل طبقه‌بندی یافت شود. [جدول ۱-۲](#) نمایش دهنده مقادیر مورد استفاده در جستجوی شبکه‌ای می‌باشد. در این جستجوی شبکه‌ای، کاهش داده غالب با توجه به توزیع برش‌های دارای خونریزی که در [شکل ۷-۲](#) نمایش داده شده است انجام شده تا داده‌هایی که کمترین تاثیر را در آموزش دارند، با احتمال بیشتری کنار گذاشته شوند و ضریبی که در جدول [جدول ۱-۲](#) برای این روش اعلام شده، به این معنی می‌باشد که نسبت برش‌های بیمار به برش‌های سالم پس از اعمال این روش، برابر ضریب اعلامی خواهد شد. در ادامه افزایش مصنوعی داده و جایگذاری داده نیز تنها به روی برش‌هایی با تشخیص خونریزی درون جمجمه‌ای صورت پذیرفت و تا متناسب با پراکندگی برش‌های دارای خونریزی، افزایش این داده‌ها صورت پذیرد که در [شکل ۷-۲](#) توزیع این داده‌ها نمایش داده شده است و پس از اعمال این روش‌ها، تعداد برش‌های بیمار در ضریب اعلام شده ضرب شده است. باید توجه داشت که در جستجوی شبکه‌ای ابتدا افزایش مصنوعی داده و جایگذاری داده اعمال شده و پس از آن کاهش داده غالب روی مجموعه‌داده اعمال شده است. در آموزش مدل طبقه‌بندی، به علت وجود

تعداد کم داده‌های دارای خونریزی و احتمال بیش‌برازش^۱، از روش 5-fold-cross-validation استفاده شد. در گام نخست از استفاده از این روش، یک زیرمجموعه ارزیابی^۲ که ۲۰ درصد از کل مجموعه‌داده می‌باشد، انتخاب شده‌است و پس از آن روی باقی مجموعه‌داده عملیات 5-fold-cross-validation را برای آموزش مدل انجام شده است؛ در انتهای پس از فرایند آموزش، تنظیم متغیرهای تصمیم‌گیری مدل‌های بدست‌آمده روی مجموعه‌داده ارزیابی^۳ نهایی شده است که این سازوکار در [زیرقسمت ۳-۸-۲](#) توضیح داده شده است. در انتهای مدل پیشنهادی روی مجموعه داده ارزیابی آزمایش شده است. استفاده از این روش باعث می‌شود تا از عملکرد مدل و مقاوم بودن آن اطمینان حاصل شود. به منظور اطمینان از اینکه متغیرهای بدست آمده در عملات جستجوی شبکه‌ای، در بهبود عملکرد مدل‌های شبکه عصبی تاثیرگذار است، مدل‌های Inception-V3 و MobileNet-V2، VGG16 و ResNet50 آموزش داده شد.

جدول ۲: ضرایب مورد استفاده در جستجوی شبکه‌ای

	ضریب سوم	ضریب اول	ضریب دوم	روش
۳/۳	۲/۵	۲		افزایش مصنوعی داده
۳/۳	۲/۵	۲		جایگذاری داده
۳	۲	۱		کاهش داده غالب
۶	۴	۲		افزایش وزن داده مثبت در تابع هزینه
-	۰/۲۵	۰/۵		کاهش وزن داده منفی در تابع هزینه

۲-۸-۲ قطعه‌بندی

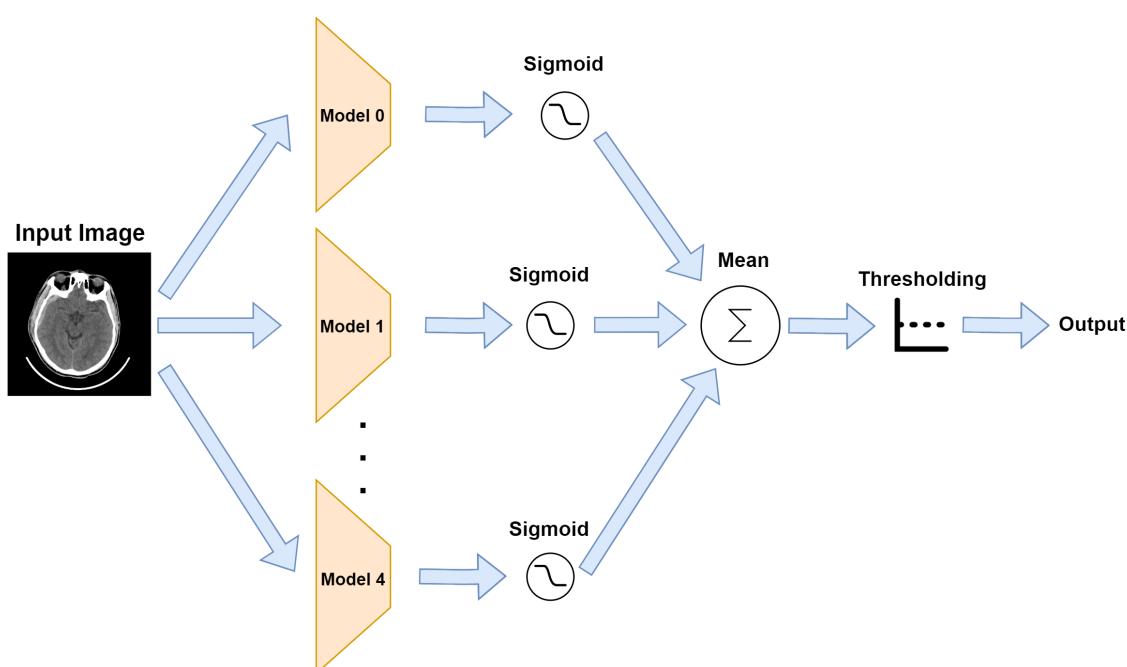
در این پژوهش، مدل شبکه عصبی عمیق U-Net به عنوان ساختار اصلی برای آموزش وظیفه قطعه‌بندی در نظر گرفته شده است. به منظور آموزش این مدل یک جستجوی شبکه‌ای جامع روی مجموعه‌داده انجام شد. متناسب با نتایجی که به روی وظیفه طبقه‌بندی بدست آمده، استفاده از روش‌هایی مثل کاهش داده غالب و جایگذاری داده تاثیر مناسبی روی نتایج نداشته است بنابراین این دو روش در جستجوی شبکه‌ای مدل قطعه‌بندی استفاده نشده است. در آموزش مدل قطعه‌بندی به روش جستجوی شبکه‌ای، از روش افزایش مصنوعی داده با ضرایب ۳، ۴، ۵ و ۶ به همراه انواع مختلف تابع هزینه شامل Dice، Cross-entropy و Cross-entropy Focal Tversky با وزن‌های ۱۰۰، ۱۰، ۱ و ۰۱

¹Overfit²Test³Voting

۲۰۰ و ۱۰۰۰ برای پیکسل‌های مثبت و انواع مختلف رمزگذار در ساختار شبکه U-Net با ابعاد متفاوت شامل DenseNet، EfficientNet، ResNeXt، ResNet و SE-ResNeXt استفاده شده است. در مراحل آموزش مدل قطعه‌بندی، داده ارزیابی ابتدا از مدل شورایی طبقه‌بندی عبور داده شد و تمام برش‌هایی که در این مدل دارای خونریزی درون جمجمه‌ای تشخیص داده شده‌اند، طبق روند نمای شکل ۱۷-۲ به مدل قطعه‌بندی ارسال شدند تا برش‌ها قطعه‌بندی شوند. در گام آخر، یک سازوکار تصمیم‌گیری شورایی که در زیر قسمت ۳-۸-۲ توضیح داده شده است، برای قطعه‌بندی برش‌ها استفاده شد تا پیش‌بینی مدل‌های متفاوت مورد استفاده قرار گیرد.

۳-۸-۲ سازوکار تصمیم‌گیری شورایی

استفاده از روش 5-fold-cross-validation برای ارزیابی مدل‌های شبکه عصبی، می‌تواند با یک سازوکار شورایی در لایه تصمیم‌گیری همراه شود که به موجب آن اثر بیش‌برازش روی مجموعه‌داده کاهش پیدا می‌کند. در این پژوهش، یک روش شورایی ساده پیشنهاد شده است که به موجب آن، از پیش‌بینی احتمالاتی تمام مدل‌ها میانگین گرفته می‌شود و در انتهای آستانه‌گذاری روی این میانگین اعمال می‌شود.



شکل ۲-۱۸: سازوکار تصمیم‌گیری شورایی

شکل ۱۸-۲، عملکرد این روش را به صورت روند نمای مشخص می‌کند. نکته‌ای که باید در مورد سازوکار تصمیم‌گیری در نظر داشت این است که این سازوکار هم در مدل قطعه‌بندی و هم در مدل طبقه‌بندی

فصل دوم: روش‌ها و مجموعه‌داده

به صورت یکسان استفاده شده است.

فصل سوم

نتائج

۱-۳ معیارهای ارزیابی در یادگیری عمیق

در این بخش، به بررسی معیارهای مختلفی که برای ارزیابی مدل‌های یادگیری عمیق استفاده می‌شوند، Intersec- Accuracy، F1 Score، Precision، Specificity، Sensitivity می‌پردازیم. این معیارها شامل Dice over Union (IoU) و ضریب tion over Union (IoU) می‌باشد.

قبل از پرداختن به تعریف این معیارها، ابتدا به تعریف چهار مفهوم اساسی می‌پردازیم که در فرمول‌های ارزیابی به کار می‌روند:

• (True Positives): تعداد نمونه‌های مثبت که به درستی به عنوان مثبت دسته‌بندی شده‌اند.

• (False Positives): تعداد نمونه‌های منفی که به اشتباه به عنوان مثبت دسته‌بندی شده‌اند.

• (True Negatives): تعداد نمونه‌های منفی که به درستی به عنوان منفی دسته‌بندی شده‌اند.

• (False Negatives): تعداد نمونه‌های مثبت که به اشتباه به عنوان منفی دسته‌بندی شده‌اند.

۱-۱-۳ Sensitivity

Sensitivity، که با نام نرخ تشخیص صحیح نیز شناخته می‌شود، معیاری برای ارزیابی توانایی مدل در تشخیص صحیح نمونه‌های مثبت است. فرمول این معیار در [معادله ۱-۳](#) مشخص شده است.

$$\text{Sensitivity} = \frac{TP}{TP + FN} \quad (3-1)$$

۲-۱-۳ Specificity

Specificity، معیاری است که نشان‌دهنده توانایی مدل در شناسایی صحیح نمونه‌های منفی است. فرمول این معیار در [معادله ۲-۳](#) مشخص شده است.

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (3-2)$$

۳-۱-۳ Precision

Precision، معیاری برای ارزیابی میزان درستی دسته‌بندی نمونه‌های مثبت است. به عبارت دیگر،

Precision نسبت نمونه‌های مثبت درست دسته‌بندی شده به تمام نمونه‌های پیش‌بینی شده به عنوان مثبت است. فرمول آن در [معادله ۳-۳](#) مشخص شده است.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3-3)$$

F1 Score ۴-۱-۳

F1 Score، میانگین موزون Precision و Sensitivity است که تعادلی بین این دو معیار ایجاد می‌کند. این امتیاز بهویژه در مواردی که تعادل بین Precision و Sensitivity اهمیت دارد، مورد استفاده قرار می‌گیرد. فرمول F1 Score در [معادله ۴-۳](#) مشخص شده است.

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}} \quad (3-4)$$

Accuracy ۵-۱-۳

Accuracy، نسبت نمونه‌هایی است که به درستی دسته‌بندی شده‌اند به تمام نمونه‌ها. این معیار نشان‌دهنده عملکرد کلی مدل است و فرمول آن در [معادله ۵-۳](#) مشخص شده است.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-5)$$

Intersection over Union (IoU) ۶-۱-۳

ارزیابی همپوشانی بین دو مجموعه، بهویژه در مسائل بخش‌بندی تصویر، استفاده می‌شود. فرمول IoU در [معادله ۶-۳](#) مشخص شده است.

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{TP}{TP + FP + FN} \quad (3-6)$$

Dice Coefficient ۷-۱-۳

ضریب Dice، مشابه IoU است اما وزن بیشتری به ناحیه اشتراک می‌دهد و در مسائل بخش‌بندی تصویر بسیار مورد استفاده قرار می‌گیرد. فرمول ضریب Dice در [معادله ۷-۳](#) مشخص شده است.

$$\text{Dice Coefficient} = \frac{2 \times |A \cap B|}{|A| + |B|} = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (3-7)$$

۲-۳ نتایج طبقه‌بندی

در این بخش، نتایج حاصل از مدل‌های طبقه‌بندی خونریزی داخل جمجمه‌ای در تصاویر سی‌تی‌اسکن، بررسی و تحلیل شده‌اند. مرکز اصلی آموزش مدر طبقه‌بندی بر روی بهینه‌سازی فرآپارامترها برای مدل ResNet50 بوده است، که بهبودهای قابل توجهی در عملکرد مدل بهویژه در معیار Sensitivity به همراه داشته است.

۱-۲-۳ نتایج برش محور

پس از آموزش مدل طبقه‌بندی برای تمام Fold‌ها، نمودار امتیاز F1 نسبت به آستانه‌های متفاوت رسم شد و در گام بعدی میانگین این نمودارها محاسبه شد. در انتهای بهترین آستانه روی میانگین این نمودارها محاسبه شده و در محاسبه معیارهای مربوط به زیرمجموعه ارزیابی استفاده شده است. [جدول ۱-۳](#) نتایج به‌دست‌آمده از آموزش مدل‌های ResNet50 و سازوکار شورا برای طبقه‌بندی برش محور نشان می‌دهد. همانطور که در جدول مشاهده می‌شود، بهترین نتایج در Fold 0 به‌دست آمده است که امتیاز F1 برابر با ۶۲٪ را نشان می‌دهد. این نشان‌دهنده این است که توزیع داده‌ها در مجموعه‌های آموزشی و اعتبارسنجی این Fold بیشتر شبیه به مجموعه آزمون است. در مقابل، Fold 4 کمترین نتایج را به‌دست آورده، در حالی که نتایج مراحل دیگر با هم بیشتر هم‌خوانی دارند.

همانطور که در [۱-۳](#) مشاهده می‌شود، با استفاده از سازوکار شورایی، امتیاز F1 بهبود قابل توجهی پیدا کرده است که نشان‌دهنده بهبود عملکرد مدل طبقه‌بندی با استفاده از سازوکار شورایی است. Sensitivity مدل به صورت برش محور ۹۴٪ بوده که یک دستاوردهای توجه در مقایسه با سایر مطالعات است خصوصا در زمینه استفاده‌های پزشکی. نکته‌ای که باید به آن توجه کرد این است که مقادیر گزارش شده برای Fold‌های متفاوت، بهارای آستانه‌های متفاوت می‌توانند مقادیر بهتری داشته باشند اما اعداد گزارش

جدول ۳-۱: نتایج برش‌محور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷

Model	Sensitivity	Specificity	Precision	F1	Accuracy
ResNet50 Fold 0	۰/۷۸	۰/۹۳	۰/۵۱	۰/۶۲	۰/۹۱
ResNet50 Fold 1	۰/۶۸	۰/۹۰	۰/۳۸	۰/۴۹	۰/۸۸
ResNet50 Fold 2	۰/۶۰	۰/۸۹	۰/۳۳	۰/۴۲	۰/۸۶
ResNet50 Fold 3	۰/۸۶	۰/۸۹	۰/۴۱	۰/۵۵	۰/۸۹
ResNet50 Fold 4	۰/۳۲	۰/۹۶	۰/۴۲	۰/۳۶	۰/۹۰
[19] Neethi et al. someone	۰/۷۶	—	۰/۶۹	۰/۶۷	۰/۵۴
ResNet50 Voting	۱	۲	۳	۴	۵
ResNet50 Voting	۰/۹۴	۰/۹۱	۰/۴۹	۰/۶۴	۰/۹۱

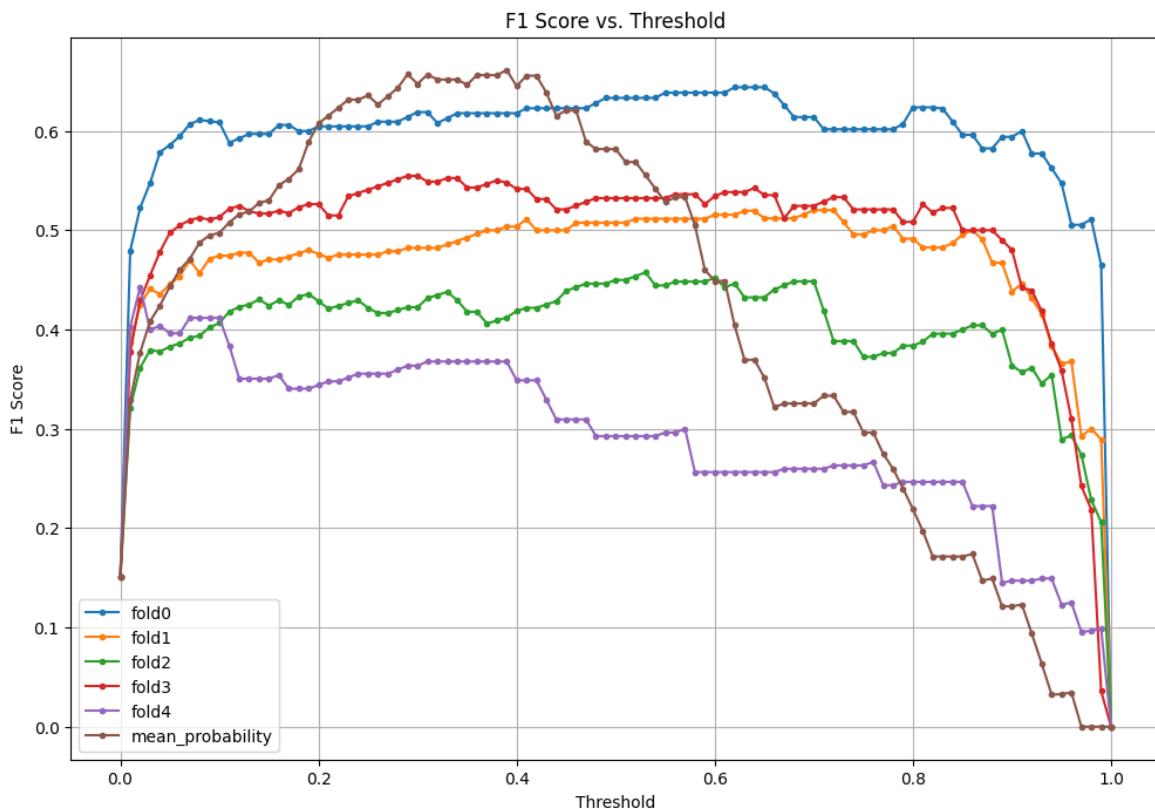
شده در بهترین آستانه برای میانگین نمودارها می‌باشد. **شکل ۲-۳** نمودارهای Precision-Sensitivity را نشان می‌دهد و **شکل ۲-۳** نمودار منحنی F1 به ازای آستانه‌های متفاوت را نشان می‌دهد، همانطور که مشخص است مدلی را نشان می‌دهد. **شکل ۳-۳** ماتریس آشفتگی مدل‌ها را نشان می‌دهد، همانطور که مشخص است مدلی که از سازوکار شورایی استفاده می‌کند به صورت قابل توجهی عملکرد بهتری پیدا می‌کند.

۲-۲-۳ نتایج بیمارمحور

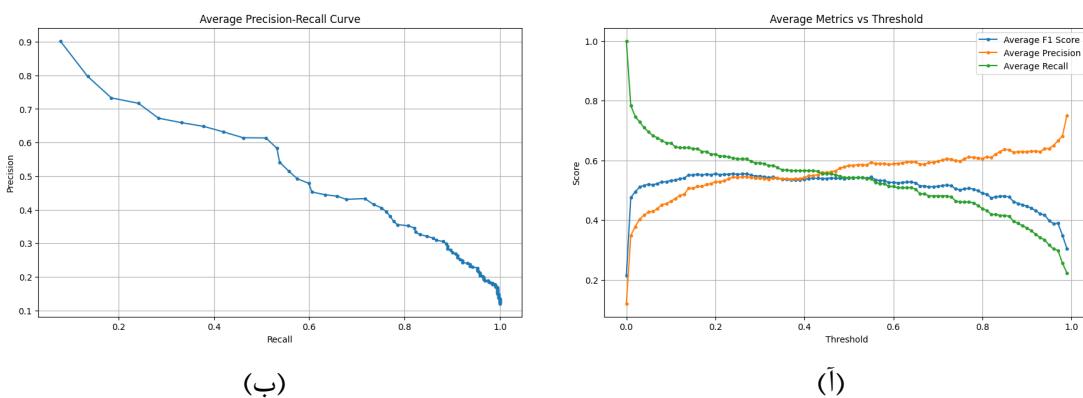
طبقه‌بندی بیمارمحور خونریزی درون‌جمجمه‌ای بر اساس پیش‌بینی‌های برش‌محور انجام شده است. یک بیمار در صورتی دارای خونریزی درون‌جمجمه‌ای در نظر گرفته می‌شود اگر حداقل یک برش از سی‌تی‌اسکن او دارای علائم خونریزی شناسایی شود. نتایج به دست آمده نشان می‌دهند که مدل در بررسی بیمارمحور سی‌تی‌اسکن‌ها، با استفاده از روش شورایی، به Sensitivity برابر با ResNet50 Precision برابر با ۰/۸۰، امتیاز F1 برابر با ۰/۷۵ و Accuracy برابر با ۰/۸۶ Specificity برابر با ۰/۸۸ دست یافته است که از تمامی معیارهای گزارش شده در سایر مطالعات، نتیجه بهتری کسب کرده است. جدول ۲-۳ نتایج بیمارمحور مدل ResNet50 را برای هر مرحله آموزشی نشان می‌دهد. **شکل ۴-۳** ماتریس آشفتگی بیمارمحور را نشان می‌دهد که از ۱۶ بیمار در مجموعه ارزیابی قرار داشته‌اند که همه ۶ بیمار دارای خونریزی درست تشخیص داده شده‌اند.

۳-۲-۳ تحلیل بیشتر نتایج

در این بخش، نتایج مرتبط با تفسیرپذیری مدل ResNet50 از طریق تکنیک‌های Grad-CAM و t-SNE تحلیل و بررسی می‌شوند.



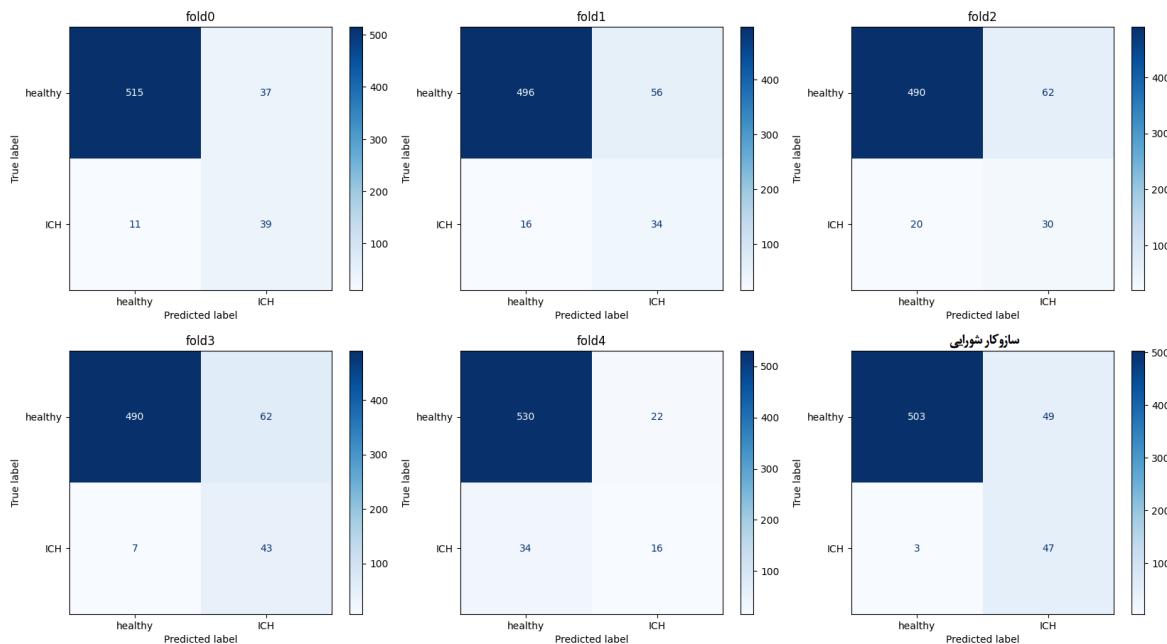
شکل ۳-۱: نمودار امتیاز F1 نسبت به آستانه برای Foldها و میانگین آنها



شکل ۳-۲: نمودارهای سازوکار شورایی روی مجموعهداده ارزیابی

تحلیل Grad-CAM

تکنیک Grad-CAM (Gradient-weighted Class Activation Mapping) به عنوان یک ابزار قدرتمند برای تفسیر مدل‌های شبکه عصبی عمیق استفاده می‌شود. این تکنیک به ما اجازه می‌دهد تا بینیم کدام بخش‌های تصویر ورودی، بیشتر در تصمیم‌گیری مدل تأثیر داشته‌اند. در این پژوهه، از روش Grad-CAM برای افزایش تفسیرپذیری مدل‌های طبقه‌بندی به کمک ایجاد تصویر استفاده شده است که نواحی مهم



شکل ۳-۳: ماتریس آشفتگی نتایج برش محور

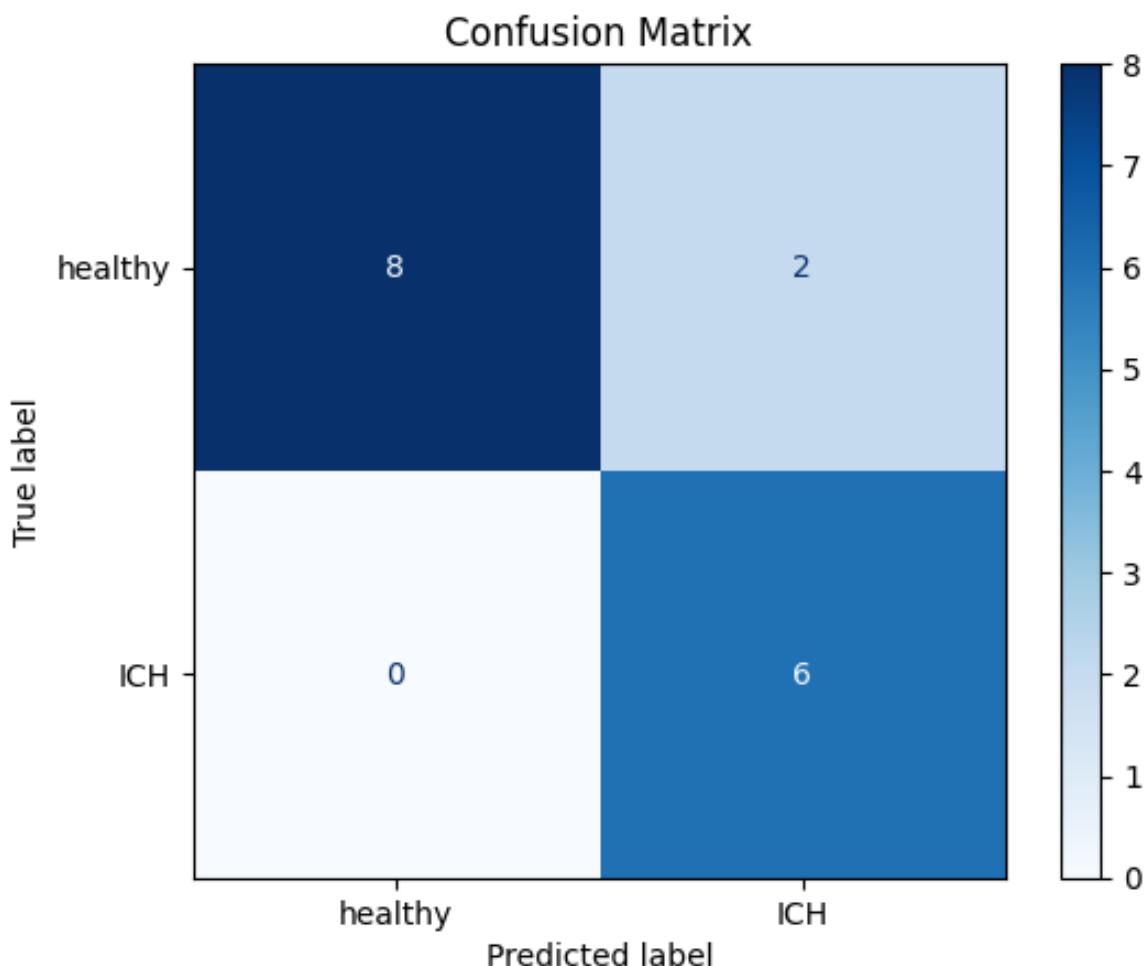
جدول ۲-۳: نتایج بیمارمحور مدل ResNet50 برای آستانه تصمیم‌گیری ۰/۲۷

Accuracy	F1	Precision	Specificity	Sensitivity	مدل
۰/۷۵	۰/۷۵	۰/۶۰	۰/۶۰	۱/۰۰	ResNet50 Fold 1
۰/۷۵	۰/۷۵	۰/۶۰	۰/۶۰	۱/۰۰	ResNet50 Fold 2
۰/۷۵	۰/۷۵	۰/۶۰	۰/۶۰	۱/۰۰	ResNet50 Fold 3
۰/۸۱	۰/۷۷	۰/۷۱	۰/۸۰	۰/۸۳	ResNet50 Fold 4
—	۰/۸۴	—	۰/۷۴	۰/۹۷	[14] Kyung et al.
۰/۸۸	۰/۸۶	۰/۷۵	۰/۸۰	۱/۰۰	ResNet50 Voting

برش‌های سی‌تی‌اسکن که منجر به تشخیص خونریزی توسط مدل شده‌اند را مشخص می‌کند. شکل ۵-۳ نمونه‌ای از این نقشه‌های حرارتی را نشان می‌دهد که به وضوح مشخص می‌کند که مدل چگونه نواحی مختلف تصویر را برای تشخیص ICH مورد ارزیابی قرار داده است.

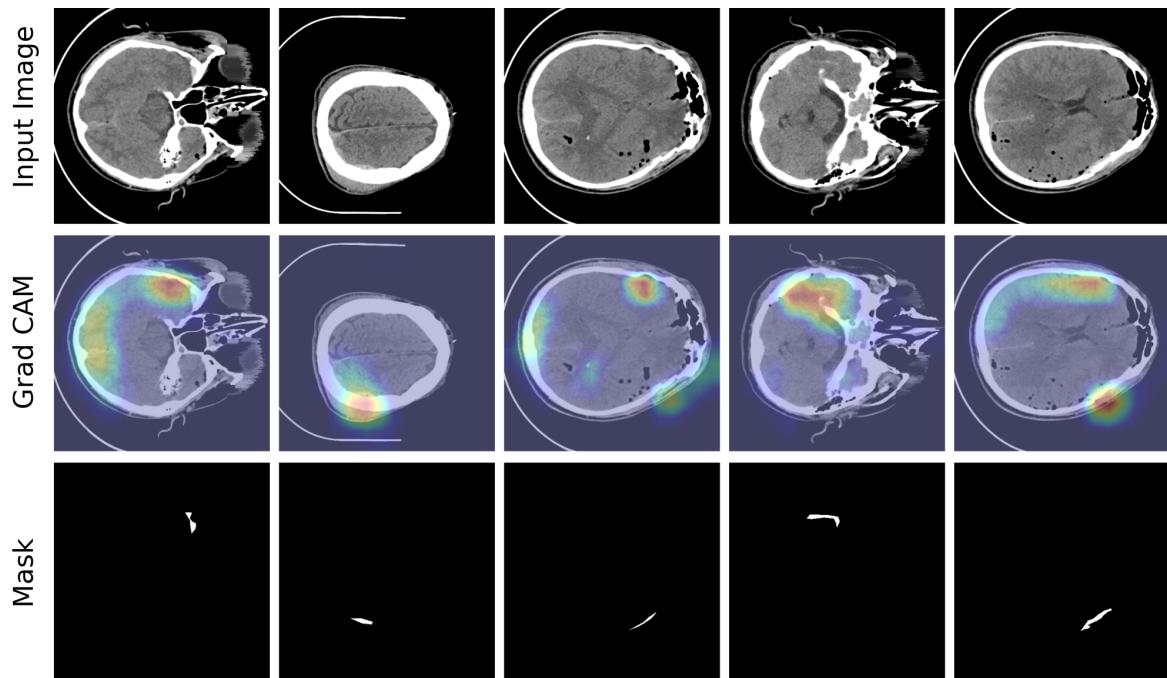
t-SNE تحلیل

روش t-SNE (t-Distributed Stochastic Neighbor Embedding) یک روش برای کاهش ابعاد و تجسم داده‌های با ابعاد بالا است. در این پژوهش، از t-SNE برای تجسم توزیع ویژگی‌های استخراج شده از مدل ResNet50 استفاده شده است تا نشان داده شود که آموزش مدل، باعث تولید ویژگی‌هایی شده است که تفکیک‌پذیری برش‌های سالم را از ناسالم زیاد کرده است. شکل ۶-۳ نشان‌دهنده توزیع ویژگی‌های استخراجی با روش t-SNE از تصاویر سی‌تی‌اسکن در فضای دوبعدی است که شکل ۳-۶ پراکندگی

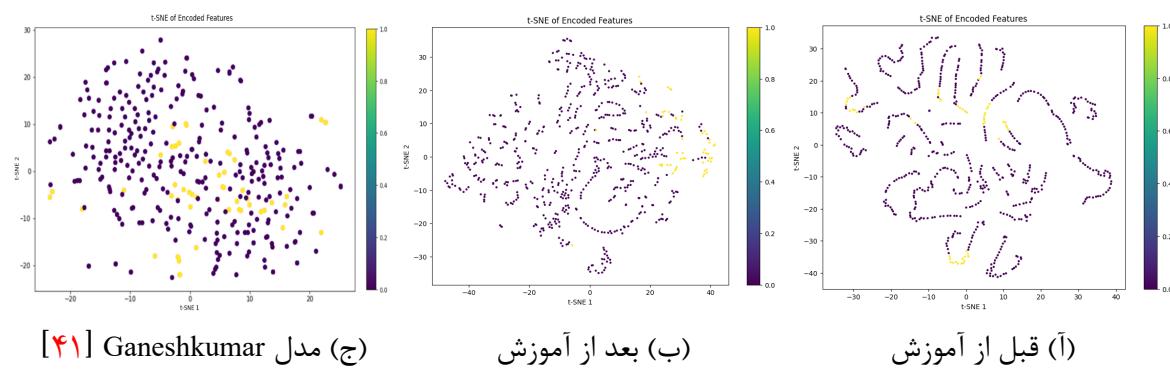


شکل ۳-۴: ماتریس آشفتگیب یمارمحور سازوکار شورایی

ویژگی‌ها از مدل طبقه‌بندی قبل از آموزش آن است و [شکل ۳-۶](#) بعد از آموزش مدل طبقه‌بندی است. [شکل ۳-۳](#) به‌وضوح نشان می‌دهد چگونه مدل قادر است تفکیک‌پذیری خطی را برای برش‌های حاوی خونریزی درون‌جمجمه‌ای ایجاد کند. این استخراج ویژگی کمک می‌کند تا دیدگاه بهتری نسبت به نحوه عملکرد مدل در سطح ویژگی‌ها داشته باشیم و نقاط ضعف و قوت آن را بهتر درک کنیم. [شکل ۳-۷](#) نمودار t-SNE حاصل از مدل طبقه‌بندی Ganeshkumar [۴۱] و همکاران است که نشان می‌دهد مدل بدست‌آمده در پژوهش آنها، امکان تفکیک‌پذیری خطی را برای برش‌ها ایجاد نکرده است.



شکل ۳-۵: چند نمونه از تصاویر تولید شده توسط Grad-CAM



شکل ۳-۶: نمودارهای t-SNE و مقایسه آنها با یکدیگر

مراجع و مراجع

- [1] Team, Health Jade. Intracerebral hemorrhage causes, symptoms, diagnosis, treatment & recovery, October 18 2019. Accessed: 2024-08-26.
- [2] CT-Scans, DICOM files, Windowing Explained — kaggle.com. <https://www.kaggle.com/code/redwankarimsony/ct-scans-dicom-files-windowing-explained/notebook>. [Accessed 29-08-2024].
- [3] at 3rd Wave Media, Xiaoying Riley. Introduction to Deep Learning — blogs.brain-mentors.com. <https://blogs.brain-mentors.com/introduction-to-deep-learning/>. [Accessed 30-08-2024].
- [4] Residual neural network - Wikipedia — en.wikipedia.org. https://en.wikipedia.org/wiki/Residual_neural_network. [Accessed 31-08-2024].
- [5] Xie, Saining, Girshick, Ross, Dollár, Piotr, Tu, Zhuowen, and He, Kaiming. Aggregated residual transformations for deep neural networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1492–1500, 2017.
- [6] Hu, Jie, Shen, Li, and Sun, Gang. Squeeze-and-excitation networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 7132–7141, 2018.

- [7] Huang, Gao, Liu, Zhuang, Van Der Maaten, Laurens, and Weinberger, Kilian Q. Densely connected convolutional networks. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 4700–4708, 2017.
- [8] Ronneberger, Olaf, Fischer, Philipp, and Brox, Thomas. U-net: Convolutional networks for biomedical image segmentation. in Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18, pp. 234–241. Springer, 2015.
- [9] Rsna intracranial hemorrhage detection. <https://www.kaggle.com/competitions/rsna-intracranial-hemorrhage-detection/overview>, 2019. Accessed: 2024-08-26.
- [10] Grewal, Monika, Srivastava, Muktabh Mayank, Kumar, Pulkit, and Varadarajan, Srikrishna. Radnet: Radiologist level accuracy using deep learning for hemorrhage detection in ct scans. in 2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018), pp. 281–284. IEEE, 2018.
- [11] Monica Jenefer, Balraj M, Senathipathi, K, Aarthi, and Annapandi. Detection and categorization of acute intracranial hemorrhage subtypes using a multilayer densenet-resnet architecture with improved random forest classifier. Concurrency and Computation: Practice and Experience, 34(22):e7167, 2022.
- [12] Arbabshirani, Mohammad R, Fornwalt, Brandon K, Mongelluzzo, Gino J, Suever, Jonathan D, Geise, Brandon D, Patel, Aalpen A, and Moore, Gregory J. Advanced machine learning in action: identification of intracranial hemorrhage on computed tomography scans of the head with clinical workflow integration. NPJ digital medicine, 1(1):9, 2018.
- [13] Burduja, Mihail, Ionescu, Radu Tudor, and Verga, Nicolae. Accurate and efficient intracranial hemorrhage detection and subtype classification in 3d ct scans with convolutional and long short-term memory neural networks. Sensors, 20(19):5611, 2020.

- [14] Morgenstern, Lewis B, Hemphill III, J Claude, Anderson, Craig, Becker, Kyra, Broderick, Joseph P, Connolly Jr, E Sander, Greenberg, Steven M, Huang, James N, Macdonald, R Loch, Messé, Steven R, et al. Guidelines for the management of spontaneous intracerebral hemorrhage: a guideline for healthcare professionals from the american heart association/american stroke association. *Stroke*, 41(9):2108–2129, 2010.
- [15] Van Asch, Charlotte JJ, Luitse, Merel JA, Rinkel, Gabriël JE, van der Tweel, Ingeborg, Algra, Ale, and Klijn, Catharina JM. Incidence, case fatality, and functional outcome of intracerebral haemorrhage over time, according to age, sex, and ethnic origin: a systematic review and meta-analysis. *The Lancet Neurology*, 9(2):167–176, 2010.
- [16] Hackett, Maree L and Anderson, Craig S. Health outcomes 1 year after subarachnoid hemorrhage: an international population-based study. *Neurology*, 55(5):658–662, 2000.
- [17] Kuo, Weicheng, Häne, Christian, Mukherjee, Pratik, Malik, Jitendra, and Yuh, Esther L. Expert-level detection of acute intracranial hemorrhage on head computed tomography using deep learning. *Proceedings of the National Academy of Sciences*, 116(45):22737–22745, 2019.
- [18] Ye, Hai, Gao, Feng, Yin, Youbing, Guo, Danfeng, Zhao, Pengfei, Lu, Yi, Wang, Xin, Bai, Junjie, Cao, Kunlin, Song, Qi, et al. Precise diagnosis of intracranial hemorrhage and subtypes using a three-dimensional joint convolutional and recurrent neural network. *European radiology*, 29:6191–6201, 2019.
- [19] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier, Prashant. Deep learning algorithms for detection of critical findings in head ct scans: a retrospective study. *The Lancet*, 392(10162):2388–2396, 2018.

- [20] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [21] Alfaro, Dennis, Levitt, M Andrew, English, David K, Williams, Virgil, and Eisenberg, Ronald. Accuracy of interpretation of cranial computed tomography scans in an emergency medicine residency program. *Annals of emergency medicine*, 25(2):169–174, 1995.
- [22] Lal, Nirish R, Murray, Uwada M, Eldevik, O Petter, and Desmond, Jeffrey S. Clinical consequences of misinterpretations of neuroradiologic ct scans by on-callradiology residents. *American journal of neuroradiology*, 21(1):124–129, 2000.
- [23] Erly, William K, Berger, William G, Krupinski, Elizabeth, Seeger, Joachim F, and Guisto, John A. Radiology resident evaluation of head ct scan orders in the emergency department. *American journal of neuroradiology*, 23(1):103–107, 2002.
- [24] Strub, WM, Leach, JL, Tomsick, T, and Vagal, A. Overnight preliminary head ct interpretations provided by residents: locations of misidentified intracranial hemorrhage. *American journal of neuroradiology*, 28(9):1679–1682, 2007.
- [25] Lee, Hyunkwang, Yune, Sehyo, Mansouri, Mohammad, Kim, Myeongchan, Tajmir, Shahein H, Guerrier, Claude E, Ebert, Sarah A, Pomerantz, Stuart R, Romero, Javier M, Kamalian, Shahmir, et al. An explainable deep-learning algorithm for the detection of acute intracranial haemorrhage from small datasets. *Nature biomedical engineering*, 3(3):173–182, 2019.
- [26] Chang, Peter D, Kuoy, Edward, Grinband, Jack, Weinberg, Brent D, Thompson, Matthew, Homo, Richelle, Chen, Jefferson, Abcede, Hermelinda, Shafie, Mohammad, Sugrue, Leo, et al. Hybrid 3d/2d convolutional neural network for hemorrhage evaluation on head ct. *American Journal of Neuroradiology*, 39(9):1609–1616, 2018.

- [27] Titano, Joseph J, Badgeley, Marcus, Schefflein, Javin, Pain, Margaret, Su, Andres, Cai, Michael, Swinburne, Nathaniel, Zech, John, Kim, Jun, Bederson, Joshua, et al. Automated deep-neural-network surveillance of cranial images for acute neurologic events. *Nature medicine*, 24(9):1337–1341, 2018.
- [28] Rsna intracranial hemorrhage detection, 2024. Accessed: 2024-08-27.
- [29] Khoruzhaya, Anna N, Bobrovskaya, Tatiana M, Kozlov, Dmitriy V, Kuligovskiy, Dmitriy, Novik, Vladimir P, Arzamasov, Kirill M, and Kremneva, Elena I. Expanded brain ct dataset for the development of ai systems for intracranial hemorrhage detection and classification. *Data*, 9(2):30, 2024.
- [30] Chilamkurthy, Sasank, Ghosh, Rohit, Tanamala, Swetha, Biviji, Mustafa, Campeau, Norbert G, Venugopal, Vasantha Kumar, Mahajan, Vidur, Rao, Pooja, and Warier, Prashant. Development and validation of deep learning algorithms for detection of critical findings in head ct scans. *arXiv preprint arXiv:1803.05854*, 2018.
- [31] Ma, Deguo, Li, Chen, Du, Tianming, Qiao, Lin, Tang, Dechao, Ma, Zhiyu, Shi, Liyu, Lu, Guotao, Meng, Qingtao, Chen, Zhihao, et al. Phe-sich-ct-ids: A benchmark ct image dataset for evaluation semantic segmentation, object detection and radiomic feature extraction of perihematomal edema in spontaneous intracerebral hemorrhage. *Computers in Biology and Medicine*, 173:108342, 2024.
- [32] Hssayeni, Murtadha D, Croock, Muayad S, Salman, Aymen D, Al-Khafaji, Hassan Falah, Yahya, Zakaria A, and Ghoraani, Behnaz. Intracranial hemorrhage segmentation using a deep convolutional model. *Data*, 5(1):14, 2020.
- [33] Neethi, AS, Niyas, S, Kannath, Santhosh Kumar, Mathew, Jimson, Anzar, Ajimi Mol, and Rajan, Jeny. Stroke classification from computed tomography scans using 3d convolutional neural network. *Biomedical Signal Processing and Control*, 76:103720, 2022.

- [34] Kyung, Sunggu, Shin, Keewon, Jeong, Hyunsu, Kim, Ki Duk, Park, Jooyoung, Cho, Kyungjin, Lee, Jeong Hyun, Hong, GilSun, and Kim, Namkug. Improved performance and robustness of multi-task representation learning with consistency loss between pre-texts for intracranial hemorrhage identification in head ct. *Medical Image Analysis*, 81:102489, 2022.
- [35] Li, Lu, Wei, Meng, Liu, BO, Atchaneeyasakul, Kunakorn, Zhou, Fugen, Pan, Zehao, Kumar, Shimran A, Zhang, Jason Y, Pu, Yuehua, Liebeskind, David S, et al. Deep learning for hemorrhagic lesion detection and segmentation on brain ct images. *IEEE journal of biomedical and health informatics*, 25(5):1646–1659, 2020.
- [36] Hssayeni, Murtadha, Croock, M, Salman, A, Al-khafaji, H, Yahya, Z, and Ghoraani, B. Computed tomography images for intracranial hemorrhage detection and segmentation. *Intracranial hemorrhage segmentation using a deep convolutional model*. *Data*, 5(1):14, 2020.
- [37] Efimov, Vyacheslav. Understanding Deep Learning Optimizers: Momentum, AdaGrad, RMSProp & Adam — towardsdatascience.com. <https://towardsdatascience.com/understanding-deep-learning-optimizers-momentum-adagrad-rmsprop-adam-e311e377e9c> [Accessed 30-08-2024].
- [38] Khandewal, Harsh. Momentum ,RMSprop And Adam Optimizer — medium.com. <https://medium.com/analytics-vidhya/momentum-rmsprop-and-adam-optimizer-5769721b4b19>. [Accessed 30-08-2024].
- [39] He, Kaiming, Zhang, Xiangyu, Ren, Shaoqing, and Sun, Jian. Deep residual learning for image recognition. in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 770–778, 2016.

- [40] Tan, Mingxing. Efficientnet: Rethinking model scaling for convolutional neural networks. arXiv preprint arXiv:1905.11946, 2019.
- [41] Ganeshkumar, M, Ravi, Vinayakumar, Sowmya, V, Gopalakrishnan, EA, Soman, KP, and Chakraborty, Chinmay. Identification of intracranial haemorrhage (ich) using resnet with data augmentation using cyclegan and ich segmentation using segan. Multimedia Tools and Applications, 81(25):36257–36273, 2022.

واژه‌نامه‌ی فارسی به انگلیسی

Slice	برش	الف
Slice-wise	برش محور	آسیب مغزی تروماتیک ...
Block	بلوک	injury
Overfit	بیش برآذش	اتصال میانبر
Patient-wise	بیمار محور	ادغام
پ		
Radiography	پرتونگاری	ارزیابی
Radiologist	پرتونگار	اعتبار سنجی
Perceptron	پرسپترون	الحق
backpropagation	پساننتشار	الکترون
Post-process	پس پردازش	انتقال یادگیری
Windowing	پنجره‌گذاری	انقجار مشتق
Pre-process	پیش پردازش	X-Ray
pixel	پیکسل	اشعه ایکس
ت		
Loss Function	تابع خطا	افزایش مصنوعی داده
Bias	بایاس	Bias

Computed Tomography Scan	سی‌تی‌اسکن	ج
System	سامانه	جاگذاری داده
	ش	Grid Search
Deep Neural Network	شبکه عصبی عمیق	ح
Convolutional Neural Network	شبکه عصبی پیچشی	حاشیه‌نویسی
Voting	شورا	خودرمزگذار
	ط	
Classification	طبقه‌بندی	خونریزی
	غ	Intracerebral Hemorrhage
Non-invasive	غیر تهاجمی	Hemorrhage (ICH)
	ف	Epidural Hemorrhage
Hyper-parameter	فراپارامتر	خونریزی سابدورال
	ق	Subdural Hemorrhage
Segmentation	قطعه‌بندی	ساب آرآکنوئید
	ک	Cerebral Hemorrhage
Cathode	کاتد	Parenchymal Hemorrhage
Channel	کanal	Intraventricular Hemorrhage
Cardinality	کاردینالیتی	خونریزی پارانشیم مغزی
Calibration	کالیبراسیون	
Undersampling	کاهش داده غالب	رايانه
	گ	Computer
Gradient	گرادیان	ز
		Real Time
		س

م

Mask ماسک

Model مدل

ن

Vanishing Gradient ... ناپدیدشدن مشتق

Neuron نرون

Second Opinion نظر ثانویه

Feature Map نقشه ویژگی

ی

Resolution وضوح

ی

یادگیری عمیق Deep Learning

یادگیری ماشین Machine Learning

واژه‌نامه‌ی انگلیسی به فارسی

A	Homomorphism	همریختی
KNTUomorphism	خودریختی	I
B	Invariant	پایا
Bijection	دوسویی	L
C	Lift	بالابر
Cycle group	گروه دوری	M
D	Module	مدول
Degree	درجه	N
E	Natural map	نگاشت طبیعی
Edge	یال	O
F	One to One	یک به یک
Function	تابع	P
G	Permutation group	گروه جایگشتی
Group	گروه	Q
H		

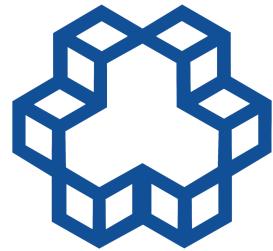
Quotient graph	گراف خارج‌قسمتی	Trivial character	سرشت بدیهی
R		U	
Reducible	تحویل پذیر	Unique	منحصربفرد
S		V	
Sequence	دنباله	Vector space	فضای برداری
T			

Abstract

This page is accurate translation from Persian abstract into English.

Key Words:

Write a 3 to 5 KeyWords is essential. Example: KNTU, M.Sc., Ph. D,..



K. N. Toosi University of Technology
Department of ...

M. Sc. Thesis

Title of Thesis

By

Name Surname

Supervisor

Dr.

Advisor

Dr.

Month & Year